BỘ GIÁO DỤC VÀ ĐÀO TẠO - TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH

KHOA HỆ THỐNG THÔNG TIN QUẢN LÝ - BỘ MÔN KHOA HỌC MÁY TÍNH

NGÂN HÀNG CÂU HỎI TRẮC NGHIỆM ÔN TẬP TỔNG HỢP (430 CÂU)

HỌC PHẦN: KHAI PHÁ DỮ LIỆU (DATA MINING)

(Đã lọc trùng lặp – Phân tầng: 241 câu Trọng tâm & 189 câu Mở rộng – In đậm duy nhất đáp án đúng)

PHẦN I: CÂU HỎI TRỌNG TÂM THI CUỐI KỲ (BÁM SÁT ĐỀ CƯƠNG & FILE ÔN TẬP)

Gồm 241 câu hỏi cốt lõi từ Đề thi mẫu trường, Đề KTGK và các chủ đề trọng điểm: KDD, CRISP-DM, Tiền xử lý, Apriori, Cây quyết định, Naive Bayes, SVM, K-means, DBSCAN, Ma trận nhầm lẫn.

Câu 1: Confusion Matrix: TP=42, TN=98, FP=18, FN=42. Tính Accuracy, Precision và Recall? [Accuracy=(TP+TN)/Total ; Precision=TP/(TP+FP) ; Recall=TP/(TP+FN)]

A. Accuracy=70%, Precision=60%, Recall=50%

B. Accuracy=80%, Precision=70%, Recall=60%

C. Accuracy=70%, Precision=70%, Recall=50%

D. Accuracy=75%, Precision=65%, Recall=55%

Câu 2: K-means với K=2: Centroid C1=(3,5), C2=(8,2). Điểm dữ liệu P=(6,4) sẽ được gán vào cụm nào? [Khoảng cách Euclidean: $d = \sqrt{(x_2-x_1)^2 + (y_2-y_1)^2}$]

A. Cả hai cụm vì khoảng cách bằng nhau

B. Cụm 2 (d(P,C2) ≈ 2.83 < d(P,C1) ≈ 3.16)

C. Không thể xác định với thông tin đã cho

D. Cụm 1 (d(P,C1) ≈ 3.16 < d(P,C2) ≈ 2.83)

Câu 3: Khi dữ liệu thuộc tính "thu nhập" có phân phối lệch phải (right-skewed) với một số giá trị cực lớn, phương pháp điền giá trị thiếu nào phù hợp nhất?

A. Mean Imputation vì phản ánh giá trị trung bình toàn tập

B. Mode Imputation vì giá trị xuất hiện nhiều nhất là đại diện tốt nhất

C. Median Imputation vì ít bị ảnh hưởng bởi ngoại lai, phản ánh trung tâm phân phối tốt hơn

D. Điền giá trị 0 để không ảnh hưởng đến tính toán

Câu 4: Confidence của luật A→B đạt 88%, mặt hàng B có tần suất mua tự nhiên là 92%. Lift của luật này gần bằng bao nhiêu và ý nghĩa là gì? [Lift = Confidence(A→B) / Support(B)]

A. Lift = 1.0: hai mặt hàng hoàn toàn độc lập

B. Không tính được Lift từ các thông số đã cho

C. Lift ≈ 0.96 < 1: mua A thực sự làm giảm nhẹ khả năng mua B

D. Lift ≈ 1.05 > 1: mối quan hệ tích cực

Câu 5: Siêu thị tìm được luật "Tã lót → Bia" với Support = 3%, Confidence = 72%, Lift = 4. Diễn giải ý nghĩa thực tiễn của luật này?

A. Lift=4 nghĩa là 4 trong 10 khách hàng mua cả tã lót và bia

B. 72% khách mua tã lót cũng mua bia; Lift=4 cho thấy khả năng mua bia tăng gấp 4 lần so với mức trung bình

C. Cần tăng Confidence lên 90% trước khi áp dụng luật

D. Chỉ 3% khách mua tã lót nên luật không đáng tin cậy

Câu 6: Khi nào nên ưu tiên dùng F1-Score thay vì Accuracy để đánh giá mô hình phân lớp?

A. Khi chỉ cần đánh giá nhanh mà không cần chi tiết

B. Khi tập dữ liệu cân bằng giữa các lớp

C. Khi dữ liệu mất cân bằng (imbalanced) và chi phí FP/FN không đồng đều

D. Khi mô hình là hồi quy tuyến tính

Câu 7: 300 giao dịch: A xuất hiện 150 lần, B xuất hiện 120 lần, A∩B xuất hiện 60 lần. Tính Support(A,B), Confidence(A→B) và Lift? [Sup=count/total ; Conf=Sup(A,B)/Sup(A) ; Lift=Conf/Sup(B)]

A. Sup=20%, Confidence=40%, Lift=0.8

B. Sup=20%, Confidence=40%, Lift=1.0

C. Sup=20%, Confidence=50%, Lift=1.25

D. Sup=40%, Confidence=60%, Lift=1.5

Câu 8: Phân phối điểm thi của sinh viên: Q1 = 60, Q3 = 78. Áp dụng phương pháp IQR (hệ số 1.5), điểm nào sau đây là ngoại lai (outlier)? [IQR = Q3 − Q1 ; Ngưỡng dưới = Q1 − 1.5×IQR ; Ngưỡng trên = Q3 + 1.5×IQR]

A. Điểm 95 — trong phạm vi bình thường

B. Điểm 35 — dưới ngưỡng dưới (33)

C. Điểm 50 — trong phạm vi bình thường

D. Điểm 68 — nằm gần tứ phân vị

Câu 9: Trong phân tích luật kết hợp, "Độ hỗ trợ" (Support) của tập mục {X, Y} được định nghĩa là gì?

A. Tỷ lệ phần trăm giao dịch chứa đồng thời cả X và Y trên tổng số giao dịch

B. Xác suất mua Y khi đã biết mua X

C. Số lần {X,Y} xuất hiện tuyệt đối trong cơ sở dữ liệu

D. Mức độ tương quan thống kê giữa X và Y

Câu 10: Trong luật kết hợp, tại sao Lift (Độ nâng) thường được xem là chỉ số đánh giá quan trọng hơn Confidence?

A. Lift không phụ thuộc vào ngưỡng min_support

B. Lift tính toán đơn giản hơn Confidence

C. Lift cho biết mối quan hệ có ý nghĩa thực sự hay chỉ do tần suất cao tự nhiên của từng mục riêng lẻ

D. Confidence luôn bằng Lift trong mọi trường hợp

Câu 11: Cơ sở dữ liệu 600 giao dịch: {Máy tính} xuất hiện 180 lần, {Phần mềm} xuất hiện 240 lần, {Máy tính, Phần mềm} cùng xuất hiện 120 lần. Tính Confidence("Máy tính → Phần mềm") và Lift? [Confidence = Sup(X,Y)/Sup(X) ; Lift = Confidence/Sup(Y)]

A. Confidence = 50%, Lift = 1.25

B. Confidence = 40%, Lift = 0.8

C. Confidence = 66.7%, Lift = 1.67

D. Confidence = 66.7%, Lift = 1.0

Câu 12: Trong đánh giá mô hình phân lớp, "Ma trận nhầm lẫn" (Confusion Matrix) cung cấp thông tin gì?

A. Mô tả phân phối dữ liệu trong tập huấn luyện

B. Thể hiện cấu trúc cây quyết định đã xây dựng

C. So sánh tốc độ xử lý của các mô hình khác nhau

D. Phân tích chi tiết các loại dự đoán đúng/sai (TP, TN, FP, FN) theo từng lớp

Câu 13: Kỹ thuật "Pruning" (Cắt tỉa) trong cây quyết định có mục đích chính là gì?

A. Tăng tốc độ xây dựng cây trong giai đoạn huấn luyện

B. Giảm overfitting bằng cách loại bỏ các nhánh không cải thiện đáng kể độ chính xác trên tập kiểm tra

C. Tăng độ sâu cây để học được nhiều quy tắc hơn

D. Chuyển đổi cây sang dạng luật IF-THEN

Câu 14: So với K-means, Hierarchical Clustering có ưu điểm nào nổi bật?

A. Nhanh hơn đáng kể với dữ liệu lớn

B. Luôn tìm ra phân cụm tối ưu toàn cục

C. Ít nhạy cảm hơn với ngoại lai trong dữ liệu

D. Không cần xác định số cụm K trước; dendrogram cho phép quan sát cấu trúc phân cụm ở nhiều mức

Câu 15: Hierarchical Clustering (Single Linkage) với 4 điểm trên trục số: W(0), X(2), Y(8), Z(11). Thứ tự các cặp được gộp là gì? [Single Linkage: khoảng cách 2 cụm = khoảng cách nhỏ nhất giữa 2 điểm bất kỳ]

A. {X,Y} → {W,Z} → {W,X,Y,Z}

B. {W,X,Y} → {Z} → toàn bộ

C. {W,X} → {Y,Z} → {W,X,Y,Z}

D. {Y,Z} → {W,X} → {W,X,Z} → toàn bộ

Câu 16: DBSCAN với eps=2, MinPts=3. Điểm X có 7 điểm lân cận trong bán kính eps. Điểm Y có 2 điểm lân cận trong eps nhưng nằm trong vùng lân cận của X. Phân loại X và Y là gì?

A. Cả X và Y đều là Core Point

B. X là Core Point, Y là Border Point

C. X là Core Point, Y là Noise Point

D. X là Border Point, Y là Core Point

Câu 17: So với Apriori, thuật toán FP-Growth có ưu điểm gì trong khai phá tập phổ biến?

A. FP-Growth yêu cầu nhiều lần quét cơ sở dữ liệu để đảm bảo độ chính xác

B. FP-Growth chỉ hoạt động tốt khi dữ liệu đã được sắp xếp

C. FP-Growth không cần ngưỡng min_support

D. FP-Growth chỉ quét CSDL 2 lần và nén dữ liệu vào FP-Tree, tránh sinh candidate itemset tốn kém

Câu 18: Thuật toán k-NN với k=5 phân loại điểm mới P. 5 láng giềng gần nhất có nhãn: [B, A, A, B, A]. P được phân loại vào lớp nào?

A. Lớp A (3 phiếu vs 2 phiếu)

B. Không xác định được vì cần k lẻ

C. Lớp A và B với xác suất bằng nhau

D. Lớp B (2 phiếu nhưng khoảng cách gần hơn)

Câu 19: K-means: sau vòng lặp đầu tiên, Cụm 1 có 3 điểm: P1=(5,1), P2=(6,2), P3=(8,3). Tính centroid mới của Cụm 1? [Centroid = (mean_x, mean_y)]

A. (6.33, 2)

B. (6, 2)

C. (7, 3)

D. (6.5, 2)

Câu 20: Trong SVM (Support Vector Machine), kỹ thuật "Kernel Trick" giải quyết vấn đề gì?

A. Chọn tự động tham số C và gamma tối ưu

B. Cho phép phân loại dữ liệu không tuyến tính bằng cách ánh xạ ngầm lên không gian đặc trưng chiều cao hơn

C. Giảm overfitting bằng cách thêm regularization vào hàm mục tiêu

D. Tăng tốc quá trình huấn luyện bằng cách giảm số lượng support vector

Câu 21: 6 giao dịch: T1:{A,B,C}, T2:{A,B,D}, T3:{A,C,D}, T4:{B,C,D}, T5:{A,B,C}, T6:{A,B,D}. Với min_support = 50%, tập mục 2 phần tử nào KHÔNG phổ biến?

A. {A,B} (4/6 = 67%)

B. {C,D} (2/6 = 33%)

C. {A,D} (3/6 = 50%)

D. {B,C} (3/6 = 50%)

Câu 22: Phân lớp Naive Bayes được gọi là "Naive" (Ngây thơ) vì lý do nào?

A. Thuật toán đơn giản và không cần huấn luyện

B. Chỉ áp dụng được khi dữ liệu có phân phối chuẩn

C. Kết quả phân lớp không chính xác trong mọi trường hợp

D. Giả định các thuộc tính đầu vào hoàn toàn độc lập có điều kiện, dù thực tế thường không đúng

Câu 23: Tập huấn luyện 12 mẫu: 8 mẫu thuộc lớp (+) và 4 mẫu thuộc lớp (−). Tính Entropy của tập S? [Entropy(S) = $-p_+ \log_2(p_+) - p_- \log_2(p_-)$]

A. 0.544 bits

B. 1.000 bits

C. 0.918 bits

D. 0.750 bits

Câu 24: 5-fold Cross Validation cho kết quả: 75%, 80%, 80%, 85%, 80%. Tính Mean Accuracy và Standard Deviation? [Mean = $\Sigma x_i/n$; SD = $\sqrt{(\Sigma(x_i-\bar{x})^2/n)}$]

A. Mean = 80%, SD ≈ 3.16%

B. Mean = 80%, SD ≈ 2.00%

C. Mean = 82%, SD ≈ 3.16%

D. Mean = 80%, SD ≈ 5.00%

Câu 25: PCA cho 5 eigenvalues: 12, 4, 2, 1, 1 (tổng = 20). Cần bao nhiêu Principal Component để giữ lại ít nhất 80% phương sai? [% phương sai PC_i = eigenvalue_i / tổng eigenvalues]

A. 2 PC (80%)

B. 3 PC (90%)

C. 4 PC (95%)

D. 1 PC (60%)

Câu 26: Bộ dữ liệu 20 bản ghi: 12 thuộc lớp "Mua" và 8 thuộc lớp "Không mua". Entropy của tập S là bao nhiêu? [Entropy(S) = $-\Sigma\ p_i \log_2(p_i)$]

A. 0.971 bits

B. 0.954 bits

C. 1.0 bits

D. 0.863 bits

Câu 27: Khi nào nên sử dụng chuẩn hóa Z-score thay vì Min-Max?

A. Khi muốn đưa dữ liệu về đoạn [0,1]

B. Khi dữ liệu không có ngoại lai (outliers)

C. Khi muốn giữ nguyên phân phối dữ liệu và có ngoại lai (outliers)

D. Không có sự khác biệt, chỉ là 2 thuật toán có độ phức tạp khác nhau

Câu 28: Trong quy trình KDD (Knowledge Discovery in Databases), giai đoạn nào thường chiếm nhiều thời gian và công sức nhất trong thực tế?

A. Tiền xử lý và chuẩn bị dữ liệu

B. Xây dựng mô hình khai phá dữ liệu

C. Đánh giá và diễn giải kết quả

D. Chọn lựa thuật toán khai phá phù hợp

Câu 29: Ngân hàng muốn phân tích hàng triệu giao dịch để phát hiện hành vi bất thường có khả năng gian lận trong thời gian thực. Kỹ thuật khai phá dữ liệu nào phù hợp nhất?

A. Phân cụm (Clustering) để nhóm khách hàng có hành vi tương đồng

B. Luật kết hợp (Association Rules) để tìm sản phẩm tài chính hay xuất hiện cùng nhau

C. Hồi quy (Regression) để dự đoán số dư tài khoản

D. Phát hiện ngoại lai (Outlier Detection) kết hợp Phân lớp (Classification) từ dữ liệu lịch sử có nhãn

Câu 30: Tính chất "Anti-monotone" của thuật toán Apriori giúp tỉa không gian tìm kiếm như thế nào?

A. Độ hỗ trợ tăng dần theo kích thước tập mục

B. Tất cả tập mục con (subset) có cùng Support với tập cha

C. Nếu tập mục phổ biến thì mọi tập cha (superset) của nó cũng phổ biến

D. Nếu một tập mục không phổ biến thì mọi tập mở rộng (superset) cũng không phổ biến → có thể bỏ qua toàn bộ

Câu 31: Trong thuật toán K-means, WCSS (Within-Cluster Sum of Squares) hay Inertia được dùng để làm gì?

A. Khởi tạo ngẫu nhiên các centroid ban đầu

B. Đánh giá chất lượng phân cụm dựa trên nhãn thực của dữ liệu

C. Xác định số cụm K tối ưu thông qua Elbow Method bằng cách quan sát điểm gãy của đồ thị WCSS

D. Tính khoảng cách giữa các centroid của các cụm khác nhau

Câu 32: Hệ thống gợi ý (Recommender System) loại nào phù hợp khi muốn gợi ý cho người dùng mới chưa có lịch sử tương tác?

A. Matrix Factorization vì tốt nhất với dữ liệu thưa

B. Hybrid Filtering nhưng cần ít nhất 10 đánh giá

C. Collaborative Filtering vì dựa trên hành vi người dùng tương tự

D. Content-based Filtering vì chỉ cần đặc trưng của item, không cần lịch sử tương tác

Câu 33: Công ty logistics muốn theo dõi GPS của 10,000 xe tải theo thời gian thực để phát hiện tắc nghẽn và điều phối lộ trình. Kỹ thuật nào phù hợp nhất?

A. Stream Mining với Sliding Window để phân tích xu hướng vị trí liên tục trong thời gian thực

B. Batch Processing với Hadoop vì xử lý được khối lượng lớn

C. Offline Clustering K-means trên dữ liệu lịch sử

D. Association Rules để tìm tuyến đường thường đi cùng nhau

Câu 34: Davies-Bouldin Index (DBI) đánh giá chất lượng phân cụm như thế nào?

A. DBI càng lớn thì phân cụm càng tốt vì các cụm tách biệt

B. DBI càng nhỏ thì phân cụm càng tốt (cụm nhỏ gọn, cách xa nhau)

C. DBI = 0 là giá trị lý tưởng trong mọi trường hợp

D. DBI chỉ áp dụng được cho K-means, không dùng cho Hierarchical

Câu 35: OLAP (Online Analytical Processing) khác với OLTP (Online Transaction Processing) ở điểm nào?

A. OLAP xử lý giao dịch real-time, OLTP phân tích dữ liệu

B. OLAP phục vụ phân tích và báo cáo, OLTP xử lý giao dịch hàng ngày

C. OLAP và OLTP có chức năng giống nhau

D. OLAP chỉ làm việc với dữ liệu lịch sử

Câu 36: FP-Growth algorithm có ưu điểm chính nào so với Apriori?

A. Tối ưu hóa bộ nhớ bằng cách chỉ tìm theo 2 itemset mỗi lần quét cơ sở dữ liệu

B. Cho kết quả chính xác hơn với trên cùng ngưỡng support

C. Chỉ quét cơ sở dữ liệu 2 lần, sử dụng cấu trúc cây FP-tree

D. Dễ triển khai (implement) và hiểu thuật toán hơn Apriori

Câu 37: Pruning (cắt tỉa) trong Decision Tree được thực hiện để:

A. Giảm overfitting bằng cách cắt bớt các nhánh không cần thiết

B. Giảm thời gian huấn luyện bằng cách tăng tốc thuật toán

C. Tăng độ phức tạp của mô hình để cải thiện độ chính xác

D. Tăng độ chính xác trên tập dữ liệu huấn luyện

Câu 38: Boosting và Bagging khác nhau như thế nào trong Ensemble Learning?

A. Boosting: huấn luyện tuần tự, tập trung vào lỗi; Bagging: huấn luyện song song, giảm phương sai

B. Không có sự khác biệt thực tế, chỉ là cách đặt tên khác nhau

C. Boosting có tốc độ xử lý nhanh hơn Bagging trong mọi trường hợp

D. Bagging luôn cho kết quả tốt hơn Boosting với mọi loại dữ liệu

Câu 39: Khai phá dữ liệu (Data Mining) trong bối cảnh doanh nghiệp chủ yếu phục vụ mục đích nào?

A. Phát hiện mẫu, xu hướng và tri thức ẩn để hỗ trợ ra quyết định kinh doanh

B. Sao lưu và phục hồi dữ liệu khi hệ thống gặp sự cố

C. Thiết kế và tối ưu hóa schema cơ sở dữ liệu

D. Tăng tốc độ truy vấn cơ sở dữ liệu quan hệ

Câu 40: Khai phá dữ liệu mô tả (Descriptive Mining) và khai phá dữ liệu dự đoán (Predictive Mining) khác nhau cơ bản ở điểm nào?

A. Hai loại không có sự khác biệt về mục tiêu

B. Mô tả tóm lược đặc trưng dữ liệu hiện tại; Dự đoán xây dựng mô hình để suy luận kết quả tương lai

C. Mô tả chỉ dùng trong thống kê học; Dự đoán dùng trong machine learning

D. Mô tả xử lý dữ liệu số; Dự đoán xử lý dữ liệu phân loại

Câu 41: Phương pháp nào sau đây được dùng để chuyển đổi biến phân loại (categorical) thành dạng vector nhị phân (0/1) để đưa vào các thuật toán học máy?

A. Log Transformation

B. Min-Max Normalization

C. One-Hot Encoding

D. Z-score Standardization

Câu 42: "Curse of Dimensionality" (Lời nguyền chiều) trong khai phá dữ liệu mô tả hiện tượng nào?

A. Khi giảm số chiều, mô hình mất hoàn toàn độ chính xác

B. Khi có quá nhiều dữ liệu, thuật toán không thể hội tụ

C. Khi dữ liệu có quá nhiều giá trị thiếu ở nhiều chiều

D. Khi số chiều tăng, dữ liệu trở nên thưa thớt và khoảng cách giữa các điểm mất dần ý nghĩa phân biệt

Câu 43: Trong khai phá dữ liệu luồng (Stream Mining), tại sao phải xử lý dữ liệu trong một lần duyệt duy nhất (one-pass)?

A. Dữ liệu luồng chỉ chứa dữ liệu số không cần nhiều phép tính

B. Dữ liệu luồng đến liên tục, không thể lưu trữ toàn bộ; cần xử lý tức thời với bộ nhớ hạn chế

C. One-pass cho độ chính xác cao hơn multi-pass

D. Do dữ liệu luồng luôn có cấu trúc đơn giản không cần nhiều lần duyệt

Câu 44: TF-IDF trong khai phá văn bản được dùng để làm gì?

A. Dịch văn bản từ ngôn ngữ này sang ngôn ngữ khác

B. Tóm tắt tự động nội dung tài liệu dài

C. Phân tích cảm xúc (sentiment) của văn bản

D. Đo lường tầm quan trọng của từ: từ phổ biến toàn corpus giảm trọng số, từ đặc trưng riêng tài liệu tăng trọng số

Câu 45: Hệ thống gợi ý phim mới ra mắt (cold start problem): bộ phim chưa có đánh giá từ người dùng. Chiến lược nào hiệu quả nhất?

A. Dùng Content-based Filtering dựa trên metadata (thể loại, đạo diễn, diễn viên) kết hợp hồ sơ sở thích người dùng

B. Gợi ý ngẫu nhiên để thu thập dữ liệu nhanh hơn

C. Dùng Collaborative Filtering với giả định người dùng mới thích phim phổ biến

D. Đợi thu thập đủ đánh giá rồi mới gợi ý

Câu 46: PCA (Principal Component Analysis) thuộc loại kỹ thuật nào trong tiền xử lý?

A. Làm sạch dữ liệu (Data cleaning)

B. Biến đổi dữ liệu (Data transformation)

C. Tích hợp dữ liệu (Data integration)

D. Giảm chiều dữ liệu (Dimensionality reduction)

Câu 47: Lift trong Association Rules có ý nghĩa gì khi Lift > 1?

A. Luật không có ý nghĩa

B. A và B có mối quan hệ thuận chiều

C. A và B có mối quan hệ nghịch đảo

D. A và B độc lập với nhau

Câu 48: K-means clustering thuộc loại thuật toán nào?

A. Học có giám sát (Supervised learning)

B. Học bán giám sát (Semi-supervised learning)

C. Học tăng cường (Reinforcement learning)

D. Học không giám sát (Unsupervised learning)

Câu 49: DBSCAN khác với K-means ở những điểm nào chính?

A. DBSCAN chỉ áp dụng cho dữ liệu số

B. DBSCAN dựa trên mật độ, tự động xác định số cụm, xử lý được nhiễu

C. DBSCAN nhanh hơn K-means

D. DBSCAN cho kết quả deterministic

Câu 50: Data cleaning trong tiền xử lý dữ liệu bao gồm:

A. Xử lý giá trị thiếu (missing values), điểm ngoại lai (outliers), nhiễu (noise) và dữ liệu không nhất quán

B. Chỉ xóa dữ liệu trùng lặp

C. Chỉ điền giá trị thiếu

D. Chỉ chuyển đổi định dạng dữ liệu

Câu 51: Tại sao cần chuẩn hóa (normalization) dữ liệu trước khi áp dụng thuật toán khai phá dữ liệu?

A. Để giảm kích thước file dữ liệu

B. Để đảm bảo các thuộc tính có cùng phạm vi giá trị

C. Để tự động loại bỏ điểm ngoại lai (outliers)

D. Để tăng tốc độ xử lý dữ liệu

Câu 52: Trong thuật toán Apriori, nguyên lý nào sau đây đúng?

A. Tất cả itemset đều có cùng mức support

B. Chỉ xét các itemset có kích thước bằng nhau

C. Nếu một itemset frequent thì tất cả superset của nó cũng frequent

D. Nếu một itemset frequent thì tất cả subset của nó cũng frequent

Câu 53: Naive Bayes classifier được gọi là "naive" (ngây thơ) vì:

A. Vì có cấu trúc đơn giản và dễ triển khai

B. Vì có độ chính xác (accuracy) thấp so với các thuật toán khác

C. Vì giả định các đặc trưng (features) độc lập với nhau

D. Vì chỉ làm việc được với dữ liệu phân loại (categorical data)

Câu 54: ROC curve được vẽ dựa trên:

A. Accuracy vs Error Rate

B. Precision vs Recall

C. True Positive Rate vs False Positive Rate

D. Sensitivity vs Specificity

Câu 55: Khai phá dữ liệu (Data Mining) là gì?

A. Quá trình lưu trữ dữ liệu trong kho dữ liệu lớn

B. Quá trình thu thập dữ liệu lớn từ Internet

C. Quá trình sao lưu và bảo mật dữ liệu lớn

D. Quá trình khám phá tri thức hữu ích từ cơ sở dữ liệu lớn

Câu 56: Học có giám sát (Supervised Learning) khác với Học không giám sát (Unsupervised Learning) ở điểm nào?

A. Không có sự khác biệt nào giữa hai phương pháp học này

B. Supervised chỉ áp dụng cho dữ liệu số, Unsupervised áp dụng cho mọi loại dữ liệu

C. Supervised có dữ liệu được gán nhãn, Unsupervised không có dữ liệu được gán nhãn

D. Supervised có tốc độ xử lý nhanh hơn Unsupervised trong mọi trường hợp

Câu 57: Closed itemset trong frequent pattern mining là:

A. Itemset cuối cùng được tìm thấy trong thuật toán

B. Itemset có số lượng items ít nhất

C. Itemset có support cao nhất trong toàn bộ dataset

D. Itemset không có superset nào có cùng support

Câu 58: Elbow method được sử dụng để:

A. Tính toán vị trí centroids cho từng cluster

B. Xác định số clusters tối ưu trong K-means

C. Đánh giá chất lượng clustering sau khi hoàn thành

D. Loại bỏ các điểm ngoại lai (outliers) khỏi dữ liệu

Câu 59: Big Data được đặc trưng bởi mô hình 3V nào?

A. Volume, Velocity, Variety

B. Velocity, Value, Visualization

C. Volume, Value, Verification

D. Variety, Verification, Validation

Câu 60: Transfer Learning trong Deep Learning có nghĩa là:

A. Sử dụng mô hình đã được huấn luyện sẵn cho nhiệm vụ mới

B. Di chuyển trọng số mô hình giữa các máy chủ khác nhau

C. Chia sẻ trọng số giữa các lớp trong cùng mạng

D. Di chuyển dữ liệu giữa các máy chủ khác nhau

Câu 61: Ưu điểm của kỹ thuật Binning (Phân thùng) trong tiền xử lý là gì?

A. Tăng số lượng biến.

B. Giảm bớt ảnh hưởng của các lỗi quan sát nhỏ hoặc nhiễu.

C. Biến dữ liệu định tính thành định lượng.

D. Luôn giữ nguyên 100% thông tin gốc.

Câu 62: Tại sao thuật toán FP-Growth lại hiệu quả hơn Apriori trên tập dữ liệu lớn?

A. Vì nó quét dữ liệu nhiều lần hơn.

B. Vì nó tránh được việc tạo ra hàng triệu ứng viên khổng lồ và chỉ quét dữ liệu 2 lần.

C. Vì nó không sử dụng độ hỗ trợ.

D. Vì nó chỉ hoạt động trên dữ liệu nhỏ.

Câu 63: Tại sao Z-score lại ít bị ảnh hưởng bởi Outliers hơn Min-Max Scaling?

A. Vì Z-score không có giá trị Max.

B. Vì Min-Max Scaling tính toán phức tạp hơn.

C. Vì Z-score dựa trên độ lệch chuẩn và trung bình của toàn tập, thay vì chỉ dựa vào 2 điểm cực trị.

D. Vì Z-score luôn đưa dữ liệu về khoảng.

Câu 64: Tại sao chuẩn hóa dữ liệu lại bắt buộc đối với thuật toán k-NN hay SVM?

A. Để các thuộc tính có thang đo lớn (như thu nhập) không áp đảo các thuộc tính có thang đo nhỏ (như tuổi).

B. Để dữ liệu đẹp hơn.

C. Để mô hình không bị lỗi chia cho 0.

D. Để tăng giá trị Bias.

Câu 65: Data Warehouse ra đời vào khoảng thời gian nào?

A. Những năm 1980.

B. Những năm 1990.

C. Những năm 2010.

D. Những năm 2020.

Câu 66: Khoảng bao nhiêu % dữ liệu nằm trong khoảng Z-score từ -1 đến +1?

A. 68%.

B. 50%.

C. 95%.

D. 99.7%.

Câu 67: Silhouette Score nằm trong khoảng nào?

A. [0, 1].

B. [-3, 3].

C. [0, $+\infty$].

D. [-1, 1].

Câu 68: Tỷ lệ p trong Dropout thường nằm trong khoảng nào?

A. 0.2 - 0.5.

B. 0.05 - 0.1.

C. 0.7 - 0.9.

D. Gần bằng 1.

Câu 69: Tại sao Accuracy có thể gây đánh lừa trong bài toán dữ liệu mất cân bằng?

A. Vì mô hình có thể đạt 99% chính xác chỉ bằng cách dự đoán tất cả là lớp đa số.

B. Vì Accuracy luôn quá thấp.

C. Vì Accuracy không tính được cho lớp âm tính.

D. Vì Accuracy chỉ dùng cho hồi quy.

Câu 70: Tại sao K-means nhạy cảm với các điểm ngoại lệ (Outliers)?

A. Vì các điểm quá xa sẽ kéo lệch tâm cụm (centroid), làm sai lệch kết quả phân cụm.

B. Vì ngoại lệ có giá trị bằng 0.

C. Vì ngoại lệ làm tăng số lượng cụm K.

D. Vì K-means chỉ dùng cho dữ liệu tròn.

Câu 71: Tại sao cần "Cắt tỉa" (Pruning) trong cây quyết định?

A. Để cây mọc dài hơn.

B. Để đơn giản hóa mô hình và giảm hiện tượng Overfitting.

C. Để tăng số lượng nút lá.

D. Để thay thế chỉ số Gini.

Câu 72: Tại sao Metadata (Siêu dữ liệu) lại quan trọng trong Data Warehouse?

A. Để chứa dữ liệu thô.

B. Để giúp người dùng hiểu cấu trúc, nguồn gốc và ý nghĩa của dữ liệu đang lưu trữ.

C. Để tăng tốc độ ghi dữ liệu.

D. Để thay thế cho kho dữ liệu.

Câu 73: Tại sao trong quy trình tiền xử lý, việc phát hiện Outliers lại quan trọng?

A. Để tăng kích thước tập dữ liệu.

B. Để làm thuật toán chạy chậm hơn.

C. Vì ngoại lệ có thể là lỗi nhập liệu gây sai lệch mô hình hoặc là thông tin cực kỳ giá trị (như gian lận).

D. Để xóa bỏ 10% dữ liệu bất kỳ.

Câu 74: Mục đích của phân tích cụm là gì?

A. Để dự đoán các giá trị trong tương lai

B. Để nhóm các đối tượng dữ liệu mà không cần tham khảo nhãn lớp

C. Để phân loại dữ liệu thành các danh mục được xác định trước

D. Để xác định các ngoại lệ trong một tập dữ liệu

Câu 75: Dữ liệu lớn đề cập đến điều gì?

A. Tập dữ liệu rất lớn và/hoặc rất phức tạp vượt quá khả năng xử lý của các kỹ thuật CNTT truyền thống

B. Tập dữ liệu nhỏ

C. Dữ liệu có thể dễ dàng xử lý bằng Excel

D. Tập dữ liệu được thu thập từ một nguồn duy nhất

Câu 76: Mục đích của việc tích hợp khai phá dữ liệu với các hệ thống cơ sở dữ liệu là gì?

A. Để cải thiện khả năng của các hệ thống cơ sở dữ liệu, giúp người dùng thực hiện phân tích dữ liệu phức tạp

B. Để loại bỏ nhu cầu về kho dữ liệu

C. Để hạn chế số lượng dữ liệu có thể được phân tích

D. Để đơn giản hóa quá trình nhập dữ liệu

Câu 77: Điều nào sau đây là một thách thức với các phương pháp thống kê truyền thống khi đối phó với các tập dữ liệu lớn và phức tạp?

A. Chúng không tốn kém và dễ thực hiện

B. Chúng phù hợp để phân tích các tập dữ liệu nhỏ

C. Chúng có thể xử lý dữ liệu trong thời gian thực

D. Chúng rất hiệu quả để phân tích dữ liệu phức tạp

Câu 78: Cho một tập dữ liệu với 100.000 cảm biến tạo ra 8 byte dữ liệu mỗi giây trong 60 phút. Tổng kích thước dữ liệu được tạo ra là bao nhiêu?

A. 2,88 MB

B. 28,8 MB

C. 28,8 GB

D. 2,88 GB

Câu 79: Mẫu "máy tính => webcam [1%, 50%]" trong phân tích hiệp hội có nghĩa là gì?

A. Máy tính và webcam luôn được mua cùng nhau

B. 1% khách hàng mua webcam cũng mua máy tính và 50% khách hàng mua máy tính cũng mua webcam

C. Không có mối quan hệ giữa việc mua máy tính và webcam

D. 50% khách hàng mua webcam cũng mua máy tính và 1% khách hàng mua máy tính cũng mua webcam

Câu 80: "Độ tin cậy" trong phân tích hiệp hội có nghĩa là gì?

A. Số lượng các mục trong một tập dữ liệu

B. Tần suất xuất hiện của một mẫu

C. Độ chính xác của một quy tắc

D. Kích thước của một tập dữ liệu

Câu 81: Sự khác biệt chính giữa "dữ liệu lớn" và "rất nhiều dữ liệu" là gì?

A. "Rất nhiều dữ liệu" luôn phức tạp hơn dữ liệu lớn

B. Dữ liệu lớn có thể rất nhỏ và không phải tất cả các tập dữ liệu lớn đều là dữ liệu lớn; kích thước và độ phức tạp là những yếu tố

C. Dữ liệu lớn luôn lớn hơn "rất nhiều dữ liệu"

D. Không có sự khác biệt

Câu 82: Một ưu điểm của việc sử dụng cây quyết định trong phân loại là gì?

A. Chúng rất khó diễn giải

B. Chúng dễ diễn giải

C. Chúng chỉ có thể được sử dụng với các tập dữ liệu nhỏ

D. Chúng không thể xử lý dữ liệu phân loại

Câu 83: Quy trình KDD gồm bao nhiêu bước chính?

A. 3.

B. 4.

C. 6.

D. 5.

Câu 84: Quy trình CRISP-DM gồm bao nhiêu giai đoạn?

A. 4.

B. 5.

C. 6.

D. 7.

Câu 85: Giai đoạn nào trong CRISP-DM tập trung vào việc xác định mục tiêu kinh doanh?

A. Modeling.

B. Data Understanding.

C. Business Understanding.

D. Evaluation.

Câu 86: Data Lake ra đời vào khoảng năm nào để giải quyết Big Data?

A. 1980.

B. 2010.

C. 1990.

D. 2020.

Câu 87: Trong PCA, trục chứa lượng phương sai lớn nhất được gọi là:

A. PC1.

B. PC2.

C. PC3.

D. PC_Final.

Câu 88: Ma trận nhầm lẫn cho bài toán nhị phân gồm bao nhiêu thành phần?

A. 2.

B. 4 (TP, TN, FP, FN).

C. 6.

D. 8.

Câu 89: Chỉ số Recall còn được gọi là gì?

A. Độ chuẩn xác.

B. Độ nhạy (Sensitivity).

C. F1-Score.

D. Specificity.

Câu 90: Trong SVM, những điểm nằm sát siêu phẳng nhất gọi là:

A. Nodes.

B. Outliers.

C. Centroids.

D. Support Vectors.

Câu 91: Chỉ số Gini Index bằng 0 khi nào?

A. Nút tinh khiết tuyệt đối (chỉ chứa 1 lớp).

B. Nút cực kỳ vẩn đục.

C. Nút có 2 lớp bằng nhau.

D. Nút bị rỗng.

Câu 92: Balanced Accuracy là trung bình cộng của chỉ số nào trên từng lớp?

A. Recall.

B. Precision.

C. Accuracy.

D. F1.

Câu 93: Gom cụm (Clustering) là bài toán học máy loại nào?

A. Học có giám sát.

B. Học sâu.

C. Học tăng cường.

D. Học không giám sát.

Câu 94: Tại sao OLTP cần các truy vấn Insert/Update cực nhanh?

A. Để hỗ trợ ra quyết định chiến lược.

B. Để phục vụ các hoạt động vận hành tức thời hàng ngày (như rút tiền ATM).

C. Để phân tích xu hướng 10 năm qua.

D. Để giảm khối lượng dữ liệu lưu trữ.

Câu 95: Tại sao Z-score giúp phát hiện điểm ngoại lệ?

A. Vì nó tính được trung bình.

B. Vì nó đưa dữ liệu về khoảng 0-1.

C. Vì những điểm có |Z| > 3 nằm quá xa giá trị trung bình so với phần còn lại của dữ liệu.

D. Vì nó chỉ áp dụng cho dữ liệu nhiễu.

Câu 96: Lift > 1 trong luật kết hợp có ý nghĩa thực tế như thế nào?

A. Khách hàng mua X thường không mua Y.

B. X và Y có mối quan hệ tích cực (mua cái này thực sự kéo theo khả năng mua cái kia).

C. X và Y hoàn toàn độc lập.

D. Support của X rất thấp.

Câu 97: Tại sao luật kết hợp âm tính khó khai thác hơn luật dương tính?

A. Vì nó không có giá trị kinh tế.

B. Vì sự bùng nổ không gian tìm kiếm của các tổ hợp "không mua" là cực lớn.

C. Vì Support của nó luôn bằng 0.

D. Vì con người không quan tâm đến sự vắng mặt của hàng hóa.

Câu 98: Trong chẩn đoán y tế (ung thư), tại sao Recall được ưu tiên hơn Precision?

A. Để tránh bắt nhầm người khỏe.

B. Để không được phép bỏ sót người bị bệnh (giảm False Negative).

C. Để tăng độ chính xác tổng thể.

D. Để tiết kiệm chi phí xét nghiệm.

Câu 99: Precision quan trọng hơn Recall trong tình huống nào?

A. Phát hiện dịch bệnh.

B. Lọc thư rác (để tránh việc đẩy thư quan trọng vào mục spam).

C. Dự báo động đất.

D. Kiểm tra nợ xấu.

Câu 100: Tại sao SVM cố gắng tối đa hóa lề (Margin)?

A. Để làm mô hình phức tạp hơn.

B. Để đảm bảo mô hình có khả năng tổng quát hóa tốt nhất, tránh sai sót khi có dữ liệu mới.

C. Để siêu phẳng nằm sát các điểm nhiễu nhất.

D. Để giảm số lượng Support Vectors.

Câu 101: Vai trò của "Kernel Trick" trong SVM là gì?

A. Để xóa bớt dữ liệu.

B. Để giảm thời gian tính toán cho tập dữ liệu lớn.

C. Đưa dữ liệu lên không gian cao chiều để phân chia tuyến tính những dữ liệu phi tuyến.

D. Để thay thế tham số C.

Câu 102: Sự khác biệt giữa Bagging và Boosting là gì?

A. Bagging huấn luyện tuần tự.

B. Bagging huấn luyện song song giúp giảm Overfitting; Boosting huấn luyện tuần tự giúp tăng Accuracy.

C. Boosting tập trung vào toàn bộ dữ liệu như nhau.

D. Cả hai đều không sử dụng mô hình yếu.

Câu 103: Ý nghĩa của chỉ số Gini Index = 0.66 trong một nút cây quyết định là gì?

A. Nút rất tinh khiết.

B. Nút này là một lá (leaf node).

C. Thuật toán sẽ dừng chia nhánh tại đây.

D. Nút đang bị vẩn đục cao, các lớp phân bổ khá đều nhau.

Câu 104: Tại sao Random Forest lại chọn ngẫu nhiên thuộc tính khi chia nhánh?

A. Để làm thuật toán chậm hơn.

B. Để tăng tính định kiến (Bias).

C. Để các cây trong rừng khác biệt nhau, giúp giảm Overfitting và tăng độ ổn định .

D. Để mô hình dễ giải thích hơn cây đơn lẻ.

Câu 105: Ưu điểm của DBSCAN so với K-means về hình dạng cụm là gì?

A. DBSCAN có thể phát hiện cụm có hình dạng bất kỳ (hình chữ S, vòng tròn lồng nhau).

B. DBSCAN chỉ tìm được cụm hình cầu.

C. DBSCAN yêu cầu cung cấp trước số cụm K.

D. DBSCAN không thể xử lý nhiễu.

Câu 106: Dropout giúp chống Overfitting như thế nào?

A. Bằng cách tăng kích thước mạng.

B. Bằng cách gán toàn bộ trọng số bằng 0.

C. Bằng cách giảm tốc độ học.

D. Bằng cách buộc các neuron phải tự học đặc trưng độc lập, không dựa dẫm vào các neuron khác.

Câu 107: Sự khác biệt giữa Hard Margin và Soft Margin trong SVM liên quan đến:

A. Kích thước tập dữ liệu.

B. Loại hàm Kernel được sử dụng.

C. Số lượng thuộc tính.

D. Sự đánh đổi giữa việc phân loại đúng hoàn toàn và việc chấp nhận sai sót để có lề rộng hơn.

Câu 108: Tại sao cấu trúc cây FP-tree trong FP-Growth lại giúp nén dữ liệu tốt?

A. Vì nó xóa bỏ các giao dịch.

B. Vì nó chỉ lưu trữ các mặt hàng hiếm.

C. Vì nó sử dụng hàm băm.

D. Vì các giao dịch có chung các mặt hàng đầu tiên sẽ chia sẻ chung các nhánh trên cây.

Câu 109: Bước tiền xử lý (preprocessing) trong quy trình KDD thực hiện nhiệm vụ gì

A. Trực tiếp sinh ra các quy tắc kết hợp và cây quyết định

B. Thực hiện thuyết trình báo cáo trước hội đồng quản trị

C. Làm sạch, lọc nhiễu và xử lý dữ liệu thô để chuẩn bị cho các bước phân tích tiếp theo

D. Cài đặt hệ điều hành máy chủ và thiết lập kết nối mạng internet

Câu 110: Kiểu thuộc tính định danh (Nominal) dùng để chỉ

A. Các giá trị đo lường có điểm 0 tuyệt đối như chiều cao và cân nặng

B. Các danh mục, trạng thái hoặc tên gọi định tính không có thứ tự hơn kém vốn có

C. Các trạng thái có thứ bậc xếp hạng rõ ràng như cấp bậc huy chương (Vàng, Bạc, Đồng)

D. Các giá trị số thực liên tục có thể thực hiện phép nhân chia

Câu 111: Khi dữ liệu có phân phối chuẩn và không có outliers, ta nên điền giá trị thiếu bằng

A. Hai thuộc tính hoàn toàn độc lập và không có mối liên hệ nào với nhau

B. Hai thuộc tính có mối tương quan tuyến tính thuận (cùng chiều) rất mạnh

C. Hai thuộc tính có mối tương quan tuyến tính nghịch (trái chiều) tuyệt đối

D. Một trong hai thuộc tính chắc chắn chứa hơn 85% giá trị khuyết thiếu

Câu 112: Đặc điểm nổi bật nhất của FP-Growth so với Apriori là

A. Khai phá tất cả các mẫu phổ biến mà hoàn toàn KHÔNG cần phải sinh tập ứng viên (Candidate-free)

B. Chỉ tìm được các tập mục có độ dài ngắn hơn 2 phần tử

C. Sử dụng bảng tính Microsoft Excel để vẽ biểu đồ tự động

D. Bắt buộc người dùng phải gán nhãn dữ liệu có giám sát trước khi chạy

Câu 113: Độ hỗ trợ (Support) của một tập mục hoặc một luật luôn có giá trị nằm trong khoảng nào?

A. [-1, 1]

B. [0, +∞)

C. [0, 1] (tương ứng từ 0% đến 100%)

D. Chỉ nhận giá trị nguyên 0 hoặc 1

Câu 114: Ý nghĩa của việc một luật kết hợp bị coi là 'lạc hướng' (misleading) dù có độ hỗ trợ và độ tin cậy đều cao là gì?

A. Vì độ tin cậy thực tế của nó bị dưới 50%

B. Vì không có khách hàng nào mua cả hai mặt hàng đó

C. Vì xác suất xuất hiện tự nhiên của vế sau luật còn cao hơn cả độ tin cậy của luật đó (Lift < 1)

D. Vì độ hỗ trợ của luật quá thấp không đạt ngưỡng

Câu 115: Với số liệu của CSDL trên, luật kết hợp {2, 5} => {3} có độ tin cậy (Confidence) là bao nhiêu?

A. 66.7%

B. 75%

C. 100%

D. 50%

Câu 116: Khai phá dữ liệu còn được gọi là gì?

A. Phân tích dữ liệu lớn

B. Khám phá tri thức từ dữ liệu (KDD)

C. Kho dữ liệu

D. Xử lý phân tích trực tuyến (OLAP)

Câu 117: Đâu là một chức năng của khai phá dữ liệu?

A. Xóa dữ liệu

B. Tóm tắt dữ liệu đa chiều

C. Nhập dữ liệu

D. Lưu trữ dữ liệu

Câu 118: Điều nào sau đây là một ví dụ về mẫu thường xuyên?

A. Một mẫu xuất hiện nhiều lần trong dữ liệu

B. Một ngoại lệ không phù hợp với hành vi chung của dữ liệu

C. Một sự kiện đơn lẻ xảy ra một lần trong một tập dữ liệu

D. Một mô hình được sử dụng để dự đoán các giá trị trong tương lai

Câu 119: Phân tích ngoại lệ hữu ích nhất trong lĩnh vực nào?

A. Phân nhóm các đối tượng dữ liệu tương tự

B. Tóm tắt dữ liệu lớn trên nhiều chiều

C. Tạo một mô hình phân biệt giữa các lớp dữ liệu khác nhau

D. Phát hiện gian lận

Câu 120: Loại học máy nào liên quan đến việc nhóm các đối tượng dữ liệu mà không cần tham khảo nhãn lớp?

A. Học tăng cường

B. Học bán giám sát

C. Học không giám sát

D. Học có giám sát

Câu 121: Mục đích của tóm tắt dữ liệu đa chiều là gì?

A. Để tóm tắt các tập dữ liệu lớn trên nhiều chiều

B. Để xác định các ngoại lệ trong dữ liệu

C. Để dự đoán xu hướng trong tương lai

D. Để phân loại dữ liệu thành các danh mục

Câu 122: Đâu là một ví dụ về phân tích hiệp hội?

A. Nhóm các đối tượng dữ liệu tương tự lại với nhau

B. Xác định các đối tượng dữ liệu không phù hợp với hành vi chung của dữ liệu

C. Tìm các mối quan hệ giữa các mục trong một tập dữ liệu, chẳng hạn như "mua (X, "máy tính") => mua (X, "webcam")"

D. Dự đoán giá trị của một biến số dựa trên các biến số khác

Câu 123: Chức năng khai phá dữ liệu nào được sử dụng để dự đoán nhãn rời rạc, không có thứ tự?

A. Hồi quy

B. Phân loại

C. Phân tích ngoại lệ

D. Phân tích cụm

Câu 124: Loại mô hình nào thường được sử dụng trong phân loại?

A. Biểu đồ hình tròn

B. Hình khối dữ liệu đa chiều

C. Mạng nơ-ron

D. Biểu đồ thanh

Câu 125: Loại chức năng khai phá dữ liệu nào được sử dụng để dự đoán các giá trị số liên tục?

A. Phân tích hiệp hội

B. Hồi quy

C. Phân tích cụm

D. Phân loại

Câu 126: Phương pháp thống kê nào được sử dụng để kiểm tra các giả thuyết bằng dữ liệu?

A. Phân tích thành phần chính (PCA)

B. Phân tích nhân tố

C. Phân tích hồi quy

D. Phân tích dữ liệu khẳng định (CDA)

Câu 127: Sự khác biệt chính giữa phân tích dữ liệu thăm dò (EDA) và phân tích dữ liệu khẳng định (CDA) là gì?

A. CDA được sử dụng để kiểm tra các giả thuyết, trong khi EDA được sử dụng để tạo ra các giả thuyết

B. EDA được sử dụng cho các tập dữ liệu nhỏ, trong khi CDA được sử dụng cho các tập dữ liệu lớn

C. EDA được sử dụng để kiểm tra các giả thuyết, trong khi CDA được sử dụng để tạo ra các giả thuyết

D. CDA được sử dụng cho dữ liệu một chiều, trong khi EDA được sử dụng cho dữ liệu đa chiều

Câu 128: Loại học máy nào liên quan đến việc học hỏi từ phản hồi dưới dạng phần thưởng hoặc hình phạt?

A. Học có giám sát

B. Học bán giám sát

C. Học tăng cường

D. Học không giám sát

Câu 129: Loại học máy nào yêu cầu dữ liệu được gắn nhãn để đào tạo?

A. Học có giám sát

B. Học tăng cường

C. Học không giám sát

D. Tất cả những điều trên

Câu 130: Ứng dụng nào sau đây không phải là một ứng dụng phổ biến của khai phá dữ liệu?

A. Nguồn nhân lực

B. Tiếp thị

C. Thiết kế thời trang

D. Tài chính

Câu 131: Loại phân tích nào liên quan đến việc xác định các hành động tốt nhất để đạt được một kết quả cụ thể?

A. Phân tích mô tả

B. Phân tích chẩn đoán

C. Phân tích dự đoán

D. Phân tích quy định

Câu 132: Loại phân tích nào tập trung vào việc hiểu điều gì đã xảy ra trong quá khứ?

A. Phân tích quy định

B. Phân tích chẩn đoán

C. Phân tích dự đoán

D. Phân tích mô tả

Câu 133: Loại phân tích nào tập trung vào việc dự đoán điều gì có thể xảy ra trong tương lai?

A. Phân tích mô tả

B. Phân tích quy định

C. Phân tích dự đoán

D. Phân tích chẩn đoán

Câu 134: "Dữ liệu" ban đầu là số nhiều của từ nào?

A. Điểm dữ liệu

B. Tri thức

C. Datum

D. Thông tin

Câu 135: Điều gì thể hiện một tập hợp các điểm dữ liệu?

A. Một datum duy nhất

B. Một tập dữ liệu

C. Thông tin

D. Một điểm dữ liệu

Câu 136: Lĩnh vực nào không hội tụ để tạo thành khai phá dữ liệu?

A. Học máy

B. Vật lý lượng tử

C. Công nghệ cơ sở dữ liệu

D. Thống kê

Câu 137: Mục tiêu của khai phá dữ liệu là gì?

A. Để tạo báo cáo trực quan

B. Để thu thập dữ liệu từ nhiều nguồn

C. Để lưu trữ lượng lớn dữ liệu

D. Để trích xuất các mẫu, mô hình và kiến thức từ các tập dữ liệu lớn

Câu 138: Điều nào sau đây là một ví dụ về một nhiệm vụ khai phá dữ liệu?

A. Tạo bản sao lưu dữ liệu

B. Thiết kế giao diện người dùng

C. Quản lý cơ sở dữ liệu

D. Phân tích dữ liệu khách hàng để xác định xu hướng

Câu 139: Sự khác biệt giữa thông tin và kiến thức là gì?

A. Thông tin là dữ liệu thô, trong khi kiến thức là dữ liệu đã qua xử lý

B. Thông tin và kiến thức là những điều giống nhau

C. Thông tin là dữ liệu đã qua xử lý, trong khi kiến thức là sự hiểu biết có được từ thông tin

D. Thông tin là dự đoán, trong khi kiến thức là mô tả

Câu 140: Một công cụ tìm kiếm sử dụng khai phá dữ liệu như thế nào?

A. Để mã hóa dữ liệu

B. Để tạo đồ họa

C. Để nhận các truy vấn làm giao dịch và khám phá nhu cầu thông tin của người dùng

D. Để quản lý cơ sở dữ liệu

Câu 141: Vai trò của thống kê trong khai phá dữ liệu là gì?

A. Tất cả những điều trên

B. Để cung cấp các phương pháp phân tích dữ liệu

C. Để tạo mô hình dữ liệu

D. Để phân tích đồng thời mối quan hệ của nhiều biến ngẫu nhiên

Câu 142: Điều gì hỗ trợ khai phá dữ liệu đa chiều?

A. Một hình ảnh đa phương tiện

B. Một hình khối dữ liệu

C. Một tài liệu văn bản

D. Một tập dữ liệu phẳng

Câu 143: Điều nào không được coi là định dạng dữ liệu điển hình cho khai phá dữ liệu?

A. Cơ sở dữ liệu quan hệ

B. Dữ liệu văn bản

C. Bảng dữ liệu phẳng

D. Bản nhạc

Câu 144: Phương pháp khai phá dữ liệu nào được sử dụng để xác định các nhóm khách hàng có hành vi mua hàng tương tự?

A. Hồi quy

B. Phân tích hiệp hội

C. Phân loại

D. Phân tích cụm

Câu 145: Điều nào sau đây không phải là một ví dụ về mẫu thường xuyên?

A. Các mẫu thời tiết bất thường

B. Các trang web thường xuyên được truy cập cùng nhau

C. Các mục được mua cùng nhau thường xuyên

D. Các trình tự sự kiện thường xuyên xảy ra

Câu 146: Khai phá dữ liệu có thể được sử dụng để làm gì trong lĩnh vực tài chính?

A. Để quản lý cơ sở dữ liệu

B. Để tạo bản sao lưu dữ liệu

C. Để dự đoán xu hướng thị trường

D. Để thiết kế giao diện người dùng

Câu 147: Vai trò của công nghệ cơ sở dữ liệu trong khai phá dữ liệu là gì?

A. Để cung cấp các công cụ để lưu trữ và quản lý các tập dữ liệu lớn

B. Để phân tích dữ liệu

C. Để thu thập dữ liệu từ nhiều nguồn

D. Để tạo báo cáo trực quan

Câu 148: Khai phá dữ liệu được sử dụng để làm gì trong lĩnh vực tiếp thị?

A. Để quản lý cơ sở dữ liệu

B. Để tạo bản sao lưu dữ liệu

C. Để xác định khách hàng mục tiêu

D. Để thiết kế giao diện người dùng

Câu 149: Điều nào sau đây không phải là một loại dữ liệu có thể được khai thác?

A. Ý kiến

B. Dữ liệu văn bản

C. Dữ liệu web

D. Dữ liệu đa phương tiện

Câu 150: Phân tích ngoại lệ có thể hữu ích trong lĩnh vực nào khác ngoài phát hiện gian lận?

A. Phân tích sự kiện hiếm gặp

B. Phân nhóm các đối tượng dữ liệu tương tự

C. Tóm tắt dữ liệu lớn trên nhiều chiều

D. Tạo một mô hình phân biệt giữa các lớp dữ liệu khác nhau

Câu 151: Mục đích của việc sử dụng mạng nơ-ron trong khai phá dữ liệu là gì?

A. Để lưu trữ dữ liệu

B. Để mô hình hóa các mối quan hệ phức tạp giữa dữ liệu

C. Để tạo báo cáo trực quan

D. Để thu thập dữ liệu từ nhiều nguồn

Câu 152: Sự khác biệt giữa "dự đoán" và "phân loại" trong khai phá dữ liệu là gì?

A. Phân loại được sử dụng để dự đoán các nhãn danh mục, trong khi dự đoán được sử dụng để dự đoán các giá trị số liên tục

B. Dự đoán và phân loại là những điều giống nhau

C. Dự đoán được sử dụng để nhóm các đối tượng dữ liệu tương tự, trong khi phân loại được sử dụng để xác định các ngoại lệ

D. Dự đoán được sử dụng để dự đoán các nhãn danh mục, trong khi phân loại được sử dụng để dự đoán các giá trị số liên tục

Câu 153: Mẫu là gì trong khai phá dữ liệu?

A. Sự thể hiện kiến thức được khám phá từ dữ liệu

B. Một công cụ để trực quan hóa dữ liệu

C. Một tập hợp các dữ liệu

D. Phương pháp lưu trữ dữ liệu

Câu 154: Sự khác biệt chính giữa phân tích dữ liệu và khai phá dữ liệu là gì?

A. Không có sự khác biệt giữa phân tích dữ liệu và khai phá dữ liệu

B. Khai phá dữ liệu liên quan đến việc sử dụng các công cụ để phân tích dữ liệu, trong khi phân tích dữ liệu liên quan đến việc khám phá các mẫu và kiến thức từ các tập dữ liệu lớn

C. Phân tích dữ liệu được sử dụng để dự đoán xu hướng trong tương lai, trong khi khai phá dữ liệu được sử dụng để mô tả dữ liệu trong quá khứ

D. Phân tích dữ liệu liên quan đến việc sử dụng các công cụ để phân tích dữ liệu, trong khi khai phá dữ liệu liên quan đến việc khám phá các mẫu và kiến thức từ các tập dữ liệu lớn

Câu 155: Trong quy trình KDD, bước nào thường là bước đầu tiên?

A. Khai phá dữ liệu.

B. Biểu diễn tri thức.

C. Lựa chọn dữ liệu.

D. Làm sạch dữ liệu.

Câu 156: CRISP-DM là viết tắt của cụm từ nào?

A. Central Industrial Standard Process for Data Mining.

B. Cross-Information System Process for Data Mining.

C. Cross-Industry Standard Process for Data Mining.

D. Cross-Industry Standard Programming for Data Mining.

Câu 157: "Siêu dữ liệu" được gọi là gì trong tiếng Anh?

A. Big Data.

B. Master Data.

C. Raw Data.

D. Metadata.

Câu 158: Hệ thống OLAP tập trung vào yếu tố nào?

A. Hiệu suất ghi.

B. Dữ liệu hiện tại duy nhất.

C. Tốc độ giao dịch Milli giây.

D. Thông tin và Insight.

Câu 159: Thuật toán PCA là viết tắt của:

A. Principal Central Analysis.

B. Primary Component Analysis.

C. Principal Component Analysis.

D. Private Component Analysis.

Câu 160: Z-score còn được gọi là gì?

A. Điểm trung bình.

B. Điểm ngoại lệ.

C. Điểm tiêu chuẩn.

D. Điểm xác suất.

Câu 161: Một giá trị Z-score bằng 0 có nghĩa là:

A. Giá trị đó thấp hơn trung bình.

B. Giá trị đó là lỗi.

C. Giá trị đó đúng bằng giá trị trung bình.

D. Giá trị đó cao hơn trung bình.

Câu 162: Kỹ thuật SMOTE dùng để xử lý vấn đề gì?

A. Dữ liệu thiếu.

B. Dữ liệu nhiễu.

C. Dữ liệu dư thừa.

D. Mất cân bằng dữ liệu.

Câu 163: SMOTE tạo ra các mẫu dữ liệu mới theo cơ chế nào?

A. Sao chép lại mẫu cũ.

B. Chỉnh sửa nhãn dữ liệu.

C. Xóa bỏ lớp đa số.

D. Tổng hợp mẫu nhân tạo dựa trên láng giềng.

Câu 164: Interaction Feature là kỹ thuật tạo ra biến mới bằng cách:

A. Kết hợp hai hoặc nhiều đặc trưng hiện có.

B. Chia dữ liệu thành các thùng.

C. Xóa các biến có độ tương quan thấp.

D. Chuẩn hóa dữ liệu về 0 và 1.

Câu 165: Feature Selection là quá trình:

A. Biến đổi dữ liệu sang không gian mới.

B. Tạo ra các biến trừu tượng PC1, PC2.

C. Giữ lại các đặc trưng quan trọng nhất và loại bỏ biến thừa.

D. Nén dữ liệu.

Câu 166: Luật kết hợp thường có cấu trúc dạng nào?

A. X + Y.

B. X $\subseteq$ Y.

C. X = Y.

D. X $\Rightarrow$ Y.

Câu 167: Support (X $\Rightarrow$ Y) đo lường điều gì?

A. Độ tin cậy của luật.

B. Tần suất xuất hiện của tập hợp {X, Y} trong toàn bộ dữ liệu.

C. Mối quan hệ âm tính.

D. Độ mạnh của biến mục tiêu.

Câu 168: Công thức tính Confidence (X $\Rightarrow$ Y) là:

A. Support(X) / Support(Y).

B. Confidence(X $\Rightarrow$ Y) / Support(Y).

C. Support(Y) / Support(X).

D. Support(X $\cup$ Y) / Support(X).

Câu 169: Thuật toán FP-Growth sử dụng cấu trúc cây gì để nén dữ liệu?

A. B-Tree.

B. Hash-Tree.

C. FP-Tree.

D. Decision Tree.

Câu 170: Luật kết hợp âm tính dạng X $\Rightarrow$ neg Y có nghĩa là:

A. Có X thì thường không có Y.

B. Có X thường có Y.

C. Không có X thường có Y.

D. X và Y không liên quan.

Câu 171: Phân loại (Classification) là bài toán học máy loại nào?

A. Học bán giám sát.

B. Học không giám sát.

C. Học có giám sát.

D. Học tăng cường.

Câu 172: Bagging là kỹ thuật lấy mẫu ngẫu nhiên có:

A. Cắt tỉa.

B. Định danh.

C. Phân cấp.

D. Lặp lại (Bootstrap).

Câu 173: Thuật toán Random Forest tính Feature Importance dựa trên chỉ số nào?

A. Support.

B. Mean Decrease Impurity (MDI).

C. Silhouette Score.

D. Z-score.

Câu 174: Logistic Regression sử dụng hàm nào để nén đầu ra về khoảng?

A. Hàm ReLU.

B. Hàm Tuyến tính.

C. Hàm Softmax.

D. Hàm Sigmoid.

Câu 175: Trong K-means, tâm cụm được gọi là:

A. Core point.

B. Mean point.

C. Border point.

D. Centroid.

Câu 176: Biến thể SGD trong Gradient Descent tính toán dựa trên:

A. Toàn bộ dữ liệu.

B. Duy nhất 1 mẫu ngẫu nhiên.

C. Một nhóm nhỏ (Mini-batch).

D. Các điểm lân cận.

Câu 177: Công thức tính kích thước output feature map trong CNN là:

A. (I + F)/S.

B. I - F + S.

C. (I - F + 2P)/S + 1.

D. (I + 2P)/S.

Câu 178: Vấn đề "triệt tiêu đạo hàm" (Vanishing Gradient) xảy ra khi gradient tiến về:

A. 1.

B. $+\infty$.

C. 0.

D. -1.

Câu 179: Thuật toán Mean Shift tìm kiếm yếu tố nào của hàm mật độ?

A. Giá trị trung bình.

B. Điểm ngoại lệ.

C. Đỉnh (mode).

D. Khoảng cách ngắn nhất.

Câu 180: Tại sao quy trình CRISP-DM lại được mô tả là một vòng lặp?

A. Vì kết quả một giai đoạn có thể yêu cầu quay lại bước trước đó (ví dụ từ Modeling quay lại Data Preparation).

B. Vì nó không bao giờ kết thúc.

C. Vì nó chỉ thực hiện một lần duy nhất.

D. Vì mục tiêu kinh doanh luôn thay đổi mỗi ngày.

Câu 181: Tại sao doanh nghiệp cần tích hợp dữ liệu (Data Integration)?

A. Để tăng dung lượng lưu trữ.

B. Để dữ liệu khó truy cập hơn.

C. Để xóa bỏ rào cản dữ liệu (Data Silos) và có cái nhìn toàn diện.

D. Để thay thế toàn bộ nhân viên kế toán.

Câu 182: So sánh ETL và ELT, ELT ưu tiên sử dụng trong trường hợp nào?

A. Hệ thống phân tích truyền thống.

B. Khi không có sức mạnh tính toán ở đích.

C. Dữ liệu lớn (Big Data) và các hệ thống Cloud hiện đại.

D. Khi dữ liệu cần được làm sạch 100% trước khi nạp.

Câu 183: Tại sao PCA lại giúp tăng tốc độ huấn luyện mô hình?

A. Vì nó tạo ra thêm nhiều đặc trưng mới.

B. Vì nó nén dữ liệu và giảm số chiều nhưng vẫn giữ lại tối đa thông tin quan trọng.

C. Vì nó xóa bỏ hoàn toàn dữ liệu.

D. Vì nó không dùng phép biến đổi tuyến tính.

Câu 184: Tại sao không nên áp dụng SMOTE lên toàn bộ dữ liệu trước khi chia Train/Test?

A. Vì nó làm máy chạy chậm.

B. Vì gây rò rỉ thông tin từ tập Test vào Train, khiến kết quả đánh giá không thực tế.

C. Vì SMOTE chỉ dùng cho tập Test.

D. Vì tập Test không cần dữ liệu nhân tạo.

Câu 185: Tại sao Target Encoding có rủi ro Overfitting cao?

A. Vì nó không dùng giá trị số.

B. Vì mô hình có thể "học thuộc lòng" giá trị mục tiêu thông qua biến đã được encode.

C. Vì nó làm tăng số lượng cột thưa thớt.

D. Vì nó chỉ áp dụng cho ID sản phẩm.

Câu 186: Ý nghĩa của "Luật dư thừa" trong khai thác đa cấp là gì?

A. Luật có độ hỗ trợ quá thấp.

B. Luật ở tầng dưới không cung cấp thêm kiến thức mới so với luật ở tầng trên.

C. Luật bị lỗi định dạng.

D. Luật có Lift < 1.

Câu 187: Log Loss phạt nặng nhất trường hợp nào?

A. Dự đoán đúng 100%.

B. Dự đoán xác suất thấp cho một nhãn đúng thực tế (ví dụ thực tế là 1 nhưng đoán gần 0).

C. Dự đoán xác suất 0.5 cho mọi trường hợp.

D. Khi không có dữ liệu nhiễu.

Câu 188: Tại sao OPTICS được coi là bản cải tiến của DBSCAN?

A. Vì nó chạy nhanh hơn.

B. Vì nó xử lý tốt dữ liệu có mật độ khác nhau giữa các vùng.

C. Vì nó không cần tham số MinPts.

D. Vì nó luôn cho ra các cụm hình cầu.

Câu 189: Tại sao Gradient Descent cần một Learning Rate hợp lý?

A. Nếu quá lớn sẽ nhảy quá đà, nếu quá nhỏ sẽ hội tụ cực chậm.

B. Để triệt tiêu hoàn toàn đạo hàm.

C. Để hàm mất mát luôn bằng 0.

D. Để không phải tính đạo hàm.

Câu 190: Tại sao ReLU được ưu tiên hơn Sigmoid trong các mạng nơ-ron sâu?

A. Vì ReLU có hình dạng cong.

B. Vì đạo hàm của ReLU bằng 1 cho phần dương, giúp giảm thiểu hiện tượng triệt tiêu đạo hàm.

C. Vì ReLU nén dữ liệu tốt hơn.

D. Vì Sigmoid quá phức tạp để tính toán.

Câu 191: Sự khác biệt giữa Batch Processing và Stream Processing về mặt dữ liệu là:

A. Batch xử lý dữ liệu đang di chuyển.

B. Batch xử lý dữ liệu tĩnh (tại chỗ); Stream xử lý dữ liệu đang di chuyển (thời gian thực).

C. Stream xử lý dữ liệu theo lô lớn định kỳ.

D. Batch có độ trễ milli giây.

Câu 192: Phân cụm phổ (Spectral Clustering) dựa trên lý thuyết nào?

A. Lý thuyết xác suất.

B. Lý thuyết hỗn loạn.

C. Lý thuyết đồ thị và trị riêng.

D. Lý thuyết trò chơi.

Câu 193: Tại sao mô hình Naive Bayes lại có từ "Naive" (Ngây thơ)?

A. Vì thuật toán này không hiệu quả.

B. Vì nó không sử dụng toán học.

C. Vì nó chỉ dành cho người mới bắt đầu.

D. Vì nó giả định một cách ngây thơ rằng các đặc trưng hoàn toàn độc lập với nhau.

Câu 194: Khi nào ta nên sử dụng thuật toán k-NN?

A. Khi có hàng tỷ bản ghi dữ liệu.

B. Khi tập dữ liệu nhỏ và các lớp có ranh giới quyết định rõ ràng .

C. Khi muốn mô hình chạy cực nhanh lúc dự báo.

D. Khi không có tài nguyên bộ nhớ.

Câu 195: Ý nghĩa của "Early Stopping" trong huấn luyện mô hình là:

A. Dừng khi máy tính bị nóng.

B. Dừng khi đã đạt đủ 1000 epoch.

C. Dừng huấn luyện khi sai số trên tập validation bắt đầu tăng để tránh Overfitting.

D. Dừng khi độ chính xác đạt 100%.

Câu 196: Tại sao Feature Extraction (như PCA) làm mất đi khả năng giải thích của biến?

A. Vì nó xóa tên các cột.

B. Vì các biến mới thu được là tổ hợp toán học của nhiều biến cũ, không còn ý nghĩa vật lý ban đầu.

C. Vì nó làm tăng phương sai.

D. Vì nó chỉ áp dụng cho dữ liệu phi cấu trúc.

Câu 197: Ý nghĩa của tham số k lẻ trong k-NN là gì?

A. Để tránh tình trạng hòa khi biểu quyết phân lớp.

B. Để thuật toán chạy nhanh hơn.

C. Để lấy được nhiều láng giềng hơn.

D. Để giảm thiểu nhiễu.

Câu 198: Tại sao trong mô hình hồi quy, Mean Squared Error (MSE) lại nhạy cảm với ngoại lai?

A. Vì sai số được bình phương lên, khiến các sai số lớn từ điểm ngoại lệ bị phóng đại rất nhiều .

B. Vì nó tính căn bậc hai.

C. Vì nó luôn cho kết quả dương.

D. Vì nó chỉ dùng cho dữ liệu nhỏ.

Câu 199: Ý nghĩa của "Reduced Support" trong luật đa cấp là:

A. Tăng support ở tầng thấp.

B. Xóa các luật ở tầng cao.

C. Giữ nguyên support cho mọi cấp độ.

D. Giảm ngưỡng min_sup khi xuống các tầng chi tiết hơn để không bỏ lỡ các quy luật có giá trị.

Câu 200: Tại sao trong phân cụm phân cấp, Dendrogram lại hữu ích?

A. Để nén dữ liệu.

B. Để tính toán khoảng cách Euclidean.

C. Để thay thế cho K-means.

D. Để trực quan hóa toàn bộ quá trình hợp nhất và giúp chọn số lượng cụm phù hợp bằng cách "cắt" cây.

Câu 201: Quy trình KDD (Knowledge Discovery in Databases) bao gồm bao nhiêu bước chính:

A. 4 bước chính (Plan, Do, Check, Act)

B. 6 bước chính (theo mô hình CRISP-DM)

C. 5 bước chính (Selection, Preprocessing, Transformation, Data Mining, Evaluation)

D. 3 bước chính (Extract, Transform, Load)

Câu 202: Đặc điểm quan trọng nhất của quy trình CRISP-DM là

A. Là quy trình tự động hóa hoàn toàn 100% không cần sự can thiệp của chuyên gia

B. Là quy trình chỉ áp dụng độc quyền cho các bài toán phân tích tài chính ngân hàng

C. Là một vòng lặp (cycle) có tính thích nghi và lặp lại liên tục giữa các bước

D. Là quy trình tuyến tính một chiều nghiêm ngặt (Waterfall) không thể quay lại

Câu 203: Câu hỏi nào thường được đặt ra trong giai đoạn “Thấu hiểu kinh doanh”

A. "Chúng ta đang thực sự cố gắng giải quyết vấn đề kinh doanh gì?"

B. "Thuật toán nào sẽ tối ưu hóa chỉ số F1-score lên 99%?"

C. "Nên cấu hình cụm máy chủ phân tán bao nhiêu Gigabyte RAM?"

D. "Cơ sở dữ liệu này có bao nhiêu bản ghi bị thiếu giá trị?"

Câu 204: Tại sao kết thúc 1 dự án khai phá dữ liệu thường bắt đầu 1 chu kỳ CRISP-DM mới

A. Vì các thuật toán khai phá dữ liệu luôn bị hết hạn sử dụng sau mỗi dự án

B. Vì quy chuẩn CRISP-DM bắt buộc mỗi dự án chỉ được kéo dài tối đa 30 ngày

C. Vì cơ sở dữ liệu bắt buộc phải bị xóa sạch và cài đặt lại từ đầu

D. Vì việc giải quyết xong một bài toán thường làm nảy sinh các câu hỏi và cơ hội kinh doanh mới

Câu 205: Đặc điểm “Lấy kinh doanh làm trung tâm” trong CRISP-DM có nghĩa là

A. Chỉ có nhân viên phòng kinh doanh mới được phép tham gia vào dự án khai phá

B. Mọi bước đi và quyết định kỹ thuật trong quy trình đều phải phục vụ trực tiếp cho mục tiêu kinh doanh

C. Doanh nghiệp phải mua các phần mềm thương mại đắt tiền nhất thị trường

D. Mọi dự án khai phá dữ liệu đều phải sinh ra lợi nhuận ngay trong tuần đầu tiên

Câu 206: Thuộc tính nhị phân bất đối xứng là thuộc tính mà

A. Hai kết quả nhị phân có xác suất xuất hiện hoàn toàn bằng nhau (50% - 50%)

B. Hai kết quả nhị phân được mã hóa bằng chuỗi văn bản thay vì số nguyên 0 và 1

C. Thuộc tính nhị phân có thể nhận thêm giá trị thứ ba trong trường hợp ngoại lệ

D. Hai kết quả nhị phân (0 và 1) không có tầm quan trọng tương đương nhau (ví dụ: kết quả xét nghiệm bệnh)

Câu 207: Thuộc tính rời rạc (discrete) có đặc điểm gì

A. Chỉ có thể nhận một tập hữu hạn các giá trị hoặc tập đếm được (vô hạn đếm được)

B. Không thể biểu diễn hoặc lưu trữ được trong các hệ thống máy tính điện tử

C. Có thể nhận vô số giá trị liên tục không đếm được trên trục số thực

D. Luôn luôn bắt buộc phải là các giá trị số âm nhỏ hơn 0

Câu 208: Thang đo tỷ lệ (ratio scaled) có đặc điểm nổi bật nào

A. Không thể thực hiện bất kỳ phép toán so sánh hơn kém hay tính toán số học nào

B. Chỉ dùng để biểu diễn các biến danh mục định tính không có giá trị số

C. Có điểm 0 tuyệt đối mang ý nghĩa tự nhiên (vốn có) thể hiện sự vắng mặt hoàn toàn của đại lượng đo

D. Giá trị điểm 0 chỉ là một mốc quy ước tùy ý của con người (như nhiệt độ độ C)

Câu 209: Trong kỹ thuật phân thùng, làm mượt theo ranh giới (bin boundaries) nghĩa là

A. Loại bỏ hoàn toàn toàn bộ thùng đó ra khỏi tập dữ liệu phân tích

B. Thay thế mọi giá trị trong thùng bằng số 0 tuyệt đối

C. Thay thế mỗi giá trị bằng giá trị trung bình cộng của toàn bộ thùng

D. Thay thế mỗi giá trị trong thùng bằng giá trị biên (cực tiểu hoặc cực đại) gần với nó nhất

Câu 210: Tại sao dữ liệu thực tế cần tiền xử lý

A. Vì các quy định pháp luật bắt buộc mọi tệp dữ liệu phải giảm dung lượng 50%

B. Vì dữ liệu trong đời thực luôn bị thiếu sót, chứa nhiều nhiễu, sai lệch và không nhất quán

C. Vì tiền xử lý dữ liệu sẽ tự động tạo ra thêm hàng triệu bản ghi mới cho doanh nghiệp

D. Vì các thuật toán học máy chỉ có thể đọc được dữ liệu nếu đã bị xáo trộn thứ tự

Câu 211: Điểm yếu của phương pháp min-max là

A. Không thể đưa các giá trị về đoạn chuẩn hóa [0, 1]

B. Rất nhạy cảm với các giá trị ngoại lệ (Outliers) vì phụ thuộc hoàn toàn vào hai điểm cực trị Min và Max

C. Đòi hỏi chi phí tính toán đạo hàm vi phân quá phức tạp

D. Làm thay đổi hoàn toàn phân phối tương đối giữa các điểm dữ liệu

Câu 212: Trong bài toán phân cụm, tại sao cần thực hiện chuẩn hóa dữ liệu (scaling)

A. Điểm dữ liệu đó là một giá trị ngoại lệ cực đoan cần phải loại bỏ ngay

B. Điểm dữ liệu đó có giá trị đúng bằng giá trị trung bình cộng của toàn bộ tập dữ liệu

C. Điểm dữ liệu đó nằm cách giá trị trung bình một khoảng đúng bằng 1 độ lệch chuẩn

D. Điểm dữ liệu đó bị lỗi dữ liệu khuyết thiếu (Null value)

Câu 213: Lợi ích của việc rời rạc hóa dữ liệu

A. Kỹ thuật thiết lập chỉ mục cây B+ trong hệ quản trị CSDL quan hệ

B. Kỹ thuật mã hóa mật mã khóa công khai RSA 2048-bit

C. Kỹ thuật lập trình hướng đối tượng trong ngôn ngữ Java

D. Các kỹ thuật phát hiện và phân tích ngoại lai (Outlier Detection / Clustering-based detection)

Câu 214: Sự khác biệt giữa thuộc tính nhị phân đối xứng và bất đối xứng là gì

A. Khoảng biến thiên của dữ liệu từ giá trị nhỏ nhất (Min) đến giá trị lớn nhất (Max): $Range = Max - Min$

B. Khoảng cách giữa phân vị thứ nhất và phân vị thứ ba ($IQR = Q_3 - Q_1$)

C. Số lượng các thuộc tính độc lập có trong bảng cơ sở dữ liệu

D. Giá trị trung bình cộng của các độ lệch tuyệt đối so với trung vị

Câu 215: Trong kỹ thuật phân thùng, nếu chia quá ít thùng sẽ dẫn đến hậu quả gì

A. Tỷ số giữa độ lệch chuẩn và giá trị trung bình cộng

B. Khoảng cách giữa tứ phân vị thứ ba và tứ phân vị thứ nhất: $IQR = Q_3 - Q_1$

C. Căn bậc hai của phương sai mẫu dữ liệu quan sát

D. Hiệu số giữa giá trị lớn nhất và giá trị nhỏ nhất của tập dữ liệu

Câu 216: Phương pháp Feature Selection khác PCA ở chỗ nào

A. Gồm 5 giá trị: Cực tiểu (Min), Tứ phân vị thứ nhất (Q1), Trung vị (Median/Q2), Tứ phân vị thứ ba (Q3) và Cực đại (Max)

B. Gồm 5 giá trị: Support, Confidence, Lift, Leverage và Conviction

C. Gồm 5 giá trị: Trung bình, Phương sai, Độ lệch chuẩn, Độ xiên và Độ nhọn

D. Gồm 5 giá trị: Số mẫu, Số biến, Số lượng null, Số lượng ngoại lệ và Thời gian đo

Câu 217: Cho thuộc tính "Nhiệt độ Kelvin". Đây là kiểu thuộc tính nào

A. Chiếu dữ liệu đa chiều lên một mặt phẳng 2D hoặc 3D sao cho khoảng cách giữa các điểm trên không gian mới phản ánh sát nhất sự tương đồng/khác biệt gốc

B. Nhân đôi số lượng chiều thuộc tính bằng cách thêm các biến số ngẫu nhiên

C. Mã hóa các thuộc tính thành các khối mã nhị phân để bảo mật đường truyền

D. Chuyển đổi toàn bộ các biến số thành các phép toán logic Boolean True/False

Câu 218: Mục tiêu chính của khai phá luật kết hợp

A. Loại bỏ các giao dịch có số lượng mặt hàng ít hơn 3 món

B. Sinh ra toàn bộ các luật kết hợp có thể từ tập dữ liệu thô ban đầu

C. Tìm kiếm tất cả các tập mục phổ biến (Frequent Itemsets) có độ hỗ trợ lớn hơn hoặc bằng ngưỡng tối thiểu min_sup

D. Tính toán ma trận hiệp phương sai giữa tất cả các thuộc tính số

Câu 219: Độ hỗ trợ của luật A-> B đươợc tính bằng

A. Một tập mục chỉ chứa duy nhất các mặt hàng bán ế không ai mua

B. Một tập mục có độ hỗ trợ đạt chính xác 100% trên toàn bộ cơ sở dữ liệu

C. Một tập mục phổ biến mà không có bất kỳ tập cha trực tiếp nào của nó có cùng độ hỗ trợ (support count) với nó

D. Một tập mục không chứa bất kỳ tập con nào khác bên trong nó

Câu 220: Bước nối (Join step) trong thủ tục Apriori-gen thực hiện việc gì

A. Tập ứng viên C_k được sinh ra ngẫu nhiên bằng cách bốc thăm các mặt hàng trong kho

B. Tập ứng viên C_k chỉ được tạo ra sau khi đã quét qua CSDL 10 lần liên tiếp

C. Tập ứng viên C_k được tạo ra bằng cách nhân đôi tập mục phổ biến L_1

D. Tập hợp các ứng viên độ dài k có thể được sinh ra bằng cách kết nối (join) hai tập mục phổ biến độ dài (k-1) có chung (k-2) mục đầu tiên

Câu 221: Cấu trúc dữ liệu nào thường được sử dụng để chứa tập ứng viên nhằm đếm độ hỗ trợ hiệu quả

A. Loại bỏ ngay ứng viên c nếu tồn tại bất kỳ một tập con độ dài (k-1) nào của c không nằm trong tập phổ biến L_(k-1)

B. Loại bỏ các giao dịch có độ dài ngắn hơn k ra khỏi cơ sở dữ liệu

C. Chỉ giữ lại các ứng viên có tên bắt đầu bằng chữ cái 'A'

D. Loại bỏ tất cả các mặt hàng có giá bán nhỏ hơn 10.000 đồng

Câu 222: Một trong những thách thức lớn nhất của giải thuật Apriori là

A. Bắt buộc phải mã hóa toàn bộ dữ liệu thành hình ảnh đa phương tiện

B. Chỉ có thể khai phá được dữ liệu nếu số giao dịch nhỏ hơn 10

C. Phải quét duyệt cơ sở dữ liệu nhiều lần và số lượng tập ứng viên sinh ra quá khổng lồ

D. Không thể chạy được trên các hệ điều hành 64-bit hiện đại

Câu 223: Phương pháp DIC (Dynamic Itemset Counting) giúp cải tiến Apriori ở điểm nào

A. Chuyển đổi toàn bộ cơ sở dữ liệu giao dịch thành dữ liệu dạng ảnh

B. Xóa bỏ hoàn toàn bước tính toán độ tin cậy Confidence của các luật

C. Tự động tăng ngưỡng min_sup lên 100% để không sinh ứng viên

D. Giảm số lần quét duyệt cơ sở dữ liệu bằng cách đếm các tập mục có độ dài khác nhau trong cùng một lượt quét

Câu 224: Cấu trúc dữ liệu chính trong giải thuật FP-Growth là

A. Cây bao trùm nhỏ nhất (Minimum Spanning Tree)

B. Cây mẫu phổ biến (FP-tree - Frequent Pattern Tree)

C. Cây phân loại C4.5 (C4.5 Decision Tree)

D. Cây nhị phân tìm kiếm (Binary Search Tree)

Câu 225: Bước đầu tiên trong xây dựng FP-tree là

A. Quét CSDL lần 1 để đếm tần suất các 1-mục, lọc các mục phổ biến và sắp xếp theo tần suất giảm dần (F-list)

B. Quét toàn bộ CSDL và xóa sạch các giao dịch có độ dài lớn hơn 5

C. Vẽ ngay các nhánh cây cho mọi giao dịch mà không cần kiểm tra tần suất

D. Mã hóa toàn bộ các mặt hàng thành các số thực ngẫu nhiên trong khoảng 0-1

Câu 226: Lợi ích của tính cô đọng (compactness) trong FP-tree là

A. Làm tăng kích thước dữ liệu lên gấp 10 lần để đảm bảo an toàn lưu trữ

B. Chuyển đổi toàn bộ dữ liệu thành một số nguyên duy nhất

C. Loại bỏ hoàn toàn các mục không phổ biến và kích thước cây thường nhỏ hơn rất nhiều so với CSDL gốc

D. Tự động xóa sạch các giao dịch quan trọng của khách hàng VIP

Câu 227: Khi một FP-tree chỉ có một đường dẫn tiền tố duy nhất (single preflix path), việc khai phá có thể

A. Chỉ giữ lại duy nhất 1 mục ở ngọn cây và xóa bỏ toàn bộ thân cây

B. Bắt buộc phải dừng thuật toán ngay lập tức và báo lỗi hệ thống

C. Phải quay lại quét lại toàn bộ cơ sở dữ liệu gốc từ đầu

D. Được sinh ra trực tiếp bằng tổ hợp tất cả các tập con của đường dẫn đó mà không cần đệ quy phức tạp

Câu 228: Kết quả cuối cùng của quá trình khai phá trên các FP-tree điều kiện là gì

A. Một biểu đồ phân cụm Dendrogram hoàn chỉnh

B. Một ma trận nhầm lẫn gồm 4 chỉ số TP, FP, TN, FN

C. Tất cả các tập mục phổ biến (Frequent Itemsets) thỏa mãn ngưỡng min_sup

D. Chỉ có duy nhất 1 luật kết hợp có độ tin cậy cao nhất

Câu 229: Thư viện Python nào thường được dùng để minh họa khai phá luật kết hợp

A. Pygame (thư viện chuyên lập trình trò chơi 2D)

B. Django (framework chuyên xây dựng ứng dụng web)

C. Matplotlib (thư viện chuyên vẽ đồ thị 2D)

D. Mlxtend (Machine Learning Extensions) hoặc thư viện apyori / arulespy

Câu 230: Nguyên lý tỉa của thuật toán Apriori (Apriori Pruning Principle) phát biểu rằng:

A. Mọi tập cha của tập phổ biến cũng phải là tập phổ biến

B. Mọi tập con không rỗng của một tập mục phổ biến đều phải là tập mục phổ biến

C. Tập mục không phổ biến luôn có ít nhất một tập con phổ biến

D. Không cần kiểm tra các tập mục có độ dài bằng 1

Câu 231: Một luật kết hợp A => B có Lift > 1 cho thấy điều gì?

A. Luật đó chắc chắn có độ tin cậy bằng 100%

B. Sự xuất hiện của A có tương quan tích cực (kích thích tăng khả năng xuất hiện) của B

C. Hai sự kiện mua A và mua B hoàn toàn độc lập với nhau

D. Độ hỗ trợ của luật rất thấp và không đáng tin cậy

Câu 232: Điểm khác biệt lớn nhất về mặt cơ chế giữa Apriori và FP-Growth là gì?

A. Apriori chỉ tìm được luật có 2 mặt hàng, FP-Growth tìm được nhiều hơn

B. Apriori sinh ứng viên và quét CSDL nhiều lần; FP-Growth nén dữ liệu vào cây FP-tree và không sinh tập ứng viên

C. Apriori tính được Lift còn FP-Growth thì không tính được

D. Apriori dùng cho dữ liệu lớn, còn FP-Growth chỉ dùng cho dữ liệu nhỏ

Câu 233: Sự khác biệt giữa 'Support count' (Tần số hỗ trợ) và 'Support' (Độ hỗ trợ) là gì?

A. Support count là số lượng giao dịch tuyệt đối chứa tập mục; Support là tỷ lệ phần trăm (xác suất) trên tổng số giao dịch

B. Support count dùng cho Apriori, còn Support dùng cho FP-Growth

C. Support count luôn luôn có giá trị nhỏ hơn 1

D. Hai khái niệm này hoàn toàn giống nhau không có điểm khác biệt

Câu 234: Một tập mục phổ biến tối đại (Maximal Frequent Itemset) được định nghĩa là:

A. Tập mục chứa tất cả các mục có mặt trong tập I

B. Tập mục có độ hỗ trợ (Support) cao nhất trong toàn bộ cơ sở dữ liệu

C. Tập mục phổ biến mà không có bất kỳ tập cha (superset) trực tiếp nào của nó là tập phổ biến

D. Tập mục chỉ xuất hiện duy nhất trong một giao dịch

Câu 235: Trong cơ sở dữ liệu trên (T100{1, 3, 4}, T200{2, 3, 5}, T300{1, 2, 3, 5}, T400{2, 5}), độ hỗ trợ (Support count) của tập mục {2, 3, 5} là bao nhiêu?

A. 4

B. 2

C. 1

D. 3

Câu 236: Với CSDL trên, tính độ tin cậy (Confidence) của luật A => C:

A. 66.7%

B. 50%

C. 100%

D. 75%

Câu 237: Cho Support(A, B) = 0.3, Support(A) = 0.5, Support(B) = 0.4. Tính Lift của luật A => B:

A. 2.0

B. 0.75

C. 1.0

D. 1.5

Câu 238: Trong FP-Growth, nếu Header Table của mục 'p' có danh sách liên kết node-link trỏ vào 3 vị trí nút khác nhau trên cây FP-tree, thuật toán sẽ xử lý như thế nào?

A. Gộp 3 nút đó thành một nút duy nhất trên cây

B. Lần theo node-link để thu thập tất cả các đường dẫn tiền tố từ cả 3 vị trí đó rồi cộng dồn số đếm của chúng vào conditional pattern base

C. Xóa bỏ nút có số đếm hỗ trợ thấp nhất để giảm độ phức tạp

D. Chỉ lấy đường dẫn tiền tố dài nhất và bỏ qua 2 đường dẫn còn lại

Câu 239: Tính độ hỗ trợ (Support) của tập mục $\{I_1, I_2, I_5\}$ trong cơ sở dữ liệu gồm 4 giao dịch: T1$\{I_1, I_2, I_5\}$, T2$\{I_1, I_2\}$, T3$\{I_1, I_2, I_5\}$, T4$\{I_2, I_5\}$:

A. 25%

B. 50%

C. 75%

D. 100%

Câu 240: Nếu một luật kết hợp Beer => Diaper có Confidence = 100%, ta có thể đưa ra kết luận chắc chắn nào về luật đảo Diaper => Beer?

A. Chưa thể kết luận được giá trị cụ thể, vì độ tin cậy của luật đảo phụ thuộc vào độ hỗ trợ của Diaper

B. Độ tin cậy của luật đảo chắc chắn cũng bằng 100%

C. Độ tin cậy của luật đảo chắc chắn luôn luôn nhỏ hơn 50%

D. Độ tin cậy của luật đảo chắc chắn bằng 0%

Câu 241: Trong giải thuật Apriori, nếu cơ sở dữ liệu có 1.000 giao dịch và một tập ứng viên có Support count = 150, với ngưỡng min_sup = 0.2 (20%), tập ứng viên này có bị loại ở bước đếm hỗ trợ không?

A. Không bị loại vì 150 là số lượng giao dịch khá lớn

B. Tùy thuộc vào số lượng mặt hàng có trong tập ứng viên đó

C. Không bị loại nếu độ tin cậy của nó đạt 100%

D. Có bị loại, vì độ hỗ trợ thực tế của nó chỉ đạt 15% (150/1000 = 0.15 < 0.2)

PHẦN II: CÂU HỎI MỞ RỘNG, THAM KHẢO & HỌC THÊM (NÂNG CAO)

Gồm 189 câu hỏi đào sâu chi tiết kỹ thuật, các biến thể thuật toán mở rộng và câu hỏi phụ trợ phục vụ nâng cao điểm số.

Câu 242: Kho dữ liệu làm gì?

A. Tích hợp dữ liệu từ nhiều nguồn và khoảng thời gian trong định dạng đa chiều

B. Lưu trữ dữ liệu trong một định dạng một chiều

C. Chỉ lưu trữ dữ liệu giao dịch

D. Chỉ lưu trữ dữ liệu văn bản

Câu 243: OLAP là gì?

A. Một phương pháp để nhập dữ liệu vào cơ sở dữ liệu

B. Một kỹ thuật để phân tích các tập dữ liệu nhỏ

C. Một kỹ thuật để xóa dữ liệu khỏi kho dữ liệu

D. Một công cụ để xử lý phân tích trực tuyến, hỗ trợ khai phá dữ liệu đa chiều

Câu 244: Khai phá dữ liệu là quá trình gì?

A. Lưu trữ dữ liệu vào kho.

B. Xóa bỏ dữ liệu cũ.

C. Khám phá tri thức hữu ích từ cơ sở dữ liệu lớn.

D. Sao chép dữ liệu từ nguồn này sang nguồn khác.

Câu 245: Giai đoạn nào thường chiếm 70-80% thời gian dự án?

A. Business Understanding.

B. Data Preparation.

C. Modeling.

D. Deployment.

Câu 246: Hoạt động EDA (khám phá dữ liệu) thuộc giai đoạn nào?

A. Data Understanding.

B. Business Understanding.

C. Modeling.

D. Deployment.

Câu 247: Phân tích mô tả tập trung vào câu hỏi chính nào?

A. Tại sao nó xảy ra?

B. Điều gì có khả năng sẽ xảy ra?

C. Điều gì đã xảy ra?.

D. Làm thế nào để nó xảy ra?

Câu 248: Phân tích dự đoán sử dụng loại dữ liệu nào để đưa ra dự báo?

A. Dữ liệu ngẫu nhiên.

B. Dữ liệu giả lập.

C. Dữ liệu lịch sử.

D. Dữ liệu hiện tại duy nhất.

Câu 249: Quy trình kết hợp dữ liệu từ nhiều nguồn khác nhau gọi là gì?

A. Data Reduction.

B. Data Cleaning.

C. Data Integration.

D. Data Transformation.

Câu 250: Phương pháp ETL là viết tắt của các bước nào?

A. End, Total, Load.

B. Entry, Transfer, List.

C. Extract, Link, Transfer.

D. Extract, Transform, Load.

Câu 251: Cơ chế "Schema-on-Write" là đặc trưng của mô hình nào?

A. Data Warehouse.

B. Data Lake.

C. Data Lakehouse.

D. NoSQL.

Câu 252: Hệ thống phục vụ các giao dịch hàng ngày liên tục được gọi là:

A. Data Warehouse.

B. OLAP.

C. OLTP.

D. Data Lakehouse.

Câu 253: Khía cạnh nào yêu cầu dữ liệu không được bị trống ở trường bắt buộc?

A. Completeness.

B. Accuracy.

C. Consistency.

D. Validity.

Câu 254: Tiêu chí nào yêu cầu giá trị "Ngày sinh" phải đúng định dạng DD/MM/YYYY?

A. Validity.

B. Completeness.

C. Accuracy.

D. Uniqueness.

Câu 255: Quy trình kiểm tra dữ liệu để phát hiện lỗi và lỗ hổng gọi là:

A. Data Profiling.

B. Data Enrichment.

C. Data Monitoring.

D. Data Cleaning.

Câu 256: Kỹ thuật mã hóa biến phân loại dựa trên mức độ phổ biến gọi là:

A. Frequency Encoding.

B. One-Hot Encoding.

C. Target Encoding.

D. Label Encoding.

Câu 257: Target Encoding còn được gọi là gì?

A. Frequency Encoding.

B. Count Encoding.

C. Mean Encoding.

D. One-Hot Encoding.

Câu 258: Nếu một tập mục là "infrequent", tất cả các tập cha của nó chắc chắn là:

A. Frequent.

B. Maximal.

C. Closed.

D. Infrequent.

Câu 259: Sequential Pattern Mining quan tâm đến yếu tố cốt lõi nào?

A. Giá cả sản phẩm.

B. Thời gian và thứ tự sự kiện.

C. Vị trí địa lý.

D. Số lượng mặt hàng.

Câu 260: Ràng buộc Monotone có đặc tính là gì?

A. Nếu S thỏa mãn thì mọi tập cha của nó cũng thỏa mãn.

B. Nếu S thỏa mãn thì tập con của nó cũng thỏa mãn.

C. Nếu S không thỏa mãn thì tập cha của nó cũng không thỏa mãn.

D. Không thể tối ưu hóa.

Câu 261: Web Usage Mining tập trung phân tích nguồn dữ liệu nào?

A. Nội dung trang web.

B. Cấu trúc liên kết.

C. Nhật ký nhật ký truy cập (log files).

D. Hình ảnh trên web.

Câu 262: Hiện tượng mô hình quá đơn giản, không học được quy luật gọi là:

A. Overfitting.

B. Scaling.

C. Convergence.

D. Underfitting.

Câu 263: SHAP values được sử dụng để:

A. Giải thích mức độ đóng góp của từng đặc trưng vào kết quả dự đoán.

B. Tăng độ chính xác mô hình.

C. Nén dữ liệu.

D. Phân cụm dữ liệu.

Câu 264: OPTICS tạo ra một biểu đồ quan trọng gọi là:

A. Dendrogram.

B. Boxplot.

C. Scatter Plot.

D. Reachability Plot.

Câu 265: Big Data đặc trưng bởi mô hình 3V gồm những gì?

A. Volume, Validity, Variety.

B. Value, Version, Volume.

C. View, Velocity, Variety.

D. Volume, Velocity, Variety.

Câu 266: Graph Neural Networks (GNN) làm việc trực tiếp với cấu trúc dữ liệu nào?

A. Hình ảnh (Grid).

B. Văn bản (Sequence).

C. Đồ thị (Graph).

D. Bảng (Table).

Câu 267: Cơ chế Message Passing trong GNN gồm 3 bước: Gom tụ, Kết hợp và:

A. Cập nhật.

B. Phân cụm.

C. Nén.

D. Xóa.

Câu 268: Cơ chế Attention giúp mô hình giải quyết vấn đề gì của RNN/LSTM?

A. Quá nhiều dữ liệu.

B. Điểm nghẽn (Bottleneck) thông tin khi xử lý chuỗi dài.

C. Tốc độ huấn luyện quá nhanh.

D. Thiếu tài nguyên bộ nhớ.

Câu 269: Trong Attention, "Key" đóng vai trò tương tự như:

A. Từ khóa tìm kiếm.

B. Kết quả dự đoán.

C. Nội dung thực tế video.

D. Tiêu đề video để so khớp.

Câu 270: Chiều của mỗi Attention head được tính bằng d_model chia cho:

A. Số lượng heads (h).

B. Độ dài chuỗi.

C. Kích thước batch.

D. Số lớp (layers).

Câu 271: Federated Learning cho phép huấn luyện mô hình mà không cần:

A. Cập nhật trọng số.

B. Kết nối các thiết bị.

C. Sử dụng mạng Internet.

D. Thu thập dữ liệu thô về máy chủ trung tâm.

Câu 272: Kỹ thuật tái sử dụng tri thức từ mô hình đã huấn luyện gọi là:

A. Active Learning.

B. Online Learning.

C. Transfer Learning.

D. Batch Learning.

Câu 273: Dropout ngẫu nhiên "tắt" các neuron trong giai đoạn nào?

A. Training.

B. Testing.

C. Deployment.

D. Inference.

Câu 274: Backpropagation sử dụng quy tắc nào trong toán học để tính đạo hàm?

A. Quy tắc cộng.

B. Quy tắc Bayes.

C. Quy tắc L'Hospital.

D. Quy tắc chuỗi (Chain Rule).

Câu 275: Hàm kích hoạt nào giúp khắc phục vấn đề Vanishing Gradient hiệu quả?

A. Sigmoid.

B. ReLU.

C. Tanh.

D. Step function.

Câu 276: Kiến trúc ResNet sử dụng kỹ thuật gì để gradient chảy trực tiếp về các lớp trước?

A. Pooling.

B. Dropout.

C. Convolution.

D. Skip-connections.

Câu 277: Exploding Gradient được xử lý bằng kỹ thuật:

A. Gradient Clipping.

B. Early Stopping.

C. Batch Normalization.

D. Pruning.

Câu 278: "Dữ liệu đang di chuyển" (Data in motion) là đặc trưng của:

A. Stream Processing.

B. Batch Processing.

C. Data Warehouse.

D. Cold Storage.

Câu 279: Sự khác biệt chính giữa Phân tích mô tả và Phân tích dự đoán là gì?

A. Dự đoán đơn giản hơn mô tả.

B. Không có sự khác biệt về giá trị kinh doanh.

C. Mô tả dùng máy học, dự đoán dùng báo cáo.

D. Mô tả tập trung vào quá khứ/hiện tại, trong khi dự đoán tập trung vào tương lai.

Câu 280: Tại sao Data Lake được gọi là "thiên đường" cho các nhà khoa học dữ liệu?

A. Vì nó rất đắt đỏ.

B. Vì nó lưu trữ dữ liệu ở định dạng thô, giúp tìm ra những quy luật ẩn mà dữ liệu bị cắt gọt không giữ được.

C. Vì nó chỉ lưu dữ liệu có cấu trúc.

D. Vì nó có hiệu suất truy vấn SQL nhanh nhất.

Câu 281: Khi nào thì Data Lake trở thành "Đầm lầy dữ liệu" (Data Swamp)?

A. Khi có quá nhiều dữ liệu có cấu trúc.

B. Khi nó được tích hợp vào Data Warehouse.

C. Khi chi phí lưu trữ quá rẻ.

D. Khi dữ liệu không được quản lý tốt, gây khó khăn trong việc tìm kiếm và sử dụng.

Câu 282: Ý nghĩa của mô hình lai Data Lakehouse là gì?

A. Chỉ dùng cho báo cáo BI.

B. Tăng số lượng hệ thống cần duy trì.

C. Thay thế hoàn toàn con người bằng AI.

D. Kết hợp khả năng lưu trữ giá rẻ của Data Lake với tính nhất quán (ACID) của Data Warehouse.

Câu 283: "Garbage In, Garbage Out" trong chất lượng dữ liệu có nghĩa là:

A. Rác sẽ biến thành vàng nếu có thuật toán tốt.

B. Dữ liệu lỗi không ảnh hưởng đến mô hình.

C. Chỉ cần nhiều dữ liệu là đủ, không cần chất lượng.

D. Dữ liệu rác đầu vào sẽ cho ra kết quả dự báo sai lệch và vô giá trị.

Câu 284: Khi nào nên dùng Median thay vì Mean để điền dữ liệu thiếu?

A. Khi dữ liệu có phân phối chuẩn.

B. Khi dữ liệu có phân phối lệch hoặc có nhiều điểm ngoại lệ (outliers).

C. Khi dữ liệu là dạng nhãn (categorical).

D. Khi muốn làm giảm phương sai của tập dữ liệu.

Câu 285: Ưu điểm của Interaction Feature so với các đặc trưng đơn lẻ là gì?

A. Nó làm mô hình đơn giản hơn.

B. Nó giảm số chiều dữ liệu.

C. Nó giúp mô hình học được các mối quan hệ phi tuyến tính phức tạp (ví dụ: diện tích kết hợp số phòng).

D. Nó chỉ áp dụng cho các mô hình dựa trên cây.

Câu 286: Feature Selection khác Feature Extraction ở điểm nào về mặt diễn giải?

A. Selection dễ giải thích hơn vì giữ nguyên ý nghĩa gốc của các biến.

B. Extraction dễ giải thích hơn.

C. Selection tạo ra các biến trừu tượng.

D. Cả hai đều không thể giải thích.

Câu 287: Tại sao khai phá dựa trên ràng buộc (Constraint-based) lại giúp tăng hiệu suất?

A. Vì nó tìm tất cả các mẫu có thể.

B. Vì nó làm tăng số lượng tập phổ biến.

C. Vì nó không cần dùng đến min_sup.

D. Vì nó loại bỏ các nhánh tìm kiếm không tiềm năng ngay từ đầu (pruning).

Câu 288: Bias cao dẫn đến hệ quả gì cho mô hình?

A. Underfitting (Mô hình quá đơn giản, bỏ lỡ đặc trưng quan trọng).

B. Overfitting.

C. Mô hình cực kỳ ổn định và chính xác.

D. Phương sai rất cao.

Câu 289: Tại sao các mô hình như Deep Learning thường được gọi là "Hộp đen"?

A. Vì chúng có màu đen trên màn hình.

B. Vì chúng không dùng dữ liệu số.

C. Vì cấu trúc cực kỳ phức tạp khiến con người khó hiểu được lý do cụ thể đằng sau một dự đoán.

D. Vì hiệu suất của chúng quá thấp.

Câu 290: Mục tiêu của IML (Interpretable Machine Learning) là gì?

A. Tăng độ phức tạp mô hình.

B. Thay thế các thuật toán Deep Learning.

C. Giúp con người hiểu và tin tưởng vào các quyết định của AI.

D. Tự động hóa việc thu thập dữ liệu.

Câu 291: Tại sao hàm Sigmoid lại cần thiết trong Logistic Regression?

A. Để nén đầu ra thành giá trị xác suất trong khoảng phù hợp cho phân loại.

B. Để tính toán nhanh hơn Linear Regression.

C. Để dự đoán giá trị số liên tục.

D. Để loại bỏ các biến phi tuyến.

Câu 292: Hiện tượng "Chaining Effect" trong Single Linkage là gì?

A. Các cụm quá xa nhau.

B. Các cụm riêng biệt bị nối lại với nhau bởi một chuỗi điểm trung gian, tạo cụm dài và mảnh.

C. Thuật toán không thể gộp cụm.

D. Cụm bị vỡ thành nhiều mảnh nhỏ.

Câu 293: Tại sao Federated Learning lại giải quyết được bài toán quyền riêng tư?

A. Vì nó không huấn luyện mô hình.

B. Vì dữ liệu cá nhân không bao giờ rời khỏi thiết bị, chỉ có bản cập nhật mô hình được gửi đi.

C. Vì nó mã hóa dữ liệu thành hình ảnh.

D. Vì nó chỉ dùng cho dữ liệu công khai.

Câu 294: Bản chất của kỹ thuật Fine-tuning trong Transfer Learning là:

A. Xây dựng lại toàn bộ mô hình từ đầu.

B. Tăng số lượng neuron trong mạng.

C. Giữ lại các lớp đặc trưng tổng quát và chỉ huấn luyện lại một vài lớp cuối cho nhiệm vụ mới.

D. Xóa bỏ các trọng số đã học được.

Câu 295: Tại sao Pooling layer (như Max Pooling) thường được dùng trong CNN?

A. Để giảm kích thước không gian của feature map và giúp mô hình bất biến với các dịch chuyển nhỏ .

B. Để tăng số lượng tham số.

C. Để làm ảnh nét hơn.

D. Để thay thế lớp Convolution.

Câu 296: Vai trò của Skip-connections trong ResNet là:

A. Để bỏ qua các bước tiền xử lý.

B. Để làm mạng nông hơn.

C. Cho phép gradient "chảy" dễ dàng hơn qua các lớp, giúp huấn luyện được mạng cực sâu.

D. Để tăng tính phi tuyến tính.

Câu 297: Tại sao trong LSTM lại có các "cổng" (gates)?

A. Để điều tiết luồng thông tin: quên đi thông tin cũ không cần thiết và nạp thông tin mới quan trọng.

B. Để dữ liệu không bị thoát ra ngoài.

C. Để làm mạng nơ-ron trông giống máy tính hơn.

D. Để tăng tốc độ lan truyền tiến.

Câu 298: Ưu điểm của phương pháp Target Encoding đối với dữ liệu High Cardinality là:

A. Tạo ra hàng ngàn cột mới.

B. Tăng tính bảo mật cho dữ liệu.

C. Làm giảm độ phức tạp của thuật toán cây.

D. Giữ nguyên số lượng cột nhưng vẫn mang lại mối tương quan mạnh với mục tiêu.

Câu 299: Tại sao quy tắc chuỗi (Chain Rule) lại quan trọng trong Backpropagation?

A. Để tính toán được đạo hàm của các lớp ẩn từ sai số của lớp đầu ra.

B. Để nhân các trọng số với nhau.

C. Để đơn giản hóa phép cộng.

D. Để mô hình không bị Underfitting.

Câu 300: Ý nghĩa của "Self-Attention" trong Transformer là gì?

A. Giúp mỗi từ hiểu được mối quan hệ của nó với tất cả các từ khác trong cùng câu đó.

B. Để mô hình tự học không cần dữ liệu.

C. Để mô hình tập trung vào hình ảnh.

D. Để nén câu văn thành một số duy nhất.

Câu 301: Sự khác biệt cốt lõi giữa "Học có giám sát" và "Học không giám sát" là:

A. Học có giám sát cần nhiều máy tính hơn.

B. Học có giám sát sử dụng dữ liệu có nhãn (biết trước đáp án), học không giám sát thì không.

C. Học không giám sát luôn chính xác hơn.

D. Học có giám sát không dùng được cho Big Data.

Câu 302: Tại sao mạng nơ-ron đồ thị (GNN) lại vượt trội hơn CNN trong phân tích mạng xã hội?

A. Vì mạng xã hội có dạng lưới (grid).

B. Vì GNN rẻ hơn CNN.

C. Vì mối quan hệ giữa con người rất phức tạp, không theo thứ tự và cấu trúc cố định như pixel ảnh.

D. Vì GNN không cần hàm kích hoạt.

Câu 303: Tại sao "Batch Normalization" lại giúp mô hình hội tụ nhanh hơn?

A. Vì nó làm mạng sâu hơn.

B. Vì nó chỉ dùng cho lớp đầu vào.

C. Vì nó xóa bỏ các trọng số nhỏ.

D. Vì nó giữ các tín hiệu đầu ra ổn định, tránh việc rơi vào vùng bão hòa của hàm kích hoạt.

Câu 304: Trong hệ thống gợi ý, "Collaborative Filtering" hoạt động dựa trên:

A. Đặc trưng của sản phẩm.

B. Sự tương đồng về hành vi/sở thích giữa những người dùng khác nhau.

C. Giá tiền của món hàng.

D. Thời gian sản xuất sản phẩm.

Câu 305: Tại sao SHAP values lại dựa trên lý thuyết trò chơi?

A. Để phân bổ mức độ đóng góp một cách công bằng cho từng "người chơi" (đặc trưng) vào kết quả cuối cùng.

B. Để chơi game giải trí.

C. Để tìm ra người chiến thắng.

D. Để dự đoán tỷ số bóng đá.

Câu 306: Ý nghĩa của "Single Source of Truth" trong Data Lakehouse là gì?

A. Mọi người đều nói thật.

B. Dữ liệu không bao giờ bị thay đổi.

C. Chỉ có một nguồn dữ liệu đầu vào.

D. Duy nhất một nền tảng dữ liệu phục vụ đồng thời cho cả báo cáo BI và huấn luyện AI.

Câu 307: Tại sao Bias-Variance Tradeoff lại được gọi là sự "đánh đổi"?

A. Vì bạn phải mất tiền để mua mô hình.

B. Vì mô hình luôn có lỗi.

C. Vì khi cố gắng giảm sai số hệ thống (Bias) thì thường làm tăng sự nhạy cảm với nhiễu (Variance) và ngược lại.

D. Vì nó chỉ áp dụng cho mô hình hồi quy.

Câu 308: Tại sao trong Backpropagation, trọng số lại được cập nhật theo hướng "ngược" với gradient?

A. Để đi xuống thung lũng (cực tiểu hóa sai số) thay vì leo lên đỉnh núi (tăng sai số).

B. Để tăng hàm mất mát.

C. Để làm gradient biến mất.

D. Vì thuật toán yêu cầu như vậy.

Câu 309: Khai phá dữ liệu (data mining) được định nghĩa là?

A. Quá trình thiết kế và chuẩn hóa các bảng quan hệ theo dạng chuẩn 3NF

B. Quá trình sao lưu dự phòng và phục hồi cơ sở dữ liệu định kỳ

C. Quá trình khám phá các tri thức hữu ích, mới mẻ và tiềm ẩn từ các cơ sở dữ liệu lớn

D. Quá trình trích xuất và xóa bỏ toàn bộ dữ liệu lịch sử không sử dụng

Câu 310: Bước cuối cùng trong quy trình KDD là

A. Lựa chọn dữ liệu mục tiêu (Data Selection)

B. Khai phá dữ liệu (Data Mining)

C. Làm sạch dữ liệu (Data Cleaning)

D. Biểu diễn và đánh giá tri thức (Interpretation / Evaluation)

Câu 311: Vai trò của khai phá dl trong quy trình KDD là gì

A. Là bước triển khai ứng dụng phần mềm lên môi trường production

B. Là bước thu thập và tích hợp toàn bộ các bảng CSDL từ các chi nhánh

C. Là bước cốt lõi áp dụng các thuật toán thông minh để trích xuất các mẫu tri thức

D. Là bước loại bỏ các thuộc tính ngoại lệ và điền khuyết giá trị null

Câu 312: Trực quan hóa dl (data visualization) đóng vai trò như thế nào trong quy trình KDD

A. Chỉ có tác dụng giải trí và minh họa, không mang giá trị phân tích dữ liệu

B. Chỉ được sử dụng duy nhất ở bước cuối cùng khi báo cáo kết quả

C. Đóng vai trò hỗ trợ xuyên suốt từ khi bắt đầu cho đến khi kết thúc quy trình

D. Chỉ áp dụng riêng cho giai đoạn xây dựng mô hình học máy

Câu 313: Để xác định mqh "khách hàng mua bia thường mua kèm bỉm" kỹ thuật anof phù hợp nhất

A. Thuật toán phân cụm K-means (K-means Clustering)

B. Mạng nơ-ron tích chập (Convolutional Neural Networks)

C. Khai phá luật kết hợp (Association Rules Mining)

D. Phân tích hồi quy phi tuyến tính (Nonlinear Regression)

Câu 314: Các hđ chính của tiền xử lý dl bao gồm:

A. Thu thập, Đăng ký bản quyền, Quảng cáo, Bán hàng và Chăm sóc khách hàng

B. Mã hóa đối xứng, Băm mật mã, Ký số, Chứng thực và Giải mã

C. Làm sạch (Cleaning), Tích hợp (Integration), Biến đổi (Transformation), Thu gọn (Reduction) và Rời rạc hóa (Discretization)

D. Lập trình, Biên dịch, Gỡ lỗi, Đóng gói và Phân phối phần mềm

Câu 315: Theo kinh nghiệm, nếu một cột dữ liệu thiếu bao nhiêu % thì nên cân nhắc xóa bỏ

A. Lớn hơn 20% (> 20% dữ liệu bị khuyết)

B. Lớn hơn 10% (> 10% dữ liệu bị khuyết)

C. Lớn hơn 5% (> 5% dữ liệu bị khuyết)

D. Lớn hơn 60% (> 60% dữ liệu bị khuyết)

Câu 316: Mục tiêu chính của kỹ thuật PCA là

A. Tăng số lượng bản ghi mẫu dữ liệu lên gấp đôi bằng cách sinh mẫu nhân tạo

B. Tìm kiếm các giá trị ngoại lệ và xóa bỏ chúng khỏi tập dữ liệu

C. Giảm số chiều của dữ liệu (Dimensionality Reduction) bằng cách chiếu dữ liệu sang các trục thành phần chính

D. Chuyển đổi dữ liệu chuỗi văn bản thành dữ liệu hình ảnh kỹ thuật số

Câu 317: Phân tích xu hướng trung tâm dữ liệu không xét đến yếu tố nào

A. Sử dụng độ lệch chuẩn và giá trị trung bình của toàn bộ tập dữ liệu thay vì phụ thuộc vào hai điểm cực trị

B. Chỉ tính toán trên các thuộc tính dạng phân loại (Categorical variables)

C. Loại bỏ tự động toàn bộ các điểm ngoại lệ ra khỏi tập dữ liệu trước khi tính toán

D. Luôn luôn ép toàn bộ dữ liệu nằm nghiêm ngặt trong khoảng cố định [0, 1]

Câu 318: Z-score bằng 0 có nghĩa gì

A. Biểu đồ mạng nhện đa giác (Radar chart)

B. Biểu đồ hộp (Boxplot / Box-and-Whisker plot)

C. Biểu đồ phân cấp nhánh cây (Dendrogram)

D. Biểu đồ phân tán đám mây điểm (Scatter plot)

Câu 319: Đối với dữ liệu dạng chữ (categorical), phương pháp điền khuyết phù hợp nhất là

A. Biểu đồ phân tán (Scatter Plot)

B. Biểu đồ phân rã chuỗi thời gian (Decomposition Chart)

C. Biểu đồ cột xếp chồng (Stacked Bar Chart)

D. Biểu đồ hình bánh tròn (Pie Chart)

Câu 320: Thuộc tính "màu tóc" (đen, nâu, vàng) thuộc loại thuộc tính nào

A. Vẽ các đường ray song song để lập lịch chạy cho các đoàn tàu hỏa

B. Biểu diễn cơ sở dữ liệu dưới dạng các bảng dữ liệu đặt song song nhau trên màn hình

C. Kỹ thuật tối ưu hóa truy vấn SQL bằng cách chạy song song nhiều luồng CPU

D. Trực quan hóa dữ liệu đa chiều bằng cách biểu diễn mỗi quan sát thành một đường gấp khúc cắt qua các trục tọa độ song song tương ứng với từng thuộc tính

Câu 321: Trong z-score, nếu một giá trị có điểm tiêu chuẩn là 2, điều đó có nghĩa là

A. Hệ thống nhận diện khuôn mặt người dùng để mở khóa màn hình điện thoại

B. Trực quan hóa dữ liệu đa chiều bằng cách ánh xạ các thuộc tính số thành các đặc điểm trên khuôn mặt hoạt họa (như độ cong miệng, kích thước mắt, hình dạng mặt)

C. Kỹ thuật trang điểm và làm đẹp ảnh chân dung kỹ thuật số bằng AI

D. Phần mềm tạo biểu tượng cảm xúc Emoji tự động khi gõ tin nhắn

Câu 322: Khai phá mẫu phổ biến là nền tảng cho bài toán nào

A. Một tập mục có số lượng phần tử mặt hàng nhiều nhất trong toàn bộ cơ sở dữ liệu

B. Một tập mục phổ biến mà không có bất kỳ tập cha trực tiếp nào của nó là một tập mục phổ biến

C. Một tập mục có giá trị độ tin cậy Confidence bằng đúng 100%

D. Một tập mục chứa toàn bộ tất cả các sản phẩm có trong siêu thị

Câu 323: Qúa trình khai phá luật kết hợp thường gồm mấy bước chính

A. Một tập mục gồm k mặt hàng (k items)

B. Một tập mục có độ tin cậy đạt mức phân cấp thứ k

C. Một tập mục được tạo ra từ k thuật toán khai phá khác nhau

D. Một tập mục xuất hiện trong ít nhất k giao dịch mua sắm

Câu 324: "Nguyên lý tỉa Apriori" khẳng định điều gì

A. Thời gian trung bình để vận chuyển tập mục từ kho đến tay khách hàng

B. Tỷ lệ phần trăm hoặc số lượng giao dịch trong cơ sở dữ liệu có chứa tập mục đó

C. Số tiền lãi thu được từ việc bán các sản phẩm trong tập mục

D. Tỷ lệ số khách hàng phàn nàn và đổi trả lại tập mục đó

Câu 325: Trong cây băm của Apriori, nút lá chứa thông tin gì

A. Cây đỏ đen (Red-Black Tree)

B. Đồ thị xoắn ốc (Directed Acyclic Graph)

C. Cây băm (Hash Tree)

D. Cây quyết định (Decision Tree)

Câu 326: Khi nào một nút lá trong cây băm được chuyển thành một nút trong

A. Khi chiều sâu của cây vượt quá 100 tầng liên tiếp

B. Số lượng các tập ứng viên được lưu trữ tại nút lá vượt quá một ngưỡng dung lượng quy định

C. Khi người dùng nhấn nút tạm dừng chương trình khai phá

D. Khi toàn bộ cơ sở dữ liệu đã được nạp xong vào bộ nhớ RAM

Câu 327: giải pháp phân hoạch (Partition) giúp thực hiện duyệt cơ sở dữ liệu bao nhiêu lần

A. Phải quét k lần ứng với độ dài k của tập mục lớn nhất

B. Phải quét ngẫu nhiên từ 10 đến 50 lần tùy thuộc kích thước RAM

C. Đúng 2 lần quét duyệt cơ sở dữ liệu

D. Đúng 1 lần quét duy nhất không cần kiểm tra lại

Câu 328: Phương pháp DHP tập trung vào cải tiến điều gì

A. Loại bỏ hoàn toàn các mặt hàng có giá trị cao trong siêu thị

B. Chỉ khai phá các giao dịch xảy ra vào ban đêm

C. Tự động dịch mã nguồn từ Python sang ngôn ngữ Assembly

D. Rút gọn tối đa số lượng các tập ứng viên 2-mục (C2) bằng cách sử dụng bảng băm trực tiếp

Câu 329: Header Table trong cấu trúc FP-tree chứa các thành phần nào

A. Tên mục (Item name), Tần suất hỗ trợ (Support count) và Liên kết nút (Node-link) trỏ tới nút đầu tiên cùng tên trong cây

B. Địa chỉ IP máy chủ, Tên tài khoản quản trị và Mật khẩu đăng nhập

C. Giá tiền bán lẻ, Hạn sử dụng của sản phẩm và Tên nhà cung cấp

D. Chỉ chứa duy nhất một con số thể hiện tổng dung lượng file CSDL

Câu 330: Kỹ thuật nào được áp dụng khi khai phá các FP-tree điều kiện

A. Kỹ thuật giải thuật di truyền mô phỏng tiến hóa sinh học (Genetic Algorithm)

B. Kỹ thuật đệ quy (Recursion) theo chiến lược chia để trị

C. Kỹ thuật hạ độ dốc ngẫu nhiên với tốc độ học thích nghi (Adam Optimizer)

D. Kỹ thuật tìm kiếm theo chiều sâu không giới hạn bộ nhớ

Câu 331: FP-Growth thực hiện việc khai phá theo chiến lược nào

A. Chiến lược Tham lam cục bộ (Greedy Search)

B. Chiến lược Thử sai ngẫu nhiên (Monte Carlo Sampling)

C. Chiến lược Quy hoạch động (Dynamic Programming)

D. Chiến lược Chia để trị (Divide and Conquer)

Câu 332: Tạo sao việc sắp xếp các mục theo tần suất giảm dần lại có lợi cho FP-tree

A. Giúp cây mọc cao hơn và có nhiều lá hơn để dễ nhìn

B. Để các mặt hàng bán ế được ưu tiên hiển thị ở trên cùng của cây

C. Bắt buộc theo quy định cú pháp của ngôn ngữ lập trình C++

D. Tối đa hóa khả năng chia sẻ các nhánh tiền tố chung, giúp cấu trúc cây nén cô đọng và nhỏ gọn nhất

Câu 333: FP-tree duy trì tính chất đầy đủ (completeness) vì

A. Nó có dung lượng file luôn lớn hơn cơ sở dữ liệu quan hệ ban đầu

B. Nó được bảo hiểm dữ liệu bởi các tổ chức tài chính quốc tế

C. Nó lưu trữ cả ảnh chụp và video quay lại hành vi của từng khách hàng

D. Nó không phá vỡ bất kỳ mẫu dài của giao dịch nào và bảo toàn đầy đủ mọi thông tin cần thiết để khai phá mẫu phổ biến

Câu 334: Trong phân tích Web log, khai phá luật kết hợp giúp tìm ra

A. Các trang web thường được người dùng truy cập cùng nhau trong một phiên làm việc (Clickstream data)

B. Màu sắc chủ đạo của giao diện trang chủ theo phong thủy

C. Địa chỉ nhà riêng và số tài khoản ngân hàng của lập trình viên web

D. Tốc độ quạt tản nhiệt của máy chủ web server

Câu 335: Độ hỗ trợ (Support) của tập mục A trong cơ sở dữ liệu giao dịch là gì?

A. Tần suất xuất hiện của mặt hàng bán chậm nhất trong A

B. Tổng số lượng các mục thành phần có trong A

C. Xác suất các giao dịch chứa tập mục A: Support(A) = P(A)

D. Xác suất có điều kiện P(B|A)

Câu 336: Công thức tính độ tin cậy (Confidence) của luật A => B là:

A. Confidence(A => B) = Support(A ∪ B) / Support(A) = P(B|A)

B. Confidence(A => B) = Support(A ∪ B) / Support(B) = P(A|B)

C. Confidence(A => B) = Support(A) / Support(B)

D. Confidence(A => B) = Support(A ∪ B) / |D|

Câu 337: Thế nào là một 'Luật mạnh' (Strong association rule)?

A. Luật có độ hỗ trợ (Support) đạt 100%

B. Luật đồng thời thỏa mãn cả độ hỗ trợ tối thiểu (min_sup) và độ tin cậy tối thiểu (min_conf)

C. Luật có vế phải chỉ gồm duy nhất một mặt hàng

D. Luật có chỉ số Lift bằng đúng 0

Câu 338: Trong thuật toán Apriori, bước 'Join' (Nối) dùng để làm gì?

A. Kết nối cơ sở dữ liệu với bộ nhớ RAM

B. Sinh các tập ứng viên độ dài (k+1) bằng cách kết hợp các cặp tập phổ biến độ dài k có (k-1) mục đầu giống nhau

C. Tính toán độ tin cậy của các luật kết hợp

D. Loại bỏ các tập mục không thỏa mãn ngưỡng min_sup

Câu 339: Cấu trúc dữ liệu nào thường được sử dụng để đếm độ hỗ trợ của các tập ứng viên trong Apriori nhằm tăng tốc độ?

A. Cây đỏ đen (Red-Black Tree)

B. Hàng đợi ưu tiên (Priority Queue)

C. Cây-băm (Hash-tree)

D. Cây tiền tố FP-tree

Câu 340: Đặc điểm nổi bật nhất của giải thuật FP-Growth so với Apriori là gì?

A. Chỉ áp dụng được cho dữ liệu dạng chuỗi số liên tục

B. Sử dụng bảng băm đơn giản thay cho cây phân cấp

C. Khai phá các mẫu phổ biến mà hoàn toàn không cần sinh tập ứng viên (Candidate-free)

D. Duyệt cơ sở dữ liệu nhiều lần hơn để tăng độ chính xác

Câu 341: Cấu trúc cây FP-tree bao gồm những thành phần chính nào?

A. Nút gốc (null), các nhánh tiền tố cây và bảng đầu mục (Header Table)

B. Các tập phổ biến và danh sách các luật mạnh

C. Các ứng viên và bộ đếm ma trận tương quan

D. Nút gốc, các nút lá và bảng băm giao dịch

Câu 342: Ứng dụng điển hình và kinh điển nhất của khai phá luật kết hợp trong kinh doanh là:

A. Dự báo thời tiết và lượng mưa

B. Phân loại thư rác và phát hiện mã độc

C. Phân tích giỏ hàng (Market Basket Analysis) để sắp xếp kệ hàng và đề xuất bán chéo

D. Nhận dạng khuôn mặt sinh trắc học

Câu 343: Tại sao giải thuật Apriori lại phải quét (duyệt) cơ sở dữ liệu nhiều lần?

A. Vì Apriori không thể sắp xếp dữ liệu theo thứ tự

B. Vì cơ sở dữ liệu quá lớn không thể nạp vào RAM

C. Vì ở mỗi bước k, Apriori cần quét lại toàn bộ CSDL để đếm độ hỗ trợ thực tế của tập ứng viên C_k

D. Để đảm bảo độ tin cậy của mọi luật đều đạt 100%

Câu 344: Trong thuật toán Apriori, nếu tập phổ biến L_k thu được là rỗng (L_k = ∅), điều gì sẽ xảy ra?

A. Thuật toán tiếp tục sinh ứng viên C_{k+1} từ tập C_k

B. Thuật toán lập tức dừng lại vì không thể sinh thêm ứng viên C_{k+1}

C. Cơ sở dữ liệu bị báo lỗi và hủy bỏ toàn bộ kết quả

D. Thuật toán quay lại bước k-1 để giảm bớt ngưỡng min_sup

Câu 345: Ưu điểm cốt lõi của việc nén dữ liệu vào cây FP-tree là gì?

A. Chỉ dùng để minh họa biểu đồ cho báo cáo quản trị

B. Giúp giải thuật Apriori chạy nhanh hơn gấp 10 lần

C. Giảm thiểu không gian lưu trữ và tránh việc phải quét lại cơ sở dữ liệu gốc nhiều lần trên đĩa cứng

D. Loại bỏ hoàn toàn các mặt hàng trong cơ sở dữ liệu để bảo mật

Câu 346: Tại sao độ tin cậy (Confidence) không mang tính chất đối xứng (tức Confidence(A => B) có thể khác Confidence(B => A))?

A. Do quy định ngẫu nhiên của thuật toán FP-Growth

B. Vì tập hợp (A ∪ B) khác với tập hợp (B ∪ A)

C. Vì mẫu số là xác suất của vế trái (Support(A) và Support(B)), và hai giá trị này thường khác nhau

D. Vì độ hỗ trợ của tập hợp (A ∪ B) bị thay đổi khi đổi chỗ

Câu 347: Trong bước 'Tỉa' (Prune) của Apriori, làm thế nào thuật toán biết một ứng viên c ∈ C_k có tập con không phổ biến?

A. Bằng cách kiểm tra xem tất cả các tập con kích thước (k-1) của c có nằm trong danh sách L_{k-1} vừa tìm được không

B. Bằng cách so sánh với danh sách F-list

C. Bằng cách quét lại toàn bộ cơ sở dữ liệu trên đĩa cứng

D. Bằng cách dùng hàm băm mã hóa giao dịch

Câu 348: Trong thuật toán FP-Growth, khi nào thì toàn bộ quá trình khai phá đệ quy kết thúc?

A. Khi tất cả các cây FP-tree có điều kiện đều đã được duyệt hết hoặc trở nên rỗng

B. Khi đã xây dựng xong cây FP-tree ban đầu

C. Khi tìm được đủ 100 luật mạnh đầu tiên

D. Khi duyệt xong bảng Header Table đúng một lượt duy nhất

Câu 349: Nếu một giao dịch không chứa bất kỳ mặt hàng nào nằm trong danh sách F-list, giao dịch đó sẽ được xử lý thế nào khi xây dựng FP-tree?

A. Bị loại bỏ hoàn toàn và không đóng góp nhánh nào vào cây FP-tree

B. Hệ thống sẽ báo lỗi và dừng chương trình

C. Được gán độ hỗ trợ bằng 0 và lưu vào nút gốc

D. Được thêm vào bảng Header Table dưới dạng mục rỗng

Câu 350: Trong thuật toán Apriori, nếu ta tìm được L_1 gồm 4 mục {A, B, C, D}, số lượng ứng viên tối đa được sinh ra trong C_2 là:

A. 6 ứng viên (tổ hợp chập 2 của 4: {AB, AC, AD, BC, BD, CD})

B. 16 ứng viên

C. 4 ứng viên

D. 8 ứng viên

Câu 351: Khi nào thì một luật kết hợp được xem là thực sự có giá trị và hữu ích (Interesting / Actionable)?

A. Khi nó chỉ bao gồm các mặt hàng có giá trị tiền đắt đỏ nhất

B. Khi nó được tìm thấy bởi thuật toán Apriori thay vì FP-Growth

C. Khi nó vừa là luật mạnh (đạt min_sup, min_conf), vừa mang lại tri thức mới lạ, bất ngờ và có tương quan tích cực (thường có Lift > 1)

D. Khi luật đó có độ tin cậy đạt đúng 100%

Câu 352: Thách thức lớn nhất khi lưu trữ và đếm độ hỗ trợ bằng Cây-băm (Hash-tree) trong Apriori là gì?

A. Khi số lượng ứng viên quá lớn, cây-băm trở nên cực kỳ đồ sộ, phức tạp và tiêu tốn nhiều bộ nhớ RAM

B. Hàm băm toán học luôn trả về giá trị null trên dữ liệu chuỗi

C. Cây-băm chỉ hoạt động được trên các chuỗi ký tự văn bản ngắn

D. Cây-băm không thể đếm được các mặt hàng bị trùng nhau

Câu 353: Trong FP-tree xây dựng từ CSDL trên, 'Prefix path' của mục 'm' gồm những đường dẫn nào?

A. {f, c, a, b}: 1

B. {f, c, a, m}: 2

C. {f, c}: 3

D. {f, c, a}: 2 và {f, c, a, b}: 1

Câu 354: Từ kết quả prefix paths của mục 'm' ở trên ({f,c,a}:2, {f,c,a,b}:1), với min_sup = 3, cấu trúc cây điều kiện m-conditional FP-tree chứa các nút nào?

A. {f: 3, b: 1}

B. {c: 3, p: 2}

C. <f: 3, c: 3, a: 3>

D. {f: 2, c: 2, a: 2}

Câu 355: Từ cây điều kiện m-conditional FP-tree <f:3, c:3, a:3>, tập hợp các mẫu phổ biến chứa 'm' được sinh ra là:

A. {b, m}

B. {fm: 3}, {cm: 3}, {am: 3}, {fcm: 3}, {fam: 3}, {cam: 3}, {fcam: 3}

C. {p, m}

D. {f, m}, {c, m}, {a, m}

Câu 356: Trong cây FP-tree ban đầu của CSDL 5 giao dịch trên, nút 'b' xuất hiện phân tán ở bao nhiêu nhánh trực tiếp?

A. 1 nhánh duy nhất

B. 3 nhánh

C. 2 nhánh

D. Không xuất hiện trên cây

Câu 357: Trong Cây-băm (Hash-tree) của Apriori, nếu mục tiêu là tìm kiếm và tăng bộ đếm cho các ứng viên độ dài 3, với giao dịch T = {1, 2, 3, 5, 6}, ta sẽ thực hiện băm tại nút gốc với những mục nào?

A. Băm các mục 1, 2, 4

B. Chỉ băm duy nhất mục 1

C. Băm toàn bộ 5 mục cùng một lúc

D. Băm lần lượt các mục 1, 2, 3 xuất hiện trong giao dịch

Câu 358: Một siêu thị có 10.000 giao dịch. Trong đó, Sữa xuất hiện 4.000 lần, Trứng xuất hiện 5.000 lần, và cả hai cùng xuất hiện trong 2.000 giao dịch. Tính Confidence của luật Sữa => Trứng:

A. 50%

B. 40%

C. 80%

D. 20%

Câu 359: Với số liệu của bài toán siêu thị ở câu trên (Sữa: 4.000, Trứng: 5.000, cả hai: 2.000 trên 10.000 giao dịch), giá trị Lift của luật Sữa => Trứng là bao nhiêu và cho thấy điều gì?

A. Lift = 0.8; cho thấy Sữa và Trứng có tương quan nghịch

B. Lift = 2.0; cho thấy khả năng mua Trứng tăng gấp đôi khi mua Sữa

C. Lift = 1.25; cho thấy Sữa và Trứng có tương quan dương mạnh

D. Lift = 1.0; cho thấy việc mua Sữa và mua Trứng hoàn toàn độc lập với nhau

Câu 360: Xác định lỗi vi phạm định nghĩa trong luật kết hợp sau: {A, B} => {A, C}:

A. Vi phạm điều kiện tiên quyết: mục A xuất hiện ở cả hai vế (giao của hai vế không rỗng: {A, B} ∩ {A, C} = {A} ≠ ∅)

B. Không có bất kỳ lỗi nào, đây là một luật kết hợp hợp lệ

C. Luật kết hợp chỉ cho phép có đúng một mặt hàng ở vế trái

D. Độ tin cậy của luật này sẽ luôn luôn bằng 0

Câu 361: Mục tiêu chính của giai đoạn "Thấu hiểu dl" là

A. Ký kết hợp đồng nghiệm thu dự án với ban giám đốc doanh nghiệp

B. Đóng gói mô hình thành API và triển khai lên hệ thống đám mây

C. Lựa chọn siêu tham số tối ưu cho mô hình mạng nơ-ron sâu

D. Thu thập dữ liệu thô ban đầu, khám phá đặc tính (EDA) và kiểm tra chất lượng dữ liệu

Câu 362: Khai phá dl là bài toán xử lý dl cơ bản nhất trong quá trình nào

A. Quá trình phân quyền truy cập người dùng trong hệ điều hành

B. Quá trình phát hiện tri thức trong cơ sở dữ liệu (KDD)

C. Quá trình biên dịch mã nguồn của lập trình viên phần mềm

D. Quá trình sao lưu dữ liệu giao dịch hàng ngày (OLTP Backup)

Câu 363: Trong tiếp thị định hướng, việc tìm các nhóm khách hàng có cùng đặc trưng (thu nhập, thói quen chi tiêu) sử dụng kỹ thuật nào

A. Khai phá luật kết hợp (Association Rules)

B. Phân tích chuỗi thời gian (Time-series Forecasting)

C. Hồi quy tuyến tính (Linear Regression)

D. Phân tích phân cụm (Clustering Analysis)

Câu 364: Một ngân hàng muốn xác định kiểu khách hàng nào thường mua sản phẩm gì tư vấn, họ nên sử dụng kết hợp các kỹ thuật nào

A. Kết hợp nén dữ liệu Lossless và giải mã mã hóa RSA

B. Kết hợp phân tích chuỗi thời gian và sao lưu phục hồi hệ thống

C. Chỉ sử dụng duy nhất các câu lệnh truy vấn SQL cơ bản SELECT/WHERE

D. Kết hợp phân tích phân cụm (Clustering) và phân lớp dữ liệu (Classification)

Câu 365: Khi xây dựng hồ sơ khách hàng (customer profilling) mục tiêu chính là

A. Nhằm thay thế hoàn toàn đội ngũ nhân viên tư vấn bán hàng của doanh nghiệp

B. Nhằm thấu hiểu đặc điểm, hành vi để xác định chính xác kiểu khách hàng nào sẽ mua sản phẩm gì

C. Nhằm kiểm tra địa chỉ IP truy cập để chặn các cuộc tấn công mạng DDoS

D. Nhằm lưu trữ thông tin cá nhân khách hàng để bán cho các công ty quảng cáo

Câu 366: Ứng dụng "Dự báo các nhân tố sẽ thu hút khách hàng mới" thuộc lĩnh vực nào trong khai phá dl

A. Phân tích yêu cầu và hành vi khách hàng (Customer Requirement & Behavior Analysis)

B. Thiết kế vi mạch bán dẫn phần cứng máy tính

C. Khai thác khoáng sản và định vị địa chất dầu khí

D. Quản lý mạng lưới đường dây truyền tải điện quốc gia

Câu 367: Nếu bạn nhận thấy dl "ngày sinh" chứa ký tự chữ, bạn đang thực hiện kiểm tra tính chất nào của chất lượng dl

A. Tính duy nhất (Uniqueness) của dữ liệu

B. Tính đầy đủ (Completeness) của dữ liệu

C. Tính hợp lệ (Validity) của dữ liệu

D. Tính kịp thời (Timeliness) của dữ liệu

Câu 368: Độ đo anof sau đây dùng để đo lường điểm trung tâm của tập dữ liệu

A. Khoảng tứ phân vị (IQR) và Giá trị ngoại lệ cực tiểu (Min)

B. Phương sai (Variance), Độ lệch chuẩn (Std Dev) và Khoảng biến thiên (Range)

C. Trung bình (Mean), Trung vị (Median) và Yếu vị (Mode)

D. Độ xiên (Skewness) và Độ nhọn (Kurtosis)

Câu 369: Kỹ thuật chia dữ liệu vào các nhóm nhỏ dựa trên giá trị đã sắp xếp được gọi là

A. Giá trị trung bình bị kéo lệch mạnh về phía đuôi dài của các giá trị ngoại lệ cực lớn

B. Giá trị trung bình và trung vị luôn bằng nhau tuyệt đối ($Mean = Median$)

C. Phân phối dữ liệu hoàn toàn đối xứng hình quả chuông chuẩn tắc

D. Giá trị trung bình sẽ nhỏ hơn đáng kể so với giá trị trung vị ($Mean < Median$)

Câu 370: Khi nào nên sử dụng median thay vì mean

A. Khi tập dữ liệu bị phân phối lệch hoặc xuất hiện nhiều giá trị ngoại lệ (outliers) cực đoan

B. Khi tập dữ liệu chỉ chứa các biến nhãn phân loại dạng chuỗi ký tự

C. Khi tập dữ liệu tuân theo phân phối chuẩn tắc đối xứng hoàn hảo

D. Khi không có bất kỳ điểm dữ liệu nào bị thiếu giá trị trong toàn bộ tập

Câu 371: Làm mượt dữ liệu bằng kỹ thuật hồi quy hoạt động như thế nào

A. Kỹ thuật phân tích mối tương quan (Correlation Analysis - như hệ số Pearson hay Chi-Square)

B. Kỹ thuật tìm kiếm nhị phân trên cây cân bằng AVL

C. Kỹ thuật phân cụm phân cấp sử dụng liên kết đơn (Single Linkage)

D. Kỹ thuật huấn luyện mạng nơ-ron hồi quy tuần hoàn (RNN)

Câu 372: Target Encoding là kỹ thuật dùng để làm gì

A. Đo lường độ tương đồng ngữ nghĩa giữa các văn bản pháp luật

B. Đo lường mối quan hệ tương quan tuyến tính giữa hai thuộc tính số liên tục

C. Đo lường mối quan hệ phụ thuộc giữa hai thuộc tính danh mục rời rạc

D. Xác định vị trí trọng tâm cụm tối ưu trong giải thuật K-means

Câu 373: Cho một bin dữ liệu gồm 4, 8, 15. Giá trị làm mượt theo trung bình (bin mean) là

A. Biểu đồ luồng dữ liệu (DFD)

B. Biểu đồ lượng vị (Q-Q Plot / Quantile-Quantile Plot)

C. Biểu đồ luồng trạng thái (State Diagram)

D. Biểu đồ quan hệ thực thể (ERD)

Câu 374: Mẫu phổ biến (Frequent pattern) được định nghĩa là

A. Nếu một tập mục là phổ biến, thì mọi tập cha mở rộng của nó cũng chắc chắn là phổ biến

B. Nếu một tập mục là phổ biến, thì mọi tập con không rỗng của nó chắc chắn cũng phải là tập mục phổ biến

C. Tập mục có kích thước càng lớn thì độ hỗ trợ trong cơ sở dữ liệu càng cao

D. Độ hỗ trợ của một tập mục luôn tăng dần khi ta bổ sung thêm các mặt hàng mới vào tập đó

Câu 375: Các thuật toán ECLAT và VIPER thăm dò dữ liệu theo hướng nào

A. Khai phá dữ liệu theo định dạng ma trận xoay chiều ngang truyền thống

B. Sắp xếp cơ sở dữ liệu theo thứ tự bảng chữ cái ngược

C. Khai phá dữ liệu theo định dạng bố cục dọc (Vertical Data Format - TID-list)

D. Chỉ quét dữ liệu từ dưới lên trên thay vì từ trên xuống dưới

Câu 376: Cơ sở mẫu điều kiện (Conditional pattern base) của một mục p là

A. Tập hợp các đường dẫn tiền tố (Prefix paths) trong cây FP-tree đồng xuất hiện cùng với mục p

B. Các tập con ngẫu nhiên được máy tính sinh ra tự động để kiểm thử

C. Danh sách các nhân viên bán hàng phụ trách doanh số của mặt hàng p

D. Tập hợp tất cả các giao dịch không chứa mục p trong toàn bộ CSDL

Câu 377: Phân tích giỏ hàng giúp nhà bán lẻ

A. Sửa chữa hệ thống điện lạnh và điều hòa không khí trong siêu thị

B. Thiết kế danh mục sản phẩm (catalog), lập kế hoạch khuyến mãi và sắp xếp vị trí các gian hàng tối ưu

C. Tự động in hóa đơn giá trị gia tăng gửi cho cơ quan thuế

D. Tính toán bảng lương hàng tháng cho nhân viên bảo vệ và thu ngân

Câu 378: Ứng dụng của khai phá mẫu phổ biến trong y sinh là

A. Đo lường nhịp tim của bệnh nhân từ khoảng cách vệ tinh

B. Tự động kê đơn thuốc tây mà không cần giấy phép y tế

C. Chế tạo các robot phẫu thuật tự động thay thế bác sĩ

D. Phân tích cấu trúc chuỗi DNA, phát hiện các đoạn gen đồng biểu hiện và cụm bệnh di truyền

Câu 379: Thuật ngữ "TID" là viết tắt của

A. Table Index Definition (Định nghĩa chỉ mục của bảng dữ liệu)

B. Transaction Identifier (Mã định danh duy nhất của một giao dịch trong cơ sở dữ liệu)

C. Time Interval Duration (Khoảng thời gian kéo dài của một sự kiện)

D. Task Iteration Depth (Độ sâu lặp của một tác vụ thuật toán)

Câu 380: "Rút gọn số lượng ứng viên" là mục tiêu cải tiến của phương pháp nào

A. Thuật toán DHP (Direct Hashing and Pruning)

B. Thuật toán Naive Bayes (Naive Bayes Classifier)

C. Thuật toán PageRank (PageRank Ranking)

D. Thuật toán K-means (K-means Clustering)

Câu 381: Khai phá luật kết hợp là gì?

A. Dự báo giá trị của một biến mục tiêu liên tục

B. Tìm kiếm các giá trị ngoại lệ và bất thường trong tập dữ liệu

C. Tìm các mẫu có tần suất cao và các mối liên hệ giữa các tập hợp đối tượng trong cơ sở dữ liệu

D. Phân chia dữ liệu thành các cụm có đặc điểm giống nhau mà không có nhãn

Câu 382: Mẫu phổ biến (Frequent pattern) được định nghĩa và công bố lần đầu bởi ai?

A. Rakesh Agrawal và cộng sự (AIS93)

B. Heikki Mannila và cộng sự

C. Ramakrishnan Srikant và cộng sự

D. Jiawei Han và cộng sự

Câu 383: Ký hiệu 'I' trong khai phá luật kết hợp đại diện cho:

A. Tập hợp toàn bộ các mục (items) riêng biệt trong cơ sở dữ liệu: $I = \{i_1, i_2, ..., i_m\}$

B. Một luật kết hợp cụ thể dạng X => Y

C. Ngưỡng độ tin cậy tối thiểu (min_conf)

D. Tập hợp tất cả các giao dịch trong cơ sở dữ liệu (D)

Câu 384: Luật kết hợp được biểu diễn dưới dạng biểu thức nào sau đây?

A. $X + Y = Z$

B. $A \cap B \neq \emptyset$

C. $A \cup B = I$

D. $A \Rightarrow B$ (trong đó $A \subset I$, $B \subset I$ và $A \cap B = \emptyset$)

Câu 385: Giải thuật Apriori sử dụng phương pháp nào để tìm kiếm các mẫu phổ biến?

A. Duyệt cây tiền tố nén FP-tree

B. Sinh và kiểm tra tập ứng viên (Candidate generation and test) theo từng mức chiều dài k

C. Thăm dò giao dịch theo danh sách TID dọc (Vertical format)

D. Sử dụng mạng nơ-ron tự kết hợp

Câu 386: Trong FP-Growth, 'F-list' là danh sách các mục phổ biến 1 phần tử được sắp xếp theo thứ tự nào?

A. Thứ tự xuất hiện ngẫu nhiên trong giao dịch đầu tiên

B. Thứ tự bảng chữ cái (A-Z)

C. Thứ tự tần suất xuất hiện giảm dần (Decreasing order of support count)

D. Thứ tự chiều dài của tên mục

Câu 387: Thuật toán DIC (Dynamic Itemset Counting) được thiết kế nhằm mục đích cải tiến điều gì ở Apriori?

A. Làm tăng số lượng ứng viên được sinh ra

B. Xây dựng cây FP-tree nhanh hơn

C. Rút gọn số lượng lần duyệt cơ sở dữ liệu bằng cách bổ sung ứng viên linh hoạt tại các điểm mốc

D. Tự động tính độ nâng cao Lift mà không cần Support

Câu 388: Giải pháp Phân hoạch (Partitioning) giúp khai phá tập phổ biến với bao nhiêu lần quét cơ sở dữ liệu?

A. Không cần quét cơ sở dữ liệu lần nào

B. Quét cơ sở dữ liệu vô số lần tùy kích thước k

C. Chỉ quét cơ sở dữ liệu đúng 2 lần

D. Quét 1 lần duy nhất

Câu 389: Độ đo nào sau đây được dùng để đánh giá mức độ tương quan phụ thuộc (tương quan dương, âm hay độc lập) giữa hai tập mục?

A. Độ hỗ trợ (Support)

B. Định danh giao dịch (TID)

C. Độ tin cậy (Confidence)

D. Độ nâng cao (Lift / Interest)

Câu 390: Trong cây FP-tree, con trỏ 'Node-link' tại mỗi mục trong Header Table dùng để làm gì?

A. Trỏ trực tiếp về nút gốc (Root)

B. Lưu trữ độ hỗ trợ tích lũy của toàn bộ cơ sở dữ liệu

C. Liên kết nối tiếp tất cả các nút có cùng tên mặt hàng nằm phân tán trên các nhánh của cây

D. Đánh dấu thời điểm kết thúc một giao dịch

Câu 391: Khai phá luật kết hợp dựa trên ràng buộc (Constraint-based Association Mining) là gì?

A. Sử dụng toàn bộ mọi mặt hàng trong I làm tiền đề bắt buộc

B. Tìm kiếm tất cả các luật có thể tồn tại trong CSDL mà không bỏ sót bất kỳ luật nào

C. Tìm kiếm các luật thỏa mãn các điều kiện ràng buộc cụ thể về nội dung, giá cả hoặc cấu trúc do người dùng đặt ra

D. Bỏ qua hoàn toàn ngưỡng độ hỗ trợ tối thiểu (min_sup)

Câu 392: 'Prefix path' (Đường dẫn tiền tố) của một nút trong FP-tree được định nghĩa là:

A. Một hàng trong bảng Header Table

B. Đường dẫn đi từ nút gốc (Root) đến nút đứng ngay trước nút đang xét trên cây

C. Tập hợp tất cả các nút lá trong cây

D. Một danh sách các nút con nằm dưới nút đang xét

Câu 393: Giải thuật DHP (Direct Hashing and Pruning) tập trung vào việc cải tiến điều gì?

A. Rút gọn đáng kể số lượng các tập ứng viên C_k thông qua kỹ thuật băm

B. Tính toán chỉ số Lift nhanh hơn mà không cần tính Support

C. Tăng số lần quét cơ sở dữ liệu trên đĩa cứng

D. Thay thế hoàn toàn cấu trúc cây FP-tree

Câu 394: Mục tiêu chính của việc sắp xếp các mặt hàng trong mỗi giao dịch theo thứ tự F-list trước khi nạp vào FP-tree là:

A. Để loại bỏ hoàn toàn các giao dịch trùng lặp trong cơ sở dữ liệu

B. Để tối ưu hóa việc dùng chung các nút tiền tố, nén dữ liệu tối đa và làm cấu trúc cây cô đọng nhất

C. Để làm cho cây có cấu trúc đối xứng đẹp mắt

D. Để tăng độ hỗ trợ của các mặt hàng hiếm

Câu 395: Giải thích tại sao bước 'Prune' (Tỉa) trong Apriori không làm mất các tập phổ biến thực sự?

A. Vì bước tỉa chỉ được thực hiện sau khi đã đếm xong hỗ trợ trên toàn bộ dữ liệu

B. Vì theo nguyên lý Apriori, nếu một tập con bất kỳ không phổ biến thì tập cha chứa nó chắc chắn không thể phổ biến

C. Vì bước này chỉ thực hiện xóa các mục bị trùng tên

D. Thực tế bước này có thể làm mất nếu đặt ngưỡng min_sup quá cao

Câu 396: Tại sao trong cấu trúc cây FP-tree, các mặt hàng có tần suất thấp hơn lại nằm gần các nút lá hơn?

A. Để giải thuật dễ dàng xóa bỏ chúng khi bộ nhớ RAM bị đầy

B. Do quy định ngẫu nhiên của bảng Header Table

C. Vì chúng có kích thước tên mục dài hơn

D. Vì thứ tự F-list đặt các mục phổ biến nhất lên gần gốc để tối đa hóa khả năng dùng chung nút tiền tố

Câu 397: Điều gì sẽ xảy ra nếu ta thiết lập ngưỡng min_sup = 0 trong khai phá luật kết hợp?

A. Chỉ có duy nhất tập mục rỗng là được công nhận phổ biến

B. Giải thuật sẽ không tìm được bất kỳ mẫu phổ biến nào

C. Giải thuật Apriori sẽ chạy với tốc độ nhanh nhất

D. Mọi tổ hợp tập hợp con của các mục xuất hiện trong CSDL đều trở thành tập phổ biến, gây bùng nổ không gian tìm kiếm

Câu 398: Tại sao bước sinh luật mạnh chỉ được thực hiện sau khi đã tìm xong toàn bộ các tập mục phổ biến?

A. Vì một luật mạnh bắt buộc phải có Support ≥ min_sup, mà độ hỗ trợ của luật A => B chính là độ hỗ trợ của tập mục (A ∪ B)

B. Do quy định bắt buộc của ngôn ngữ lập trình Python

C. Để giảm thiểu việc sử dụng bộ nhớ RAM của máy tính

D. Vì luật mạnh không cần quan tâm đến độ hỗ trợ

Câu 399: Cấu trúc 'Header Table' trong FP-Growth giúp ích gì trong quá trình khai phá?

A. Dùng để đếm tổng số lượng giao dịch của hệ thống

B. Cung cấp điểm bắt đầu (head pointer) để duyệt nhanh toàn bộ các nút của một mặt hàng cụ thể trên cây qua các node-link

C. Lưu trữ toàn bộ nội dung của các giao dịch trong cơ sở dữ liệu

D. Thay thế hoàn toàn cho bước sắp xếp danh sách F-list

Câu 400: Nếu chỉ số Lift(A => B) < 1, ta hiểu mối quan hệ giữa hai mặt hàng A và B như thế nào?

A. A và B có tương quan nghịch (sự xuất hiện của A làm giảm khả năng xuất hiện của B / mặt hàng thay thế)

B. A và B hoàn toàn độc lập và không ảnh hưởng gì đến nhau

C. A và B có mối quan hệ tương quan thuận (mua A kéo theo mua B)

D. Hai mặt hàng luôn luôn được mua cùng nhau trong mọi giao dịch

Câu 401: Giải thích khái niệm 'Conditional FP-tree' (Cây FP-tree có điều kiện):

A. Là cây chỉ chứa duy nhất các nút lá mà không có nút trung gian

B. Là bảng mở rộng của Header Table không chứa cây

C. Là cây FP-tree ban đầu của toàn bộ cơ sở dữ liệu

D. Là cây FP-tree được xây dựng từ tập dữ liệu rút gọn (conditional pattern base) chứa một mục phổ biến đang xét

Câu 402: Tại sao việc 'Sắp xếp các mặt hàng theo tần số giảm dần' lại được coi là nguyên tắc then chốt của cấu trúc FP-tree?

A. Vì nó giúp người lập trình dễ đọc dữ liệu hơn

B. Vì các mục xuất hiện nhiều nhất nằm gần gốc, tối đa hóa việc dùng chung các nút và tăng độ nén dữ liệu

C. Vì Header Table bắt buộc phải có thứ tự bảng chữ cái

D. Để dễ dàng tính toán chỉ số Lift của các luật

Câu 403: Khi một cây FP-tree chỉ có một đường dẫn tiền tố duy nhất (Single Prefix Path), thuật toán có lợi thế gì?

A. Cây không thể tiếp tục khai phá được nữa

B. Có thể sinh trực tiếp mọi tổ hợp mẫu phổ biến bằng tổ hợp các nút trên đường dẫn mà không cần xây dựng thêm cây điều kiện

C. Làm tăng gấp đôi thời gian tính toán của giải thuật

D. Chỉ sinh được duy nhất một luật kết hợp

Câu 404: Tại sao khai phá luật kết hợp lại đóng vai trò quan trọng trong phân tích Web log (Web Usage Mining)?

A. Để tự động chặn các địa chỉ IP truy cập bất thường

B. Để thiết kế bảng màu giao diện website

C. Để phát hiện các cụm trang web thường được người dùng duyệt cùng nhau trong một phiên (Session) nhằm tối ưu hóa liên kết và gợi ý trang

D. Để đếm tổng số lượt người dùng truy cập trang chủ

Câu 405: Giải thích vai trò của nút 'null' (Root) trong cây FP-tree:

A. Là giá trị mặc định khi cây FP-tree bị đầy bộ nhớ

B. Là nút chứa các giao dịch bị lỗi hoặc bị thiếu giá trị

C. Là nút chứa các mặt hàng có độ hỗ trợ thấp nhất trong CSDL

D. Là nút gốc không mang giá trị mặt hàng, dùng làm điểm xuất phát chung cho tất cả các nhánh giao dịch trên cây

Câu 406: Tại sao giải pháp Phân hoạch (Partitioning) lại chỉ cần quét cơ sở dữ liệu đúng 2 lần để tìm toàn bộ tập phổ biến?

A. Vì phương pháp này sử dụng cấu trúc cây FP-tree trong mỗi phân hoạch

B. Lần 1 tìm các tập phổ biến cục bộ trong từng phân hoạch để gom thành tập ứng viên toàn cục; lần 2 đếm hỗ trợ thực tế trên toàn CSDL

C. Lần 1 tìm các luật mạnh, lần 2 kiểm tra lại độ tin cậy

D. Vì thuật toán chỉ áp dụng được cho cơ sở dữ liệu có quy mô dưới 100 giao dịch

Câu 407: Kỹ thuật đệ quy (Recursion) trong thuật toán FP-Growth được áp dụng tại bước nào?

A. Khi xây dựng các cây FP-tree có điều kiện (conditional FP-trees) cho các mẫu phổ biến dài hơn

B. Khi tính toán độ tin cậy của các luật kết hợp

C. Khi sắp xếp danh sách các mục trong Header Table

D. Khi quét cơ sở dữ liệu lần đầu tiên để tạo F-list

Câu 408: Cho cơ sở dữ liệu 4 giao dịch: T100{1, 3, 4}, T200{2, 3, 5}, T300{1, 2, 3, 5}, T400{2, 5}. Với ngưỡng min_sup count = 2, hãy tìm tập các mục phổ biến 1 phần tử L_1:

A. {1}:2, {2}:3, {3}:3, {5}:3

B. {1, 2, 3, 5}

C. {2, 3, 5}

D. {1}:2, {2}:3, {3}:3, {4}:1, {5}:3

Câu 409: Dựa trên tập L_1 = {1, 2, 3, 5} ở câu trên, tập ứng viên 2 phần tử C_2 sinh ra sau bước Join gồm bao nhiêu tập mục?

A. 4 tập mục

B. 3 tập mục

C. 12 tập mục

D. 6 tập mục

Câu 410: Trong CSDL trên với min_sup count = 2, tập mục {1, 3} có phải là tập phổ biến không?

A. Có, vì support count của nó bằng 2

B. Có, vì nó nằm trọn vẹn trong giao dịch T100

C. Không, vì mục 1 không phải là mục phổ biến

D. Không, vì support count của nó chỉ bằng 1

Câu 411: Cho CSDL 4 giao dịch: T10{A,C,D}, T20{B,C,E}, T30{A,B,C,E}, T40{B,E}. Đặt min_sup = 0.5 (50%), giá trị min_sup count (ngưỡng số lần xuất hiện tối thiểu) là:

A. 1

B. 3

C. 4

D. 2

Câu 412: Trong CSDL trên, tập phổ biến 2 phần tử L_2 nào có độ hỗ trợ lớn nhất?

A. {A, C}

B. {C, E}

C. {B, C}

D. {B, E}

Câu 413: Theo kết quả khai phá trên CSDL trên với min_sup = 50%, tập phổ biến 3 phần tử L_3 duy nhất là:

A. {A, C, E}

B. {A, B, C}

C. Không tồn tại tập phổ biến 3 phần tử nào

D. {B, C, E}

Câu 414: Cho CSDL 5 giao dịch: 100{f,c,a,m,p}, 200{f,c,a,b,m}, 300{f,b}, 400{c,b,p}, 500{f,c,a,m,p}. Đặt min_sup = 3. Hãy xác định danh sách F-list sắp xếp theo tần số giảm dần:

A. f - c - b - a - m - p

B. f - c - a - b - m - p

C. a - b - c - f - m - p

D. f - c - a - m - p - b

Câu 415: Cho L_3 = {{a,b,c}, {a,b,d}, {a,c,d}, {a,c,e}, {b,c,d}}. Sau bước Join của thủ tục Apriori-gen, các ứng viên 4 phần tử C_4 nào được sinh ra?

A. {a,b,c,d,e}

B. {a,b,c,d} duy nhất

C. {a,b,c,d}, {a,b,c,e}, {b,c,d,e}

D. {a,b,c,d}, {a,c,d,e}

Câu 416: Nếu một giao dịch thực tế là {f, a, c, d, g, i, m, p} và danh sách F-list chuẩn là f - c - a - b - m - p, danh sách các mục phổ biến được lọc và sắp xếp để chèn vào cây FP-tree sẽ là:

A. {a, c, f, m, p}

B. {f, c, a, b, m, p}

C. {f, c, a, m, p}

D. {f, a, c, m, p}

Câu 417: Nếu ngưỡng min_sup được đặt là 60% và cơ sở dữ liệu có 5 giao dịch, một tập mục cần xuất hiện trong ít nhất bao nhiêu giao dịch để được coi là tập phổ biến?

A. 3 giao dịch

B. 5 giao dịch

C. 4 giao dịch

D. 2 giao dịch

Câu 418: Cho một giao dịch T = {1, 2, 5} và tập các ứng viên C_2 = {{1, 2}, {1, 3}, {1, 5}, {2, 3}, {2, 5}, {3, 5}}. Khi duyệt qua giao dịch T, những ứng viên nào trong C_2 sẽ được tăng bộ đếm hỗ trợ lên 1?

A. Chỉ duy nhất ứng viên {1, 2}

B. {1, 2}, {1, 5}, {2, 5}

C. Không có ứng viên nào được tăng

D. Tất cả 6 ứng viên trong C_2

Câu 419: KDD là viết tắt của:

A. Knowledge Discovery in Databases

B. Knowledge Domain Design for Databases

C. Knowledge Decision Development in Business

D. Key Data Distribution in Databases

Câu 420: Thuật toán ECLAT sử dụng định dạng dữ liệu nào để khai phá tập phổ biến?

A. Định dạng ma trận nhị phân thưa

B. Định dạng ngang (Horizontal data format: TID -> Itemset)

C. Định dạng cây quyết định phân tầng

D. Định dạng dọc (Vertical data format: Item -> TID-list)

Câu 421: Trong câu chuyện kinh điển 'Bia và Bỉm' (Beer and Diapers), mục tiêu của bài toán là tìm:

A. Khách hàng nào uống bia nhiều nhất trong tháng

B. Mức giá bán tối ưu nhất cho sản phẩm bia

C. Số lượng bỉm tồn kho cần thanh lý

D. Mối quan hệ mua kèm bất ngờ giữa các nhóm sản phẩm để tối ưu chiến lược bán hàng

Câu 422: 'Conditional pattern base' (Cơ sở mẫu điều kiện) của một mục được xây dựng từ đâu?

A. Từ toàn bộ cơ sở dữ liệu gốc chưa qua xử lý

B. Từ tập hợp các đường dẫn tiền tố (prefix paths) kết thúc bằng mục đang xét kèm theo số đếm của chúng

C. Từ danh sách các mục bị loại bỏ trong F-list

D. Từ tập ứng viên C_k trong Apriori

Câu 423: Khai phá mẫu phổ biến (Frequent Pattern Mining) là nền tảng cốt lõi cho các bài toán nào sau đây?

A. Phân cụm dữ liệu phi cấu trúc

B. Làm sạch và điền giá trị thiếu của dữ liệu

C. Giảm chiều dữ liệu bằng phép chiếu ma trận

D. Phân lớp kết hợp (Associative Classification), phân tích tương quan và khai phá mẫu tuần tự

Câu 424: Sự kiện kinh điển 'Bia và Bỉm' (Beer & Diaper) minh họa cho giá trị thực tiễn nào của khai phá dữ liệu?

A. Siêu thị nên đặt quầy bia và quầy bỉm ở hai đầu xa nhau nhất để khách phải đi bộ nhiều

B. Bia là mặt hàng có doanh thu cao nhất trong siêu thị

C. Khách hàng mua bia thì luôn luôn mua thêm đồ nhắm

D. Mối liên hệ bất ngờ giữa các mặt hàng không liên quan trực tiếp giúp ích cho chiến lược bán hàng và sắp xếp gian hàng

Câu 425: Tác động của việc tăng ngưỡng 'min_sup' lên kết quả khai phá là gì?

A. Không có bất kỳ thay đổi nào về số lượng mẫu tìm thấy

B. Độ tin cậy của tất cả các luật sẽ tự động giảm đi một nửa

C. Số lượng tập phổ biến tìm được sẽ tăng lên đáng kể

D. Số lượng tập phổ biến tìm được sẽ giảm xuống và thời gian thực thi của thuật toán sẽ nhanh hơn

Câu 426: Tại sao trong khai phá chuỗi sinh học và DNA, khai phá mẫu phổ biến lại được áp dụng rộng rãi?

A. Để tính toán chiều dài vật lý của chuỗi nhiễm sắc thể

B. Để phân loại hình thái bên ngoài của các loài sinh vật

C. Để trực tiếp thay đổi và chỉnh sửa cấu trúc gen di truyền

D. Để phát hiện các đoạn motif hoặc tổ hợp đột biến gen thường xuyên đồng xuất hiện cùng nhau liên quan đến bệnh lý

Câu 427: Với CSDL trên và min_sup = 50%, tập các mục phổ biến 1 phần tử L_1 gồm những mục nào?

A. {A, B, C, D, E}

B. {A, C}

C. {A, B, C, E}

D. {B, C, E}

Câu 428: Tiếp tục từ kết quả câu trên với L_3 = {{a,b,c}, {a,b,d}, {a,c,d}, {a,c,e}, {b,c,d}}, sau bước Prune (Tỉa), tại sao ứng viên {a,c,d,e} lại bị loại khỏi C_4?

A. Vì tập con {a,d,e} không thuộc L_3

B. Vì support count của nó nhỏ hơn min_sup

C. Vì tập con {a,c,d} không thuộc L_3

D. Vì tập con {a,c,e} không thuộc L_3

Câu 429: Cho cơ sở mẫu điều kiện gồm 2 đường dẫn tiền tố: {f, c, a}: 2 và {f, c, b}: 1. Với ngưỡng min_sup = 3, những mục nào sẽ được giữ lại trong cây điều kiện?

A. {f, c}

B. {f, c, a}

C. Không có mục nào đạt chuẩn

D. {f, c, b}

Câu 430: Tập mục (Itemset) là gì?

A. Một giao dịch đơn lẻ duy nhất trong cơ sở dữ liệu

B. Một tập hợp gồm một hoặc nhiều mặt hàng (items)

C. Một chỉ số định danh giao dịch (TID)

D. Một quy tắc suy diễn nhân quả giữa các biến

HẾT