TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH

KHAI PHÁ DỮ LIỆU

CHƯƠNG 2

TIỀN XỬ LÝ DỮ LIỆU

Bộ môn Khoa học máy tính - Khoa Hệ thống thông tin quản lý


H U B
1976
TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH

Mục tiêu

- Giải thích các nhiệm vụ tiền xử lý dữ liệu.
- Vận dụng kỹ thuật tiền xử lý dữ liệu vào một tập dữ liệu cụ thể
- Sử dụng công cụ để thực hiện tiền xử lý dữ liệu.

Nội dung

1. Tổng quan về giai đoạn tiền xử lý dữ liệu
2. Mô tả tóm tắt về dữ liệu
3. Làm sạch dữ liệu
4. Tích hợp dữ liệu
5. Chuyển đổi dữ liệu
6. Rút gọn dữ liệu
7. Rời rạc hóa dữ liệu

1. Tổng quan về giai đoạn tiền xử lý dữ liệu

- Trước khi thực hiện bước khai phá dữ, khả năng dữ liệu có thể bị nhiễu, không đầy đủ và không nhất quán

1. Những vấn đề cơ bản để hiểu dữ liệu

Thu thập dữ liệu (*Data Acquisition*)

- Cách thu thập được dữ liệu cần thiết để mô hình hóa

Tích hợp dữ liệu (Data Integration)

- Cách kết hợp dữ liệu tìm được từ các nguồn dữ liệu khác nhau

Mô tả dữ liệu (Data Description)

Đánh giá dữ liệu (Data Assessment)

- Đánh giá chất lượng (độ sạch) của dữ liệu

1.1 Thu thập dữ liệu

- Cách thu thập dữ liệu cần thiết để mô hình hóa
  - Trích chọn dữ liệu theo câu hỏi từ CSDL tới tập tin phẳng (Flat file)
  - Dùng ngôn ngữ truy vấn bậc cao vào CSDL
  - Kết nối mức thấp để truy nhập trực tiếp CSDL
    - Loại bỏ ràng buộc không gian/thời gian khi di chuyển khối lượng lớn dữ liệu
    - Hỗ trợ việc quản lý và bảo quản dữ liệu tập trung hóa
    - Rút gọn sự tăng không cần thiết của dữ liệu
    - Tạo điều kiện quản trị dữ liệu tốt hơn để đáp ứng mối quan tâm đúng đắn

1.2 Tích hợp dữ liệu

- Cách kết hợp dữ liệu tìm được từ các nguồn dữ liệu khác nhau

File #1: Name & Address

Name	Address	City	State	Zipcode
John Brown	1234 E St.	Chicago	IL	60610
Jean Blois	300 Day St.	Houston	TX	77091
Neal Smith	325 Clay St.	Portland	OR	97201

File #2: Product

Name	Address	Product	Sales Date
John Brown	1234 E. St.	Mower	1/3/2007
John Brown	1234 E. St.	Rake	4/16/2006
Neal Smith	325 Clay St.	Shovel	8/23/2005
Jean Blois	300 Day St.	Hoe	9/28/2007

Name	Address	City	State	Zipcode	Product1	Product2
John Brown	1234 E. St.	Chicago	IL	60610	Mower	Rake
Neal Smith	325 Clay St.	Portland	OR	97201	Shovel	
Jean Blois	300 Day St.	Houston	TX	77091	Hoe	

2. Vai trò của tiền xử lý dữ liệu

- Không có dữ liệu tốt, không thể có kết quả khai phá tốt!
  - Quyết định chất lượng phải dựa trên dữ liệu chất lượng
    - Chẳng hạn, dữ liệu bội hay thiếu là nguyên nhân thống không chính xác, thậm chí gây hiểu nhầm.
  - Kho dữ liệu cần tích hợp nhất quán của dữ liệu chất lượng
- Phân lớn công việc xây dựng một kho dữ liệu là trích chọn, làm sạch và chuyển đổi dữ liệu —Bill Inmon .
- Dữ liệu có chất lượng cao nếu như phù hợp với mục đích sử dụng trong điều hành, ra quyết định, và lập kế hoạch

Kiểu dữ liệu (Data types)

- **Tập dữ liệu** (Data sets) được tạo thành từ các **đối tượng dữ liệu** (Data objects)
- **Đối tượng dữ liệu** thể hiện cho **thực thể** (*entity*)
- Ví dụ: Trong **cơ sở dữ liệu bán hàng** (*sales database*) sẽ có các đối tượng dữ liệu như khách hàng (*customers*), hàng hóa (*items*), đơn hàng (*sales*),... Hoặc trong cơ sở dữ liệu y tế có các đối tượng dữ liệu như bệnh nhân (*patients*),... trong cơ sở dữ liệu của trường đại học có các đối tượng như sinh viên (*students*), giảng viên (*professors*), học phần (*courses*).
- Đối tượng dữ liệu đôi khi được đề cập như ***mẫu*** *(samples), ví dụ (examples),* ***thể hiện*** *(instances),* ***điểm dữ liệu*** *(data points), hoặc* ***đối tượng*** *(objects)*

Kiểu dữ liệu (Data types)

- Đối tượng dữ liệu nếu được lưu trữ trong cơ sở dữ liệu thường được gọi là **bộ dữ liệu** (*data tupes*)

	SalesOrderID	OrderDate	Status	SalesOrderNumber	PurchaseOrderNumber	AccountNumber	CustomerID	SalesPersonID	TerritoryID
1	43659	2011-05-31 00:00:00.000	5	SO43659	PO522145787	10-4020-000676	29825	279	5
2	43660	2011-05-31 00:00:00.000	5	SO43660	PO18850127500	10-4020-000117	29672	279	5
3	43661	2011-05-31 00:00:00.000	5	SO43661	PO18473189620	10-4020-000442	29734	282	6
4	43662	2011-05-31 00:00:00.000	5	SO43662	PO18444174044	10-4020-000227	29994	282	6
5	43663	2011-05-31 00:00:00.000	5	SO43663	PO18009186470	10-4020-000510	29565	276	4
6	43664	2011-05-31 00:00:00.000	5	SO43664	PO16617121983	10-4020-000397	29898	280	1
7	43665	2011-05-31 00:00:00.000	5	SO43665	PO16588191572	10-4020-000146	29580	283	1
8	43666	2011-05-31 00:00:00.000	5	SO43666	PO16008173883	10-4020-000511	30052	276	4
9	43667	2011-05-31 00:00:00.000	5	SO43667	PO15428132599	10-4020-000646	29974	277	3
10	43668	2011-05-31 00:00:00.000	5	SO43668	PO14732180295	10-4020-000514	29614	282	6
11	43669	2011-05-31 00:00:00.000	5	SO43669	PO14123169936	10-4020-000578	29747	283	1
12	43670	2011-05-31 00:00:00.000	5	SO43670	PO14384116310	10-4020-000504	29566	275	3
13	43671	2011-05-31 00:00:00.000	5	SO43671	PO13978119376	10-4020-000200	29890	283	1
14	43672	2011-05-31 00:00:00.000	5	SO43672	PO13862153537	10-4020-000119	30067	282	6

Mỗi **dòng dữ liệu** (*data row*) thể hiện cho một đối tượng dữ liệu
Mỗi **cột** *(column)* thể hiện cho một **thuộc tính** (*attribute*)

Thuộc tính (attribute)

- **Thuộc tính** là một **trường dữ liệu** (*data field*), thể hiện một **đặc tính** (*characteristic*) hoặc **đặc trưng** (*feature*) của một đối tượng dữ liệu.
- Các thuật ngữ thuộc tính (*attribute)*, chiều (*dimension)*, đặc trưng (*feature)*, và biến (*variable)* thường được dùng thay thế cho nhau.
  - **Chiều** thường được dùng trong kho dữ liệu (data warehouse)
  - **Đặc trưng** thường được dùng trong học máy (machine learning)
  - **Biến** thường được dùng trong thống kê
- **Kiểu (*type*)** của thuộc tính được xác định bởi tập hợp các giá trị có thể có của nó. Có các kiểu:
  - **Định danh/danh nghĩa** (*nominal*),
  - **Nhị phân** (*binary*),
  - **Có thứ tự/thức bậc** (*ordinal*)
  - **Số** (*numeric*)

Kiểu thuộc tính

- Định danh: lớp, trạng thái, hoặc "tên đồ vật"
  - Hair_color = {auburn, black, blond, brown, grey, red, white}
  - Tình trạng hôn nhân (marital status), nghề nghiệp (occupation), số ID (ID numbers), mã zip bưu điện (zip codes)
- Nhị phân
  - Thuộc tính định danh hai trạng thái (0 và 1)
  - Nhị phân đối xứng: Cả hai kết quả quan trọng như nhau
    - Chẳng hạn, giới tính
  - Nhị phân bất đối xứng: kết quả không quan trọng như nhau.
    - Chẳng hạn, kiểm tra y tế (tích cực/tiêu cực)
    - Quy ước: gán 1 cho kết quả quan trọng nhất (chẳng hạn, dương tính HIV)
- Có thứ tự
  - Thứ tự các giá trị mang ý nghĩa (xếp hạng) nhưng độ lớn các giá trị liên kết: không được biết
  - Size = {small, medium, large}, grades, army rankings

Kiểu thuộc tính số

- Có tính định lượng (*quantitative*), nó là đại lượng có thể đo lường được, được biểu thị bằng số nguyên hoặc số thực. Nó có thang đo khoảng hoặc tỉ lệ.
- Thang đo khoảng (*interval-scaled*)
  - Được đo theo kích thước các đơn vị cùng kích thước
  - Các giá trị có thứ tự
    - Chẳng hạn, nhiệt độ theo C°hoặc F°, ngày lịch
  - Không làm điểm "true zero-point"
- Thang đo tỷ lệ (*ratio-scaled*)
  - zero-point vốn có
  - Các giá trị là một thứ bậc của độ đo so với đơn vị đo lường (10 K° là hai lần cao hơn 5 K°).
    - Ví dụ, nhiệt độ theo Kelvin, độ dài đếm được, tổng số đếm được, số lượng tiền

Thuộc tính rời rạc và liên tục

- Thuộc tính rời rạc (*Discrete*)
  - Chỉ có một tập hữu hạn hoặc hữu hạn đếm được các giá trị
    - Chẳng hạn, mã zip, nghề nghiệp hoặc tập các từ trong một tập tài liệu
  - Đôi lúc trình bày như các biến nguyên
  - Lưu ý: Thuộc tính nhị phân là trường hợp riêng của thuộc tính rời rạc
- Thuộc tính liên tục (*Continuous*)
  - Có rất nhiều các giá trị thuộc tính
    - Như nhiệt độ, chiều cao, trong lượng
  - Thực tế, giá trị thực chỉ tính và trình bảng bằng sử dụng một hữu hạn chữ số
  - Thuộc tính liên tục được trình bày phổ biến như biến dấu phẩy động

Thống kê mô tả dữ liệu

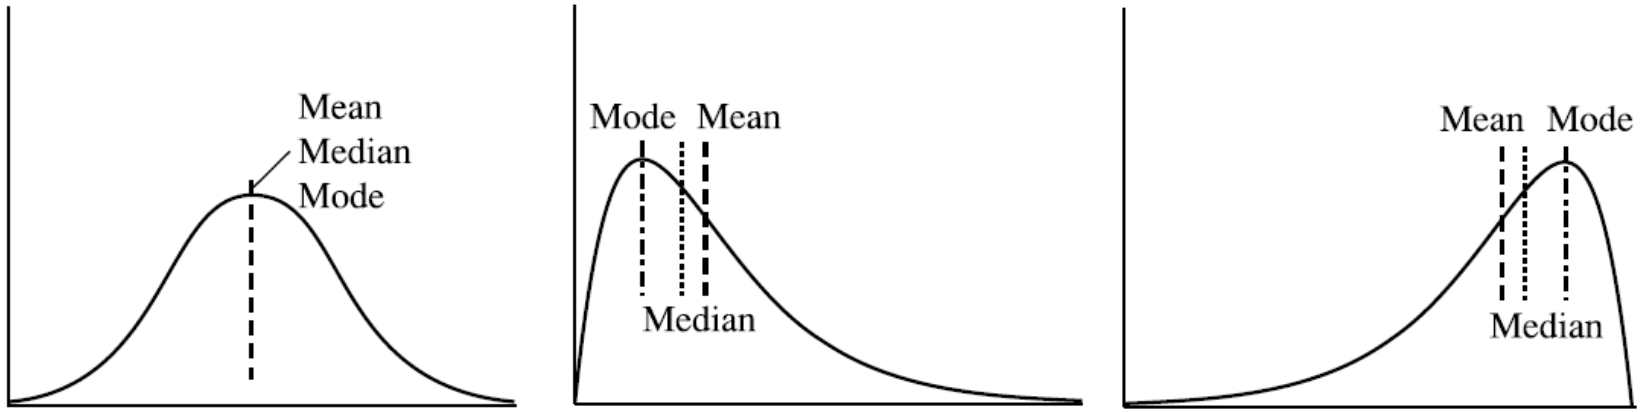
- Đo độ tập trung của dữ liệu
- Đo độ phân tán của dữ liệu
- Trực quan dữ liệu

Đo độ tập trung của dữ liệu

- Trung bình (mean)
- Trung vị (median)
- Mode

$$\bar{x} = \frac{\sum_{i=1}^{N} x_i}{N} = \frac{x_1 + x_2 + \cdots + x_N}{N}.$$

$$median \approx L_1 + \left(\frac{N/2 - (\sum freq)_l}{freq_{median}} \right) \times width,$$



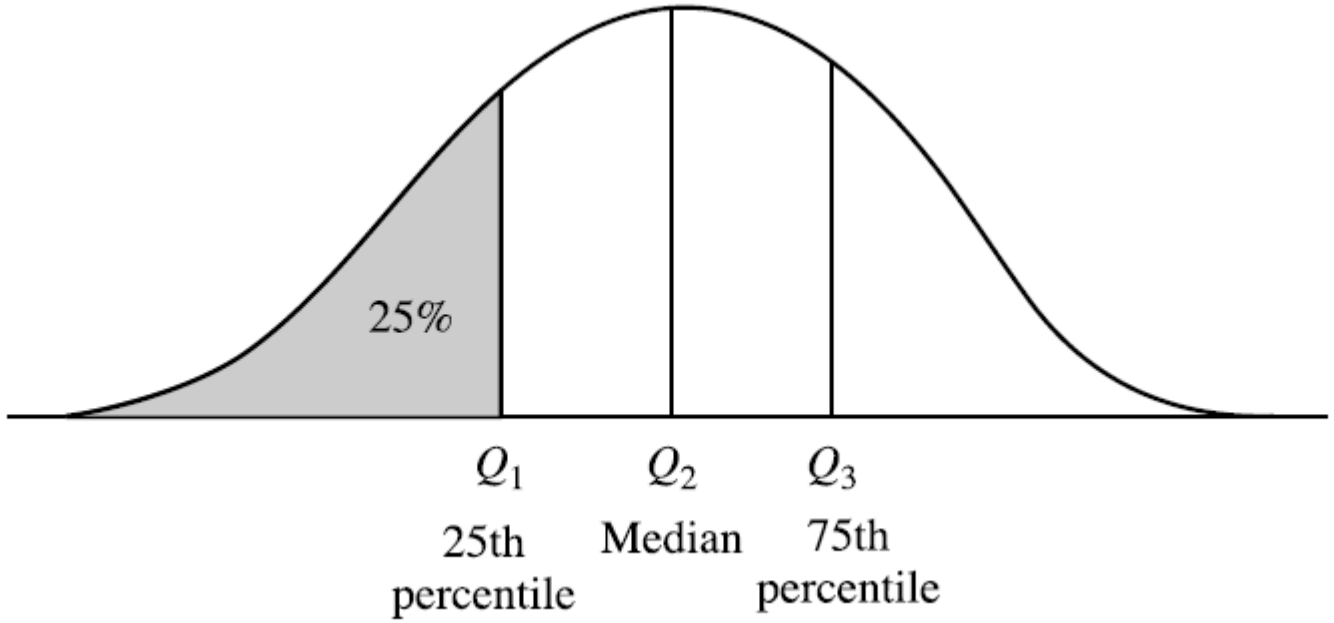
(a) Symmetric data (b) Positively skewed data (c) Negatively skewed data

Một số độ đo thống kê

- Độ lệch chuẩn (Standard deviation)
  - Phân bố dữ liệu xung quanh kỳ vọng
- Cực tiểu (Minimum) và Cực đại (Maximum)
  - Giá trị nhỏ nhất và Giá trị lớn nhất
- Đô đo phân tán
  - [Min, Max]: giá trị k% là giá trị x sao cho
  - $|y \in D: min \leq y \leq x|/|y \in D| = k\%$
  - Q1=25%, Q2=50%, Q3=75%
  - interquartile range (IQR): Q3-Q1
  - Min, Q1, Median, Q3, Max
- Bảng tần suất (Frequency tables)
  - Phân bố tần suất giá trị của các biến
- Lược đồ (Histograms)
  - Cung cấp kỹ thuật đồ họa biểu diễn tần số giá trị của một biến

Đo độ phân tán của dữ liệu

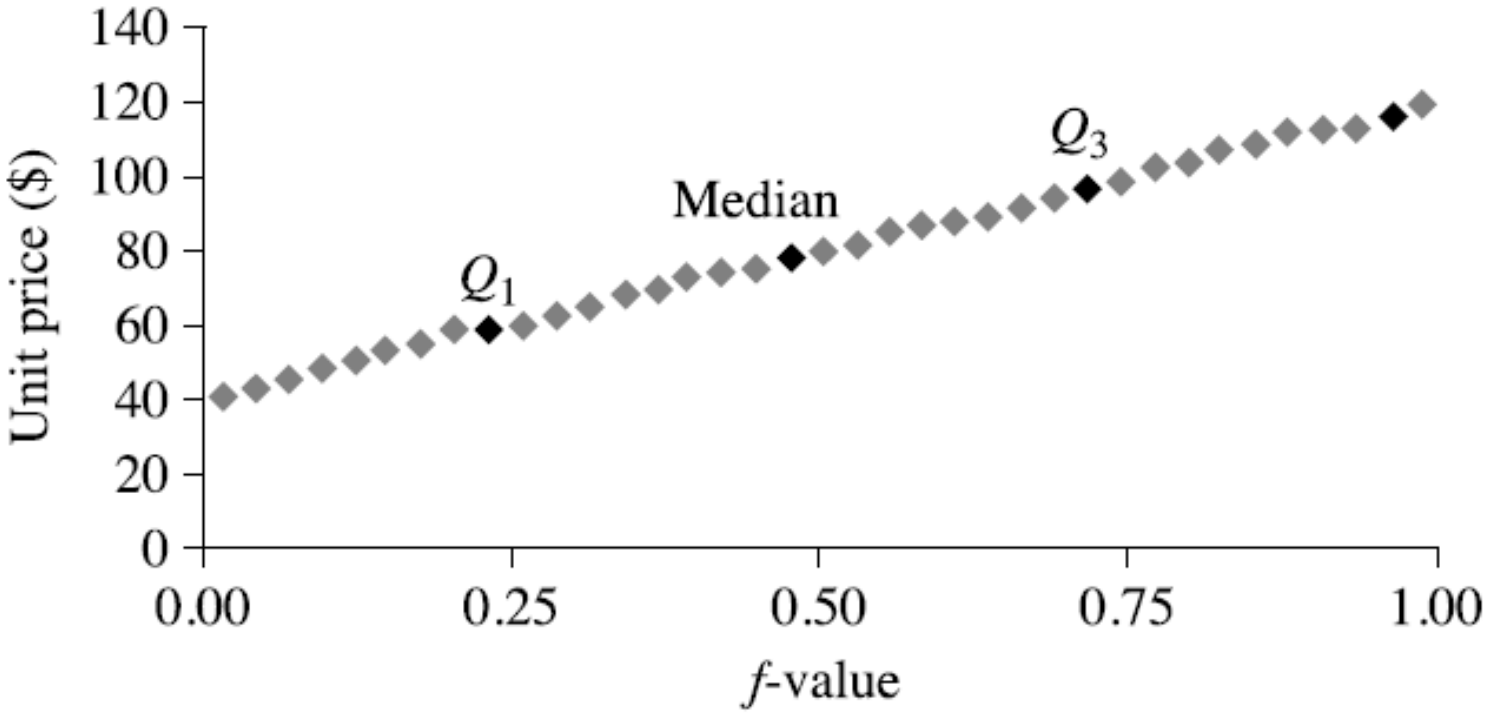
- Khoảng biến thiên (*Range*)
- Tứ phân vị (*Quartiles*)
- Khoảng phân vị (*Interquartile range* IQR)



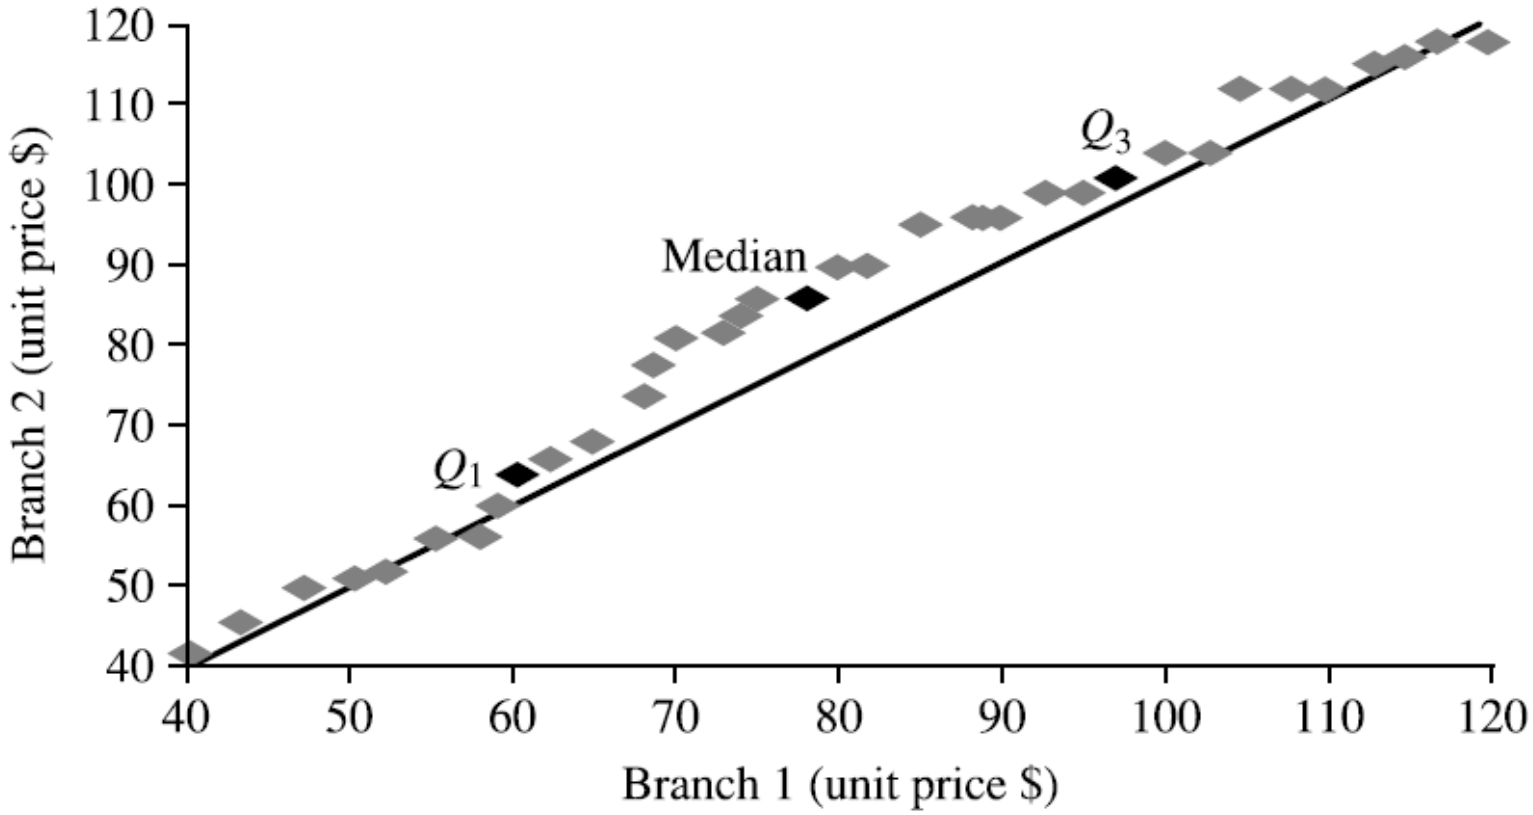
Biểu đồ trực quan

- Quantile plot
- Quantile-quantile plot
- Histograms
- Scatter plots
- Boxplot

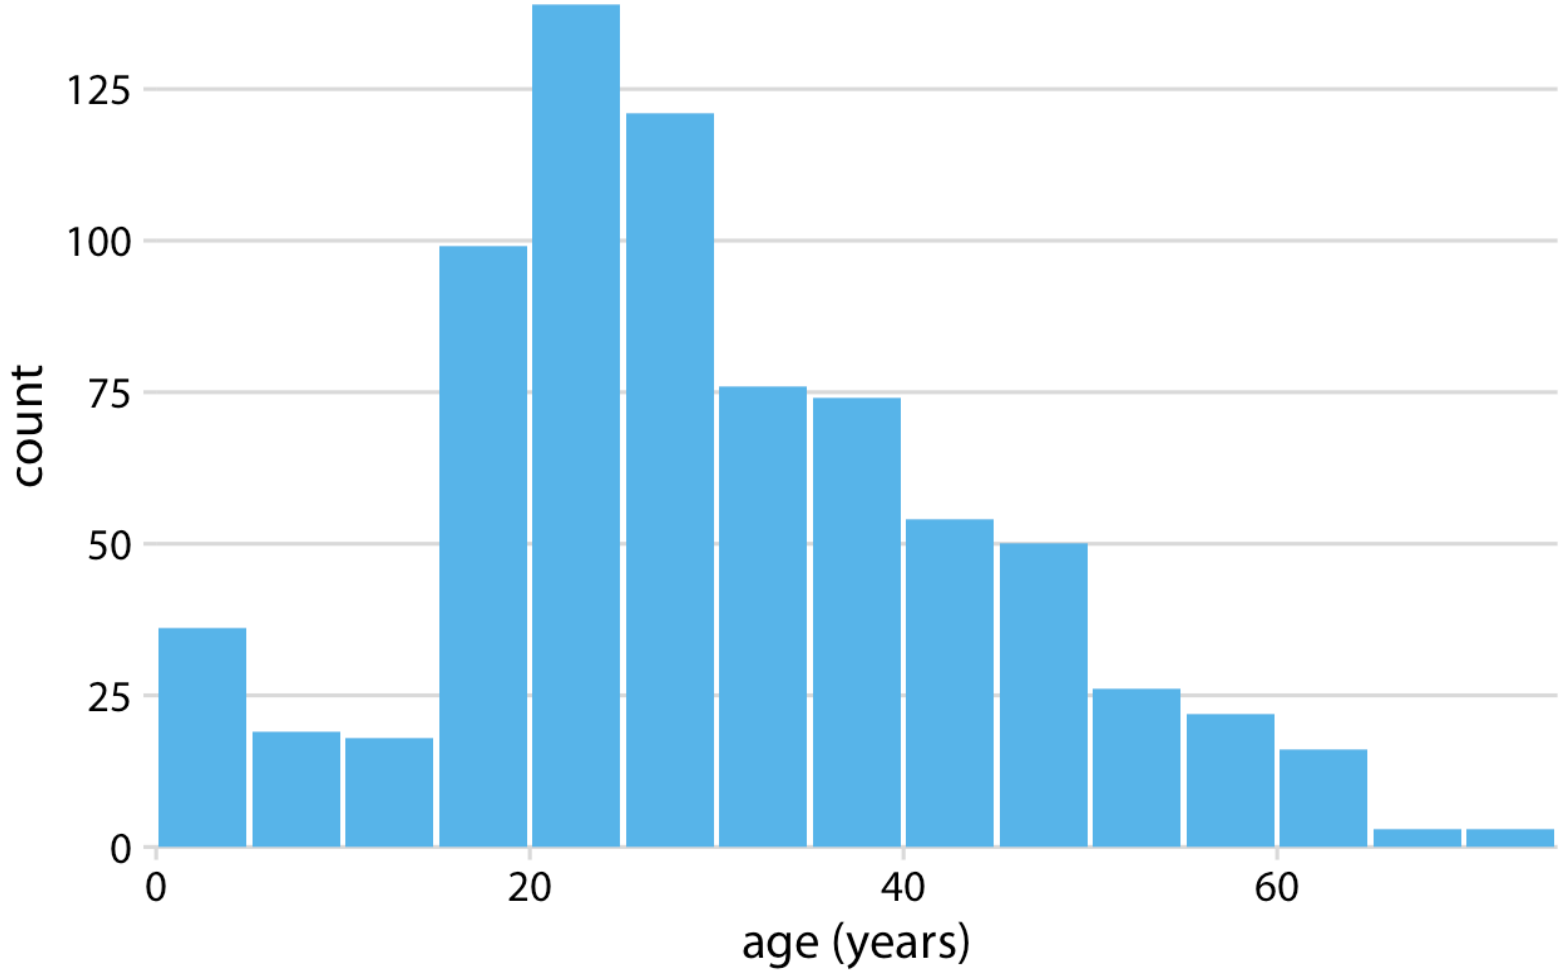
Quantile plot



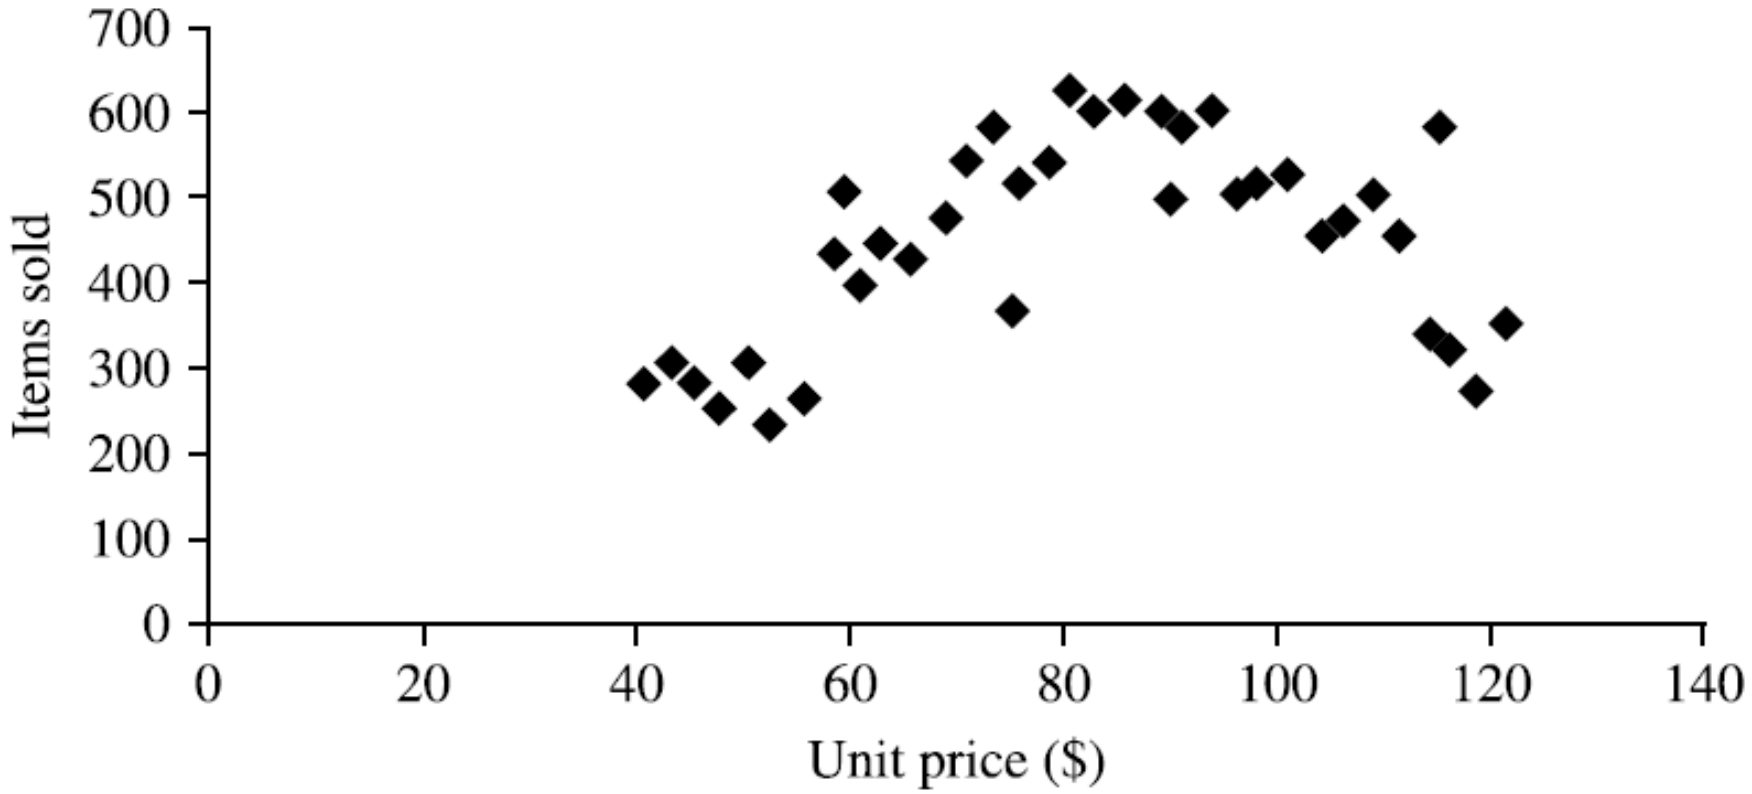
Quantile-quantile plot



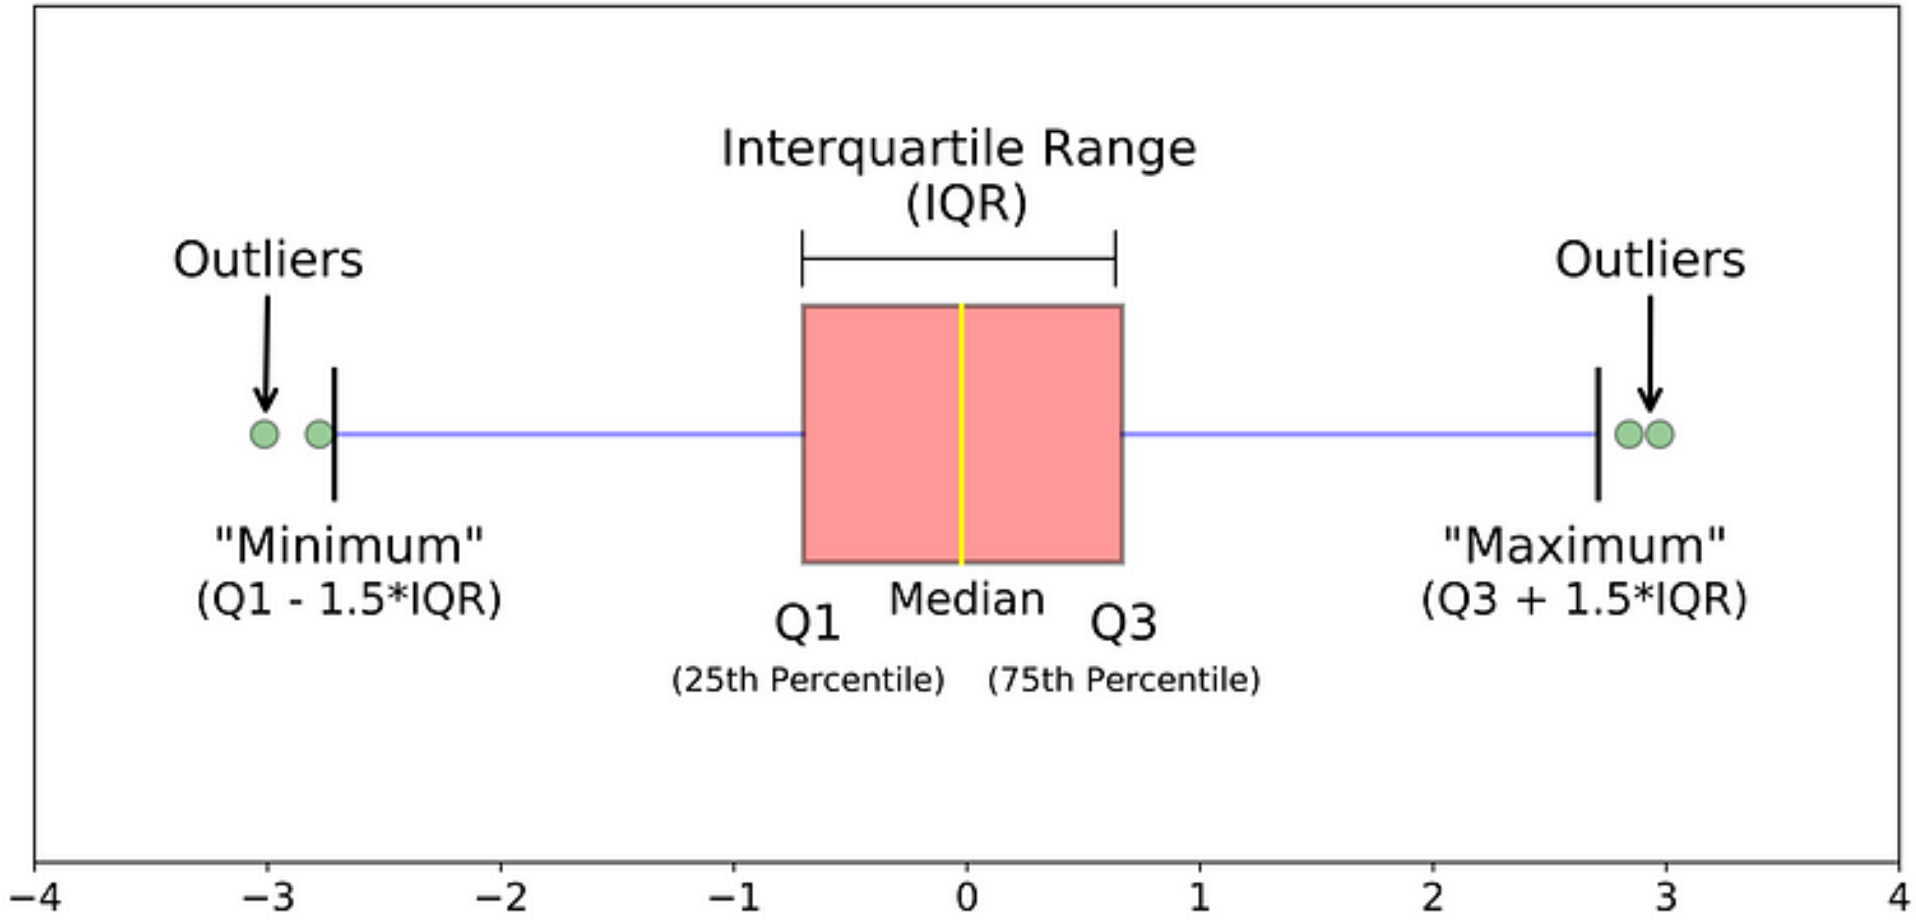
Histograms



Scatter plots and data correlation

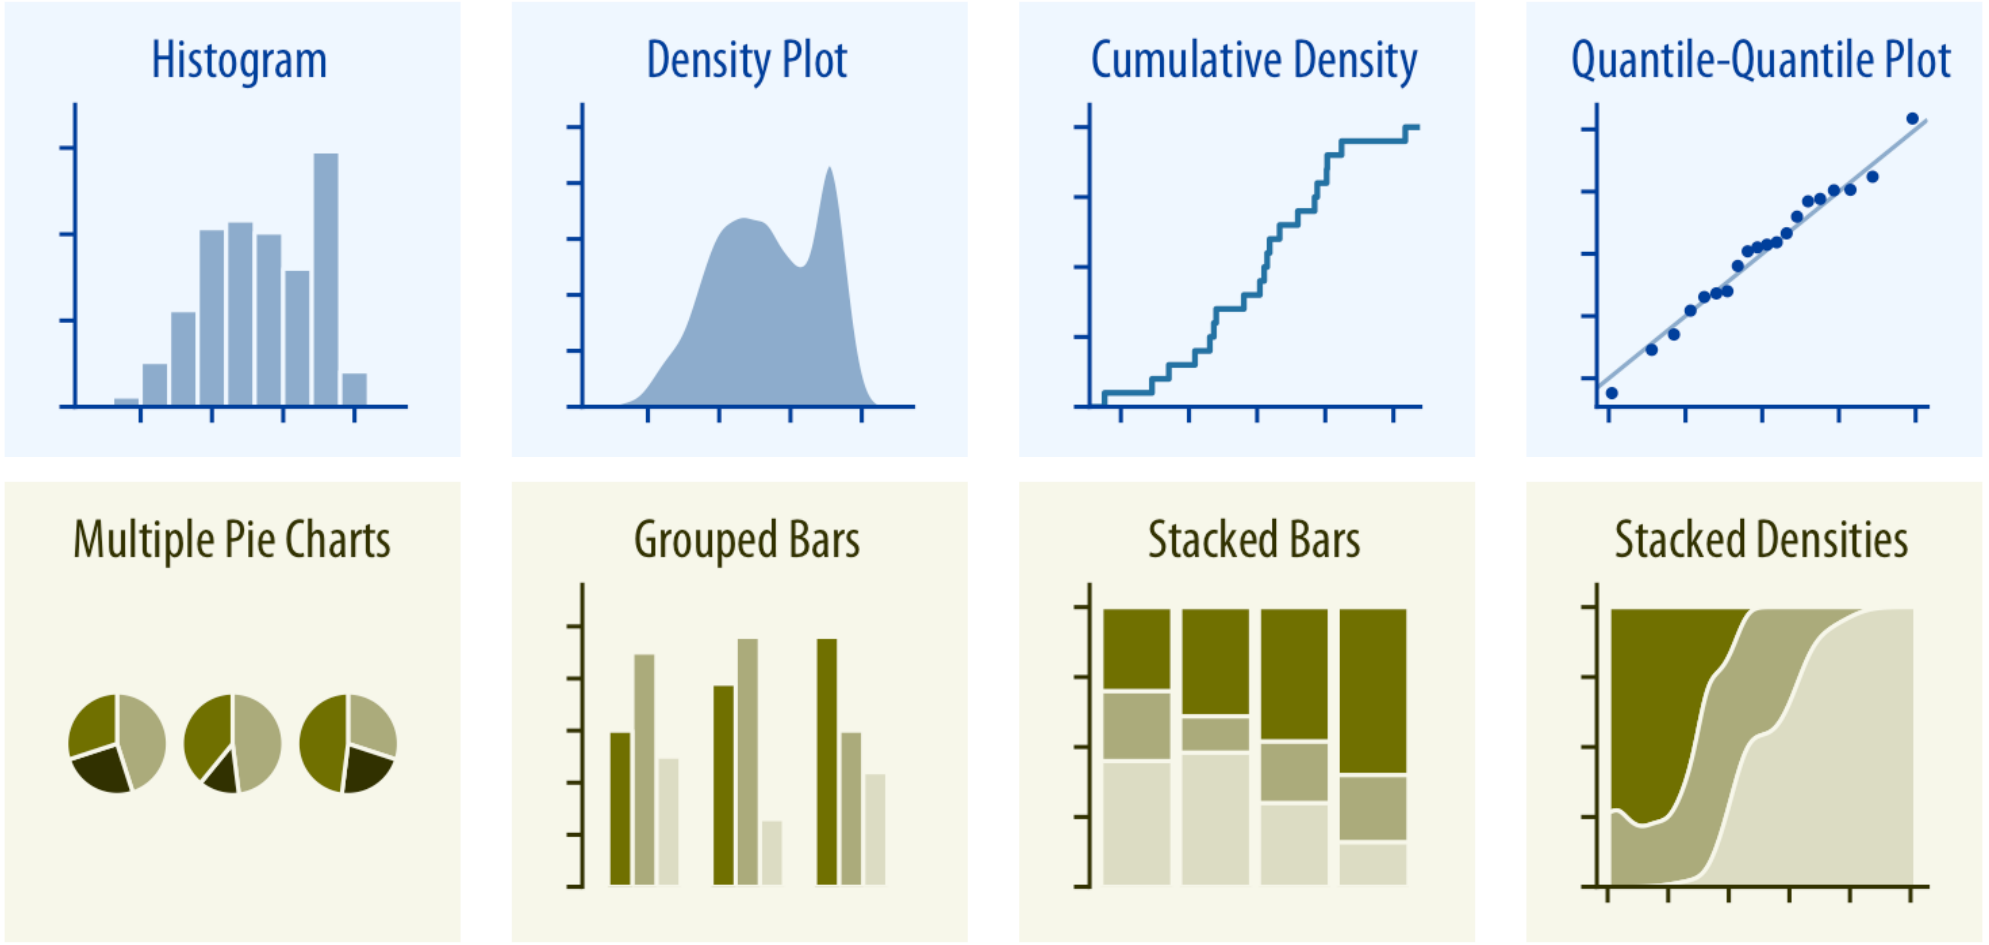


Biểu diễn giá trị dữ liệu: Biểu đồ hộp (Boxplot)



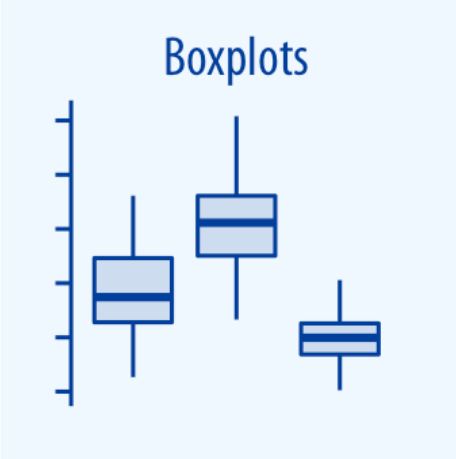
https://machinelearningcoban.com/tabml_book/ap/visualization.html

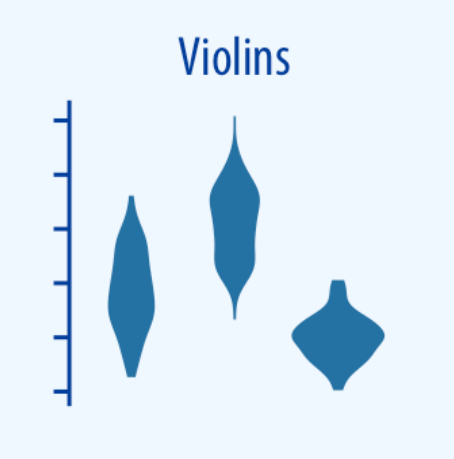
Mô tả dữ liệu: trực quan hóa

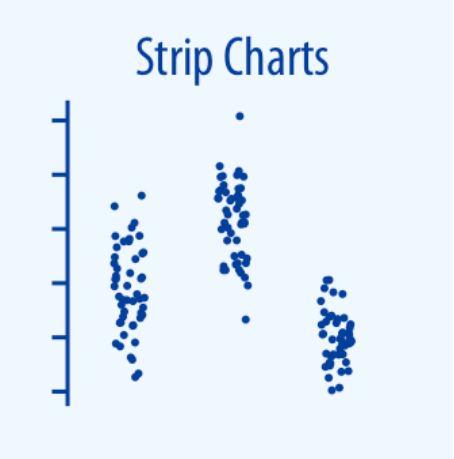


Claus O. Wilke , Fundamentals of Data Visualization

Mô tả dữ liệu: trực quan hóa

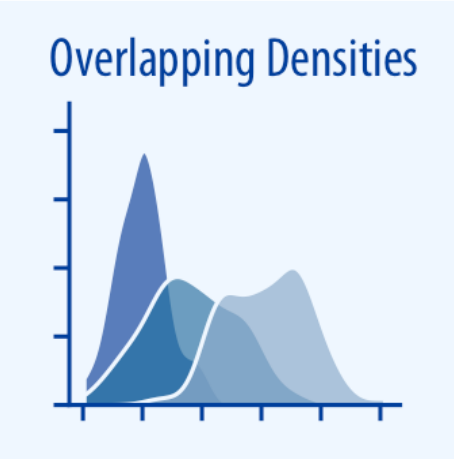


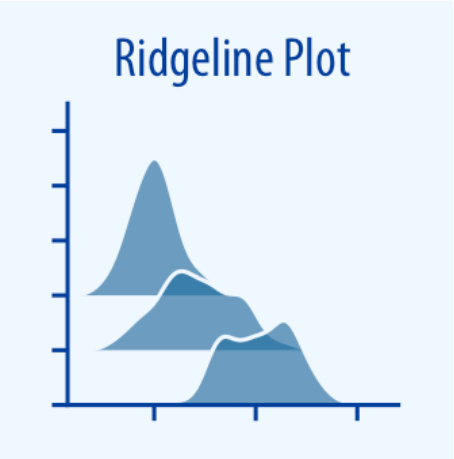












Claus O. Wilke , Fundamentals of Data Visualization

Đánh giá và lập hồ sơ dữ liệu

- Đánh giá dữ liệu
  - Định vị một vấn đề trong dữ liệu cần giải quyết: Tìm ra và quyết định cách nắm bắt vấn đề
  - Mô tả dữ liệu sẽ làm hiện rõ một số vấn đề
  - Kiểm toán dữ liệu: lập hồ sơ dữ liệu và phân tích ảnh hưởng của dữ liệu chất lượng kém.
- Lập hồ sơ dữ liệu
  - Tâm của dữ liệu
  - Các ngoại lai tiềm năng bất kỳ
  - Số lượng và phân bố các khoảng trong trong mọi trường hợp
  - Bất cứ dữ liệu đáng ngờ, như mã thiếu (miscodes), dữ liệu học, dữ liệu test, hoặc chỉ đơn giản dữ liệu rác
  - Những phát hiện nên được trình bày dưới dạng các báo cáo và liệt kê như các mốc quan trọng của kế hoạch

3. Những nhiệm vụ chính trong tiền xử lí dữ liệu

Làm sạch dữ liệu (*Data Cleaning/Data cleansing*)

- Điền giá trị thiếu, làm trơn dữ liệu nhiễu, định danh hoặc xóa ngoại lai, và khử tính không nhất quán

Tích hợp dữ liệu (*Data Integration*)

- Tích hợp CSDL, khối dữ liệu hoặc tập tin phức

Chuyển dạng dữ liệu (*Data transformation*)

- Chuẩn hóa và tổng hợp

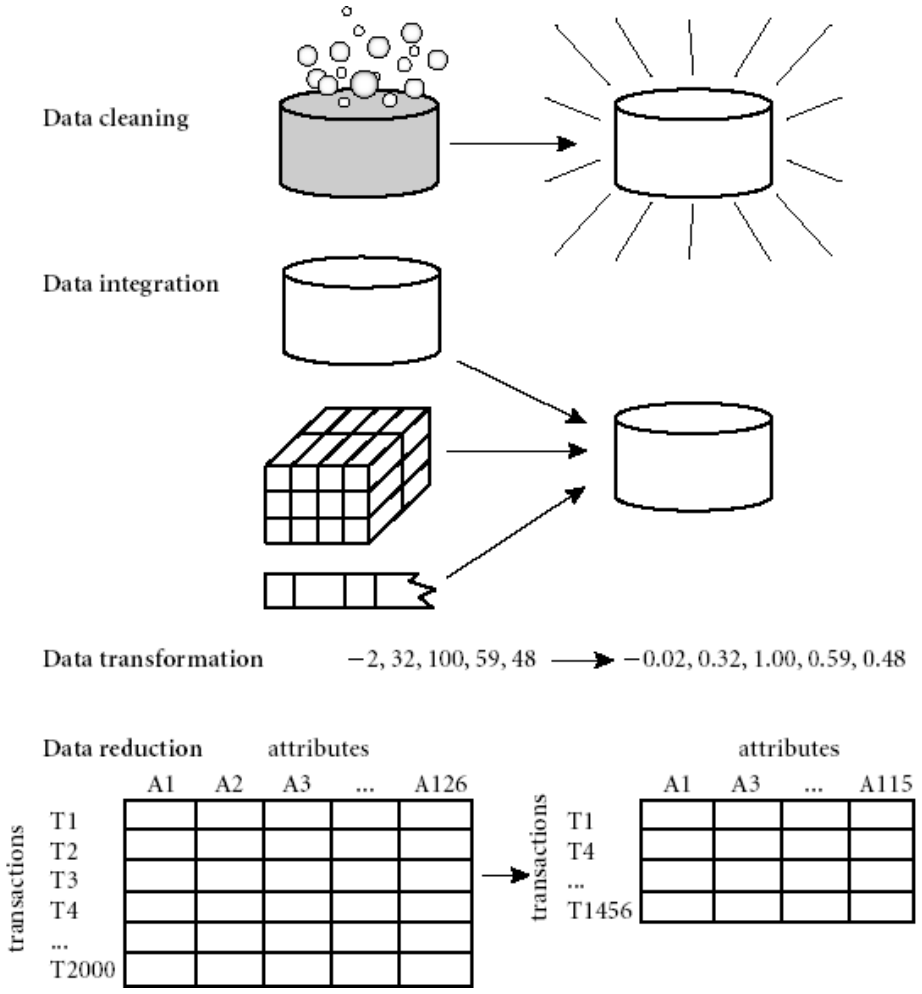
Rút gọn dữ liệu (*Data Reduction*)

- Thu được trình bày thu gọn về kích thước những sản xuất cùng hoặc tương tự kết quả phân tích

Rời rạc hóa dữ liệu (*Data Discretization*)

- Bộ phận đặc biệt của rút gọn dữ liệu (rút gọn miền giá trị) nhưng có độ quan trọng riêng, đặc biệt với dữ liệu số

Những nhiệm vụ chính trong tiền xử lí dữ liệu



Các độ đo về chất lượng dữ liệu: Góc nhìn đa chiều

- Độ chính xác (Accuracy)
- Tính đầy đủ (Completeness)
- Tính nhất quán (Consistency)
- Tính kịp thời (Timeliness)
- Độ tin cậy (Believability)
- Giá trị gia tăng (Value added)
- Biểu diễn được (Interpretability)

3.2 Làm sạch dữ liệu

- Là quá trình
  - xác định tính không chính xác, không đầy đủ/tính bất hợp lý của dữ liệu
  - chỉnh sửa các sai sót và thiếu sót được phát hiện
  - nâng cao chất lượng dữ liệu.
- Quá trình bao gồm
  - kiểm tra định dạng, tính đầy đủ, tính hợp lý, miền giới hạn,
  - xem xét dữ liệu để xác định ngoại lai (địa lý, thống kê, thời gian hay môi trường) hoặc các lỗi khác,
  - đánh giá dữ liệu của các chuyên gia miền chủ đề.
- Quá trình thường dẫn đến
  - loại bỏ, lập tài liệu và kiểm tra liên tiếp và hiệu chỉnh đúng bản ghi nghi ngờ.
  - Kiểm tra xác nhận có thể được tiến hành nhằm đạt tính phù hợp với các chuẩn áp dụng, các quy luật, và quy tắc.

3.2 Làm sạch dữ liệu

- Một số phương pháp sạch dữ liệu
  - Xử lý giá trị thiếu (*Missing values*)
  - Xử lý dữ liệu bị nhiễu (*Noisy data*)
  - Chỉnh sửa dữ liệu không nhất quán
  - Giải quyết tính dư thừa tạo ra sau tích hợp dữ liệu.
- Làm sạch dữ liệu phải là một quy trình
  - Vận dụng tất cả những tri thức sẵn có về dữ liệu
  - Tìm hiểu mọi mâu thuẫn trong dữ liệu
  - Dựa trên một số quy tắc: quy tắc duy nhất, quy tắc liên tục, quy tắc NULL
  - Sử dụng công cụ hỗ trợ: **Data scrubbing tools, Data auditing tools, Data migration tools**

3.2.1 Làm sạch dữ liệu: Xử lý giá trị bị thiếu

- Bỏ qua những bản ghi thiếu dữ liệu
- Xác định các giá trị còn thiếu một cách thủ công
- Sử dụng hằng số toàn cục
- Sử dụng các độ đo hướng trọng tâm
- Sử dụng giá trị trung bình hoặc trung vị của một thuộc tính cho tất cả các giá trị của cùng một lớp
- Dùng giá trị có khả năng cao nhất để thay thế cho giá trị thiếu.

3.2.2 Dữ liệu bị nhiễu

- Nhiễu:
  - Lỗi ngẫu nhiên
  - Biến dạng của một biến đo được
- Giá trị không chính xác
  - Lỗi do thiết bị thu thập dữ liệu
  - Vấn đề nhập dữ liệu: người dùng hoặc máy có thể sai
  - Vấn đề truyền dữ liệu: sai từ thiết bị gửi/nhận/truyền
  - Hạn chế của công nghệ: ví dụ, phần mềm có thể xử lý không đúng
  - Thiết nhất quán khi đặt tên: cũng một tên song cách viết khác nhau
- Các vấn đề dữ liệu khác yêu cầu làm sạch dữ liệu
  - Bội bản ghi
  - Dữ liệu không đầy đủ
  - Dữ liệu không nhất quán

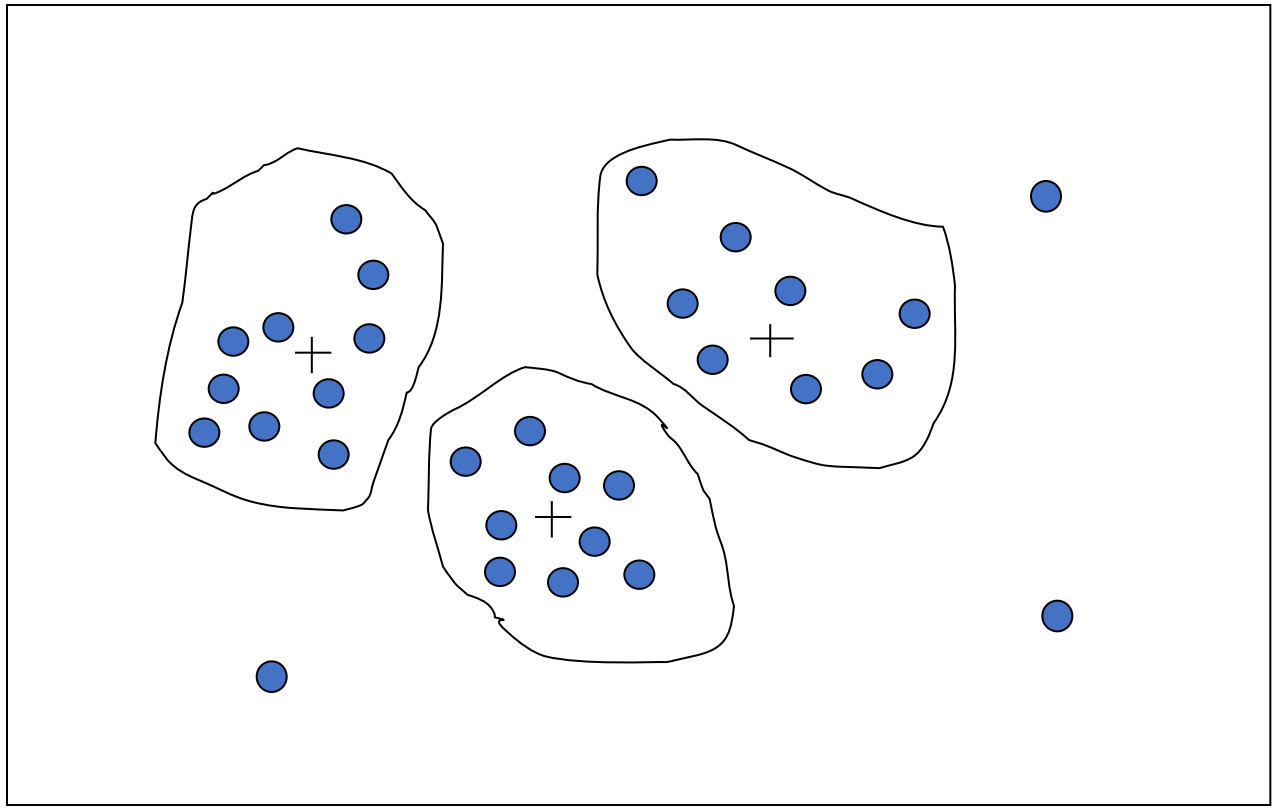
3.2.2 Xử lý dữ liệu nhiễu

- Phương pháp đóng thùng (*Binning*):
  - Sắp dữ liệu tăng và chia "đều" vào các thùng
  - Làm trơn: theo trung bình, theo trung tuyến, theo biên…
- Phương pháp hồi quy (*Regression*)
  - Làm trơn: ghép dữ liệu theo các hàm hồi quy
- Phương pháp phân tích ngoại lai (*Outlier analysis*)
  - Các giá trị ngoại lai có thể được xác định bằng phương pháp phân tích gom cụm (*clustering*)

Phương pháp đóng thùng làm trơn dữ liệu

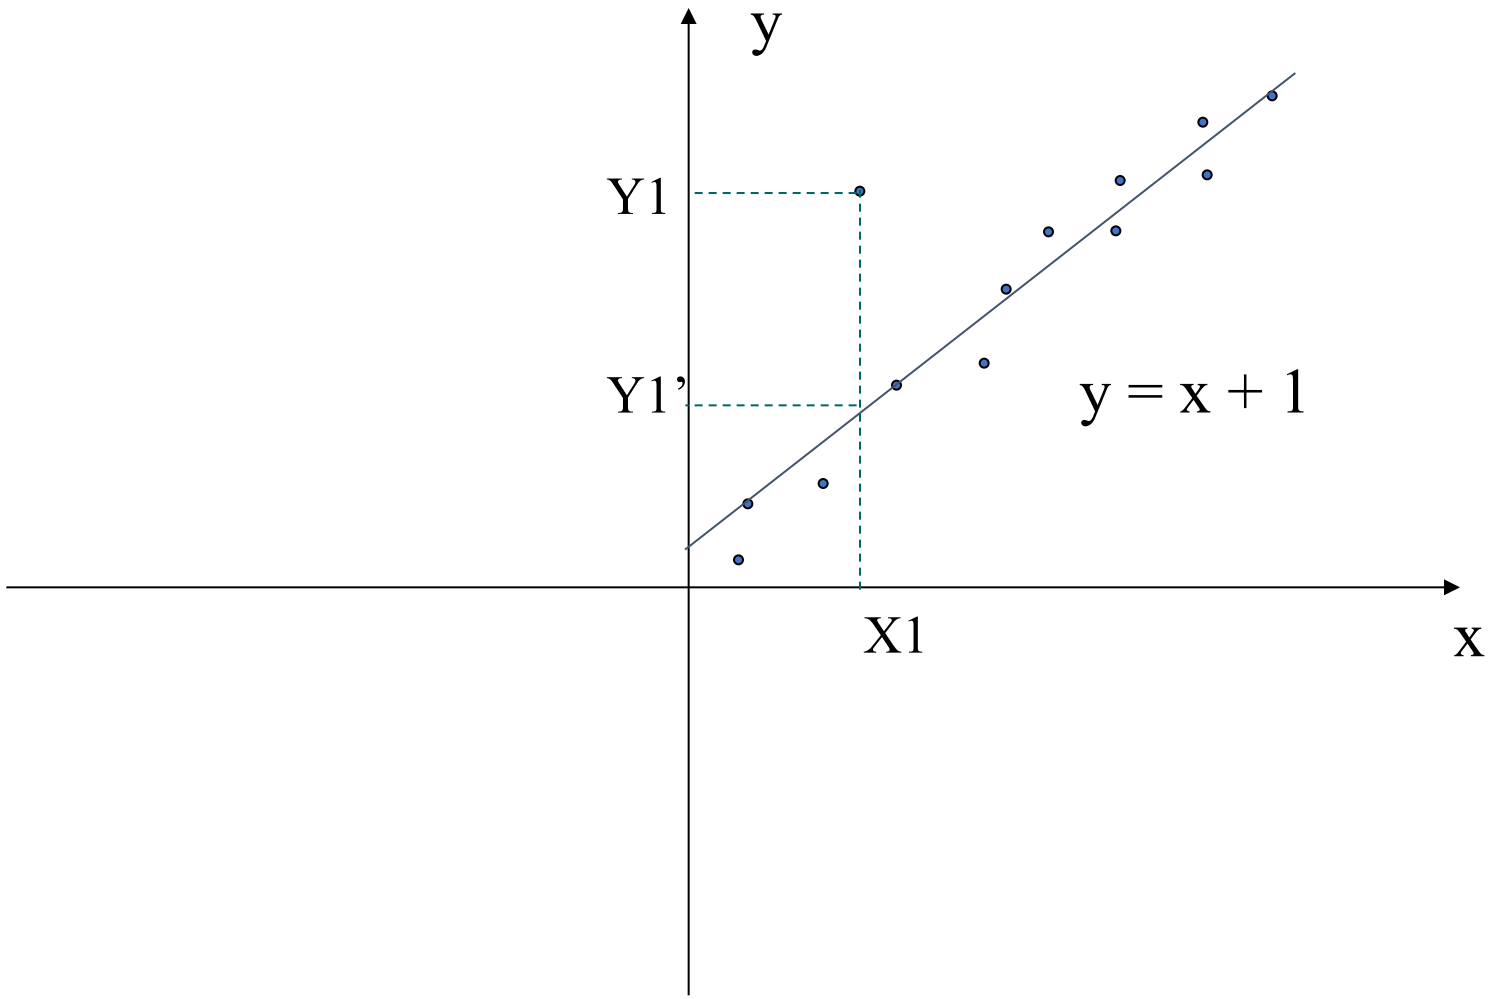
- Dữ liệu được xếp theo giá: 4, 8, 9, 15, 21, 21, 24, 25, 26, 28, 29, 34
- Chia thùng theo chiều sâu:
  - Bin 1: 4, 8, 9, 15
  - Bin 2: 21, 21, 24, 25
  - Bin 3: 26, 28, 29, 34
- Làm trơn thùng theo trung bình:
  - Bin 1: 9, 9, 9, 9
  - Bin 2: 23, 23, 23, 23
  - Bin 3: 29, 29, 29, 29
- Làm trơn thùng theo biên:
  - Bin 1: 4, 4, 4, 15
  - Bin 2: 21, 21, 25, 25
  - Bin 3: 26, 26, 26, 34

Phân tích cụm (Cluster Analysis)



Cụm: Các phần tử trong cụm là "tương tự nhau"
Làm trơn phần tử trong cụm theo đại diện.
Thuật toán phân cụm: Chương 6.

Hồi quy (Regression)



3.3 Tích hợp dữ liệu

- Tích hợp dữ liệu (*Data integration*):
  - Hợp nhất dữ liệu từ nhiều nguồn khác nhau về một nguồn lưu trữ chung chẳng hạn như kho dữ liệu (*Data warehouse*)
  - Giúp giảm và tránh dư thừa cũng như sự không nhất quán
  - Giúp cải tiến hiệu năng và tốc độ quá trình khai phá dữ liệu
- Một số vấn đề và cách giải quyết:
  - Nhận diện thực thể
  - Sự dư thừa và phân tích độ tương quan
  - Phát hiện các bộ lặp
  - Phát hiện xung đột trong dữ liệu và mức độ trừu tượng

3.4 Chuyển đổi dữ liệu

- **Làm trơn/làm mịn** (*Smoothing*): loại bỏ nhiễu từ dữ liệu
- **Tổng hợp** (*Aggregation*): tóm tắt, xây dựng khối dữ liệu
- **Tổng quát hóa** (*Generalization*): theo kiến trúc khái niệm
- **Chuẩn hóa** (*Normalization*): biến đổi miền giá trị của các thuộc tính về những miền giá trị nhỏ hơn
  - Chuẩn hóa min-max
  - Chuẩn hóa z-score
  - Chuẩn hóa tỷ lệ thập phân
- **Xây dựng thuộc tính/đặc trưng**
  - Thuộc tính mới được xây dựng từ các thuộc tính đã có
- **Rời rạc hóa** (*Discretization*)

3.4.1 Chuyển đổi dữ liệu: Chuẩn hóa dữ liệu

- Chuẩn hóa min-max

$$v' = \frac{v - min_A}{max_A - min_A}(new_max_A - new_min_A) + new_min_A$$

- Chuẩn hóa z-score (còn gọi là *zero-mean normalization)*

$$v' = \frac{v - mean_A}{\sigma_A} \qquad \sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})^2 = \left(\frac{1}{N}\sum_{i=1}^{N}x_i^2\right) - \bar{x}^2,$$

- Chuẩn hóa tỷ lệ thập phân *(Normalization by decimal scaling)*

$$v' = \frac{v}{10^j} \qquad j : \text{số nguyên nhỏ nhất mà } Max(|v'|) < 1$$

3.4.1 Chuẩn hóa dữ liệu: Ví dụ

3.5 Rút gọn dữ liệu

- Rút gọn dữ liệu
  - Nhằm giảm lượng dữ liệu nhiều nhất có thể mà vẫn giữ được tính toàn vẹn của dữ liệu gốc.
  - Kết quả phân tích trên dữ liệu đã rút gọn vẫn tốt (hoặc gần tốt) như trên dữ liệu gốc
- Các chiến lược:
  - Giảm số chiều của dữ liệu
  - Giảm số lượng dữ liệu
  - Nén dữ liệu

3.5 Rời rạc hóa

- Rời rạc hóa dữ liệu là một kỹ thuật chuyển đổi dữ liệu phổ biến
- Một số phương pháp áp dụng cho dữ liệu số:
  - Phương pháp đóng thùng (*Binning*)
  - Phương pháp phân tích biểu đồ tần suất *(Histogram analysis)*
  - Phương pháp phân cụm, cây quyết định và phân tích tương quan



THANK YOU FOR WATCHING!