TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH

KHAI PHÁ DỮ LIỆU

CHƯƠNG 3
MỘT SỐ PHƯƠNG PHÁP KHAI PHÁ LUẬT KẾT HỢP

Bộ môn Khoa học máy tính - Khoa Hệ thống thông tin quản lý


H U B
1976
TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH

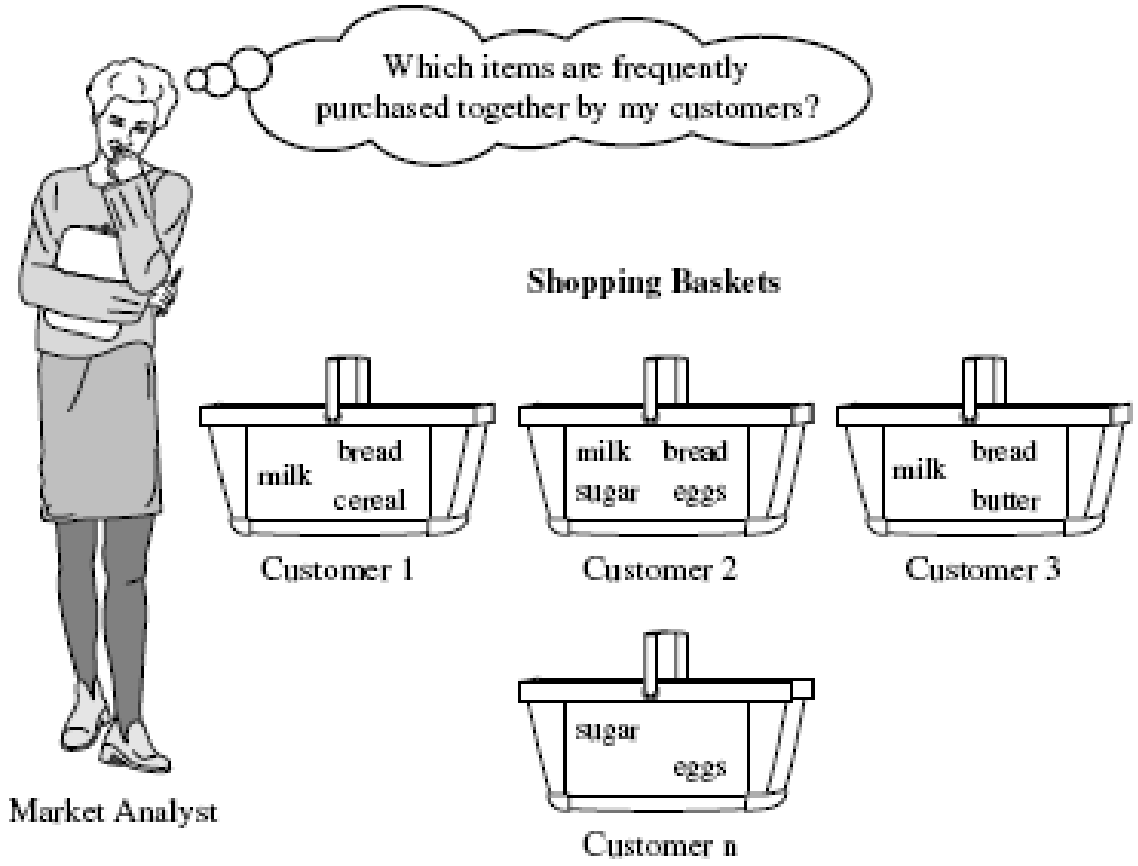
Mục tiêu

- Hiểu các đặc điểm liên quan đến luật kết hợp
- Hiểu được giải thuật Apriori, FP-Grow để khai phá luật kết hợp
- Giải thích được các kết quả tìm ra từ quá trình khai phá luật kết hợp
- Áp dụng được giải thuật tìm luật kết hợp vào bài toán cụ thể
- Áp dụng được công cụ để khai phá luật kết hợp từ tập dữ liệu

Nội dung

- Giới thiệu về khai phá luật kết hợp
- Khai phá các tập mục phổ biến
- Giải thuật FP-Growth
- Khai phá các luật kết hợp từ các mẫu phổ biến
- Khám phá các luật kết hợp dựa trên ràng buộc
- Một số ứng dụng của khai phá luật kết hợp

1. Giới thiệu về khai phá kết hợp



$$computer \Rightarrow antivirus_software \ [support = 2\%, confidence = 60\%]$$

Khái niệm khai phá luật kết hợp

- Khai phá luật kết hợp (Association Rules):
  - Tìm tất cả mẫu phổ biến, kết hợp, tương quan, hoặc cấu trúc nhân-quả trong tập các mục hoặc đối tượng trong CSDL quan hệ hoặc các kho chứa thông tin khác.
  - Mẫu phổ biến (Frequent pattern): là mẫu (tập mục, dãy mục…) mà xuất hiện phổ biến trong 1 CSDL [AIS93]
- Động lực: tìm mẫu qui tắc(regularities pattern) trong DL
  - Các mặt hàng nào được mua cùng nhau? - Bia và bỉm (diapers)?!
  - Mặt hàng nào sẽ được mua sau khi mua một PC ?
  - Kiểu DNA nào nhạy cảm với thuộc mới này?
  - Có khả năng tự động phân lớp Web hay không ?

Ví dụ

- Một số ví dụ về "luật kết hợp" (associate rule)
  - "98% khách hàng mà mua tạp chí thể thao thì đều mua các tạp chí về ôtô"
  - ⇨ sự kết hợp giữa "tạp chí thể thao" với "tạp chí về ôtô"
  - "60% khách hàng mà mua bia tại siêu thị thì đều mua bỉm trẻ em"
    - ⇨ sự kết hợp giữa "bia" với "bỉm trẻ em"
  - "Có tới 70% người truy nhập Web vào địa chỉ Url 1 thì cũng vào địa chỉ Url 2 trong một phiên truy nhập web"
  - ⇨ sự kết hợp giữa "Url 1" với "Url 2".

Một số khái niệm cơ bản

- Item (phần tử)
- Itemset (tập phần tử)
- Transaction (giao dịch)
- Cơ sở dữ liệu giao dịch (Transaction database)
- Association rule (luật kết hợp)
- Support (độ hỗ trợ)
- Confidence (độ tin cậy)
- Frequent itemset (tập phần tử phổ biến/thường xuyên/tập phổ biến)
- Strong association rule (luật kết hợp mạnh)

Mẫu phổ biến và khai phá luật

- Nền tảng của nhiều bài toán KPDL:
  - Kết hợp, tương quan, nhân quả
  - Mẫu tuần tự, kết hợp thời gian hoặc vòng, chu kỳ bộ phận, kết hợp không gian và đa phương tiện
  - Phân lớp kết hợp, phân tích cụm, khối tảng băng, tích tụ (nén dữ liệu ngữ nghĩa)
- Ứng dụng:
  - Phân tích dữ liệu bóng rổ, tiếp thị chéo (cross-marketing), thiết kế catalog, phân tích chiến dịch bán hàng
  - Phân tích Web log (click stream), Phân tích chuỗi DNA v.v.

Khái niệm cơ sở: Tập phổ biến và luật kết hợp

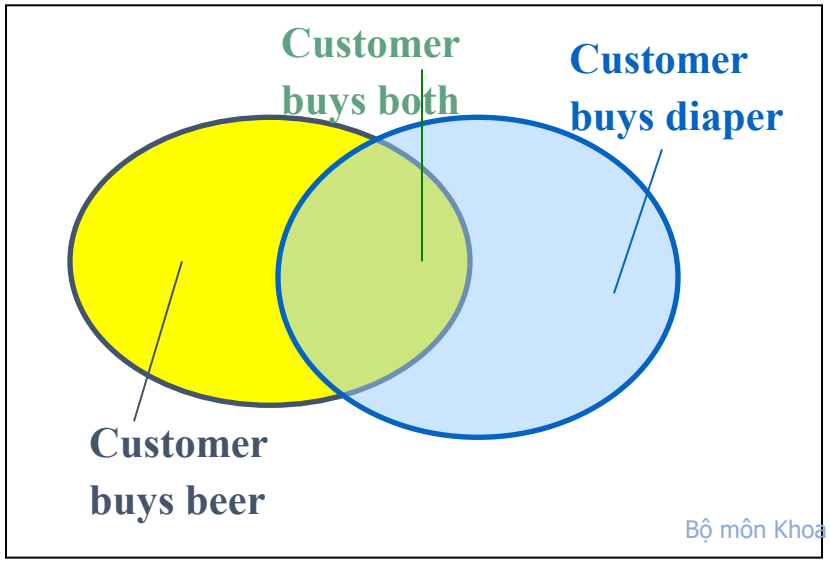
- Cơ sở dữ liệu giao dịch (transaction database)
  - Giao dịch: danh sách các mặt hàng/mục (item) trong một phiếu mua hàng của khách hàng. Giao dịch T là một tập mục (item set).
  - Tập toàn bộ các mục I = {i1, i2, …, ik} "tất cả các mặt hàng". Một giao dịch T là một tập con của I: $T \subseteq I$. Mỗi giao dịch T có một định danh là TID.
  - A là một tập mục $A \subseteq I$ và T là một giao dịch: Nói T chứa A nếu $A \subseteq T$.

Khái niệm cơ sở: Tập phổ biến và luật kết hợp

- Luật kết hợp
  - Gọi $A \rightarrow B$ là một "luật kết hợp" nếu $A \subseteq I$, $B \subseteq I$ và $A \cap B = \varnothing$.
  - Luật kết hợp $A \rightarrow B$ có độ hỗ trợ (support) s trong CSDL giao dịch D nếu trong D có s% các giao dịch T chứa AB: chính là xác suất P(AB). Tập mục A có $P(A) \geq s > 0$ (với s cho trước) được gọi là tập phổ biến. Luật kết hợp $A \rightarrow B$ có độ tin cậy (confidence) c trong CSDL D nếu như trong D có c% các giao dịch T chứa A thì cũng chứa B: chính là xác suất P(B|A).
  - Support $(A \rightarrow B) = P(A \cup B) : 1 \geq s\ (A \rightarrow B) \geq 0$
  - Confidence $(A \rightarrow B) = P(B|A) : 1 \geq c\ (A \rightarrow B) \geq 0$
  - Luật $A \rightarrow B$ được gọi là đảm bảo độ hỗ trợ s trong D nếu $s(A \rightarrow B) \geq s$.
  - Luật $A \rightarrow B$ được gọi là đảm bảo độ tin cậy c trong D nếu $c(A \rightarrow B) \geq c$ (luật mạnh)

2.1 Khái niệm cơ bản: Bài toán tìm luật kết hợp

Tid	Items bought
10	Beer, Nuts, Diaper
20	Beer, Coffee, Diaper
30	Beer, Diaper, Eggs
40	Nuts, Eggs, Milk
50	Nuts, Coffee, Diaper, Eggs, Milk



- Tập mục $I=\{i_1, \ldots, i_k\}$.
- CSDL giao dịch $D = \{d \subseteq I\}$
- $A, B \subseteq I$, $A \cap B = \emptyset$: $A \rightarrow B$ là luật kết hợp
- Bài toán tìm luật kết hợp:

  Cho trước độ hỗ trợ tối thiểu s>0, độ tin cậy tối thiểu c>0. Hãy tìm mọi luật kết hợp mạnh X→Y.

Giả sử min_support = 50%, min_conf = 50%:

Freq. Pat.: Beer:3, Nuts:3, Diaper:4, Eggs:3, {Beer, Diaper}:3

Luật kết hợp:

- *Beer → Diaper* (60%, 100%)
- *Diaper → Beer* (60%, 75%)

Chỉ ra các luật kết hợp còn lại

Một ví dụ tìm luật kết hợp

- Với luật A → C:
  - support = support({A}∪{C}) = 50%
  - confidence = support({A}∪{C})/support({A}) = 66.6%

Min. support 50%
Min. confidence 50%

Transaction-id	Items bought
10	A, B, C
20	A, C
30	A, D
40	B, E, F

Frequent pattern	Support
{A}	75%
{B}	50%
{C}	50%
{A, C}	50%

2.2. Khám phá mẫu phổ biến

- Giải thuật Apriori: khám phá các mẫu phổ biến với tập dự tuyển (ứng viên)
- Giải thuật FP-Growth: khám phá các mẫu phổ biến với FP-tree

2.1 Giải thuật Apriori

- Khái quát: Khai phá luật kết hợp gồm hai bước:
  - Tìm mọi tập phổ biến: theo min-sup
  - Sinh luật mạnh từ tập phổ biến
- Mọi tập con của tập phổ biến cũng là tập phổ biến
  - Nếu {bia, bỉm, hạnh nhân} là phổ biến thì {bia, bỉm} cũng vậy: Mọi giao dịch chứa {bia, bỉm, hạnh nhân} cũng chứa {bia, bỉm}.
- Nguyên lý tỉa Apriori: Với mọi tập mục không phổ biến thì mọi tập bao không cần phải sinh ra/kiểm tra!
- Phương pháp:
  - Sinh các tập mục ứng viên dài (k+1) từ các tập phổ biến có độ dài k (Độ dài tập mục là số phần tử của nó),
  - Kiểm tra các tập ứng viên theo CSDL
- Các nghiên cứu hiệu năng chứng tỏ tính hiệu quả và khả năng mở rộng của thuật toán (Agrawal & Srikant 1994, Mannila, và cộng sự 1994)

2.2 Giải thuật Apriori

- Trên cơ sở tính chất (nguyên lý tỉa) Apriori, thuật toán hoạt động theo quy tắc quy hoạch động
  - Từ các tập Fi = {ci| ci tập phổ biến, |ci| = i} gồm mọi tập phổ biến có độ dài i với $1 \leq i \leq k$,
  - Tìm tập Fk+1 gồm mọi tập phổ biến có độ dài k+1.
- Trong thuật toán, các tên mục I1, i2, … in (n = |I|) được sắp xếp theo một thứ tự cố định (thường được đánh chỉ số 1, 2, ..., n).

2.1 Giải thuật Apriori

Input: - Cơ sở dữ liệu giao dịch D = {t| t giao dịch}
- Độ hỗ trợ tối thiểu minsup > 0

Output: - Tập hợp tất cả các tập phổ biến.

```
0:  mincount = minsup * |D|;
1.  F1 = {các tập phổ biến có độ dài 1}
2.  for (k=1; Fk ≠∅; k++) do begin
3.          Ck+1 = apriori-gen (Fk); // sinh mọi ứng viên độ dài k+1
4.          for t ∈ D  do begin
5.                  Ct  = {c ∈ Ck+1 | c ⊆ t}; //mọi ứng viên chứa trong t
6.                  for c ∈ Ct  do
7.                          c.count ++;
8.          end
9.          Fk+1 = {c ∈ Ck+1 | c.count ≥ mincount} ;
10.  end
11. Answer  ∪k Fk ;
```

Giải thuật toán Apriori: Thủ tục con Apriori-gen

- Trong mỗi bước k, thuật toán Apriori đều phải duyệt CSDL D.
- Khởi động, duyệt D để có được F1.
- Các bước k sau đó, duyệt D để tính số lượng giao dịch t thoả từng ứng viên c của Ck+1: mỗi giao dịch t chỉ xem xét một lần cho mọi ứng viên c thuộc Ck+1.
- Thủ tục co

Bước nối: Sinh các tập mục R_{k+1} là ứng viên tập phổ biến có độ dài k+1 bằng cách kết hợp hai tập phổ biến P_k và Q_k có độ dài k và trùng nhau ở k-1 mục đầu tiên:

$$R_{k+1} = P_k \cup Q_k = \{i_1, i_2, ..., i_{k-1}, i_k, i_{k'}\} \text{ với}$$

$$P_k = \{i_1, i_2, ..., i_{k-1}, i_k\} \text{ và } Q_k = \{i_1, i_2, ..., i_{k-1}, i_{k'}\}$$

trong đó $i_1 \le i_2 \le ... \le i_{k-1} \le i_k \le i_{k'}$.

Bước tỉa: Giữ lại tất cả các R_{k+1} thỏa tính chất Apriori ($\forall X \subseteq R_{k+1}$ và $|X|=k \Rightarrow X \in F_k$), nghĩa là đã loại (tỉa) bớt đi mọi ứng viên R_{k+1} không đáp ứng tính chất này.

2.2 Giải thuật Apriori:Thủ tục con Apriori-gen

(1) for mọi tập mục phổ biến $l_1 \in L_k$
(2) for mọi tập mục phổ biến $l_2 \in L_k$
(3) if $(l_1[1]=l_2[1]) \wedge (l_1[2]=l_2[2]) \wedge \ldots \wedge (l_1[k-1]=l_2[k-1]) \wedge (l_1[k]<l_2[k])$
then {
$c = l_1 \Leftrightarrow l_2$; // join step: generate candidates
// c = $\{l_1[1], l_1[2], \ldots, l_1[k-1], l_1[k], l_2[k]\}$
(5) if has_infrequent_subset(c, L_k) then
(6) delete c; // bước tỉa: bỏ ứng viên không đúng
else add c to C_{k+1};
(8) }
(9) return Ck;

procedure has_infrequent_subset(c: tập ứng viên độ dài $k+1$;
L_k: tập các tập mục phổ biến độ dài k); // tri thức đã có
(1) for mỗi tập con s độ dài k *của* c
(2) if $s \notin L_k$ then
(3) return TRUE;
(4) return FALSE;

Một ví dụ thuật toán Apriori (s=0.5)

Database TDB

Tid	Items
10	A, C, D
20	B, C, E
30	A, B, C, E
40	B, E

1st scan

C_1

Itemset	sup
{A}	2
{B}	3
{C}	3
{D}	1
{E}	3

L_1

Itemset	sup
{A}	2
{B}	3
{C}	3
{E}	3

C_2

Itemset
{A, B}
{A, C}
{A, E}
{B, C}
{B, E}
{C, E}

2nd scan

C_2

Itemset	sup
{A, B}	1
{A, C}	2
{A, E}	1
{B, C}	2
{B, E}	3
{C, E}	2

L_2

Itemset	sup
{A, C}	2
{B, C}	2
{B, E}	3
{C, E}	2

C_3

Itemset
{B, C, E}

3rd scan

L_3

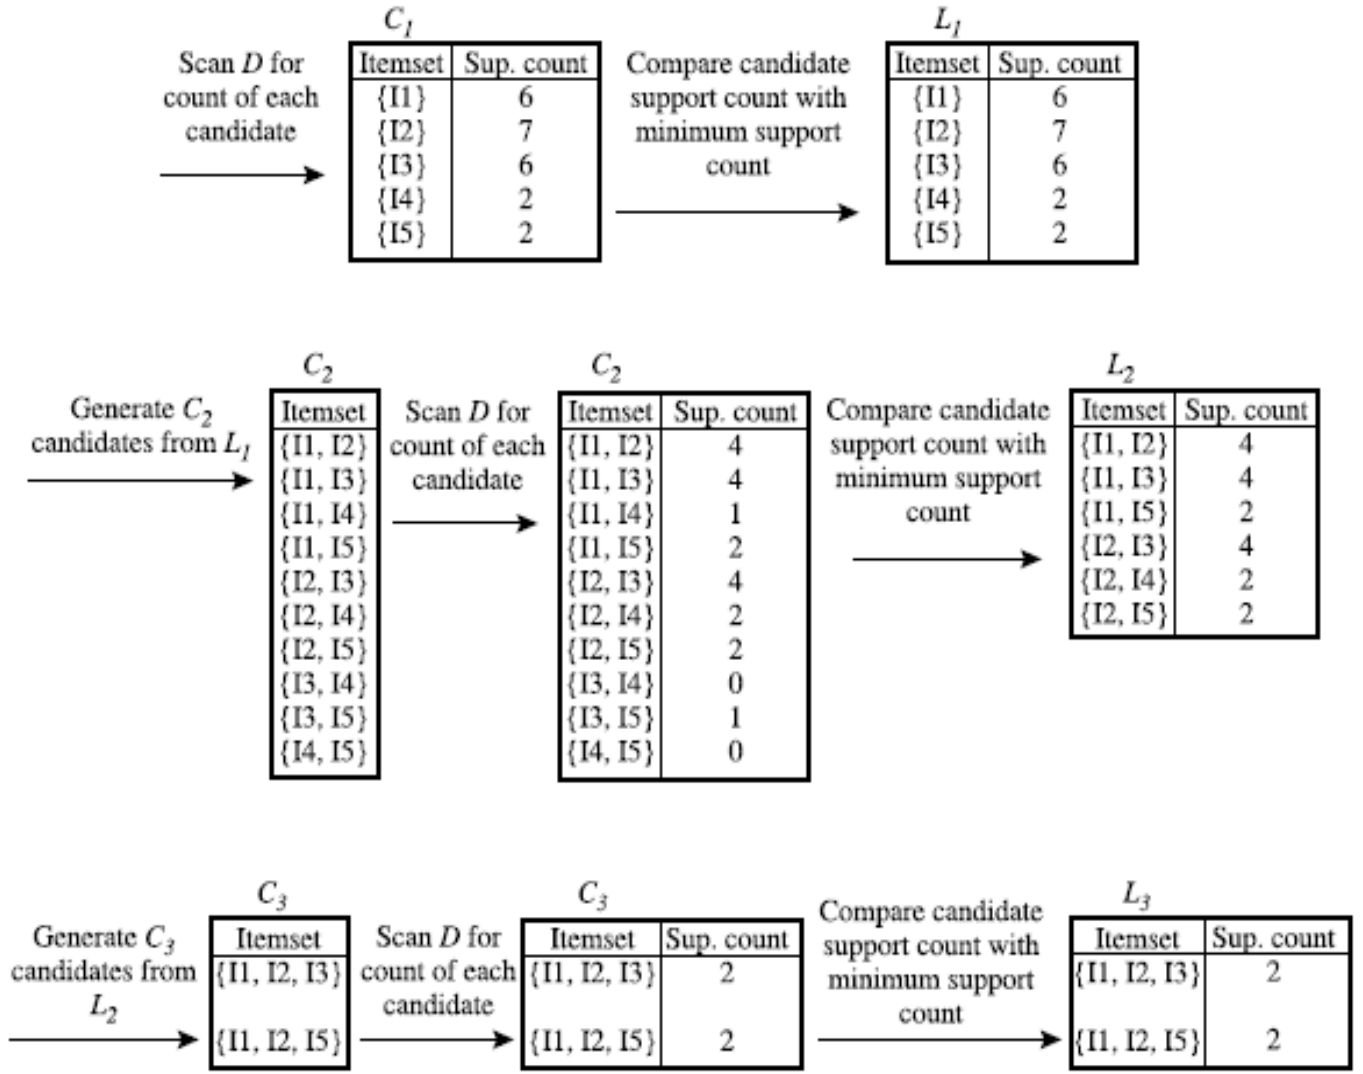
Itemset	sup
{B, C, E}	2

Chi tiết quan trọng của Apriori

- Cách thức sinh các ứng viên:
  - Bước 1: Tự kết nối Lk
  - Bước 2: Cắt tỉa
- Cách thức đếm hỗ trợ cho mỗi ứng viên.
- Ví dụ thủ tục con sinh ứng viên
  - L3={abc, abd, acd, ace, bcd}
  - Tự kết nối: L3*L3
    - abcd từ abc và abd
    - acde từ acd và ace
  - Tỉa:
    - acde là bỏ đi vì ade không thuộc L3
  - C4={abcd}

Ví dụ: D, min_sup* |D| = 2 (C4 = ∅)

TID	List of item_IDs
T100	I1, I2, I5
T200	I2, I4
T300	I2, I3
T400	I1, I2, I4
T500	I1, I3
T600	I2, I3
T700	I1, I3
T800	I1, I2, I3, I5
T900	I1, I2, I3



Sinh luật kết hợp

- Việc sinh luật kết hợp gồm hai bước
  - Với mỗi tập phổ biến W tìm được hãy sinh ra mọi tập con thực sự X khác rỗng của nó.
  - Với mỗi tập phố biến W và tập con X khác rỗng thực sự của nó:
  - sinh luật X $\rightarrow$ (W – X) nếu P(W-X|X) $\geq$ c.
- Như ví dụ đã nêu có L3 = {{I1, I2, I3}, {I1, I2, I5}}

TID	List of item_IDs
T100	I1, I2, I5
T200	I2, I4
T300	I2, I3
T400	I1, I2, I4
T500	I1, I3
T600	I2, I3
T700	I1, I3
T800	I1, I2, I3, I5
T900	I1, I2, I3

y tối thiểu 70%, xét tập phổ biến {I1, I2, I5} có 3 luật như

$$I1 \wedge I2 \Rightarrow I5, \quad confidence = 2/4 = 50\%$$
$$I1 \wedge I5 \Rightarrow I2, \quad confidence = 2/2 = 100\%$$
$$I2 \wedge I5 \Rightarrow I1, \quad confidence = 2/2 = 100\%$$
$$I1 \Rightarrow I2 \wedge I5, \quad confidence = 2/6 = 33\%$$
$$I2 \Rightarrow I1 \wedge I5, \quad confidence = 2/7 = 29\%$$
$$I5 \Rightarrow I1 \wedge I2, \quad confidence = 2/2 = 100\%$$

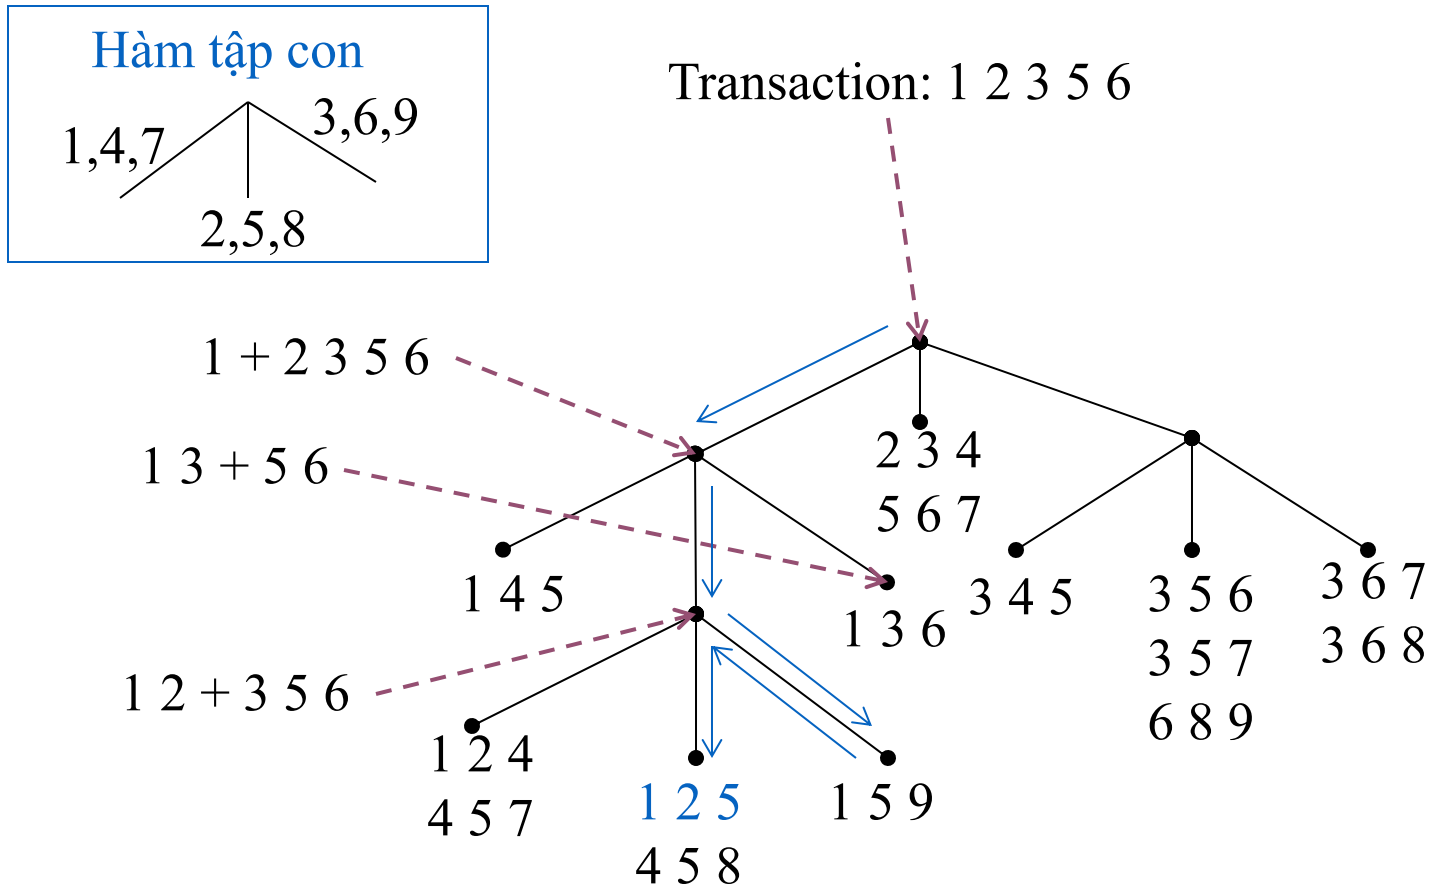
Cách thức tính độ hỗ trợ của ứng viên

- Tính độ hỗ trợ ứng viên là vấn đề cần quan tâm
  - Số lượng ứng viên là rất lớn
  - Một giao dịch chứa nhiều ứng viên
- Phương pháp:
  - Tập mục ứng viên được chứa trong một cây-băm (hash-tree)
  - Lá của cây băm chứa một danh sách các tập mục và bộ đếm
  - Nút trong chứa bảng băm
  - Hàm tập con: tìm tất cả các ứng viên

Cách thức tính độ hỗ trợ của ứng viên

- Tập các ứng viên Ck được lưu trữ trong một cây-băm.
  - Gốc của cây băm ở độ sâu 1. Lá chứa một danh sách tập mục
  - Nút trong chứa một bảng băm: mỗi thùng của bảng trỏ tới một nút khác (Nút ở độ sâu d trỏ tới các nút ở độ sâu d+1).
  - Khi khởi tạo, tất cả các nút là lá.
- Khi thêm một tập mục c:
  - bắt đầu từ gốc đi xuống theo cây cho đến khi gặp một lá.
  - Tại một nút trong độ sâu d:
    - quyết định theo nhánh nào bằng cách áp dụng hàm băm tới mục thứ d của tập mục này.
    - Khi số lượng tập mục tại một lá vượt quá ngưỡng quy định, nút lá được chuyển thành một nút trong.
- Bắt đầu từ gốc, tìm tất cả các ứng viên thuộc giao dịch t:
  - Nếu ở nút gốc: băm vào mỗi mục trong t.
  - Nếu ở một lá: tìm các tập mục ở lá này thuộc t và bổ sung chỉ dẫn tới các tập mục này tới tập trả lời.
  - Nếu ở nút trong và đã đạt được nó bằng cách băm mục i, trên từng mục đứng sau i trong t và áp dụng đệ quy thủ tục này sang nút trong thùng tương ứng.

Ví dụ: Tính độ hỗ trợ các ứng viên



Thách thức khai phá mẫu phổ biến

- Thách thức
  - Duyệt nhiều lần CSDL giao dịch
  - Số lượng rất lớn các ứng viên
  - Phức tạp trong việc tính toán độ hỗ trợ
- Cải tiến Apriori: (ý tưởng chung)
  - Giảm số lần duyệt CSDL giao dịch
  - Rút gọn số lượng các ứng viên
  - Đơn giản trong việc tính độ hỗ trợ của các ứng viên

Một số phương pháp cải tiến

- DIC (Đếm tập mục động): Rút gọn số lượng duyệt CSDL
- Giải pháp Phân hoạch (Partition): Duyệt CSDL chỉ hai lần
- DHP: Rút gọn số lượng các ứng viên
- Eclat/MaxEclat và VIPER: Thăm dò dạng dữ liệu theo chiều ngang
- Khai phá mẫu phổ biến không cần sinh ứng viên

Khai phá mẫu phổ biến không cần sinh ứng viên

- Dùng các mục phổ biến để tăng độ dài mẫu từ các mẫu ngắn hơn
  - "abc" là một mẫu phổ biến
  - Nhận mọi giao dịch có "abc": DB|abc
  - "d" là một mục phổ biến trong DB|abc → abcd là một mẫu phổ biến

Xây dựng FP-tree từ một CSDL giao dịch

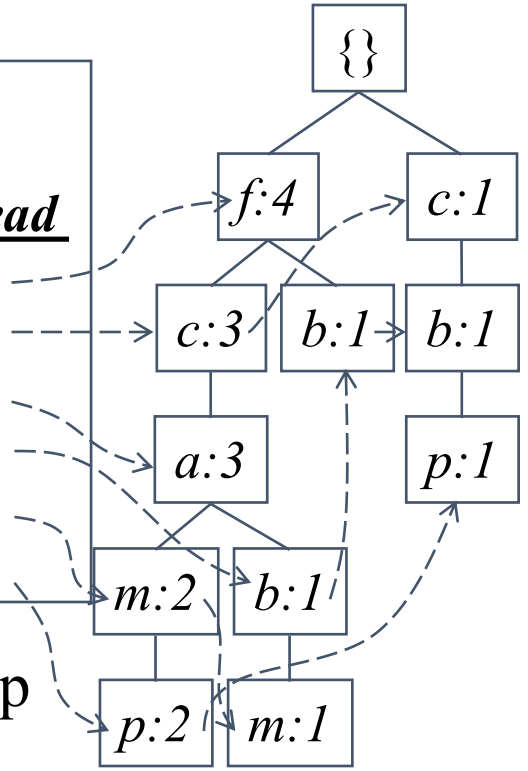
TID	*Items bought*	*(ordered) frequent items*
100	{*f, a, c, d, g, i, m, p*}	{*f, c, a, m, p*}
200	{*a, b, c, f, l, m, o*}	{*f, c, a, b, m*}
300	{*b, f, h, j, o, w*}	{*f, b*}
400	{*b, c, k, s, p*}	{*c, b, p*}
500	{*a, f, c, e, l, p, m, n*}	{*f, c, a, m, p*}

min_support = 3

1. Duyệt CSDL một lần, tìm các 1-tập phổ biến (mẫu mục đơn)
2. Sắp xếp các mục phổ biến theo thứ tự giảm dần về bậc, F-list
3. Duyệt CSDL lần nữa, xây dựng FP-tree

Header Table

Item	*frequency*	*head*
f	4	
c	4	
a	3	
b	3	
m	3	
p	3	



F-list=f-c-a-b-m-p

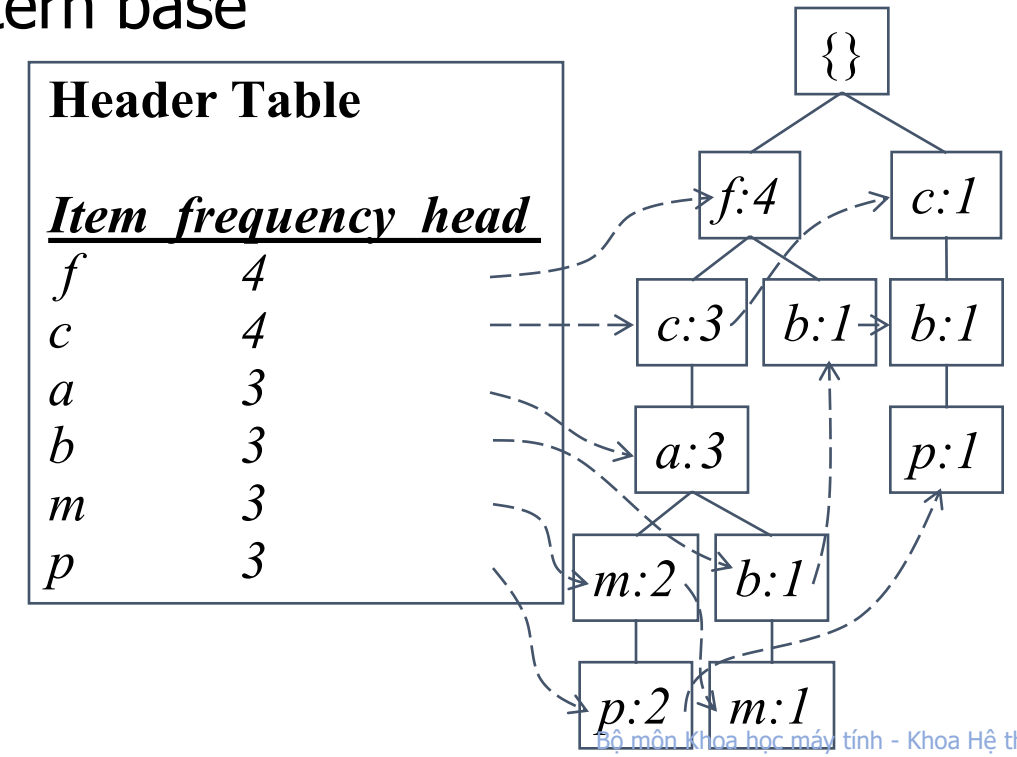
⇨**Từ FP-tree tìm luật kết hợp**

Partition Patterns and Databases

- Frequent patterns can be partitioned into subsets according to f-list
  - F-list = f-c-a-b-m-p
  - Patterns containing p
  - Patterns having m but no p
  - …
  - Patterns having c but no a nor b, m, p
  - Pattern f
- Completeness and non-redundency

Find Patterns Having P From P-conditional Database

- Starting at the frequent item header table in the FP-tree
- Traverse the FP-tree by following the link of each frequent item p
- Accumulate all of transformed prefix paths of item p to form p's conditional pattern base

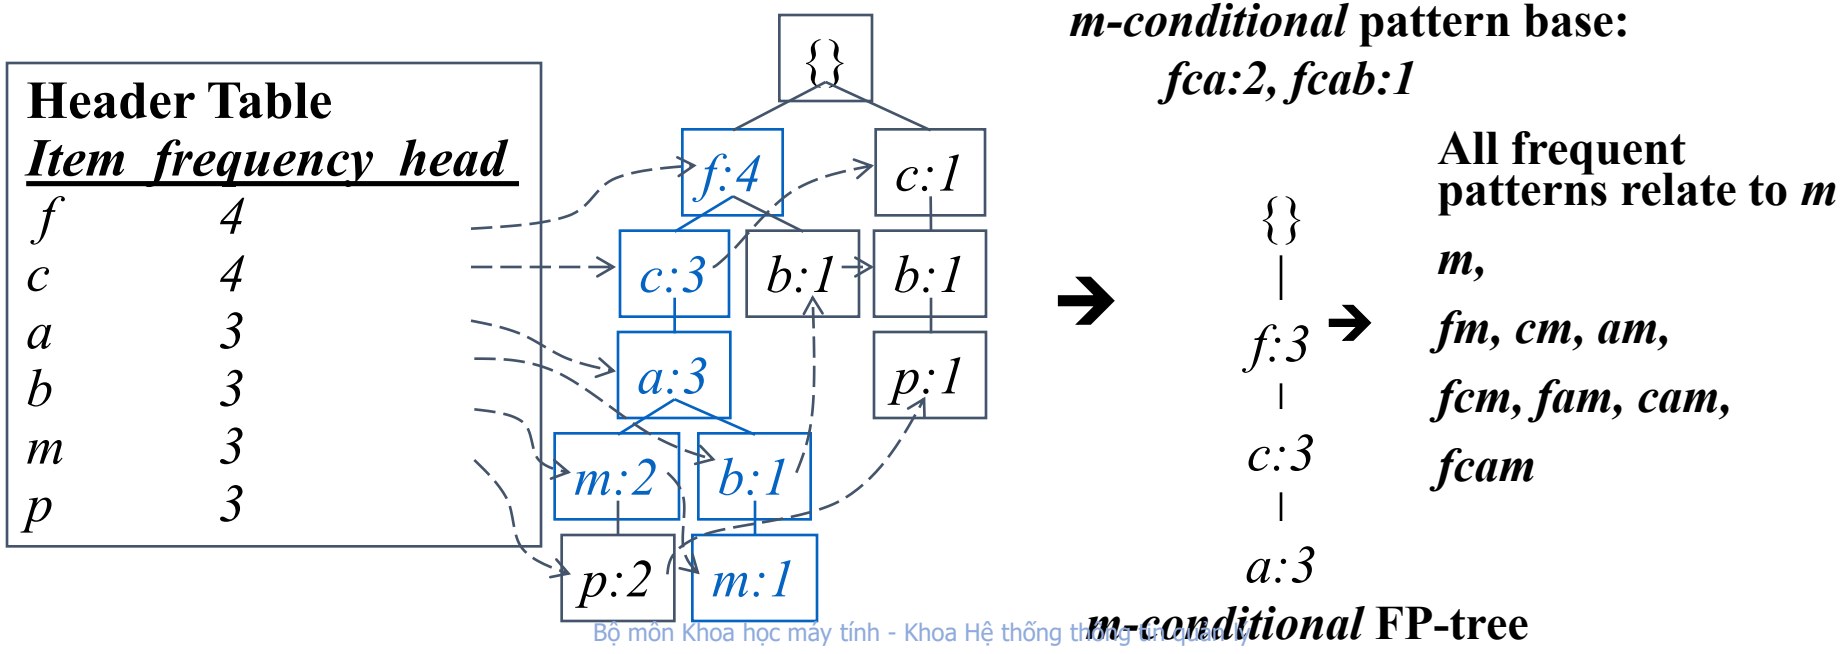


***Conditional* pattern bases**

item	*cond. pattern base*
c	*f:3*
a	*fc:3*
b	*fca:1, f:1, c:1*
m	*fca:2, fcab:1*
p	*fcam:2, cb:1*

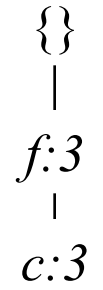
From Conditional Pattern-bases to Conditional FP-trees

- For each pattern-base
  - Accumulate the count for each item in the base
  - Construct the FP-tree for the frequent items of the pattern base



Recursion: Mining Each Conditional FP-tree

Cond. pattern base of "am": (fc:3)

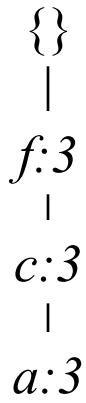


***am-conditional* FP-tree**

Cond. pattern base of "cm": (f:3)



***cm-conditional* FP-tree**



***m-conditional* FP-tree**

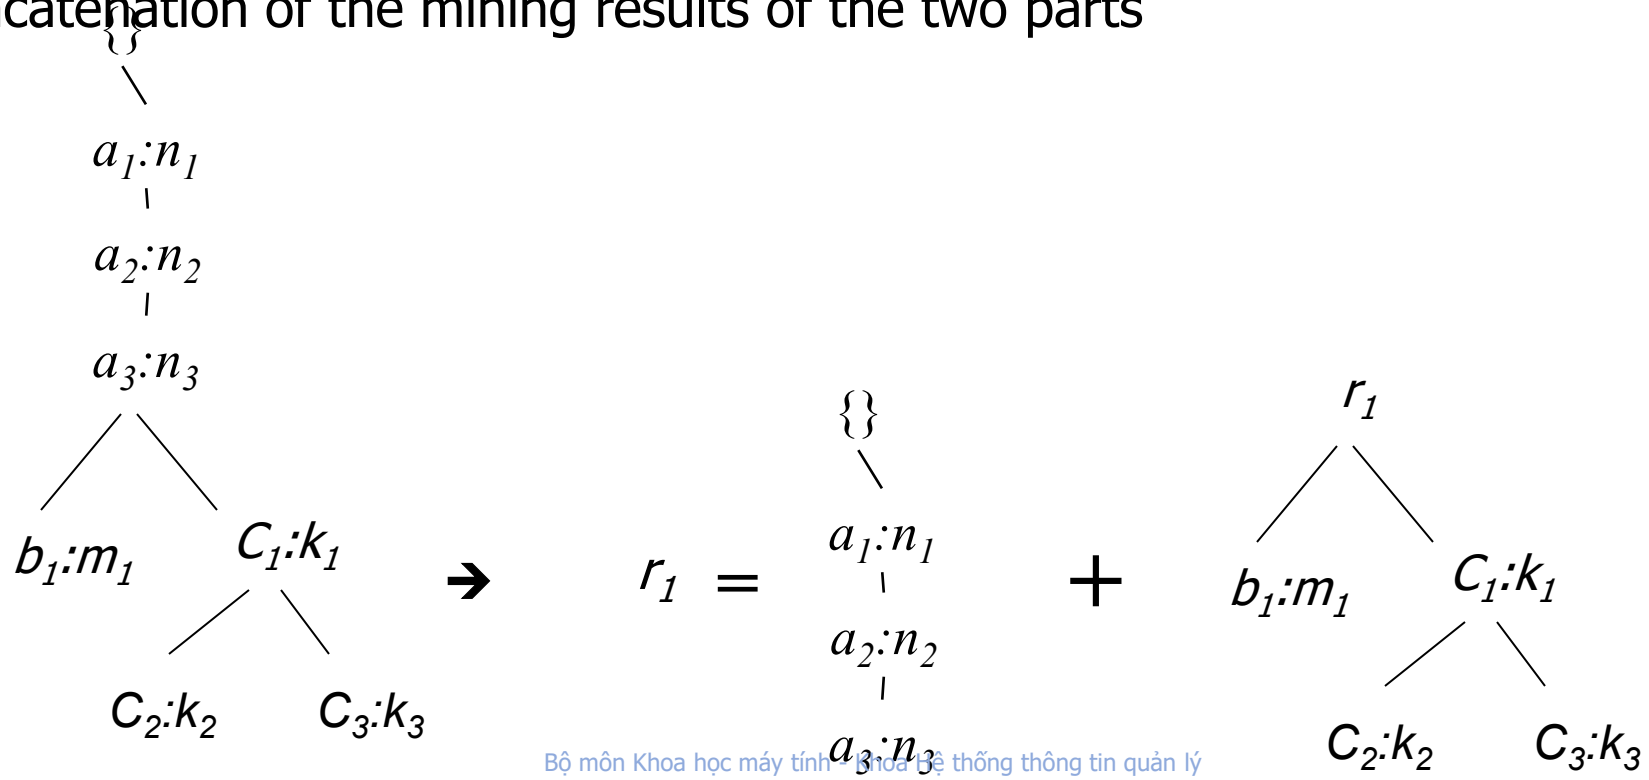
Cond. pattern base of "cam": (f:3)



***cam-conditional* FP-tree**

A Special Case: Single Prefix Path in FP-tree

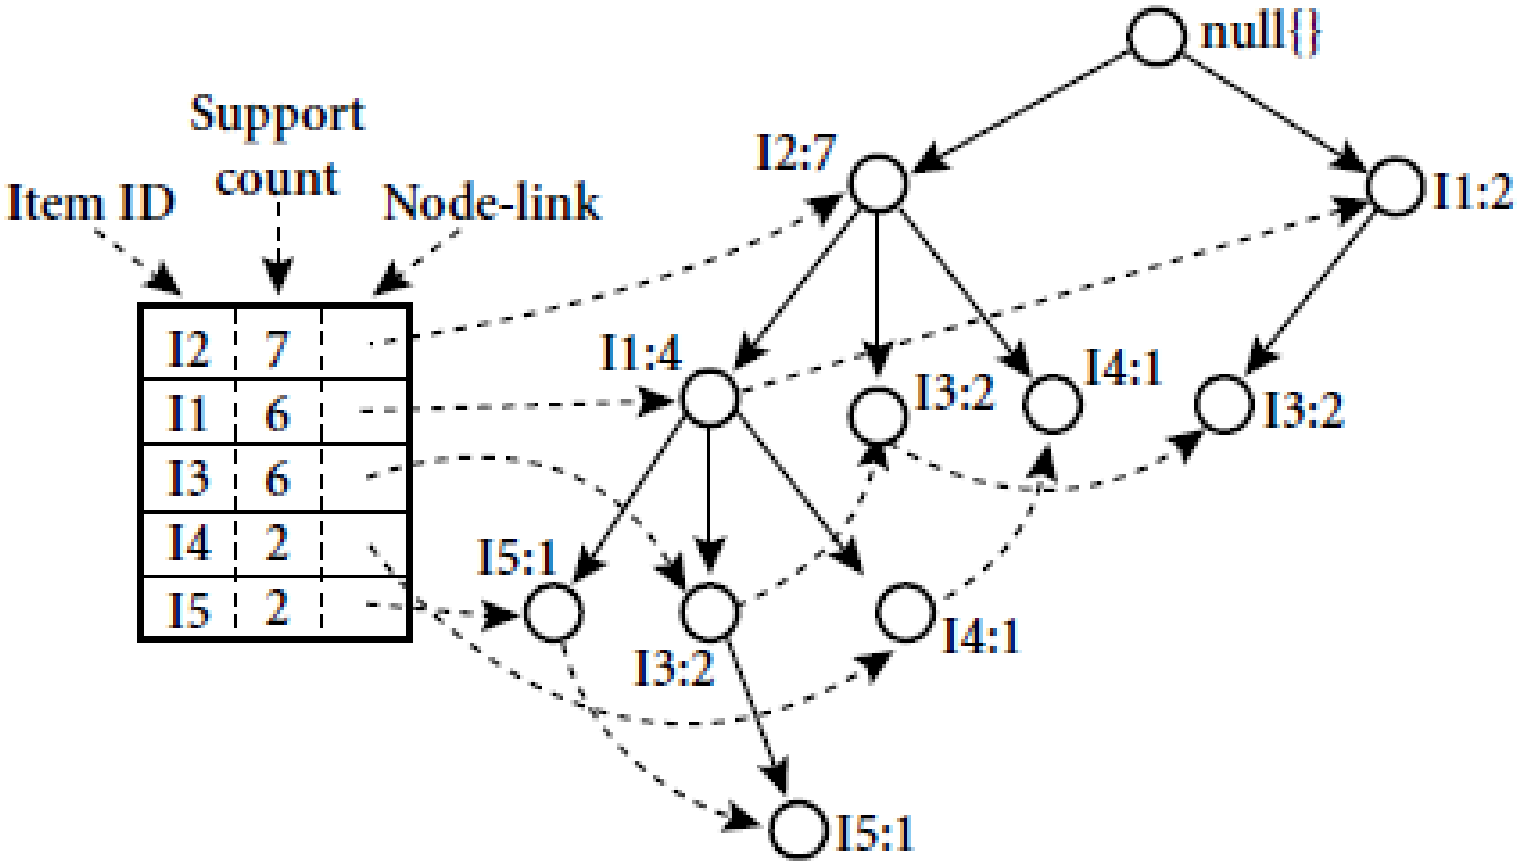
- Suppose a (conditional) FP-tree T has a shared single prefix-path P
- Mining can be decomposed into two parts
  - Reduction of the single prefix path into one node
  - Concatenation of the mining results of the two parts



min_support=2, F-list=I2(7), I1(6), I3(6), I4(2), I5(2)

Mã số giao dịch	Danh sách các mặt hàng
1	I2, I1, I5
2	I2, I4
3	I2, I3
4	I2, I1, I4
5	I1, I3
6	I2, I3
7	I1, I3
8	I2, I1, I3, I5
9	I2, I1, I3

FP-Tree


null{}
Item ID
Support count
Node-link
I2 7
I1 6
I3 6
I4 2
I5 2
I2:7
I1:2
I1:4
I3:2
I4:1
I3:2
I5:1
I3:2
I4:1
I5:1

Sinh tập phổ biến từ FP-tree

item	conditional pattern base	conditional FP-tree	frequent patterns generated
I5	{{I2,I1: 1}, {I2,I1,I3: 1}}	⟨I2: 2, I1: 2⟩	{I2,I5: 2}, {I1,I5: 2}, {I2,I1,I5: 2}
I4	{{I2,I1: 1}, {I2: 1}}	⟨I2: 2⟩	{I2,I4: 2}
I3	{{I2,I1: 2}, {I2: 2}, {I1: 2}}	⟨I2: 4, I1: 2⟩, ⟨I1: 2⟩	{I2,I3: 4}, {I1,I3: 4}, {I2,I1,I3: 2}
I1	{{I2: 4}}	⟨I2: 4⟩	{I2,I1: 4}

Lợi ích của cấu trúc FP-tree

- Tính đầy đủ
  - Duy trì tính đầy đủ thông tin để khai phá mẫu phổ biến
  - Không phá vỡ mẫu dài với bất kỳ giao dich
- Tính cô đọng
  - Giảm các thông tin không liên quan: mục không phổ biến bỏ đi
  - Sắp mục theo tần số giảm: xuất hiện càng nhiều thì càng hiệu quả
  - Không lớn hơn so với CSDL thông thường

Độ đo của luật

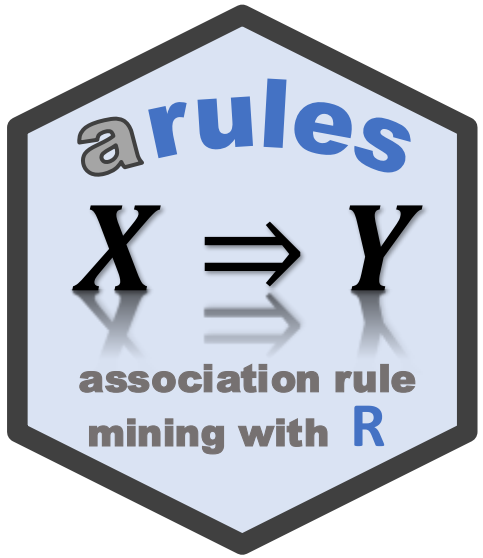
$$support(A \rightarrow B) = \mathrm{P}(\mathrm{A} \cup B)$$

$$confidence(A \rightarrow B) = P(A|B) = \frac{P(A \cup B)}{P(A)}$$

$$lift(A \rightarrow B) = \frac{confidence(A \rightarrow B)}{P(B)} = \frac{P(A \cup B)}{P(A) * P(B))}$$

Minh họa khai phá luật kết hợp





arulespy

min_support=30%

Mã số giao dịch	Danh sách các mặt hàng
1	I1, I4
2	I1, I2, I5
3	I2, I3, I4, I6
4	I2, I3, I4, I5
5	I1, I3, I5, I6
6	I2, I3, I4, I5, I6
7	I2,I4, I5
8	I2, I3, I5
9	I2, I3, I4, I6
10	I1, I2, I3, I5



THANK YOU FOR WATCHING!