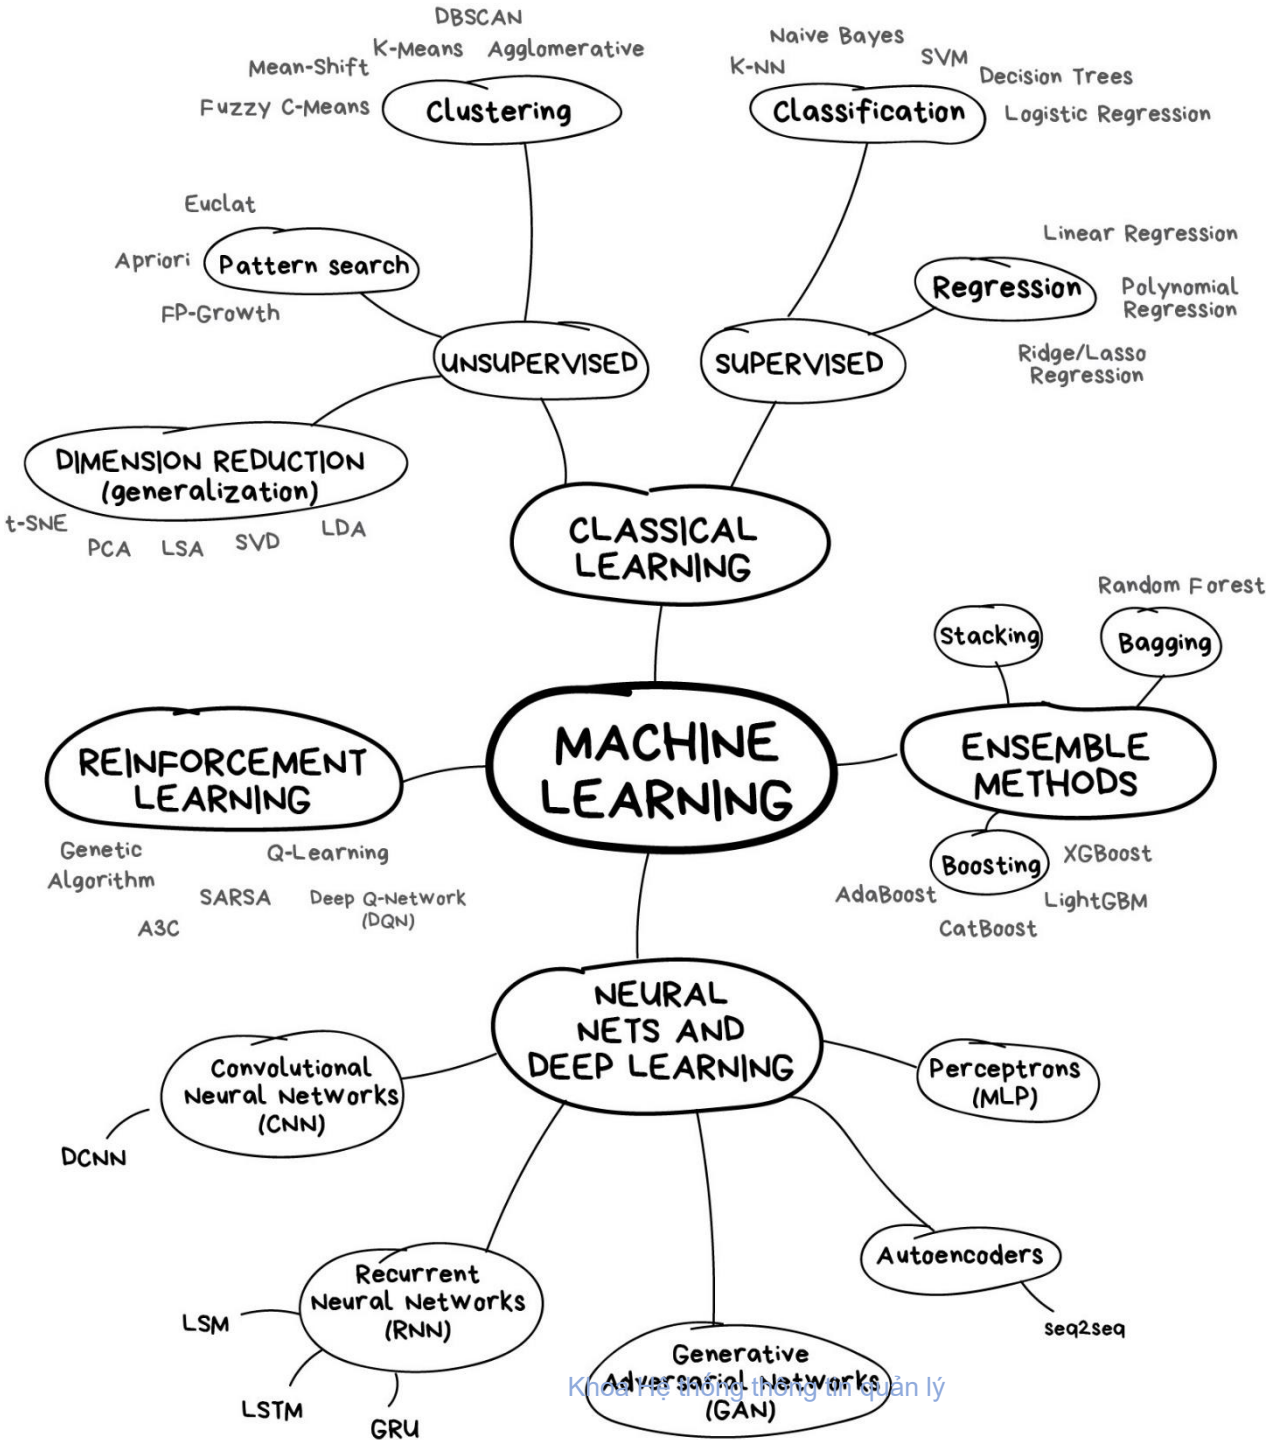
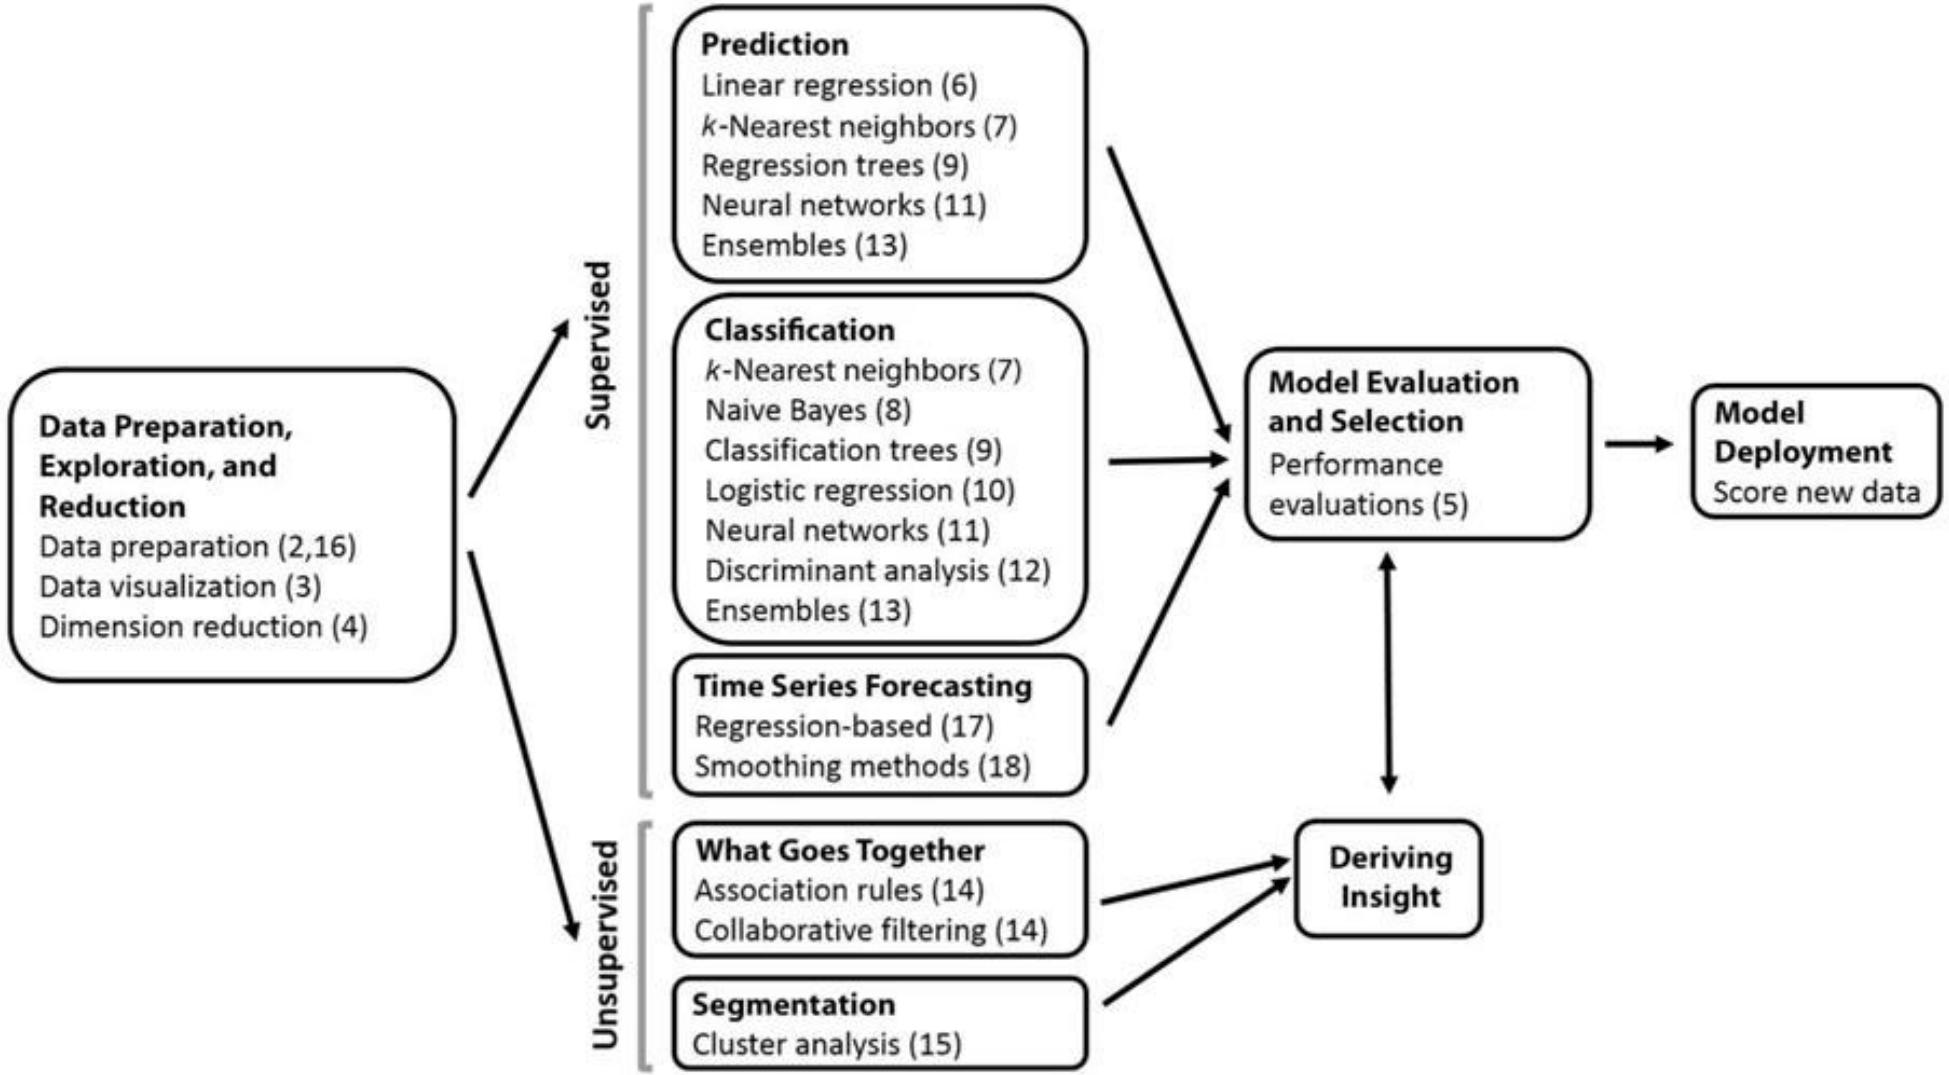
TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH

KHAI PHÁ DỮ LIỆU

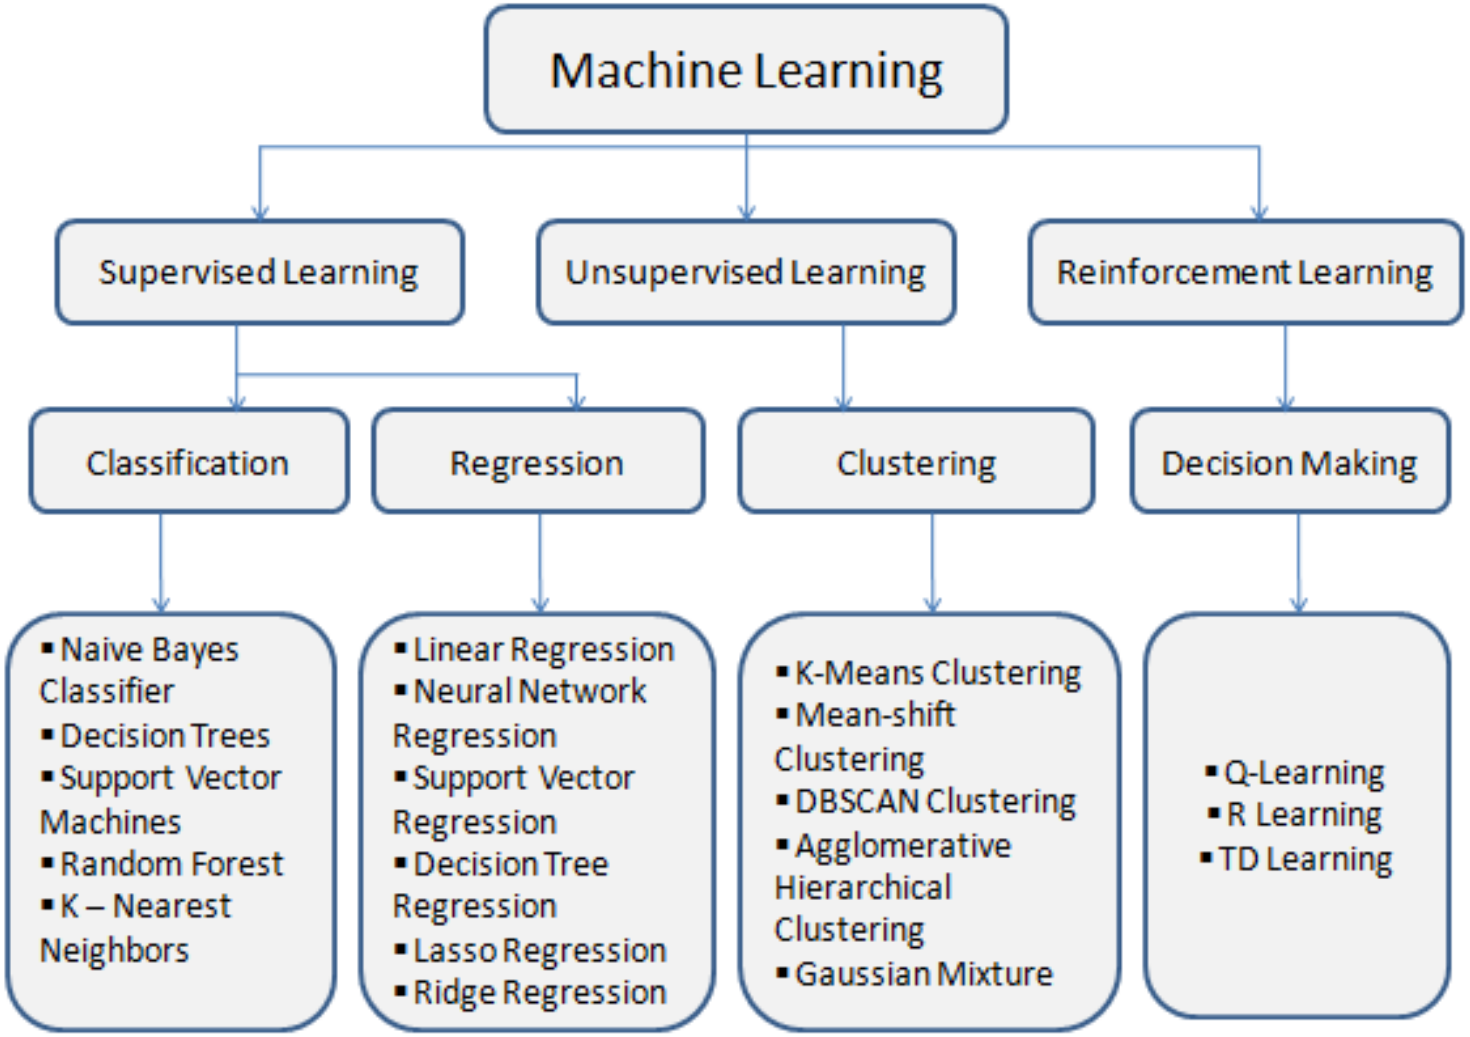
CHƯƠNG 4
MỘT SỐ PHƯƠNG PHÁP PHÂN LỚP VÀ DỰ BÁO
(PHẦN 1)


H U B
1976
TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH


MACHINE LEARNING
CLASSICAL LEARNING
UNSUPERVISED
Clustering
DBSCAN
K-Means
Agglomerative
Mean-Shift
Fuzzy C-Means
Pattern search
Euclat
Apriori
FP-Growth
DIMENSION REDUCTION (generalization)
t-SNE
PCA
LSA
SVD
LDA
SUPERVISED
Classification
Naive Bayes
K-NN
SVM
Decision Trees
Logistic Regression
Regression
Linear Regression
Polynomial Regression
Ridge/Lasso Regression
REINFORCEMENT LEARNING
Genetic Algorithm
Q-Learning
SARSA
Deep Q-Network (DQN)
A3C
ENSEMBLE METHODS
Stacking
Bagging
Random Forest
Boosting
XGBoost
AdaBoost
LightGBM
CatBoost
NEURAL NETS AND DEEP LEARNING
Convolutional Neural Networks (CNN)
DCNN
Perceptrons (MLP)
Recurrent Neural Networks (RNN)
LSM
LSTM
GRU
Generative Adversarial Networks (GAN)
Autoencoders
seq2seq


Data Preparation, Exploration, and Reduction
Data preparation (2,16)
Data visualization (3)
Dimension reduction (4)
Supervised
Prediction
Linear regression (6)
k-Nearest neighbors (7)
Regression trees (9)
Neural networks (11)
Ensembles (13)
Classification
k-Nearest neighbors (7)
Naive Bayes (8)
Classification trees (9)
Logistic regression (10)
Neural networks (11)
Discriminant analysis (12)
Ensembles (13)
Time Series Forecasting
Regression-based (17)
Smoothing methods (18)
Unsupervised
What Goes Together
Association rules (14)
Collaborative filtering (14)
Segmentation
Cluster analysis (15)
Model Evaluation and Selection
Performance evaluations (5)
Model Deployment
Score new data
Deriving Insight

Xác định mục đích khai phá dữ liệu



Mục tiêu

- Giải thích quá trình phân lớp dữ liệu
- Minh họa các giải thuật phân lớp cây quyết định, Bayes, ANN, kNN, SVM, hồi qui
- Sử dụng công cụ để hiện thực bài toán phân lớp.

Nội dung

1. Giới thiệu về phân lớp dữ liệu
2. Phân lớp dữ liệu với cây quyết định
3. Phương pháp phân lớp dữ liệu Bayes
4. Phân lớp và dự báo với máy vector hỗ trợ
5. Phân lớp và dự báo dữ liệu với mạng nơ-ron
6. Phân lớp k-NN
7. Hồi qui tuyến tính và hồi qui Logistic
8. Đánh giá và lựa chọn mô hình
9. Một số ứng dụng của phân lớp dữ liệu

1. Giới thiệu về phân lớp dữ liệu

- Tổng quan về phân lớp dữ liệu
- Một số phương pháp phân lớp dữ liệu

1.1 Tổng quan về phân lớp dữ liệu

- Phân lớp dữ liệu:
  - Dự đoán nhãn (label) của lớp phân loại
  - Phân lớp dữ liệu (xây dựng mô hình) dựa trên tập huấn luyện và các giá trị (các nhãn của lớp) trong thuộc tính phân lớp và dùng nó để phân lớp dữ liệu mới
- Một số ứng dụng điển hình:
  - Phê duyệt tín dụng/khoản vay
  - Chuẩn đoán y tế
  - Dò tìm lỗi
  - Phân loại trang web

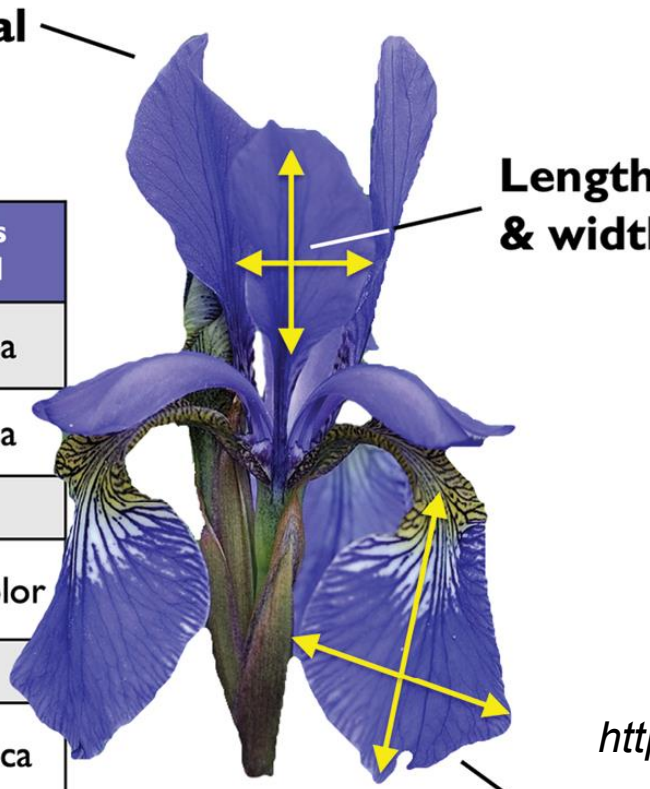
Phân lớp (Classification)

Samples
(instances, observations)

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
			...		
50	6.4	3.5	4.5	1.2	Versicolor
			...		
150	5.9	3.0	5.0	1.8	Virginica

Features
(inputs, attributes, measurements, dimensions)

Class labels
(targets, outcomes)



Tập dữ liệu Iris dự đoán loài hoa dựa vào kích thước cánh hóa và đài hoa

https://archive.ics.uci.edu/ml/datasets/iris

Tổng quan về hồi qui

- Mô hình hồi qui (regression model): mô hình mô tả mối liên kết (relationship) giữa một tập các biến dự báo (predictor variables/independent variables) và một hay nhiều đáp ứng (responses/dependent variables).
- Phân loại
  - Hồi qui tuyến tính (linear) và phi tuyến (nonlinear)
  - Hồi qui đơn biến (single) và đa biến (multiple)
  - Hồi qui có tham số (parametric), phi tham số (nonparametric), và tham số kết hợp (semiparametric)
  - Hồi qui đối xứng (symmetric) và bất đối xứng (asymmetric)

Hồi quy (Regression)

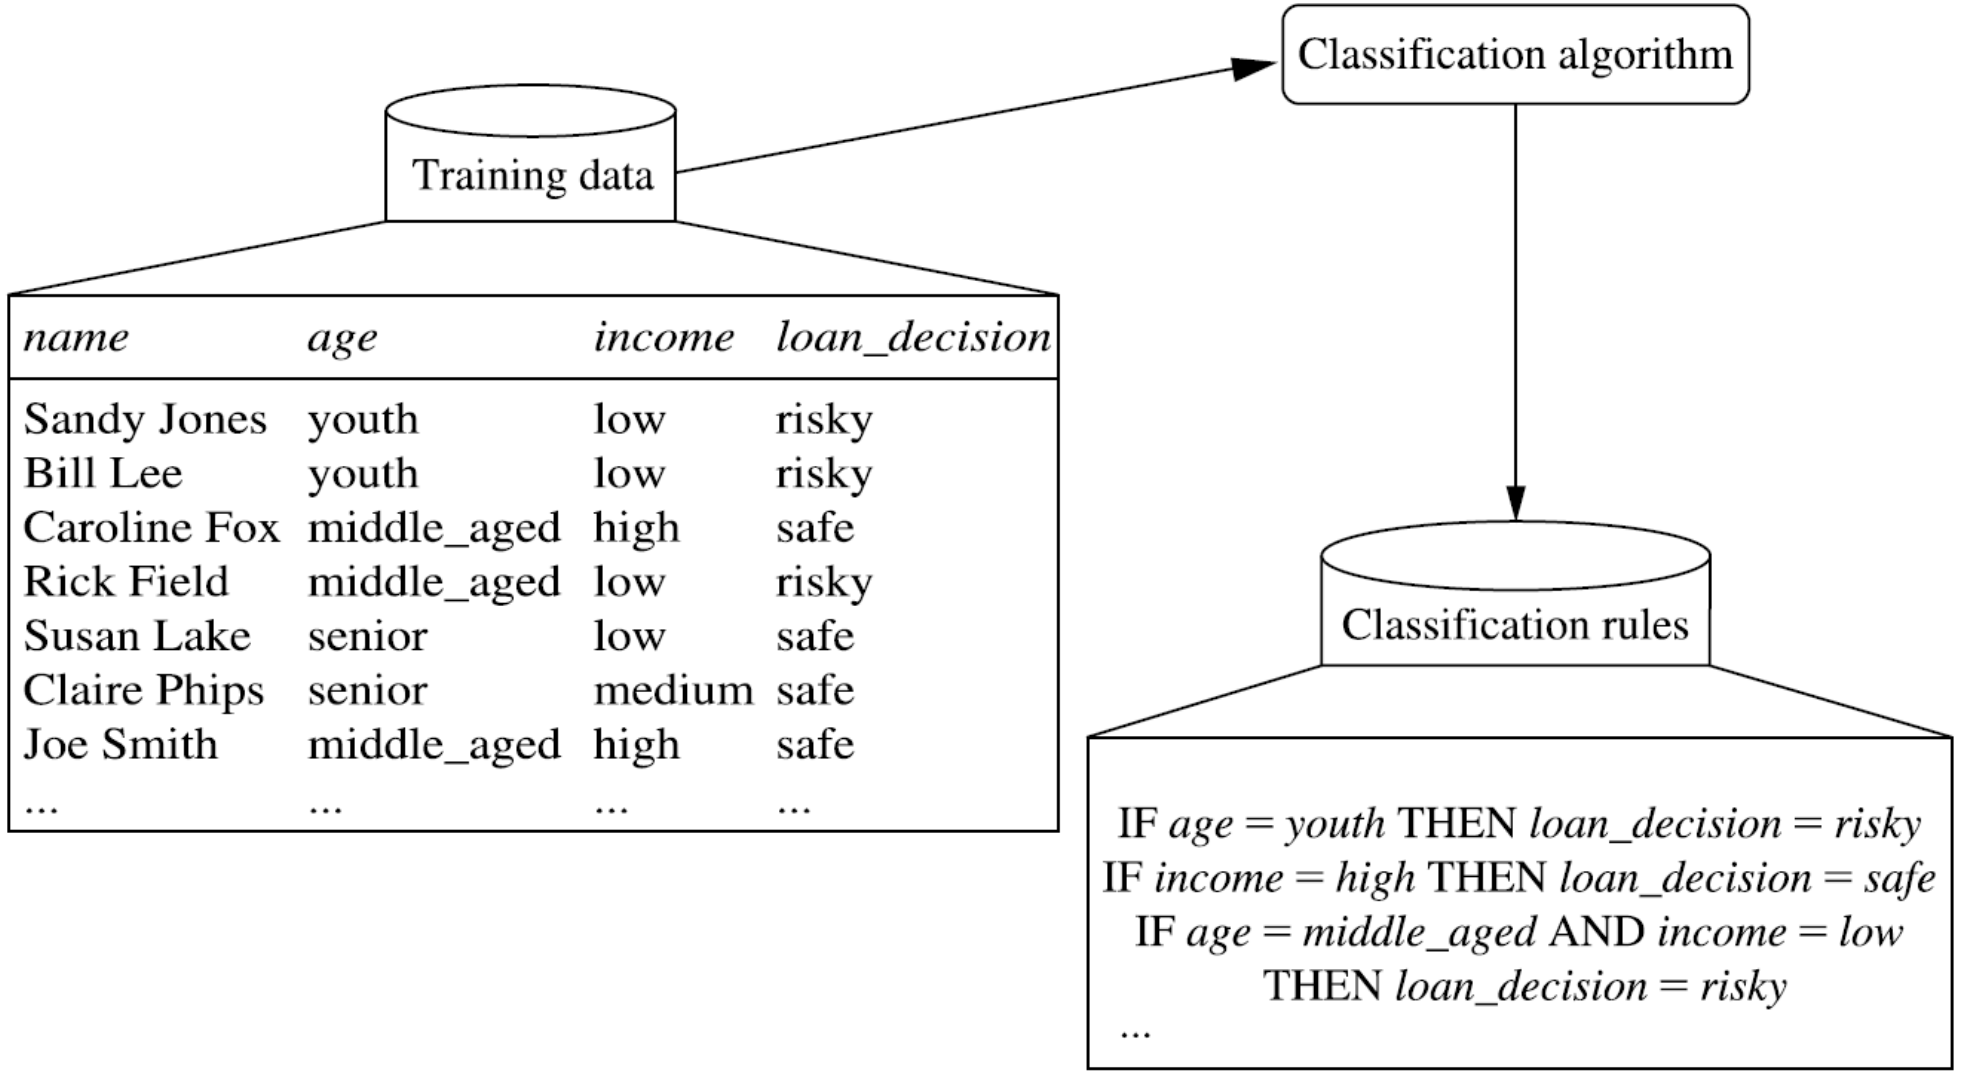
	A	B	C	D	E
1	area	bedrooms	balcony	age	price
2	1200	2	0	2	500000
3	2300	3	2	5	620000
4	2500	4	2	1	122500
5	3650	5	3	3	6000000
6	1800	3	1	5	2122000
7	3000	3	1	4	120000
8	1222	1	0	2	450000
9	4600	5	3	1	6500000
10	2050	2	2	2	1530000
11	1450	2	2	3	1563330

Nhãn liên tục

3.2 Quá trình phân lớp

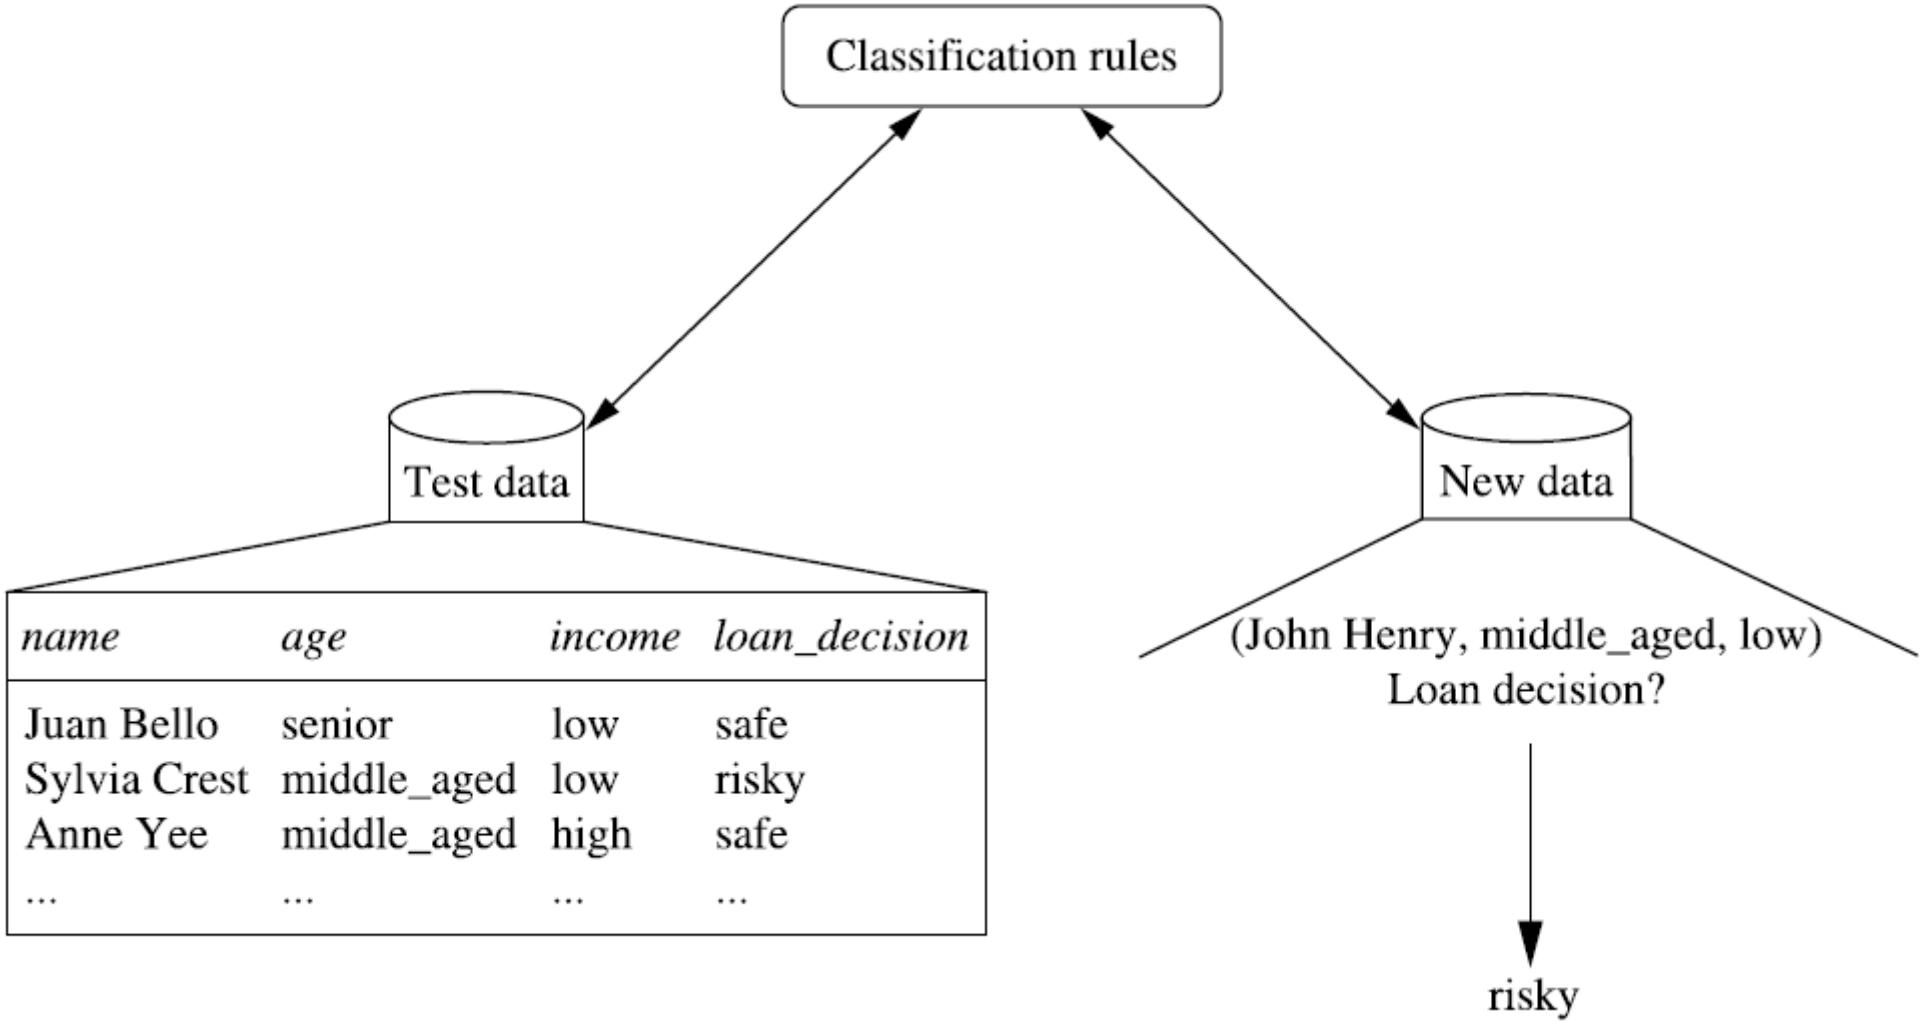
- Bước 1: Học (*Learning*) hay xây dựng mô hình (*Model Construction*)
  - Mô tả một tập hợp các lớp đã xác định trước
- Bước 2: Phân lớp (*Classification)* hay Sử dụng mô hình (*Model usage*)
  - Dùng để phân lớp sau này hoặc những mục tiêu chưa biết

Bước 1: Học (xây dựng mô hình)



name	*age*	*income*	*loan_decision*
Sandy Jones	youth	low	risky
Bill Lee	youth	low	risky
Caroline Fox	middle_aged	high	safe
Rick Field	middle_aged	low	risky
Susan Lake	senior	low	safe
Claire Phips	senior	medium	safe
Joe Smith	middle_aged	high	safe
...	...	...	...

Bước 2: Phân lớp (sử dụng mô hình)



name	*age*	*income*	*loan_decision*
Juan Bello	senior	low	safe
Sylvia Crest	middle_aged	low	risky
Anne Yee	middle_aged	high	safe
...	...	...	...

1.3 Các loại phân lớp

- Phân lớp nhị phân/đa lớp:
  - |C|=2: phân lớp nhị phân.
  - |C|>2: phân lớp đa lớp.
- Phân lớp đơn nhãn/đa nhãn:
  - Đơn nhãn: mỗi đối tượng được gán vào chính xác một lớp.
  - Đa nhãn: một đối tượng có thể được gán nhiều hơn một lớp.
  - Phân cấp: lớp này là cha/con của lớp kia

1.4 Đánh giá mô hình phân lớp

- Các phương pháp đánh giá độ chính xác của mô hình phân lớp:
  - Holdout method, random subsampling
  - Cross-validation
  - Bootstrap
- Ma trận lỗi/nhầm lẫn (Confusion Matrix)

Lớp dự đoán (*Predicted class*)

Lớp thật (*Actual class*)		C_1	$\neg C_1$
	C_1	**True Positives (TP)**	**False Negatives (FN)**
	$\neg C_1$	**False Positives (FP)**	**True Negatives (TN)**

- True Positives (TP): Thực dương/Dương tính thật
- True Negatives (TN): Thực âm/Âm tính giả
- False Positives (FP): Dương sai/Dương tính giả
- False Negatives (FN): Âm sai/Âm tính giả

3.4 Đánh giá mô hình phân lớp: Đánh giá phân lớp nhị phân

- Độ chính xác của bộ phân lớp (Classifier Accuracy):

$$Accuracy = \frac{TP+TN}{All}$$

- Tỉ lệ lỗi (Error rate):

$$Error\ rate = \frac{FP + FN}{All} = 1 - accuracy$$

❖ Dùng độ chính xác (Accuracy), tỉ lệ lỗi (Error rate), Độ nhạy (Sensitivity) và độ đặc trưng/đặc hiệu (Specificity)

A\P	C	¬C	
C	**TP**	**FN**	**P**
¬C	**FP**	**TN**	**N**
	P'	**N'**	**All**

- Sensitivity: True Positive recognition rate

$$Sensitivity = \frac{TP}{P}$$

- Specificity: True Negative recognition rate

$$Specificity = \frac{TN}{N}$$

3.4 Đánh giá mô hình phân lớp: Đánh giá phân lớp nhị phân

- Dùng độ chính xác (Precision), độ hồi tưởng (Recall) và các độ đo F (F-measures)

$$precision = \frac{TP}{TP + FP}$$

$$recall = \frac{TP}{TP + FN}$$

$$F = \frac{2 \times precision \times recall}{precision + recall}$$

$$F_\beta = \frac{(1 + \beta^2) \times precision \times recall}{\beta^2 \times precision + recall}$$

3.4 Đánh giá mô hình phân lớp: Đánh giá phân lớp đa lớp

- Bài toán ban đầu: C gồm có k lớp
- Đối với mỗi lớp C_i , cho thực hiện thuật toán với các dữ liệu thuộc D_{test} nhận được các đại lượng TP_i, TF_i, FP_i, FN_i (như bảng dưới đây)

Lớp C_i		Giá trị qua bộ phân lớp đa lớp	
		Thuộc lớp C_i	**Không thuộc lớp C_i**
Giá trị thực	**Thuộc lớp C_i**	TP_i	FN_i
	Không thuộc lớp C_i	FP_i	TN_i

3.4 Đánh giá mô hình phân lớp: Đánh giá phân lớp đa lớp

- Tương tự bộ phân lớp nhị phân
  - Độ chính xác Pri của lớp Ci là tỷ lệ số phần tử dương được thuật toán phân lớp cho giá trị đúng trên tổng số ví dụ được thuật toán phân lớp vào lớp Ci :

$$\mathrm{Pr}_i = \frac{TP_i}{TP_i + FP_i}$$

  - Độ hồi tưởng Rei của lớp Ci là tỷ lệ số ví dụ dương được thuật toán phân lớp cho giá trị đúng trên tổng số ví dụ dương thực sự thuộc lớp Ci:

$$\mathrm{Re}_i = \frac{TP_i}{TP_i + FN_i}$$

3.4 Đánh giá mô hình phân lớp: Đánh giá phân lớp đa lớp

- ρi : Độ chính xác của lớp Ci
- πi : Độ hồi tưởng của lớp Ci.
- Đánh giá mô hình phân lớp theo các độ đo:
  - Vi trung bình (microaveraging) (được ưa chuộng) ρμ và πμ
  - Trung bình lớn (macroaveraging) ρM và πM

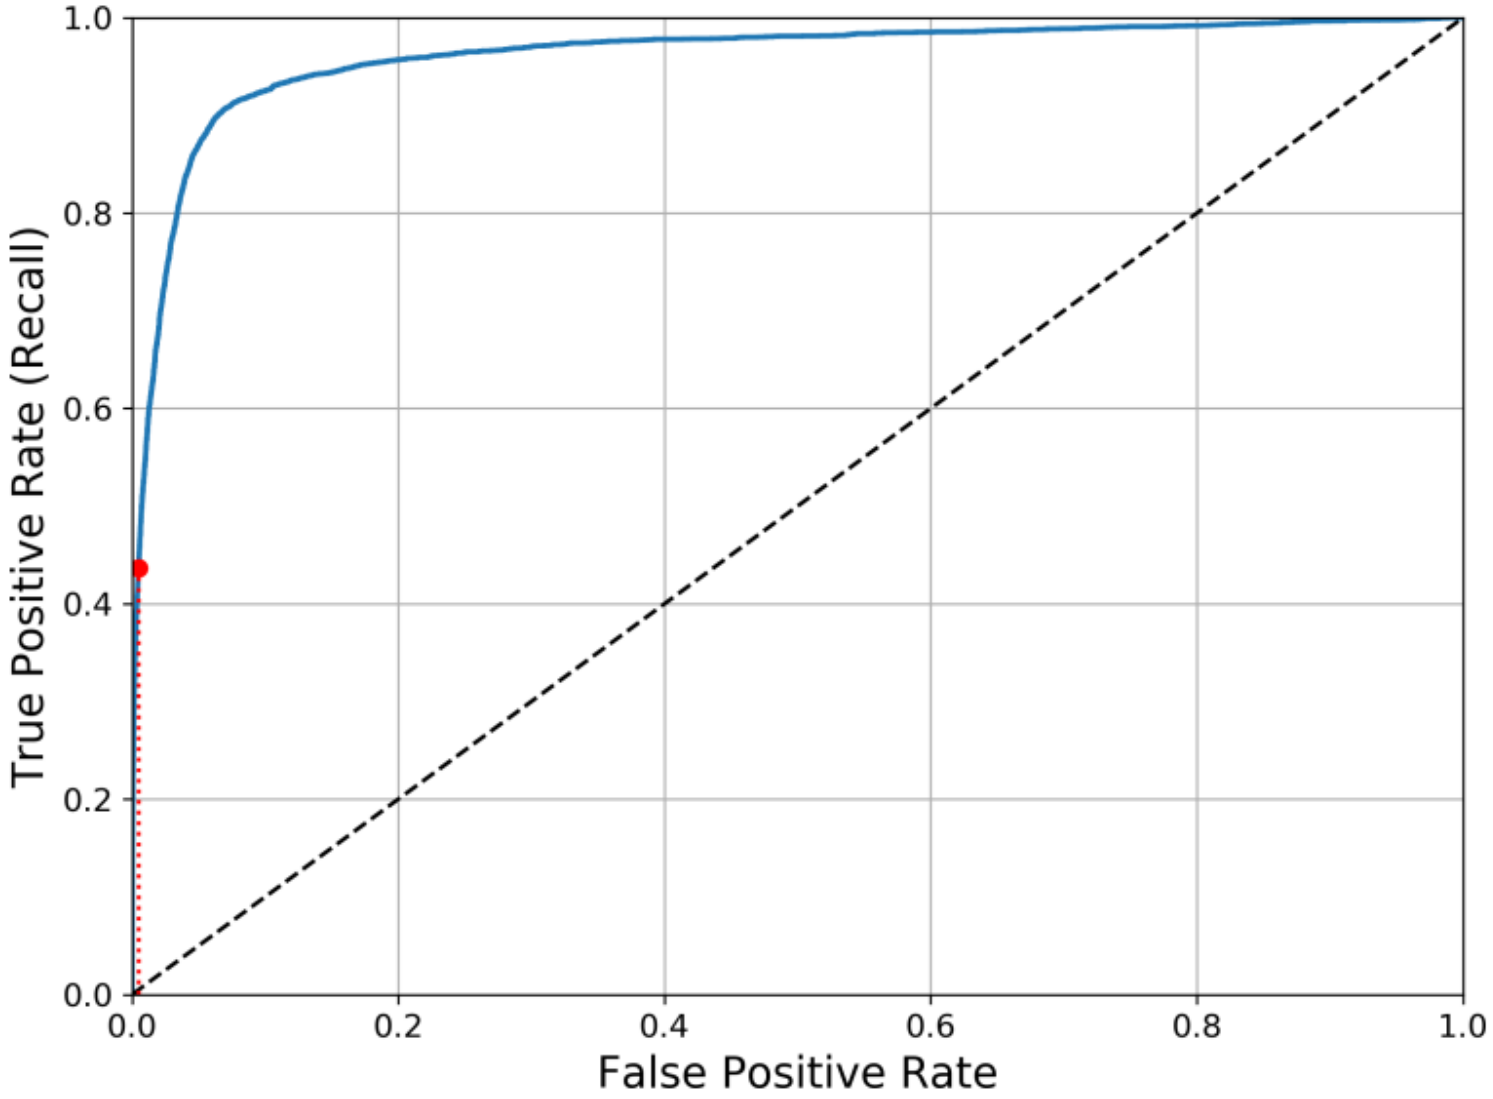
$$\rho^M = \frac{1}{K}\sum_{c=1}^{K}\rho_c \qquad \pi^M = \frac{1}{K}\sum_{c=1}^{K}\pi_c$$

$$\rho^\mu = \frac{\sum_{c=1}^{K} TP_c}{\sum_{c=1}^{K}(TP_c + FP_c)} \qquad \pi^\mu = \frac{\sum_{c=1}^{K} TP_c}{\sum_{c=1}^{K}(TP_c + FN_c)}$$

Đánh giá các mô hình phân lớp (nhãn rời rạc)

Measure	*Formula*
accuracy, recognition rate	$\frac{TP+TN}{P+N}$
error rate, misclassification rate	$\frac{FP+FN}{P+N}$
sensitivity, true positive rate, recall	$\frac{TP}{P}$
specificity, true negative rate	$\frac{TN}{N}$
precision	$\frac{TP}{TP+FP}$
F, F_1, F-score, harmonic mean of precision and recall	$\frac{2 \times precision \times recall}{precision + recall}$
F_β, where β is a non-negative real number	$\frac{(1+\beta^2) \times precision \times recall}{\beta^2 \times precision + recall}$

Đánh giá các mô hình phân lớp (nhãn rời rạc)



ROC curve

Receiver Operating Characteristics (ROC)

Đánh giá mô hình hồi quy (nhãn liên tục)

R-Squared (R2), Adjusted R-Squared

Mean absolute error (MAE)

$$\text{MAE} = \frac{1}{\text{N}}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

Mean Squared Error (MSE)

$$\text{MSE} = \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{N}$$

Root mean square error (RMSE)

$$\text{RMSE} = \sqrt{\frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{N}}$$

Mean absolute percentage error (MAPE)

$$\text{MAPE} = \frac{\sum_{i=1}^{N}\frac{|y_i - \hat{y}_i|}{y_i}}{N}$$

Bayesian Information Criteria (BIC)

1.5 Một số phương pháp phân lớp dữ liệu

- Phương pháp dựa trên cây quyết định (Decision Tree based Methods)
- Phương pháp Naïve Bayes
- Phương pháp dựa trên luật (Rule-based Methods)
- Các phương pháp máy vector hỗ trợ (Support Vector Machines)
- Lập luận dưa trên ghi nhớ (Memory based reasoning)
- Các phương pháp mạng nơron (Neural Networks)

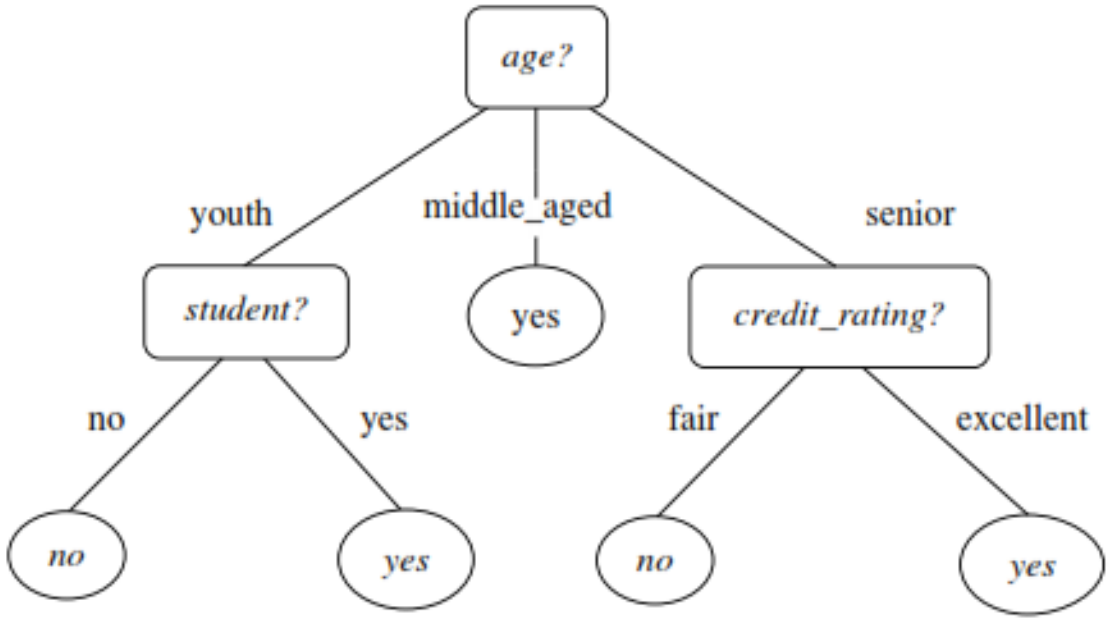
2. Phân lớp với cây quyết định

RID	age	income	student	credit_rating	Class: buys_computer
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	low	yes	fair	yes
6	senior	low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

Cơ sở dữ liệu khách hàng dùng cho bước học

3.5.1 Phân lớp với cây quyết định

- Cây quyết định (decision tree) - mô hình phân lớp
  - Node nội: phép kiểm thử (test) trên một thuộc tính
  - Node lá: nhãn/mô tả của một lớp (class label)
  - Nhánh từ một node nội: kết quả của một phép thử trên thuộc tính tương ứng



Cây quyết định học được từ tập huấn luyện

2.1 Phân lớp với cây quyết định

- Giải thuật xây dựng cây quyết định
  - ID3, C4.5, CART (Classification and Regression Trees – binary decision trees)

Algorithm: Generate decision tree. Generate a decision tree from the training tuples of data partition, *D*.

Input:

- Data partition, *D*, which is a set of training tuples and their associated class labels;
- *attribute list*, the set of candidate attributes;
- *Attribute selection method*, a procedure to determine the splitting criterion that "best" partitions the data tuples into individual classes. This criterion consists of a *splitting attribute* and, possibly, either a *split-point* or *splitting subset*.

Output: A decision tree.

3.5.1 Phân lớp với cây quyết định

Method:

(1) create a node *N*;

(2) **if** tuples in *D* are all of the same class, *C*, **then**

(3) return *N* as a leaf node labeled with the class *C*;

(4) **if** *attribute list* is empty **then**

(5) return *N* as a leaf node labeled with the majority class in *D*; // majority voting

(6) apply **Attribute selection method**(*D*, *attribute list*) to **find** the "best" *plitting criterion*;

(7) label node *N* with *splitting criterion*;

(8) **if** *splitting attribute* is discrete-valued **and** multiway splits allowed **then** // not restricted to binary trees

(9) *Attribute list attribute list splitting attribute*; // remove *splitting attribute*

(10) **for each** outcome *j* of *splitting criterion*

// partition the tuples and grow subtrees for each partition

(11) let *Dj* be the set of data tuples in *D* satisfying outcome *j*; // a partition

(12) **if** *Dj* is empty **then**

(13) attach a leaf labeled with the majority class in *D* to node *N*;

(14) **else** attach the node returned by **Generate decision tree**(*D*, *attribute list*) to node *N*;

endfor

(15) return *N*;

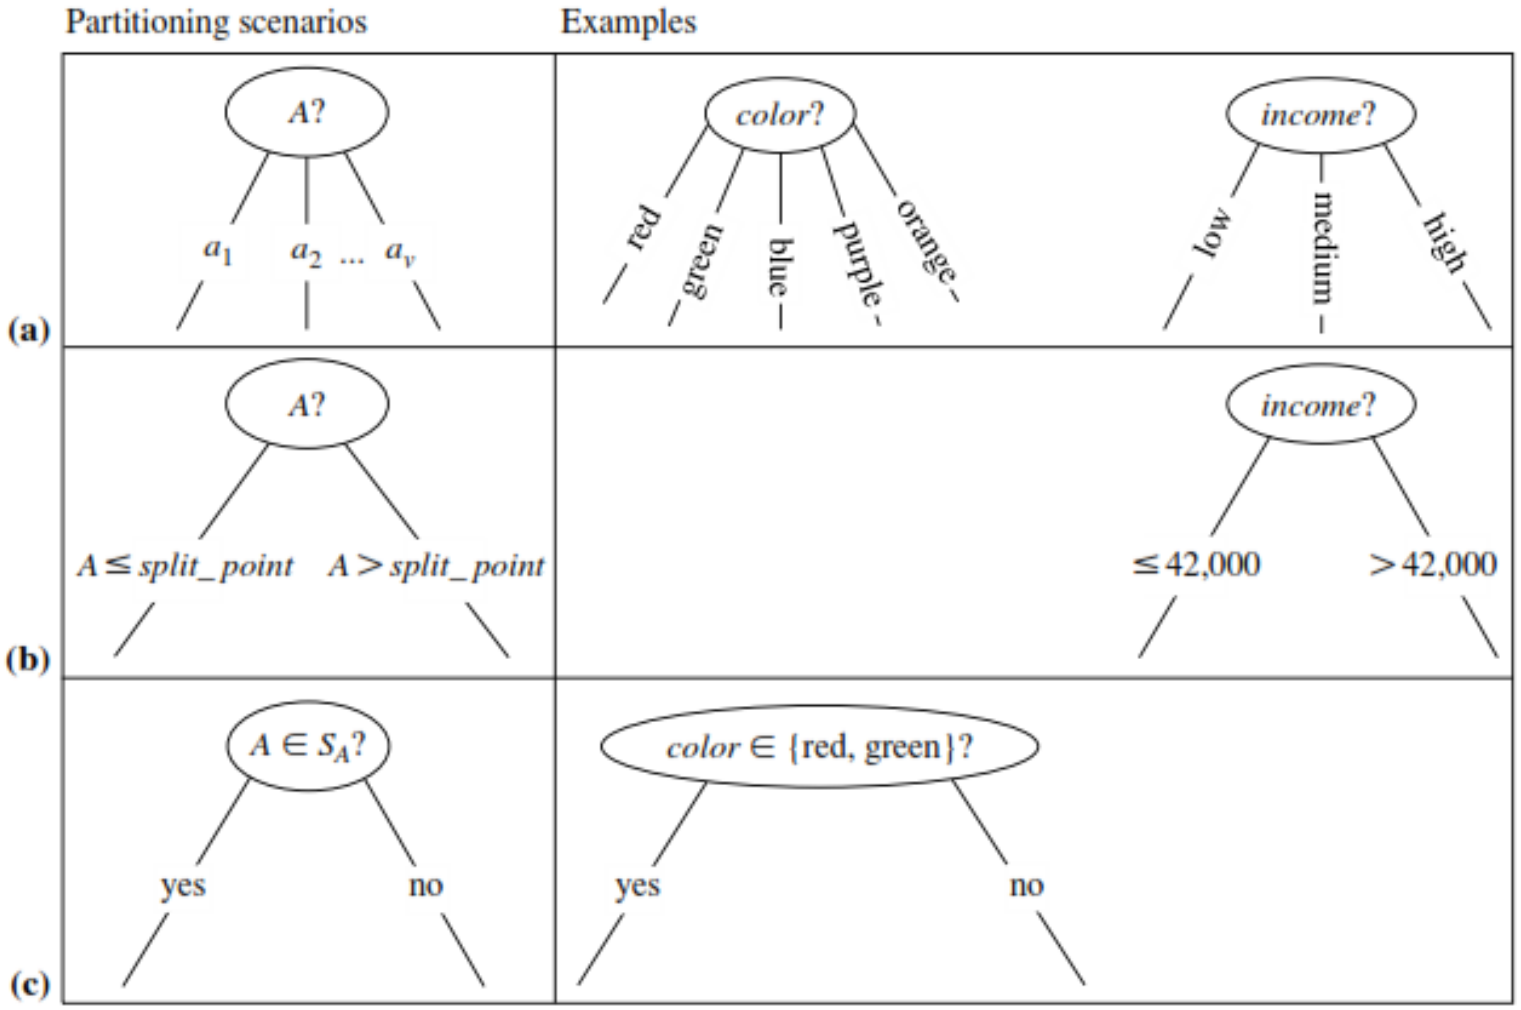
2.1 Phân lớp với cây quyết định

- Đặc điểm của giải thuật:
  - Giải thuật tham lam (không có quay lui), chia để trị, đệ qui, từ trên xuống
  - Độ phức tạp với tập huấn luyện D gồm |D| phần tử (đối tượng), mỗi phần tử gồm n thuộc tính
    - O(n*|D|*log|D|)
      - Mỗi thuộc tính ứng với mỗi mức (level) của cây.
      - Cho mỗi mức của cây, |D| phân tử huấn luyện được duyệt qua.

2.1 Phân lớp với cây quyết định

- Phương pháp chọn thuộc tính
  - Phương thức dùng heuristic để chọn tiêu chí rẽ nhánh tại một node, i.e. phân hoạch tập huấn luyện D thành các phân hoạch con với các nhãn phù hợp
    - Xếp hạng mỗi thuộc tính
    - Thuộc tính được chọn để rẽ nhánh là thuộc có trị số điểm (score) lớn nhất
    - Độ đo chọn thuộc tính phân tách (splitting attribute):
      - information gain (dùng trong ID3, C4.5/J48)
      - gain ratio (dùng trong C4.5/J48)
      - gini index (dùng trong CART)

2.1 Phân lớp với cây quyết định



A là thuộc tính phân tách (splitting attribute).

2.1 Phân lớp với cây quyết định

- Độ đo Information Gain (Độ lợi thông tin)
  - Dựa trên lý thuyết thông tin (information theory) của Claude Shannon về giá trị (nội dung thông tin) của tin
  - Thuộc tính tương ứng với information gain lớn nhất sẽ được chọn làm thuộc tính phân hoạch (splitting attribute) cho node N.
    - Node N là node hiện tại cần phân hoạch các phần tử trong D.
    - Splitting attribute đảm bảo sự trùng lắp (impurity)/ngẫu nhiên (randomness) ít nhất giữa các phân hoạch tạo được.
    - Cách tiếp cận này giúp tối thiểu số phép thử (test) để phân loại một phần tử.

2.1 Phân lớp với cây quyết định

- Độ đo *Information Gain*
  - Lượng thông tin cần để phân loại một phần tử trong D (= Entropy của D): Info(D)
    - p_i: xác suất để một phần tử bất kỳ trong D thuộc về lớp C_i với i = 1..m
    - $C_{i,D}$: tập các phần tử của lớp C_i trong D

$$Info(D) = -\sum_{i=1}^{m} p_i \log_2(p_i)$$

$$p_i = \frac{|C_{i,D}|}{|D|}$$

3.5.1 Phân lớp với cây quyết định

- Độ lợi thông tin (Information Gain)
  - Lượng thông tin cần để phân loại một phần tử trong D dựa trên thuộc tính A: $Info_A(D)$
    - Thuộc tính A dùng phân tách D thành v phân hoạch $\{D_1, D_2, \ldots, D_j, \ldots, D_v\}$.
    - Mỗi phân hoạch D_j gồm $|D_j|$ phần tử trong D.
    - Lượng thông tin này sẽ cho biết mức độ trùng lắp giữa các phân hoạch, nghĩa là một phân hoạch chứa các phần tử từ một lớp hay nhiều lớp khác nhau.
    - Mong đợi: $Info_A(D)$ càng nhỏ càng tốt.

$$Info_A(D) = \sum_{j=1}^{v} \frac{|D_j|}{|D|} * Info(D_j)$$

X={age=senior, income=high, student=no, credit_rating=fair}

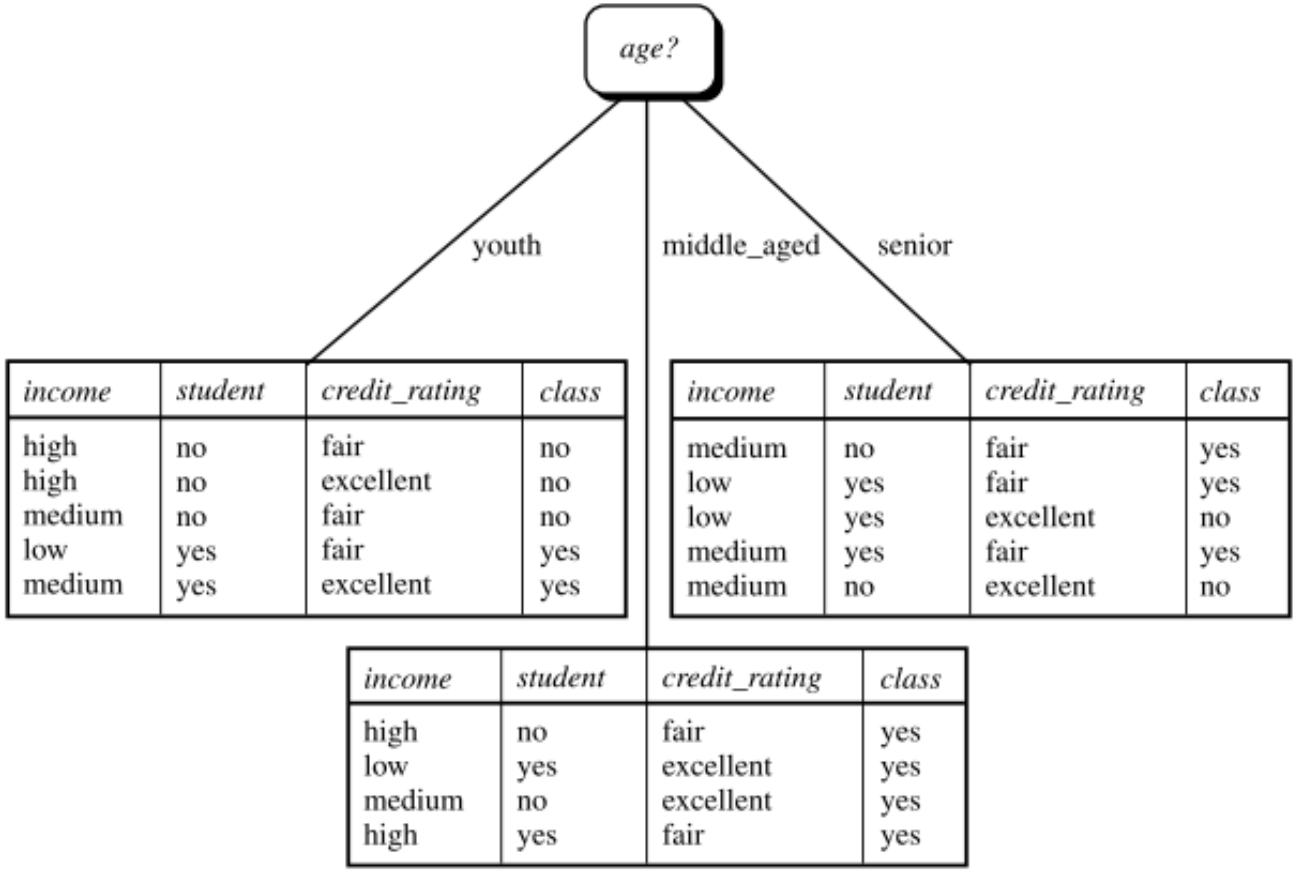
RID	age	income	student	credit_rating	Class: buys_computer
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	low	yes	fair	yes
6	senior	low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

3.5.1 Phân lớp với cây quyết định

- Độ lợi thông tin (*Information Gain*)
  - Information gain chính là độ sai biệt giữa trị thông tin Info(D) ban đầu (trước phân hoạch) và trị thông tin mới $Info_A(D)$ (sau phân hoạch với A).

$$Gain(A) = Info(D) - Info_A(D)$$

3.5.1 Phân lớp với cây quyết định



income	*student*	*credit_rating*	*class*
high	no	fair	no
high	no	excellent	no
medium	no	fair	no
low	yes	fair	yes
medium	yes	excellent	yes

income	*student*	*credit_rating*	*class*
medium	no	fair	yes
low	yes	fair	yes
low	yes	excellent	no
medium	yes	fair	yes
medium	no	excellent	no

income	*student*	*credit_rating*	*class*
high	no	fair	yes
low	yes	excellent	yes
medium	no	excellent	yes
high	yes	fair	yes

$$Gain(age) = Info(D) - Info_{age}(D) = 0.940 - 0.694 = 0.246 \text{ bits}.$$

Gain(income)= 0.029 bits,
Gain(student)= 0.151 bits
Gain(credit_rating)= 0.048 bits

Gain(age)=0.246 bits

Gain(income)?

Gain(student)?

Gain(credit_rating)?

→ Splitting attribute?

$$Info(D) = -\frac{9}{14}\log_2\left(\frac{9}{14}\right) - \frac{5}{14}\log_2\left(\frac{5}{14}\right) = 0.940 \text{ bits}$$

$$\begin{aligned} Info_{age}(D) = {} & \frac{5}{14} \times \left(-\frac{2}{5}\log_2\frac{2}{5} - \frac{3}{5}\log_2\frac{3}{5}\right) \\ & + \frac{4}{14} \times \left(-\frac{4}{4}\log_2\frac{4}{4} - \frac{0}{4}\log_2\frac{0}{4}\right) \\ & + \frac{5}{14} \times \left(-\frac{3}{5}\log_2\frac{3}{5} - \frac{2}{5}\log_2\frac{2}{5}\right) \\ = {} & 0.694 \text{ bits}. \end{aligned}$$

3.5.1 Phân lớp với cây quyết định

- Độ đo Gain Ratio: GainRatio(A)
  - Dùng với C4.5
  - Giải quyết vấn đề một thuộc tính được dùng tạo ra rất nhiều phân hoạch (thậm chí mỗi phân hoạch chỉ gồm 1 phần tử).
  - Chuẩn hoá information gain với trị thông tin phân tách (split information): $SplitInfo_A(D)$
  - Thuộc tính phân tách (Splitting attribute): A tương ứng với trị **GainRatio(A) là trị lớn nhất**.

$$SplitInfo_A(D) = -\sum_{j=1}^{v} \frac{|D_j|}{|D|} \times \log_2\left(\frac{|D_j|}{|D|}\right)$$

$$GainRatio(A) = \frac{Gain(A)}{SplitInfo_A(D)}$$

$$SplitInfo_{income}(D) = -\frac{4}{14} \times \log_2\left(\frac{4}{14}\right) - \frac{6}{14} \times \log_2\left(\frac{6}{14}\right) - \frac{4}{14} \times \log_2\left(\frac{4}{14}\right)$$

$$= 1.557.$$

From Example 8.1, we have $Gain(income) = 0.029$. Therefore, $GainRatio(income) = 0.029/1.557 = 0.019$. ■

2.1 Phân lớp với cây quyết định

- Độ đo Gini Index
  - Dùng với CART
  - Sự phân tách nhị phân (binary split) cho mỗi thuộc tính A
    - A ∈ SA?
    - SA là một tập con gồm một hay v-1 trị thuộc tính A.
  - Gini index của một thuộc tính là trị nhỏ nhất tương ứng với một tập con SA từ 2v – 2 tập con.
  - Splitting attribute tương ứng với gini index nhỏ nhất để tối đa hóa sự suy giảm về độ trùng lắp giữa các phân hoạch.

$$gini(D) = 1 - \sum_{j=1}^{n} p_j^2$$

$$gini_A(D) = \frac{|D_1|}{|D|} gini(D_1) + \frac{|D_2|}{|D|} gini(D_2)$$

$$\Delta gini(A) = gini(D) - gini_A(D)$$

2.1 Phân lớp với cây quyết định

$$Gini(D) = 1 - \left(\frac{9}{14}\right)^2 - \left(\frac{5}{14}\right)^2 = 0.459$$

$$Gini_{income \in \{low,medium\}}(D)$$

$$= \frac{10}{14} Gini(D_1) + \frac{4}{14} Gini(D_2)$$

$$= \frac{10}{14}\left(1 - \left(\frac{7}{10}\right)^2 - \left(\frac{3}{10}\right)^2\right) + \frac{4}{14}\left(1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2\right)$$

$$= 0.443$$

$$= Gini_{income \in \{high\}}(D).$$

$Gini_{income \in \{low,high\}} = ?$

$Gini_{income \in \{medium\}} = ?$

$Gini_{income \in \{medium,high\}} = ?$

$Gini_{income \in \{low\}} = ?$

→ $Gini_{income \in \{medium,high\}/\{low\}} = ?$

$Gini_{age \in \{youth,senior\}/\{middle_aged\}} = ?$

$Gini_{student} = ?$

$Gini_{credit_rating} = ?$

→ Splitting attribute?

2.1 Phân lớp với cây quyết định

- Xây dựng cây quyết định từ cơ sở dữ liệu huấn luyện
  - Dùng độ đo Information Gain
  - Dùng độ đo Gain Ratio
  - Dùng độ đo Gini Index
  - Các cây quyết định học được giống nhau ???
  - Tiến hành đánh giá và phân loại với các cây quyết định học được

2.3 Minh họa

- sklearn.tree.DecisionTreeClassifier



THANK YOU FOR WATCHING!