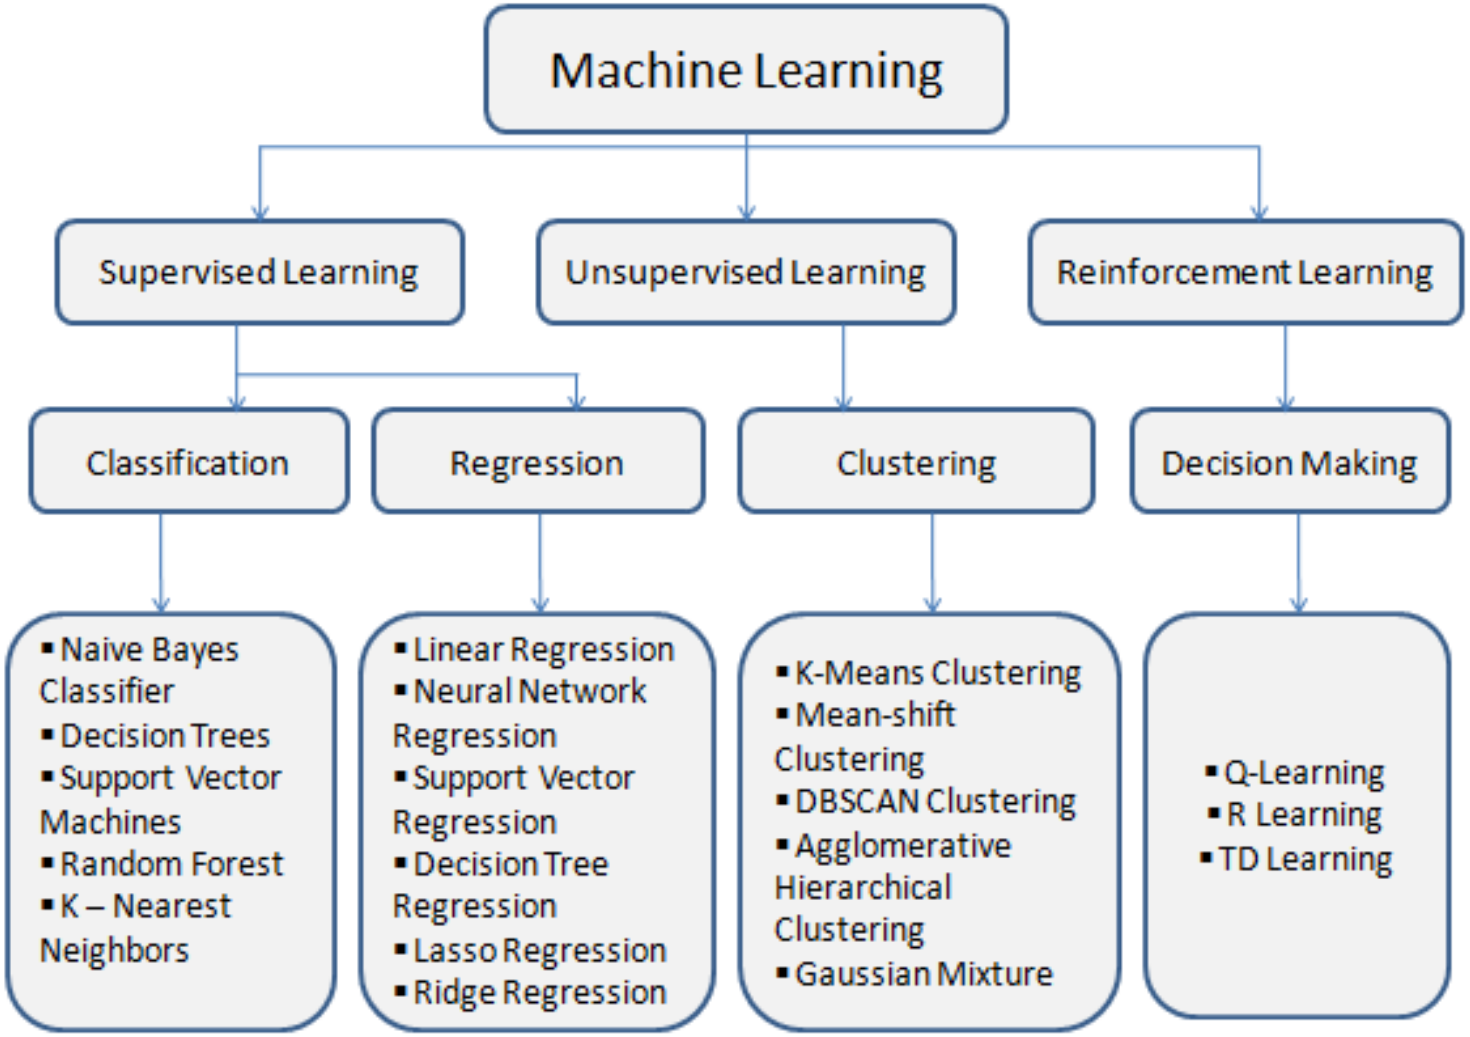
TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH

KHAI PHÁ DỮ LIỆU

CHƯƠNG 4
MỘT SỐ PHƯƠNG PHÁP PHÂN LỚP VÀ DỰ BÁO
(PHẦN 2)


H U B
1976
TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH

Xác định mục đích khai phá dữ liệu



Nội dung

1. Giới thiệu về phân lớp dữ liệu
2. Phân lớp dữ liệu với cây quyết định
3. Phương pháp phân lớp dữ liệu Bayes
4. Phân lớp và dự báo với máy vector hỗ trợ
5. Phân lớp và dự báo dữ liệu với mạng nơ-ron
6. Phân lớp k-NN
7. Hồi qui tuyến tính và hồi qui Logistic
8. Đánh giá và lựa chọn mô hình
9. Một số ứng dụng của phân lớp dữ liệu

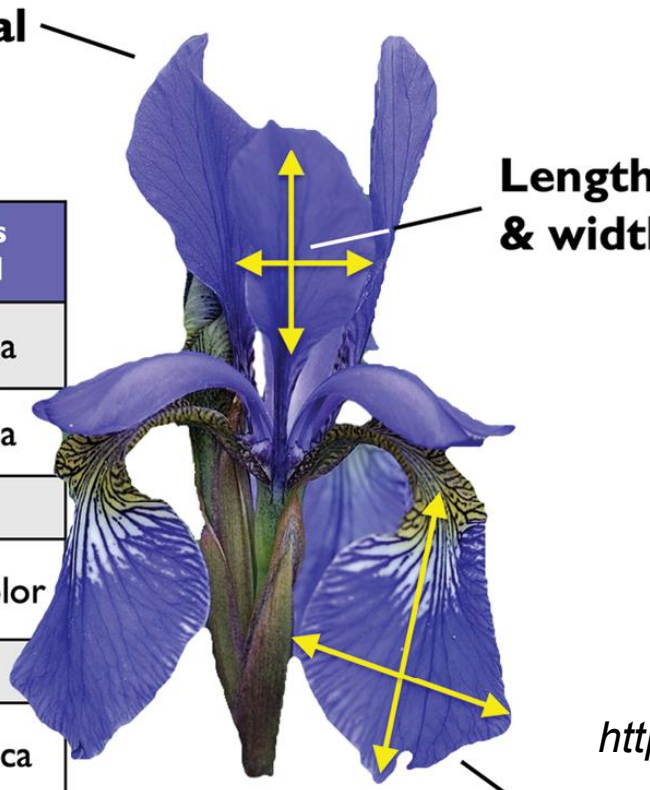
Phân lớp (Classification)

Samples
(instances, observations)

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
			...		
50	6.4	3.5	4.5	1.2	Versicolor
			...		
150	5.9	3.0	5.0	1.8	Virginica

Features
(inputs, attributes, measurements, dimensions)

Class labels
(targets, outcomes)



Tập dữ liệu Iris dự đoán loài hoa dựa vào kích thước cánh hóa và đài hoa

https://archive.ics.uci.edu/ml/datasets/iris

Hồi quy (Regression)

	A	B	C	D	E
1	area	bedrooms	balcony	age	price
2	1200	2	0	2	500000
3	2300	3	2	5	620000
4	2500	4	2	1	122500
5	3650	5	3	3	6000000
6	1800	3	1	5	2122000
7	3000	3	1	4	120000
8	1222	1	0	2	450000
9	4600	5	3	1	6500000
10	2050	2	2	2	1530000
11	1450	2	2	3	1563330

Nhãn liên tục

3.2 Phân lớp Bayes

RID	age	income	student	credit_rating	Class: buys_computer
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	low	yes	fair	yes
6	senior	low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

Cơ sở dữ liệu khách hàng dùng cho bước học

3.2 Phân lớp Native Bayes: Định lý Bayes

- P(H|X): Xác suất hậu nghiệm (posterior probability)
  - Xác suất có điều kiện của H đối với X.
  - Ví dụ:

    P(buys_computer=yes|age=youth, income=high) là xác suất mua máy tính của khách hàng có tuổi "youth" và thu nhập "high".
- P(X|H): Xác suất hậu nghiệm (posterior probability)
  - Xác suất có điều kiện của X đối với H nó cho biết khả năng (likelihood) xảy ra của X
  - Ví dụ:

    P(age= youth, income=high|buys_computer=yes) là xác suất khách hàng mua máy tính có tuổi "youth" và thu nhập "high".

    P(age= youth, income=high|buys_computer=yes) = 0

    P(age= youth, income=high|buys_computer=no) = 2/5 = 0.4

3.2 Phân lớp Bayes: Định lý Bayes

- P(H): prior probability (*xác suất tiên nghiệm*)
  - Xác suất của H
  - Ví dụ: P(buys_computer=yes) là xác suất mua máy tính của khách hàng nói chung.
    - P(buys_computer=yes) = 9/14 = 0.643
    - P(buys_computer=no) = 5/14 = 0.357
- P(X): prior probability
  - Xác suất của X
  - Ví dụ: P(age= youth, income=high) là xác suất khách hàng có tuổi "young" và thu nhập "high".
    - P(age= youth, income=high) = 2/14 = 0.143

3.2 Phân lớp Bayes: Định lý Bayes

- P(H), P(X|H), P(X) có thể được tính từ tập dữ liệu cho trước.
- P(H|X) được tính từ định lý Bayes.

$$P(H \mid X) = \frac{P(X \mid H)P(H)}{P(X)}$$

P(buys_computer=yes|age=young, income=high) = ?

P(buys_computer=no|age=young, income=high) = ?

3.2 Phân lớp Bayes

- Cho trước tập dữ liệu huấn luyện D với mô tả (nhãn) của các lớp Ci, i=1..m, quá trình phân loại một tuple/đối tượng X = (x1, x2, …, xn) với mạng Bayesian như sau:
  - X được phân loại vào Ci nếu và chỉ nếu P(Ci|X) > P(Cj|X) với 1<=j<=m, j<>i

$$P(C_i \mid X) = \frac{P(X \mid C_i)P(C_i)}{P(X)}$$

  - Tối đa hóa P(Ci|X) (i.e. chọn Ci nếu P(Ci|X) là trị lớn nhất)
  - Tối đa hóa P(X|Ci)P(Ci)
    - P(C1) = P(C2) = .. = P(Cm) hoặc P(Ci) = |Ci,D|/|D| …

3.2 Phân lớp Bayes

- P(X|C_i) được tính với giả định class độc lập điều kiện.

$$P(X \mid C_i) = \prod_{k=1}^{n} P(x_k \mid C_i) = P(x_1 \mid C_i) * P(x_2 \mid C_i) * .. * P(x_n \mid C_i)$$

x_k, k = 1..n: trị thuộc tính A_k của X

- $P(x_k|C_i)$ được tính như sau:
  - A_k là thuộc tính rời rạc.

$$P(x_k|C_i) = \frac{|\{X'|x'_k = x_k \Lambda X' \in C_i\}|}{|C_i, D|}$$

Với $|C_i, D|$ là số lượng đối tượng của lớp C_i trong D

  - A_k là thuộc tính liên tục.
    - $P(x_k|C_i)$ tuân theo một phân bố xác suất nào đó (ví dụ: phân bố Gauss).

$$g(x, \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \qquad P(x_k|C_i) = g(x_k, \mu_{C_i}, \sigma_{C_i})$$

3.2 Phân lớp Bayes

RID	age	income	student	credit_rating	Class: buys_computer
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	low	yes	fair	yes
6	senior	low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

Cơ sở dữ liệu khách hàng dùng cho bước học

3.2 Phân lớp Bayes

$$P(age = youth \mid buys_computer = yes) = 2/9 = 0.222$$
$$P(age = youth \mid buys_computer = no) = 3/5 = 0.600$$
$$P(income = medium \mid buys_computer = yes) = 4/9 = 0.444$$
$$P(income = medium \mid buys_computer = no) = 2/5 = 0.400$$
$$P(student = yes \mid buys_computer = yes) = 6/9 = 0.667$$
$$P(student = yes \mid buys_computer = no) = 1/5 = 0.200$$
$$P(credit_rating = fair \mid buys_computer = yes) = 6/9 = 0.667$$
$$P(credit_rating = fair \mid buys_computer = no) = 2/5 = 0.400$$

$$\boldsymbol{X} = (age = youth, income = medium, student = yes, credit_rating = fair)$$

$$P(\boldsymbol{X} \mid buys_computer = yes) = P(age = youth \mid buys_computer = yes) \times P(income = medium \mid buys_computer = yes) \times P(student = yes \mid buys_computer = yes) \times P(credit_rating = fair \mid buys_computer = yes)$$
$$= 0.222 \times 0.444 \times 0.667 \times 0.667 = 0.044.$$

$$P(\boldsymbol{X} \mid buys_computer = no) = 0.600 \times 0.400 \times 0.200 \times 0.400 = 0.019.$$
$$P(\boldsymbol{X} \mid buys_computer = yes) P(buys_computer = yes) = 0.044 \times 0.643 = 0.028$$
$$P(\boldsymbol{X} \mid buys_computer = no) P(buys_computer = no) = 0.019 \times 0.357 = 0.007$$

RID	age	income	student	credit_rating	Class: buys_computer
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	low	yes	fair	yes
6	senior	low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

$C_1 = \{X' | X'.buys_computer = yes\}$
$C_2 = \{X'' | X''.buys_computer = no\}$

$$P(buys_computer = yes) = 9/14 = 0.643$$
$$P(buys_computer = no) = 5/14 = 0.357$$

→ **X ∈ C1**

3.2 Phân lớp Bayes

Vấn đề khi xác suất bằng 0?

age	Buy=*Yes*	Buy=*No*
youth	2	3
middled_age	4	0
senior	3	2
Total	**9**	**5**

income	Buy=*Yes*	Buy=*No*
low	3	1
medium	4	2
high	2	2
Total	**9**	**5**

student	Buy=*Yes*	Buy=*No*
yes	6	1
no	3	4
Total	**9**	**5**

credit_rating	Buy=*Yes*	Buy=*No*
fair	6	2
excellent	3	3
Total	**9**	**5**

Naive Bayes Laplace Correction

- To eliminate zeros, we use add-one or Laplace smoothing, which simply adds one to each count

$$\hat{P}(t|c) = \frac{T_{ct}}{\sum_{t' \in V} T_{ct'}},$$

$$\hat{P}(t|c) = \frac{T_{ct} + 1}{\sum_{t' \in V} (T_{ct'} + 1)} = \frac{T_{ct} + 1}{(\sum_{t' \in V} T_{ct'}) + B'},$$

3.2 Phân lớp Bayes: Laplace Correction

age	Buy=*Yes*	Buy=*No*
youth	2+1	3+1
middled_age	4+1	0+1
senior	3+1	2+1

income	Buy=*Yes*	Buy=*No*
low	3+1	1+1
medium	4+1	2+1
high	2+1	2+1

student	Buy=*Yes*	Buy=*No*
yes	6+1	1+1
no	3+1	4+1

credit_rating	Buy=*Yes*	Buy=*No*
fair	6+1	2+1
excellent	3+1	3+1

3.2 Phân lớp Bayes: Laplace Correction

age	Buy=*Yes*	Buy=*No*
youth	3	4
middled_age	5	1
senior	4	3

income	Buy=*Yes*	Buy=*No*
low	4	2
medium	5	3
high	3	3

student	Buy=*Yes*	Buy=*No*
yes	7	2
no	4	5

credit_rating	Buy=*Yes*	Buy=*No*
fair	7	3
excellent	4	4

Xác định phân lớp cho X

Cho X={age=senior, income=high, student=yes, credit_rating=fair}

$$P(age = senior|buy = yes) = \frac{3}{9}$$

P(income=high|buy=yes)=2/9

P(student=no|buy=yes)=3/9

"P(credit_rating=fair|buy=yes)=6/9"

"P(age=senior|buy=no)=2/5"

"P(income=high|buy=no)=2/5"

"P(student=no|buy=no)=4/5"

"P(credit_rating=fair|buy=no)=2/5"

"P(buy=yes)=9/14"

"P(buy=no)=5/14"

Hãy tính P(X|buy=yes)xP(buy=yes) và P(X|buy=no)xP(buy=no) từ đó cho biết X thuộc lớp nào?

Xác định phân lớp cho X

- X={age=senior, income=high, student=no, credit_rating=fair}
- P(age=senior|buy=yes)=3/9
- P(income=high|buy=yes)=2/9
- P(student=no|buy=yes)=3/9
- P(credit_rating=fair|buy=yes)=6/9
- P(age=senior|buy=no)=2/5
- P(income=high|buy=no)=2/5
- P(student=no|buy=no)=4/5
- P(credit_rating=fair|buy=no)=2/5
- P(buy=yes)=9/14
- P(buy=no)=5/14
- -->P(X|buy=yes)P(buy=yes) ? P(X|buy=no)P(buy=no) ?

Example

PlayTennis: training examples

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Example

- Learning Phase :

Outlook	Play=*Yes*	Play=*No*
Sunny	2/9	3/5
Overcast	4/9	0/5
Rain	3/9	2/5

Temperature	Play=*Yes*	Play=*No*
Hot	2/9	2/5
Mild	4/9	2/5
Cool	3/9	1/5

Humidity	Play=*Yes*	Play=No
High	3/9	4/5
Normal	6/9	1/5

Wind	Play=*Yes*	Play=*No*
Strong	3/9	3/5
Weak	6/9	2/5

- P(Play=Yes) = 9/14
- P(Play=No) = 5/14

Example

- Test Phase :
  - -Given a new instance, predict its label
  - x´=(Outlook=Sunny, Temperature=Cool, Humidity=High, Wind=Strong)
  - -Look up tables achieved in the learning phrase

P(Outlook=Sunny|Play=Yes) = 2/9	**P(Outlook=Sunny|Play=No) = 3/5**
P(Temperature=Cool|Play=Yes) = 3/9	**P(Temperature=Cool|Play==No) = 1/5**
P(Huminity=High|Play=Yes) = 3/9	**P(Huminity=High|Play=No) = 4/5**
P(Wind=Strong|Play=Yes) = 3/9	**P(Wind=Strong|Play=No) = 3/5**
P(Play=Yes) = 9/14	**P(Play=No) = 5/14**

  - -Decision making with the MAP rule:

P(Yes|x´): [P(Sunny|Yes) P(Cool|Yes) P(High|Yes) P(Strong|Yes)] P(Play=Yes) = 0.0053

P(No|x´): [P(Sunny|No) P(Cool|No) P(High|No) P(Strong|No)] P(Play=No) = 0.0206

Given the fact **P(Yes|x´) < P(No|x´)** , we label **x´** to be “No”.

Naive Bayes

- Algorithm: Continuous-valued Features
  - - Numberless values for a feature
  - - Conditional probability often modeled with the normal distribution

$$\hat{P}(X_j \mid C = c_i) = \frac{1}{\sqrt{2\pi}\sigma_{ji}} \exp\left(-\frac{(X_j - \mu_{ji})^2}{2\sigma_{ji}^2}\right)$$

μ_{ji} : mean (avearage) of feature values X_j of examples for which $C = c_i$

σ_{ji} : standard deviation of feature values X_j of examples for which $C = c_i$

  - -

for $\mathbf{X} = (X_1, \cdots, X_n)$, $C = c_1, \cdots, c_L$

$P(C = c_i)$ $i = 1, \cdots, L$

$\mathbf{X}' = (a_1', \cdots, a_n')$ $n \times L$

  - Learning Phase:
  - Output: normal distributions and
  - - Test Phase: Given an unknown instance
    - -Instead of looking-up tables, calculate conditional probabilities with all the normal
    - distributions achieved in the learning phrase
    - -Apply the MAP rule to make a decision

Naive Bayes

- Example: Continuous-valued Features
  - -Temperature is naturally of continuous value.
  - Yes: 25.2, 19.3, 18.5, 21.7, 20.1, 24.3, 22.8, 23.1, 19.8
  - No: 27.3, 30.1, 17.4, 29.5, 15.1
  - -Estimate mean and variance for each class

$$\mu = \frac{1}{N}\sum_{n=1}^{N} x_n, \quad \sigma^2 = \frac{1}{N}\sum_{n=1}^{N}(x_n - \mu)^2 \qquad \mu_{Yes} = 21.64, \ \sigma_{Yes} = 2.35 \qquad \mu_{No} = 23.88, \ \sigma_{No} = 7.09$$

  - -Learning Phase: output two Gaussian models for P(temp|C)
  -

$$\hat{P}(x \mid Yes) = \frac{1}{2.35\sqrt{2\pi}} \exp\left(-\frac{(x-21.64)^2}{11.09}\right)$$

$$\hat{P}(x \mid No) = \frac{1}{7.09\sqrt{2\pi}} \exp\left(-\frac{(x-23.88)^2}{50.25}\right)$$

Minh họa

- Naive Bayes trong **scikit-learn**



THANK YOU FOR WATCHING!