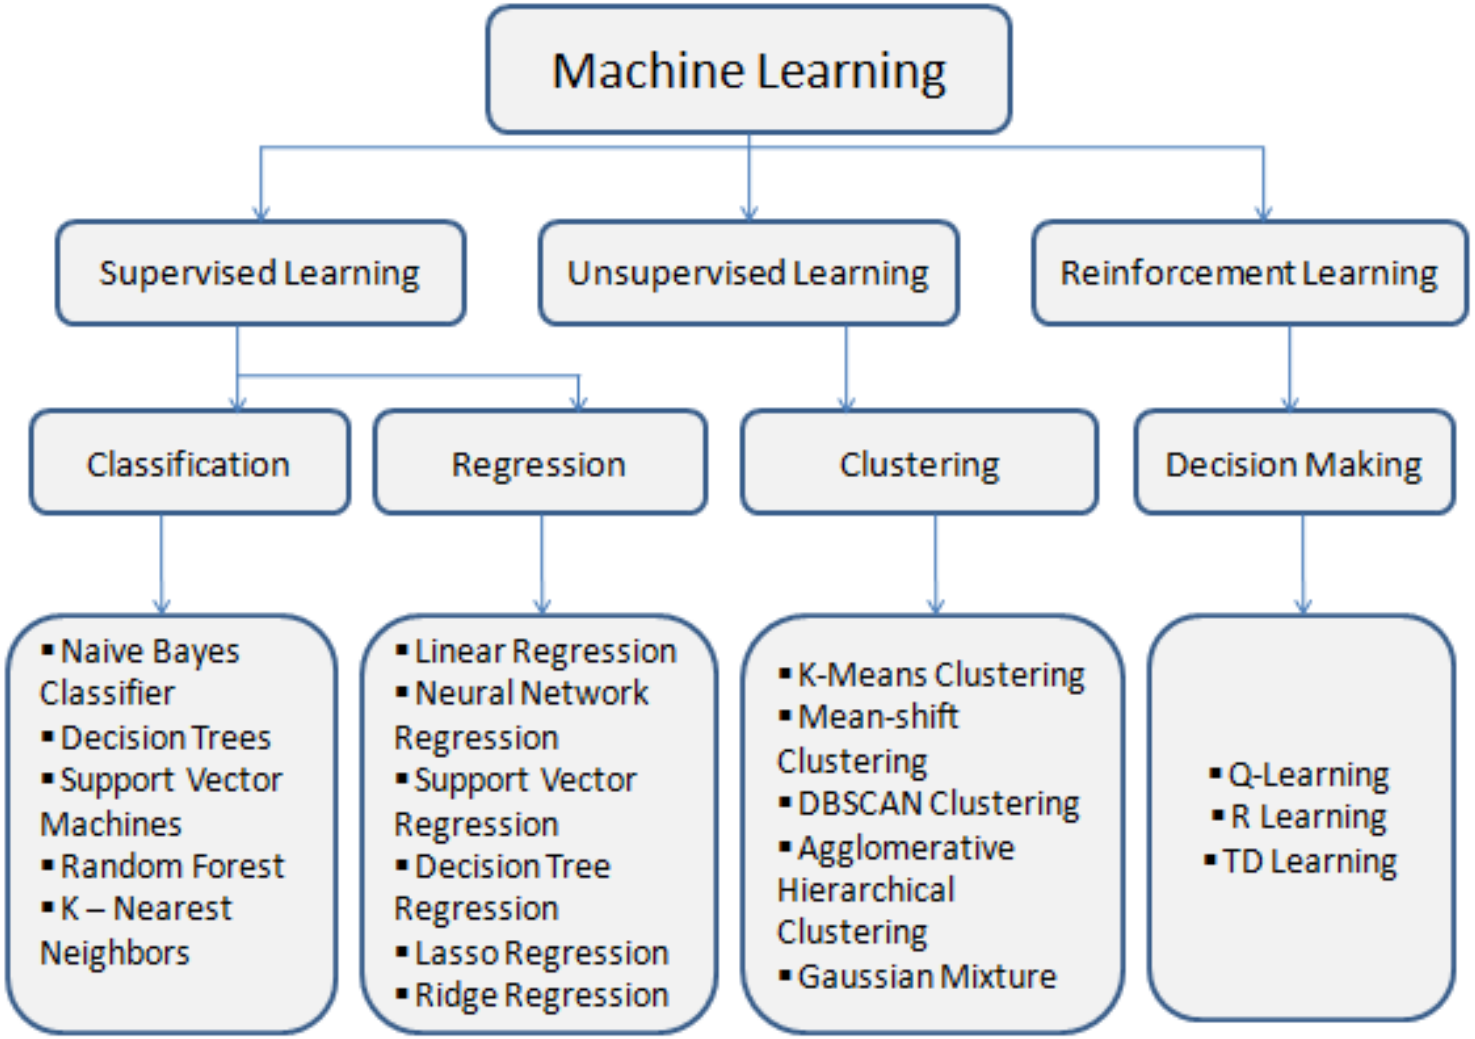
TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH

KHAI PHÁ DỮ LIỆU

CHƯƠNG 4
MỘT SỐ PHƯƠNG PHÁP PHÂN LỚP VÀ DỰ BÁO
(PHẦN 3)


H U B
1976
TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH

Xác định mục đích khai phá dữ liệu



Nội dung

1. Giới thiệu về phân lớp dữ liệu
2. Phân lớp dữ liệu với cây quyết định
3. Phương pháp phân lớp dữ liệu Bayes
4. Phân lớp và dự báo với máy vector hỗ trợ
5. Phân lớp và dự báo dữ liệu với mạng nơ-ron
6. Phân lớp k-NN
7. Hồi qui tuyến tính và hồi qui Logistic
8. Đánh giá và lựa chọn mô hình
9. Một số ứng dụng của phân lớp dữ liệu

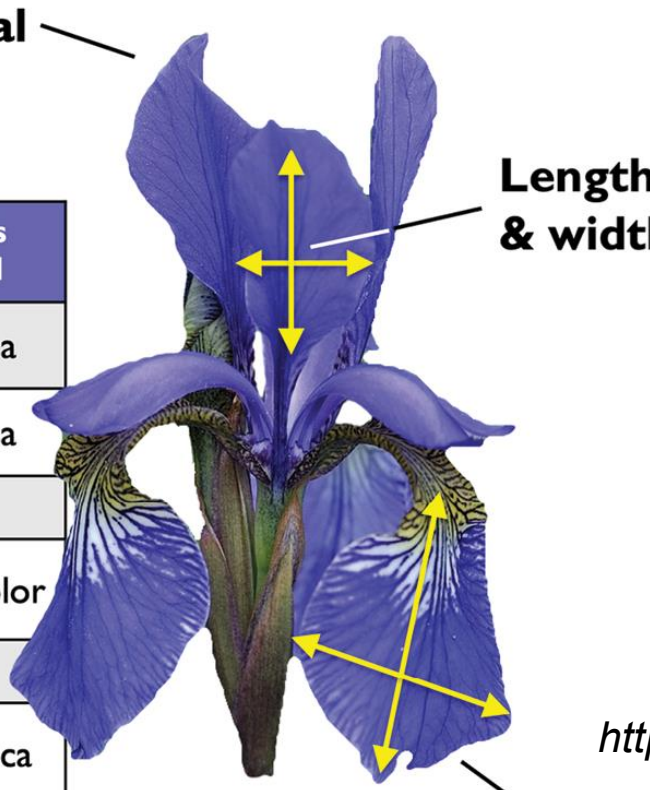
Phân lớp (Classification)

Samples
(instances, observations)

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
			...		
50	6.4	3.5	4.5	1.2	Versicolor
			...		
150	5.9	3.0	5.0	1.8	Virginica

Features
(inputs, attributes, measurements, dimensions)

Class labels
(targets, outcomes)



Tập dữ liệu Iris dự đoán loài hoa dựa vào kích thước cánh hóa và đài hoa

https://archive.ics.uci.edu/ml/datasets/iris

Hồi quy (Regression)

	A	B	C	D	E
1	area	bedrooms	balcony	age	price
2	1200	2	0	2	500000
3	2300	3	2	5	620000
4	2500	4	2	1	122500
5	3650	5	3	3	6000000
6	1800	3	1	5	2122000
7	3000	3	1	4	120000
8	1222	1	0	2	450000
9	4600	5	3	1	6500000
10	2050	2	2	2	1530000
11	1450	2	2	3	1563330

Nhãn liên tục

4. Phân lớp SVM

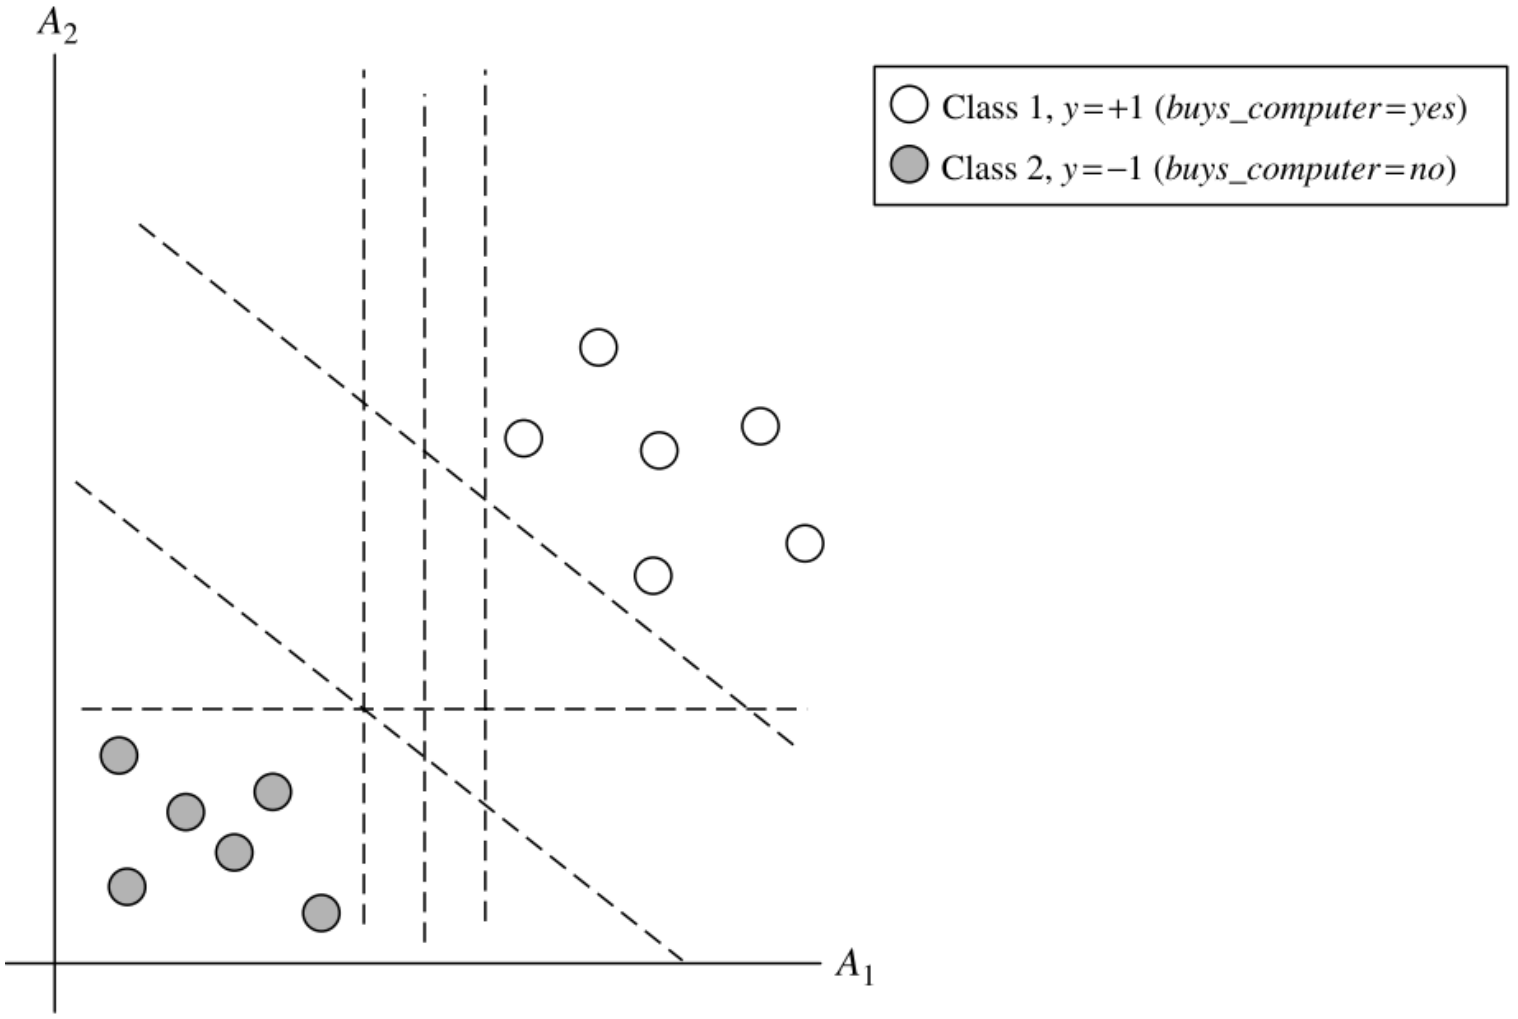
RID	age	income	student	credit_rating	Class: buys_computer
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	low	yes	fair	yes
6	senior	low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

Cơ sở dữ liệu khách hàng dùng cho bước học

Thuật toán SVM

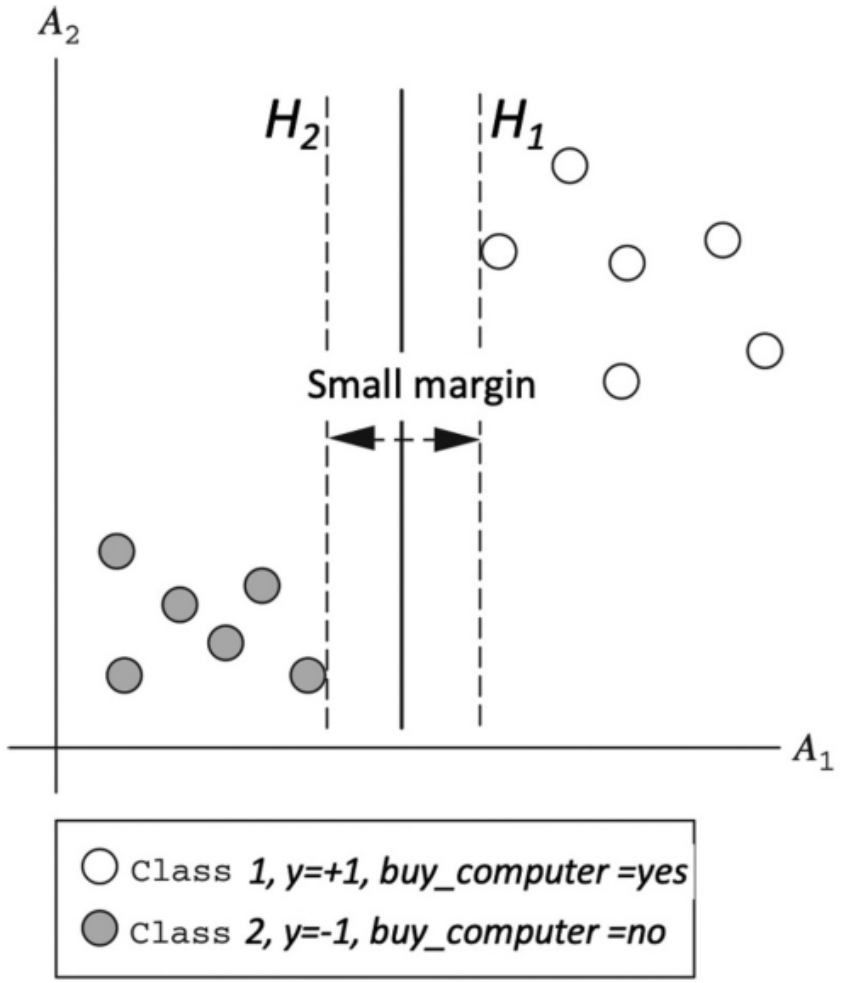
- Thuật toán máy vector hỗ trợ (Support Vector Machine – SVM): được Corters và Vapnik giới thiệu vào năm 1995.
- SVM rất hiệu quả để giải quyết các bài toán với dữ liệu có số chiều lớn (như các vector biểu diễn văn bản).

SVM-Support Vectors Machine

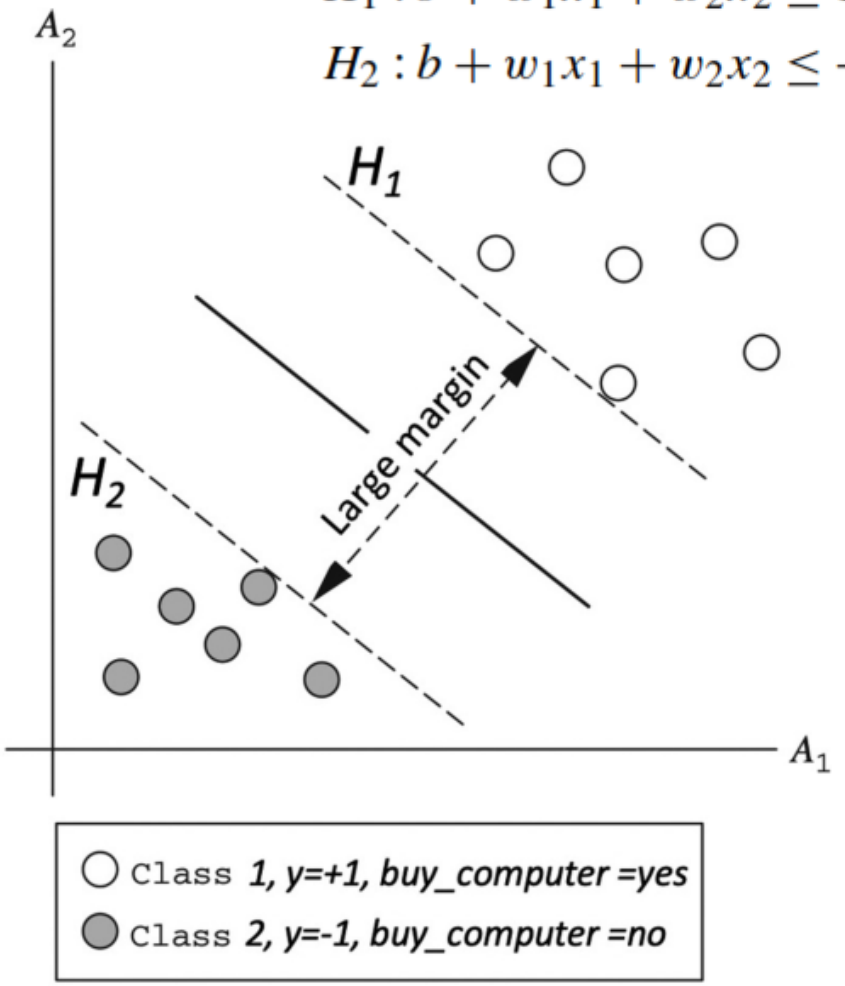


Máy vec-tơ hỗ trợ

$$H_1 : b + w_1 x_1 + w_2 x_2 \geq 1 \quad \text{for } y_i = +1,$$
$$H_2 : b + w_1 x_1 + w_2 x_2 \leq -1 \quad \text{for } y_i = -1.$$



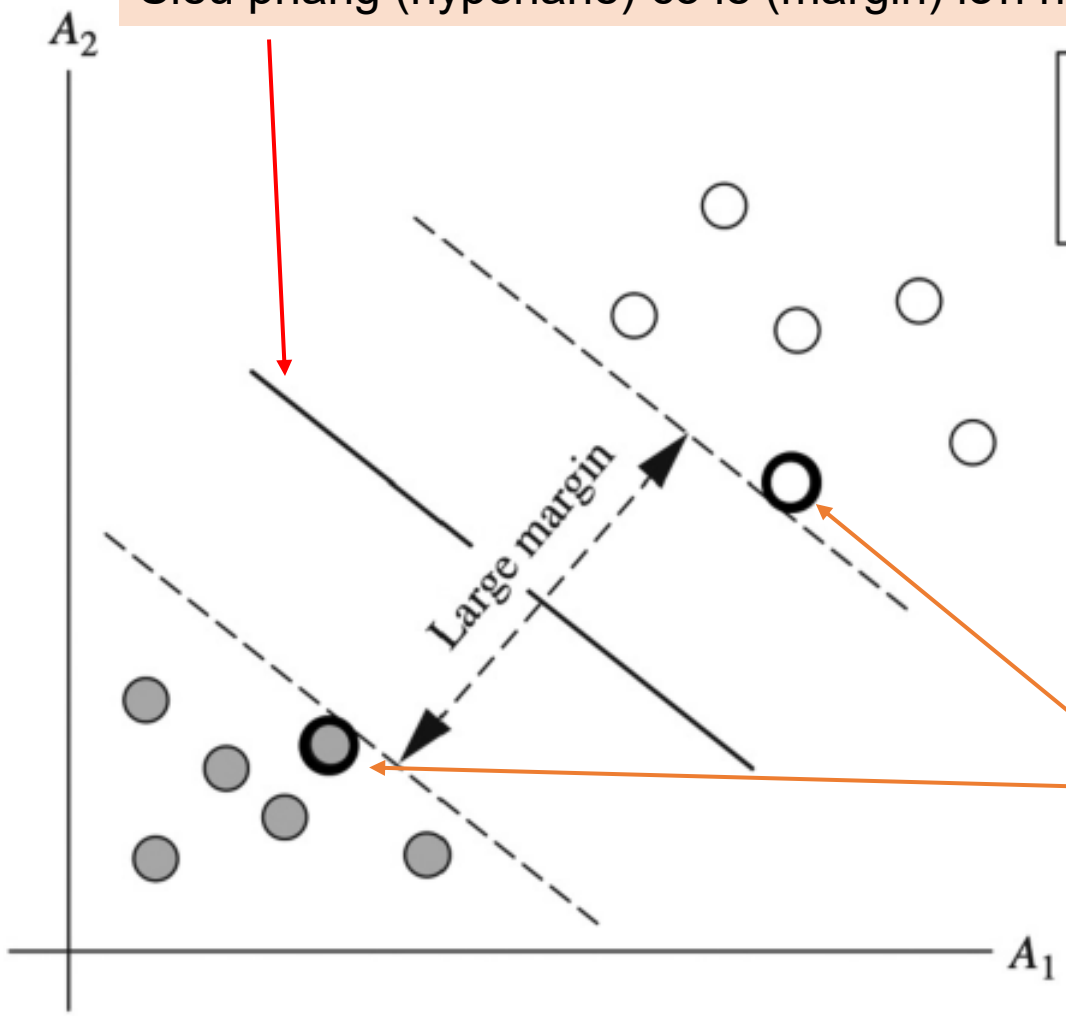
(a)



(b)

Máy vec-tơ hỗ trợ

Siêu phẳng (hyperlane) có lề (margin) lớn nhất



Class 1, $y=+1$ (*buys_computer=yes*)

Class 2, $y=-1$ (*buys_computer=no*)

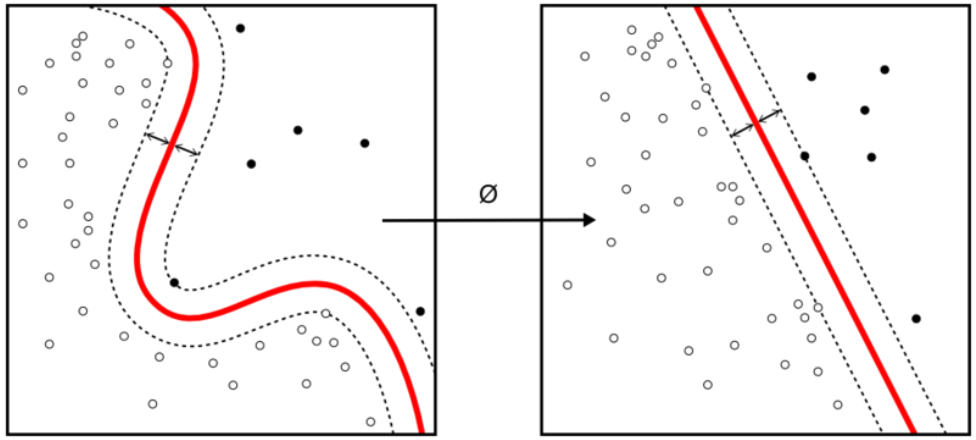
$$y_i(b + w_1x_1 + w_2x_2) \geq 1, \ \forall i.$$

Những điểm dữ liệu thuộc H1, H2

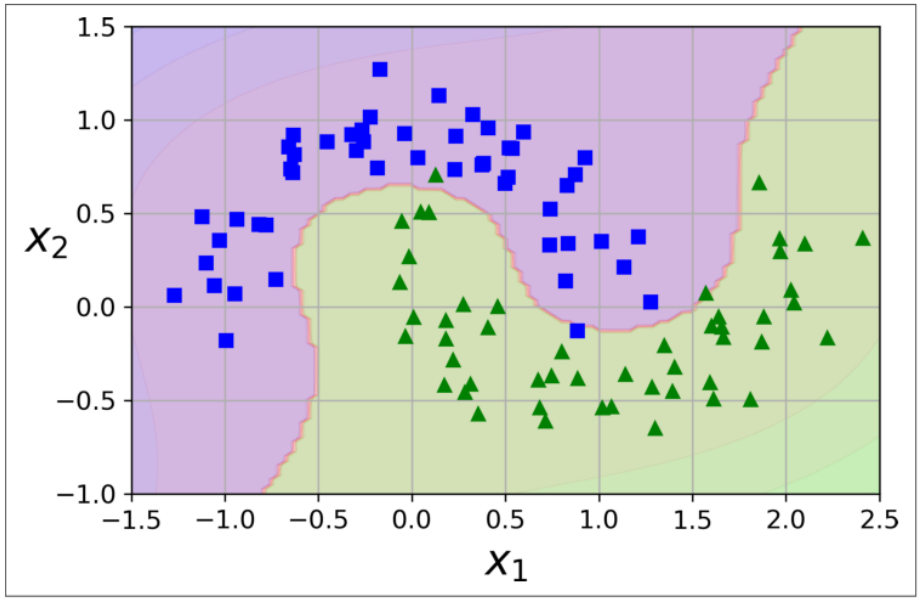
$$y_i(b + w_1x_1 + w_2x_2) = 1$$

Được gọi là vec-tơ hỗ trợ

SVM: Dữ liệu không khả phân tuyến tính

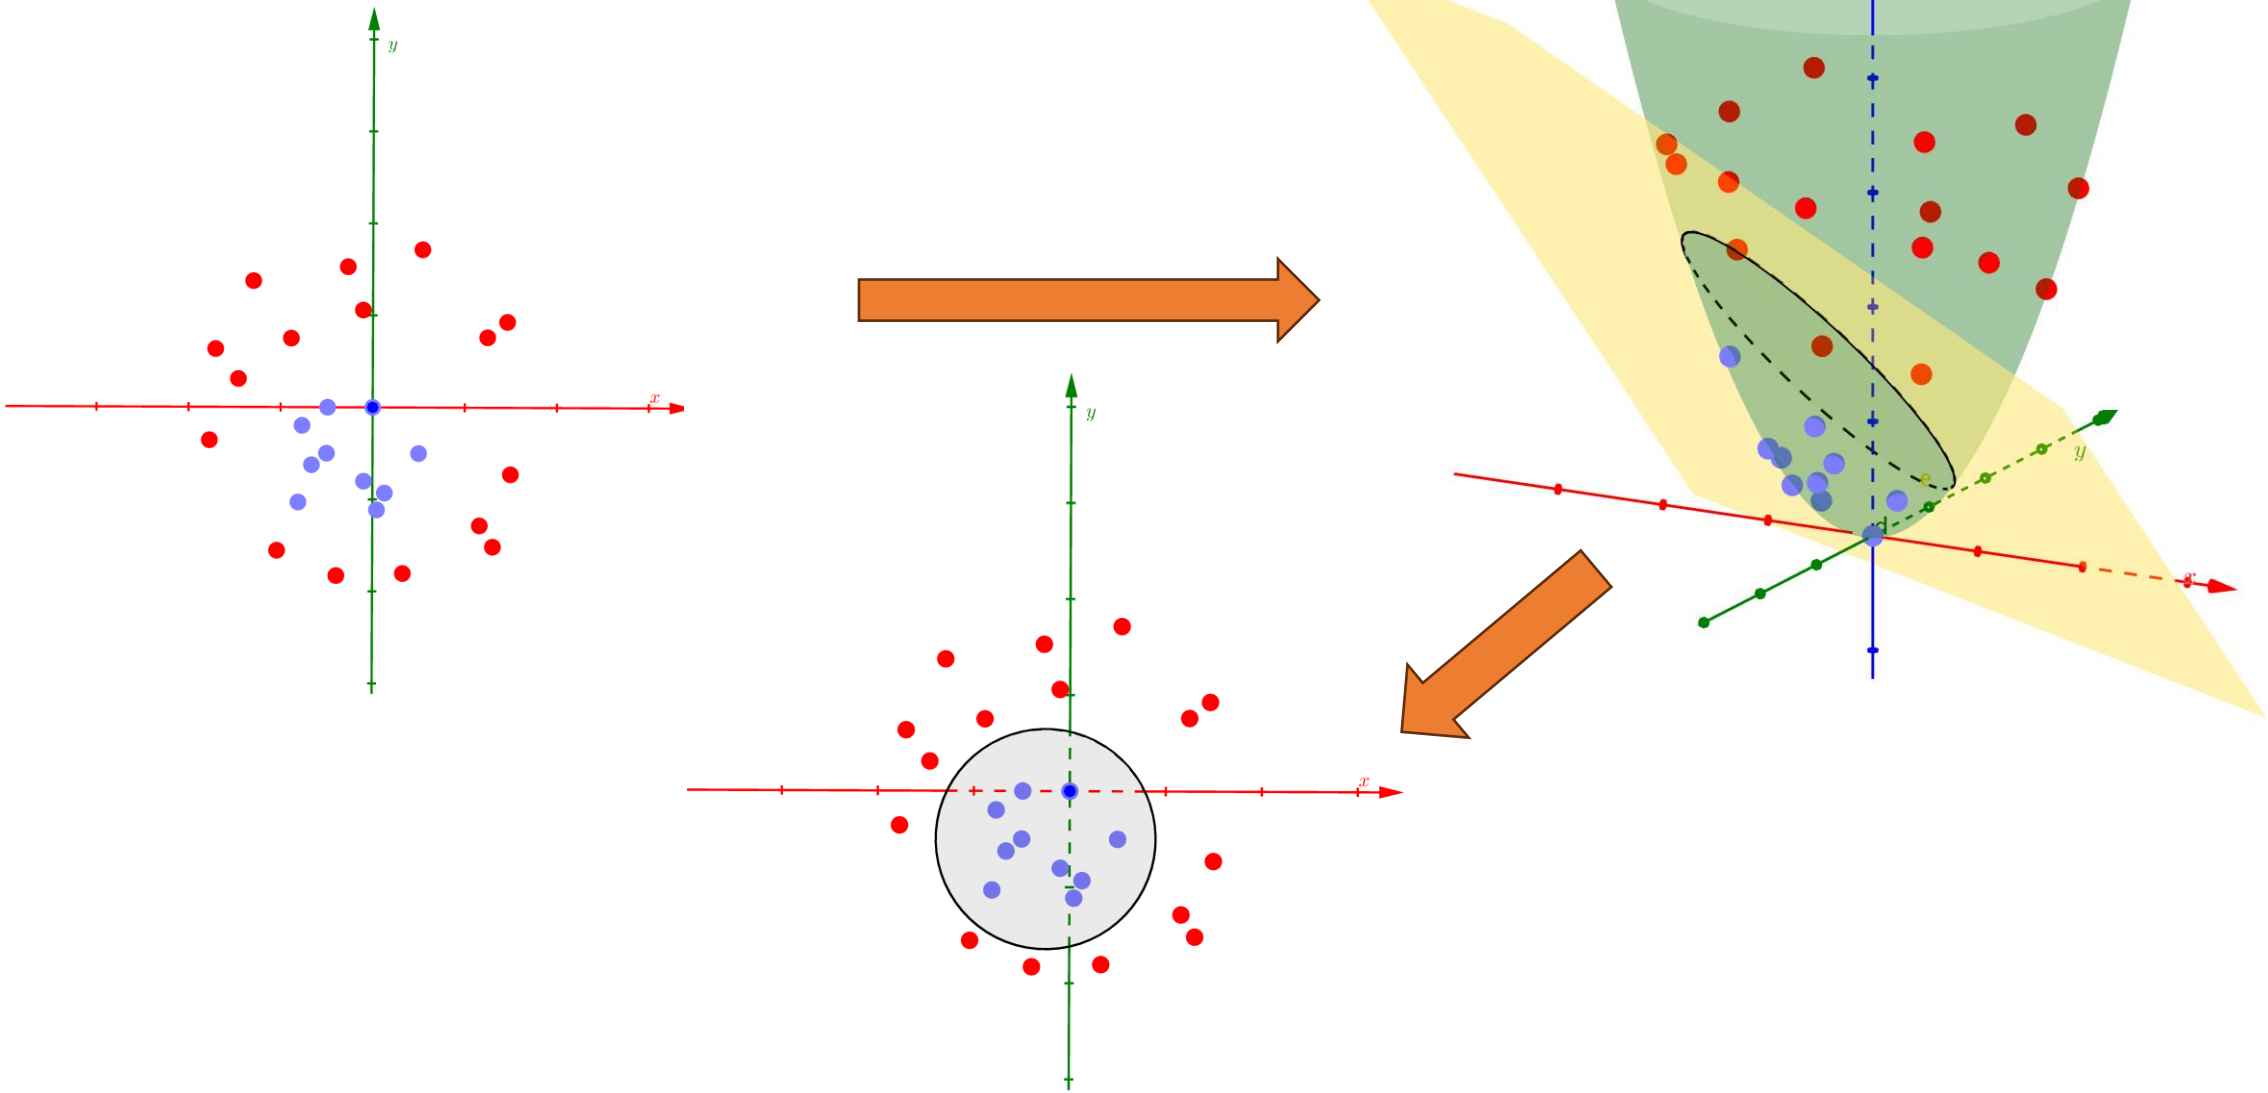


Source: [Alisneaky on Wikipedia](#) / CC0 license

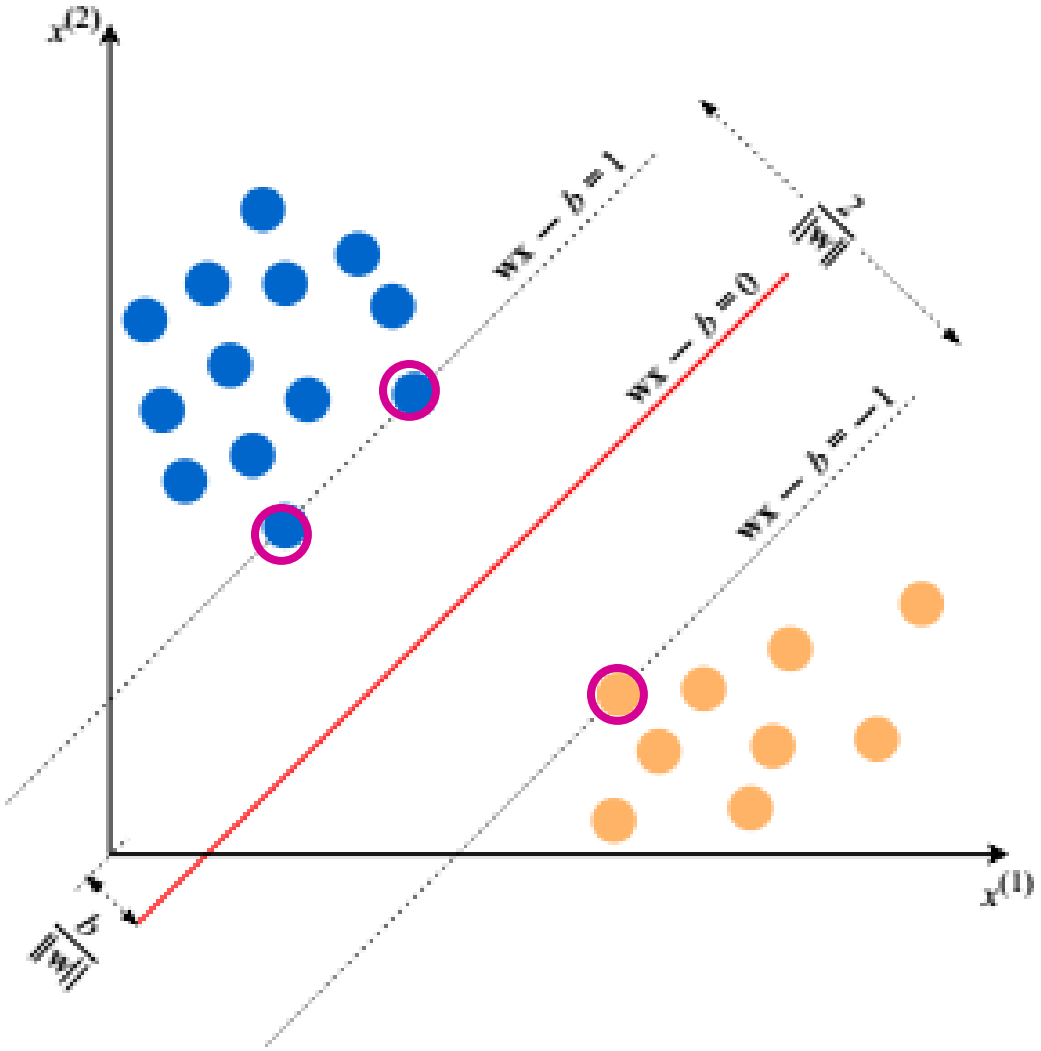


Chuyển không gian dữ liệu ban đầu về một không gian dữ liệu có số chiều lớn hơn bằng một ánh xạ phi tuyến. Sau đó tìm một siêu phẳng tuyến tính trên không gian mới.
Có nhiều hàm nhân được dùng để giúp chuyển sang không gian mới như *Polynomial Kernel Function, Gaussian Radial Basis Function (RBF), Sigmoid Kernel Function*

SVM: Biến đổi kernel



Thuật toán SVM



Thuật toán SVM

- Nếu dữ liệu học là tách rời tuyến tính:
  - Cực tiểu: $\frac{1}{2}\alpha.\alpha \quad \left(=\frac{1}{2}\|\alpha\|^2\right) \quad (1)$
  - Thỏa mãn: $c_i\left(\alpha.d_i+b\right)\geq 1 \quad \forall i=1,\ldots,n \quad (2)$
- Nếu dữ liệu học không tách rời tuyến tính: thêm biến $\{\xi_1 \cdots \xi_n\}$:
  - Cực tiểu: $\frac{1}{2}\alpha.\alpha + C\sum_{i=1}^{n}\xi_i \quad (3)$
  - Thỏa mãn: $c_i\left(\alpha.d_i+b\right)\geq 1-\xi_i \quad \forall i=1,\ldots,n$

$$\xi_i \geq 0 \forall i=1,\ldots,n \quad (4)$$

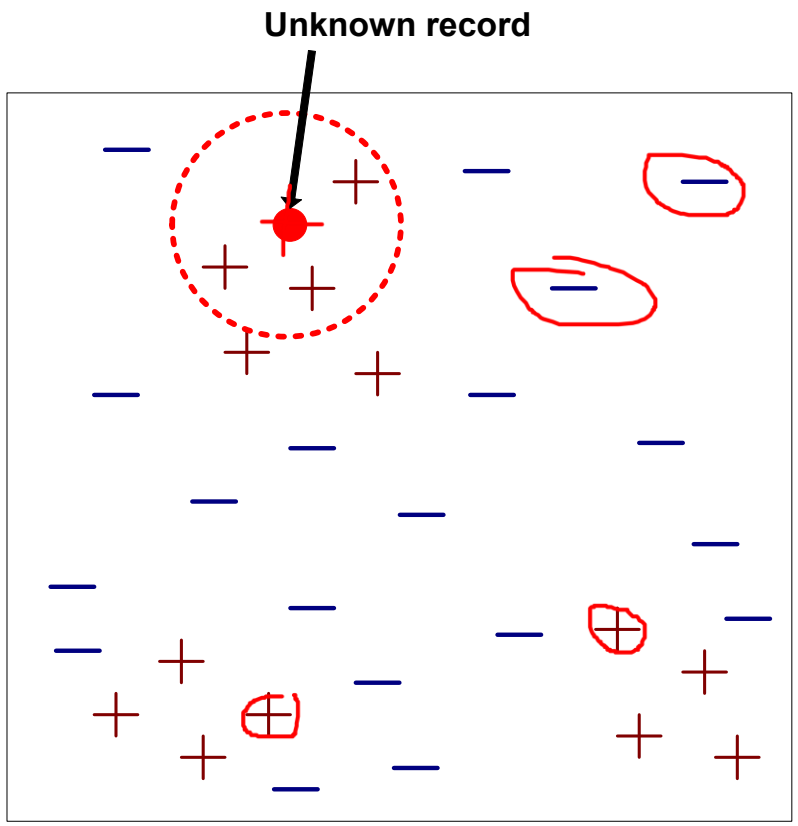
- Tổng quát: sử dụng hàm nhân (kernel function)
  - Biến đổi không gian biểu diễn dữ liệu sang số chiều lớn hơn để khả phân tuyến tính

4. Phân lớp k-NN

k = 3

lazing

local



- Phân loại k-nn (k-nearest neighbor)
  - Cho trước tập dữ liệu huấn luyện D với các lớp, phân loại record/object X vào các lớp dựa vào k phần tử tương tự với X nhất (dùng luật số đông: majority vote)
  - Phụ thuộc
    - Độ đo khoảng cách để xác định sự tương tự.
    - Trị k, số phần tử láng giềng → k <= |D|1/2

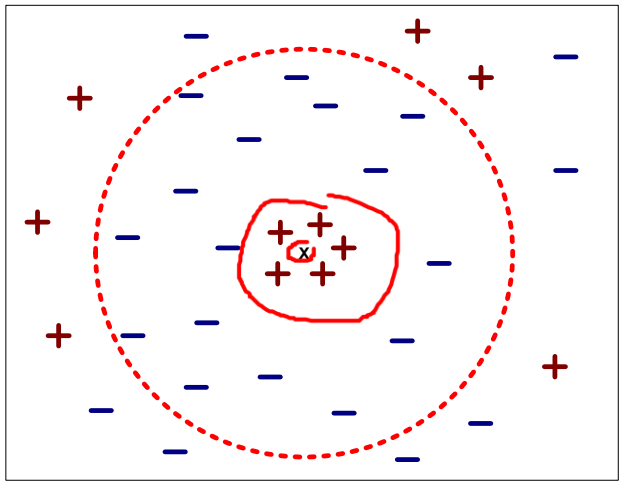
4. Phân loại k-NN

- Chọn độ đo
  - Độ đo Euclidean

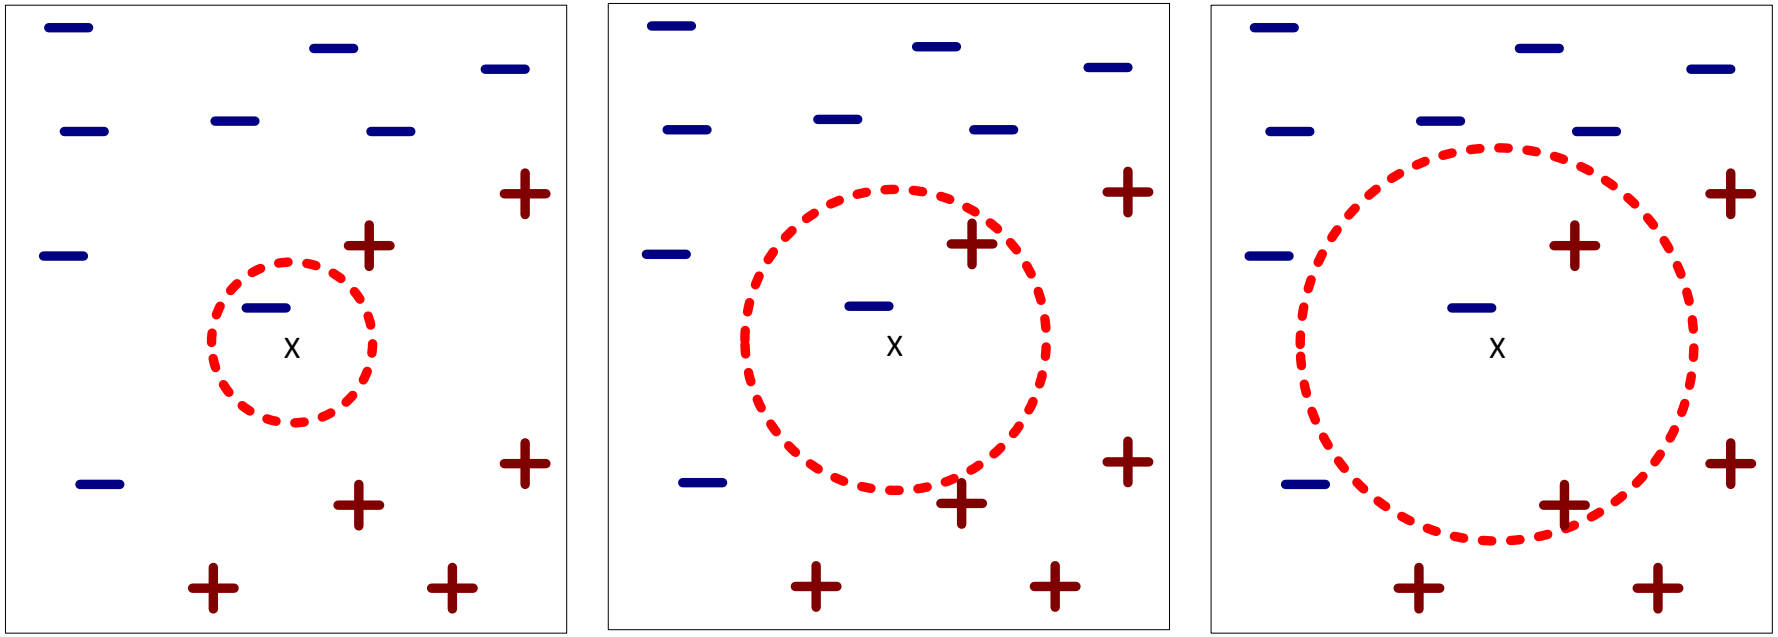
$$d(p,q) = \sqrt{\sum_i (p_i - q_i)^2}$$

- Chọn trị k
  - Nếu k quá nhỏ thì kết quả dễ bị ảnh hưởng bởi nhiễu.
  - Nếu k quá lớn thì nhiều phần tử láng giềng chọn được có thể đến từ các lớp khác.

k quá lớn!



3.5.3 Phân lớp k-NN



(a) 1-nearest neighbor

(b) 2-nearest neighbor

(c) 3-nearest neighbor

X ∈ MINUS

X ∈ MINUS
hay
X ∈ PLUS ?

X ∈ PLUS

Độ đo khoảng cách: các kiểu dữ liệu

- Thuộc tính dạng số (numeric attributes)
- Thuộc tính nhị phân (Binary attributes)
- Thuộc tính danh nghĩa (Nominal), thứ bậc (ordinal)
- Thuộc tính với kiểu hỗn hợp

Interval-valued variables

- Standardize data
  - Calculate the mean absolute deviation:

$$s_f = \frac{1}{n}(|x_{1f} - m_f| + |x_{2f} - m_f| + \ldots + |x_{nf} - m_f|)$$

where $m_f = \frac{1}{n}(x_{1f} + x_{2f} + \ldots + x_{nf})$.

  - Calculate the standardized measurement (z-score)

$$z_{if} = \frac{x_{if} - m_f}{s_f}$$

- Using mean absolute deviation is more robust than using standard deviation

Similarity and Dissimilarity Between Objects

- Distances are normally used to measure the similarity or dissimilarity between two data objects
- Some popular ones include: Minkowski distance:

$$d(i,j) = \sqrt[q]{(|x_{i1} - x_{j1}|^q + |x_{i2} - x_{j2}|^q + ... + |x_{ip} - x_{jp}|^q)}$$

where $i = (x_{i1}, x_{i2}, \ldots, x_{ip})$ and $j = (x_{j1}, x_{j2}, \ldots, x_{jp})$ are two p-dimensional data objects, and q is a positive integer

- If q = 1, d is Manhattan distance

$$d(i,j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + ... + |x_{ip} - x_{jp}|$$

Similarity and Dissimilarity Between Objects (Cont.)

- If q = 2, d is Euclidean distance:

$$d(i,j) = \sqrt{(|x_{i1} - x_{j1}|^2 + |x_{i2} - x_{j2}|^2 + \ldots + |x_{ip} - x_{jp}|^2)}$$

  - Properties
    - d(i,j) ≥ 0
    - d(i,i) = 0
    - d(i,j) = d(j,i)
    - d(i,j) ≤ d(i,k) + d(k,j)



- Also, one can use weighted distance, parametric Pearson product moment correlation, or other disimilarity measures

Binary Variables

- A contingency table for binary data
- Distance measure for symmetric binary variables:

$$d(i,j) = \frac{b+c}{a+b+c+d}$$

- Distance measure for asymmetric binary variables:

$$d(i,j) = \frac{b+c}{a+b+c}$$

- Jaccard coefficient (similarity measure for asymmetric binary variables):

$$sim_{Jaccard}(i,j) = \frac{a}{a+b+c}$$

		Object j		
		1	0	*sum*
Object i	1	a	b	$a+b$
	0	c	d	$c+d$
	sum	$a+c$	$b+d$	p

Dissimilarity between Binary Variables

- Example

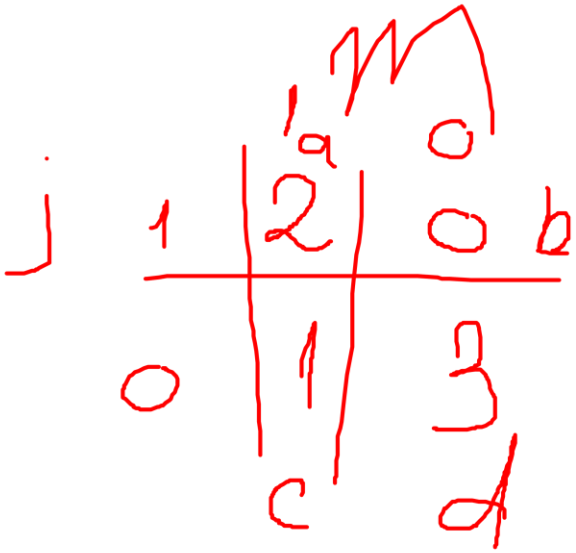
Name	Gender	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	M	Y	N	P	N	N	N
Mary	F	Y	N	P	N	P	N
Jim	M	Y	P	N	N	N	N

  - gender is a symmetric attribute
  - the remaining attributes are asymmetric binary
  - let the values Y and P be set to 1, and the value N be set to 0

$$d(jack, mary) = \frac{0+1}{2+0+1} = 0.33$$

$$d(jack, jim) = \frac{1+1}{1+1+1} = 0.67$$

$$d(jim, mary) = \frac{1+2}{1+1+2} = 0.75$$



Nominal Variables

- A generalization of the binary variable in that it can take more than 2 states, e.g., red, yellow, blue, green
- Method 1: Simple matching
  - m: # of matches, p: total # of variables

$$d(i,j) = \frac{p - m}{p}$$

- Method 2: use a large number of binary variables
  - creating a new binary variable for each of the M nominal states

income	→	income_L	income_M	income_H
L		1	0	0
M		0	1	0
H		0	0	1

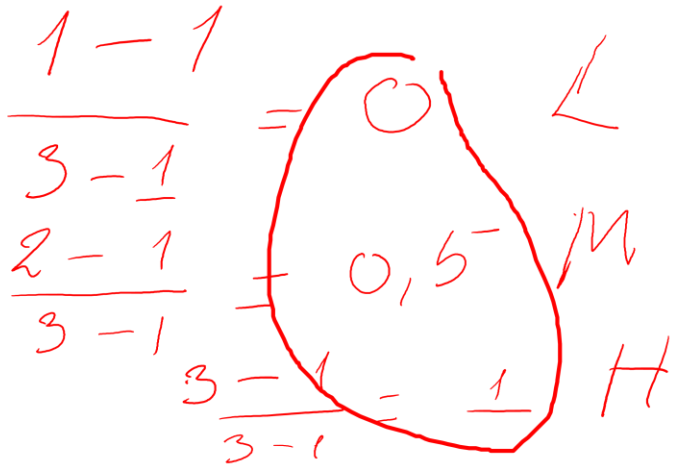
Biến thứ tự (Ordinal Variables)

- An ordinal variable can be discrete or continuous
- Order is important, e.g., rank
- Can be treated like interval-scaled
  - replace xif by their rank
  - map the range of each variable onto [0, 1] by replacing i-th object in the f-th variable by

$$r_{if} \in \{1,\ldots,M_f\}$$

  - compute the dissimilarity using methods for interval-scaled variables

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$



Biến với kiểu hỗn hợp

- Giả sử một tập dữ liệu có *p* thuộc tính, khoảng cách giữa đối tượng *i, j* được tính như sau:

$$d(i,j) = \frac{\sum_{f=1}^{p} \delta_{ij}^{(f)} d_{ij}^{(f)}}{\sum_{f=1}^{p} \delta_{ij}^{(f)}}$$

$\delta_{ij}^{(f)} = 0$ nếu gặp 1 trong 2 trường hợp sau, ngược lại = 1

(1) x_{if} *hoặc* x_{jf} *bị khuyết dữ liệu*

(2) $x_{if} = x_{jf} = 0$ *và thuộc tính* f *là nhị phân bất đối xứng*

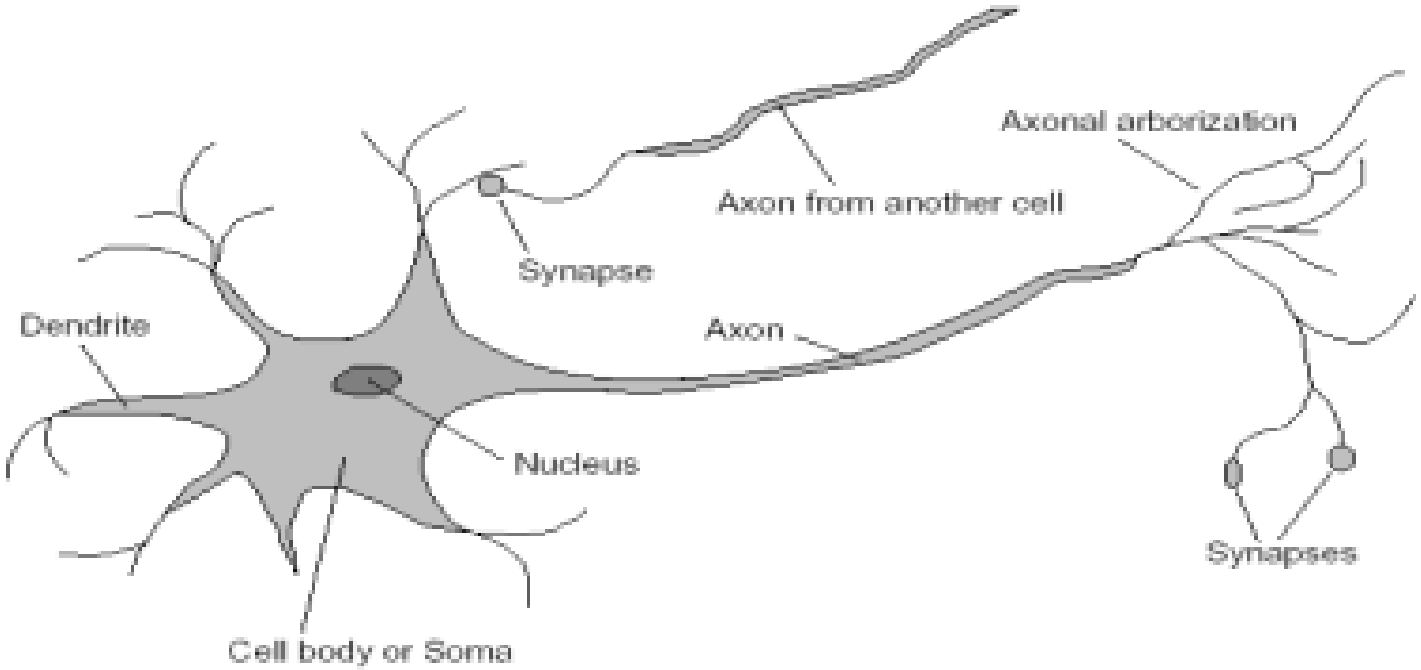
- Nếu *f* là dạng số:

$d_{ij}^{(f)} = \frac{|x_{if} - x_{jf}|}{max_f - min_f}$ với max_f *và* min_f *là giá trị lớn nhất và nhỏ nhất của thuộc tính* f

- Nếu *f* là danh nghĩa hoặc nhị phân: $d_{ij}^{(f)} = 0$ *nếu* $x_{if} = x_{jf}$ *ngược lại* $d_{ij}^{(f)} = 1$
- Nếu *f* là thứ bậc: tính r_{if} và $z_{if} = \frac{r_{if}-1}{M_f-1}$

4. Phân lớp và dự báo dữ liệu với mạng nơ-ron

- Mạng Neural sinh học



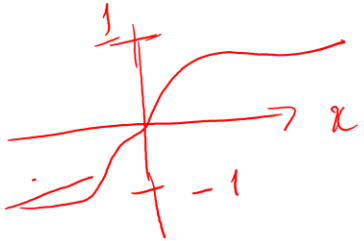
Perceptron

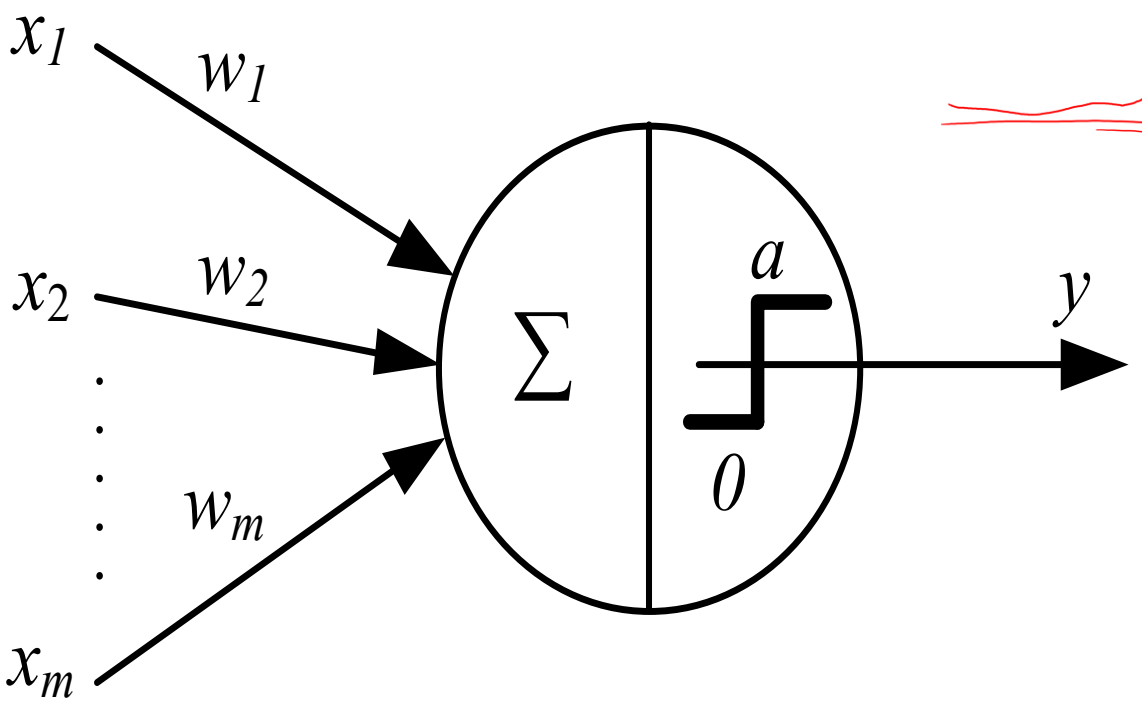
$$y = a(w_1 x_1 + w_2 x_2 + w_3 x_3 + \cdots + w_m x_m)$$

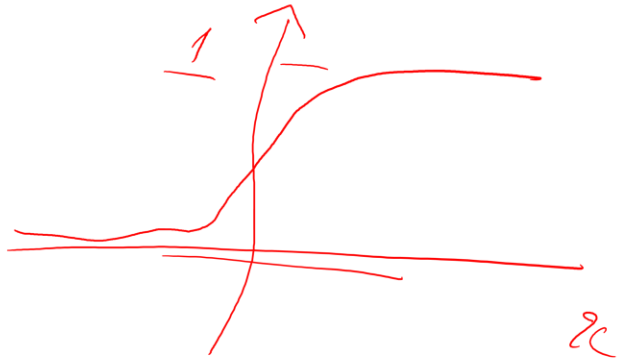
$$a(x) = \frac{1}{1 + e^{-x}}$$

Sigmoid

$$\tanh = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

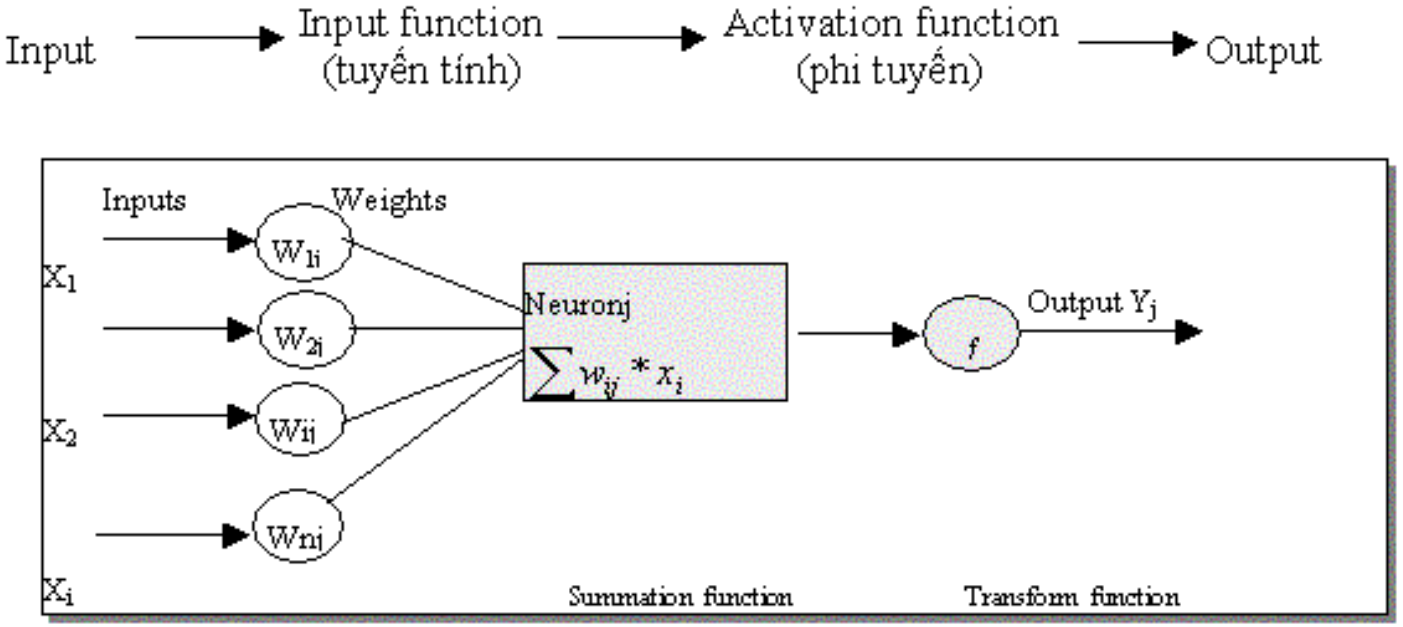




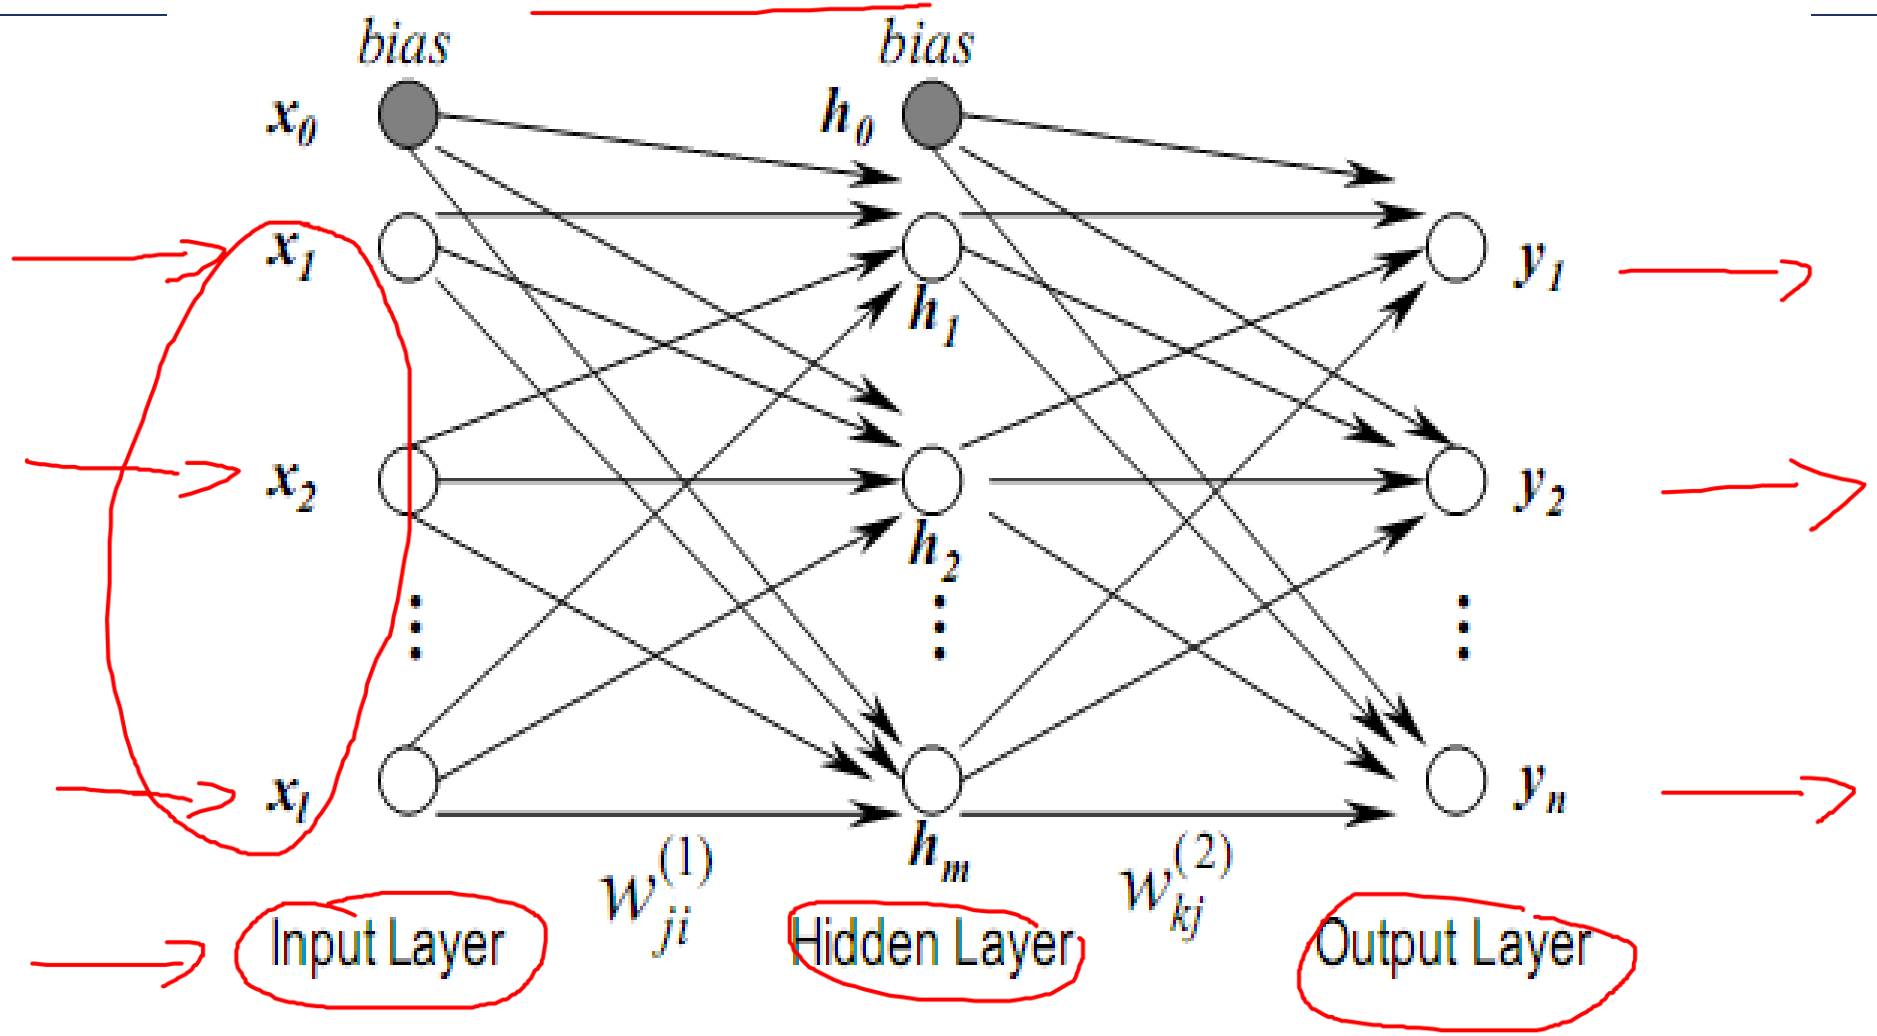


4.3 Mạng Neural

Quá trình xử lý thông tin tại một neuron của mạng Neural nhân tạo

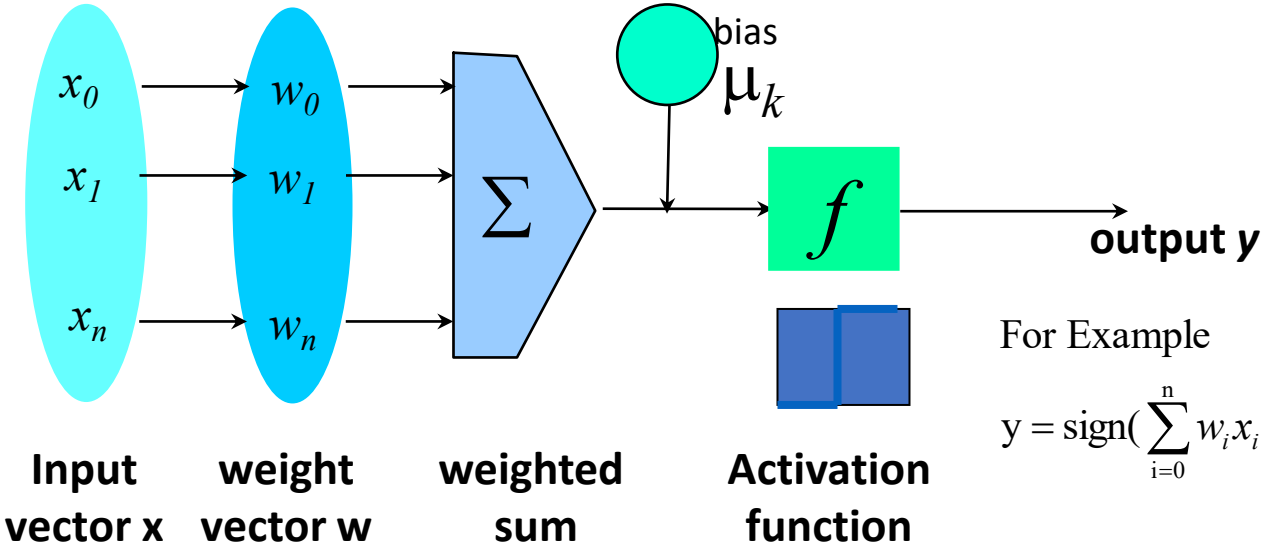


MLP


bias
bias
x_0
x_1
x_2
x_I
h_0
h_1
h_2
h_m
y_1
y_2
y_n
$w_{ji}^{(1)}$
$w_{kj}^{(2)}$
Input Layer
Hidden Layer
Output Layer

Neuron: A Hidden/Output Layer Unit

- An n-dimensional input vector x is mapped into variable y by means of the scalar product and a nonlinear function mapping
- The inputs to unit are outputs from the previous layer. They are multiplied by their corresponding weights to form a weighted sum, which is added to the bias associated with unit. Then a nonlinear activation function is applied to it.



For Example

$$y = \text{sign}\left(\sum_{i=0}^{n} w_i x_i - \mu_k\right)$$

How A Multi-Layer Neural Network Works

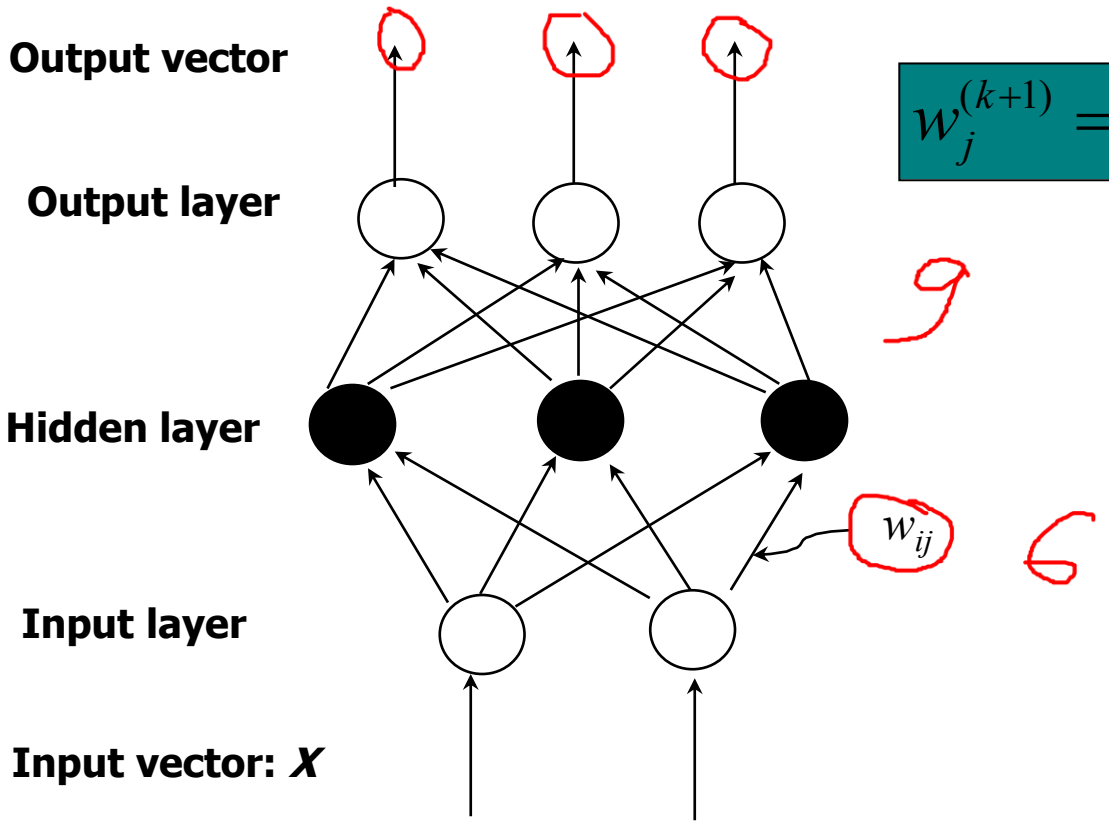
- The inputs to the network correspond to the attributes measured for each training tuple
- Inputs are fed simultaneously into the units making up the input layer
- They are then weighted and fed simultaneously to a hidden layer
- The number of hidden layers is arbitrary, although usually only one
- The weighted outputs of the last hidden layer are input to units making up the output layer, which emits the network's prediction
- The network is feed-forward: None of the weights cycles back to an input unit or to an output unit of a previous layer
- From a statistical point of view, networks perform nonlinear regression: Given enough hidden units and enough training samples, they can closely approximate any function

Defining a Network Topology

- Decide the network topology: Specify # of units in the input layer, # of hidden layers (if > 1), # of units in each hidden layer, and # of units in the output layer
- Normalize the input values for each attribute measured in the training tuples to [0.0—1.0]
- One input unit per domain value, each initialized to 0
- Output, if for classification and more than two classes, one output unit per class is used
- Once a network has been trained and its accuracy is unacceptable, repeat the training process with a different network topology or a different set of initial weights

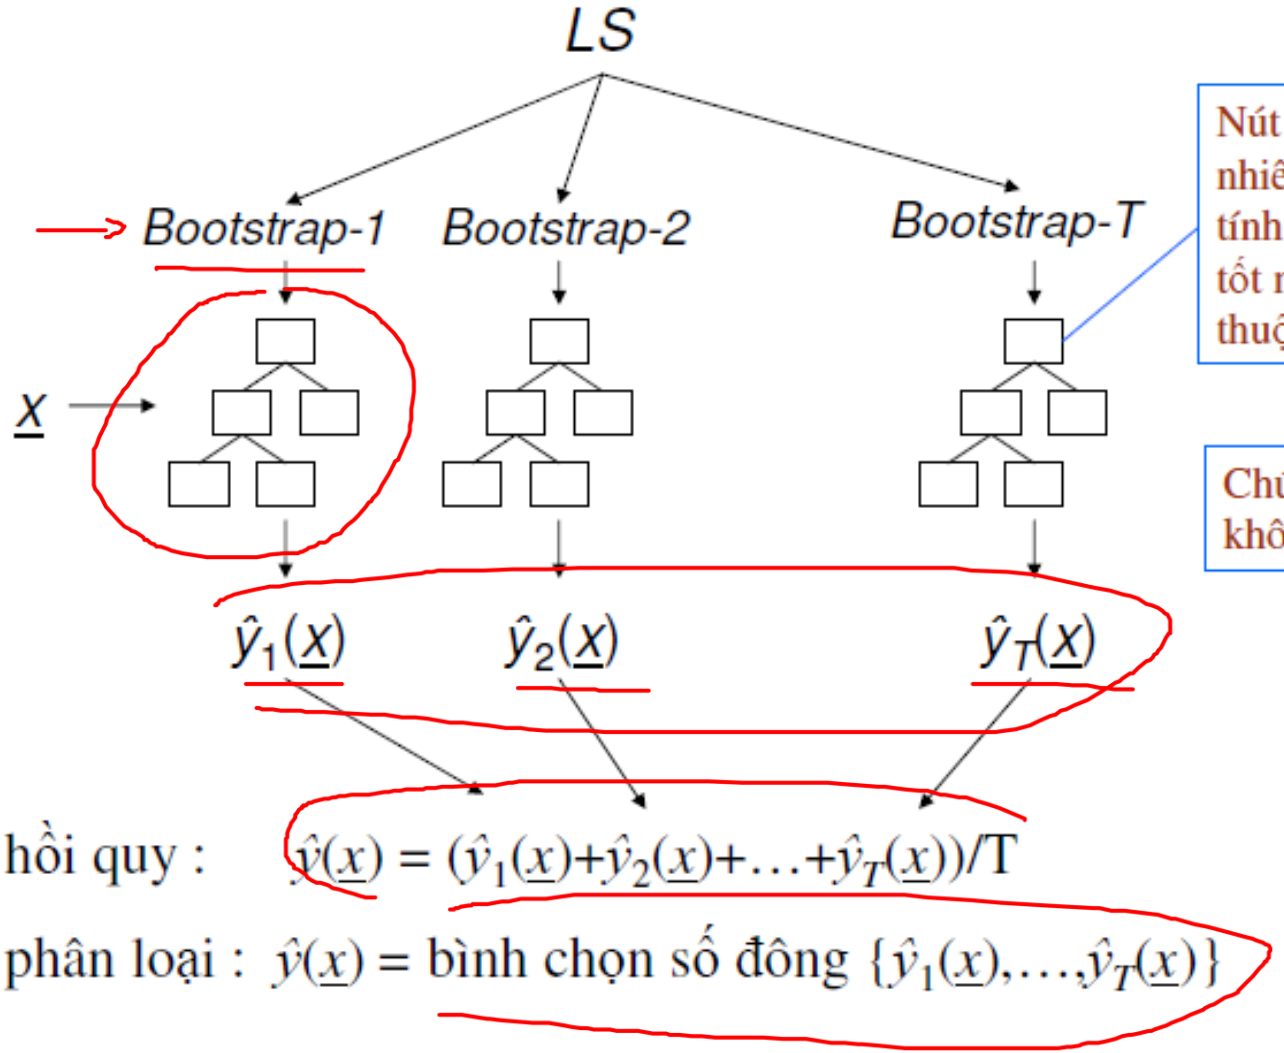
A Multi-Layer Feed-Forward Neural Network

Loss function



$$w_j^{(k+1)} = w_j^{(k)} + \lambda(y_i - \hat{y}_i^{(k)})x_{ij}$$

Random Forest - Rừng cây ngẫu nhiên (RF)



Nút trong: chọn ngẫu nhiên n' thuộc tính và tính toán phân hoạch tốt nhất dựa trên n' thuộc tính này

Chú ý: xây dựng cây không cắt nhánh

Tóm tắt

- Phân lớp:
  - Hồi quy logit (Logistic regression)
  - Decision Tree Classifier
  - Support Vector Classification (SVC)
  - Nearest Neighbors Classification (KNeighborsClassifier)
  - Stochastic Gradient Descent Classification (SGDClassifier)
- Hồi quy:
  - Ordinary Least Squares (LinearRegression)
  - Decision Tree Regressor
  - Support Vector Regression (SVR)
  - Stochastic Gradient Descent Regression (SGDRegressor)
  - Nearest Neighbors Regression (KNeighborsRegressor)



THANK YOU FOR WATCHING!