TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH

KHAI PHÁ DỮ LIỆU

CHƯƠNG 5
MỘT SỐ PHƯƠNG PHÁP PHÂN TÍCH CỤM

Bộ môn Khoa học máy tính - Khoa Hệ thống thông tin quản lý

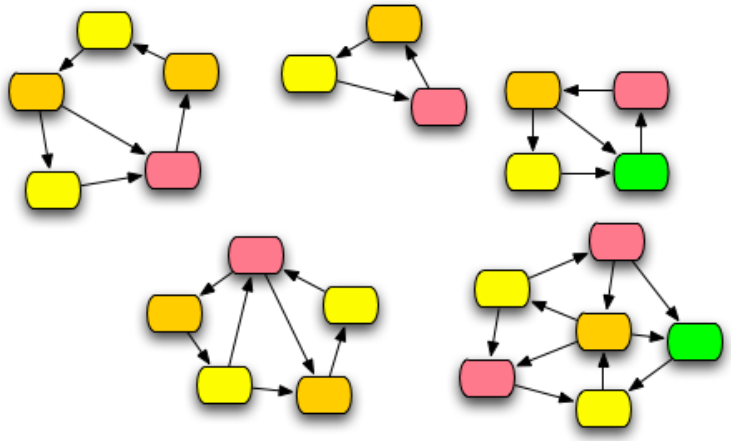

HUB
1976
TRƯỜNG ĐẠI HỌC NGÂN HÀNG
THÀNH PHỐ HỒ CHÍ MINH

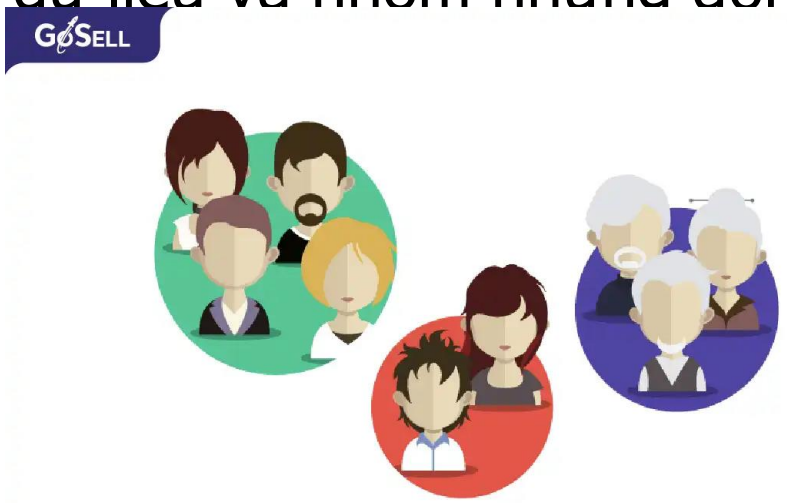
Nội dung

- Tổng quan về phân tích cụm
- Gom cụm dữ liệu bằng phân hoạch
- Gom cụm dữ liệu bằng phân cấp
- Một số phương pháp gom cụm dữ khác
- Đánh giá việc gom cụm dữ liệu

1 Tổng quan

- Cụm (*Cluster*): Một tập hợp các đối tượng dữ liệu
  - Tương tự (hoặc có liên hệ) đối với những đối tượng khác trong cùng nhóm
  - Không tương tự (hoặc không có liên hệ) đối với những đối tượng thuộc các nhóm khác
- Phân tích cụm - *cluster analysis* (hoặc gom cụm-*clustering*, *data segmentation, …*) tìm những dữ liệu tương tự phụ thuộc vào những đặc tính được tìm thấy trong dữ liệu và nhóm những đối tượng tương tự vào các cụm.





Phân khúc khách hàng theo nhân khẩu học



1.1 Các yêu cầu tiêu biểu

- Khả năng co giãn về tập dữ liệu (scalability)
- Khả năng xử lý nhiều kiểu thuộc tính khác nhau (different types of attributes)
- Khả năng khám phá các cụm với hình dạng tùy ý (clusters with arbitrary shape)
- Tối thiểu hóa yêu cầu về tri thức miền trong việc xác định các thông số nhập (domain knowledge for input parameters)
- Khả năng xử lý dữ liệu có nhiễu (noisy data)
- Khả năng gom cụm tăng dần và độc lập với thứ tự của dữ liệu nhập (incremental clustering and insensitivity to the order of input records)
- Khả năng xử lý dữ liệu đa chiều (high dimensionality)
- Khả năng gom cụm dựa trên ràng buộc (constraint-based clustering)
- Khả diễn và khả dụng (interpretability and usability)

1.2. Các cách tiếp cận tiêu biểu

- Dựa trên lưới (grid-based):
  - Dựa trên cấu trúc chi tiết ở nhiều mức độ (a multiple-level granularity structure). Bằng cách chia không gian dữ liệu thành các ô (cells) và phân tích mật độ trong từng ô.
  - Tiêu biểu STING, WaveCluster, CLIQUE
- Dựa trên mô hình (model-based):
  - Một mô hình giả thuyết (như mô hình xác suất hoặc hàm phân phối) được đưa ra cho mỗi cụm; sau đó hiệu chỉnh các thông số để mô hình phù hợp với cụm dữ liệu/đối tượng nhất.
  - Tiêu biểu: EM, SOM, COBWEB
- Dựa trên mẫu phổ biến (Frequent pattern-based):
  - Dựa trên phân tích mẫu phổ biến. Một cụm được hình thành từ các đối tượng chia sẻ mẫu phổ biến giống nhau.
  - Tiêu biểu: p-Cluster
- ....

1.2. Các cách tiếp cận tiêu biểu (tt)

- Phân hoạch (partitioning):
  - Các phân hoạch được tạo ra và đánh giá theo một tiêu chí nào đó (ví dụ: khoảng cách trong cụm nhỏ nhất, giữa cụm lớn nhất).
  - Tiêu biểu k-means, k-medoids, CLARANS
- Phân cấp (hierarchical):
  - Phân rã tập dữ liệu/đối tượng có thứ tự phân cấp theo một tiêu chí nào đó.
  - Tiêu biểu Diana, Agnes, BIRCH, CAMELEON
- Dựa trên mật độ (density-based):
  - Dựa trên hàm tính toán mức độ kết nối hoặc mật độ (connectivity and density functions).
  - Tiêu biểu DBSACN, OPTICS, DenClue

1.2. Các cách tiếp cận tiêu biểu (tt)

	Nguyên lý chính	Ưu điểm	Hạn chế	Thuật toán tiêu biểu
Phân hoạch	Chia tập dữ liệu thành *k* cụm, tối ưu theo tiêu chí (ví dụ: khoảng cách đến tâm cụm).	Đơn giản, dễ hiểu, hiệu quả cho dữ liệu vừa.	Phải biết trước số cụm *k*; dễ kẹt ở cực tiểu cục bộ; không tốt với cụm có hình dạng phức tạp.	K-means, K-medoids, CLARANS
Phân cấp	Xây dựng cây phân cấp (từ gộp dần hoặc chia dần).	Không cần biết trước số cụm; có cái nhìn đa cấp.	Khó xử lý dữ liệu lớn; nhạy cảm với nhiễu.	AGNES, DIANA, BIRCH, CAMELEON
Dựa trên mật độ	Cụm hình thành từ vùng có mật độ điểm đủ cao, dựa trên hàm kết nối & mật độ.	Khám phá cụm hình dạng tùy ý; chống nhiễu tốt.	Khó với dữ liệu có mật độ thay đổi; cần chọn tham số (ε, minPts).	DBSCAN, OPTICS, DENCLUE
Dựa trên lưới	Chia không gian dữ liệu thành lưới nhiều mức (granularity), gom cụm theo mật độ ô.	Tốc độ nhanh, thích hợp dữ liệu lớn, đa chiều.	Phụ thuộc vào kích thước ô lưới; không tốt với cụm nhỏ lẻ.	STING, WaveCluster, CLIQUE
Dựa trên mô hình	Giả thuyết mô hình cho mỗi cụm, điều chỉnh tham số để phù hợp dữ liệu.	Phân cụm chặt chẽ; có cơ sở thống kê; phát hiện phân bố phức tạp.	Tính toán phức tạp; cần giả định mô hình đúng.	EM, SOM, COBWEB
Dựa trên mẫu phổ biến	Khai thác mẫu phổ biến để phát hiện nhóm đối tượng thường xuất hiện cùng nhau.	Hiệu quả cho dữ liệu dạng giao tác; phát hiện cụm ẩn.	Dễ sinh nhiều mẫu dư thừa; cần ngưỡng hỗ trợ phù hợp.	p-Cluster

2. Gom cụm dữ liệu bằng phân hoạch: Thuật toán K-mean

- Input
  - Số nguyên k > 0: số cụm biết trước
  - Tập tài liệu D (cho trước)
- Output
  - Phân D thành k cụm "tốt nhất", mỗi đối tượng thuộc một cụm (mà khoảng cách từ đối tượng tới tâm cụm này là ngắn nhất)
- Định hướng
  - Tinh chỉnh dần
  - Mỗi cụm gồm một đối tượng đại diện và các đối tượng gần đại diện cụm nhất. S = {d_{S*} và mọi d∈D mà sim (d,d_{S*}) > sim (d,d_S), ∀d_S là đại diện các cụm khác}

$$S_i = \{d \in S \mid sim(d, d_i) \leq sim(d, d_j)\ \forall\ j \neq i\}$$

2. Thuật toán K-mean

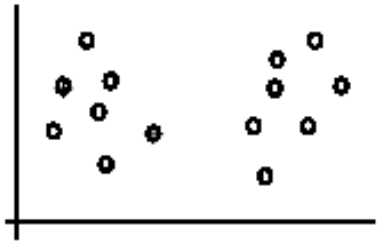
1. Khởi động: Chọn ngẫu nhiên *k* trang web trong *S* làm trọng tâm
   cho các cụm: $\{c_i : c_i \in S, i=1,..., k\}$
2. Bước lặp
   2.1. $S_i = \varnothing$ (các cụm rỗng)
   2.2. $\forall d \in S$:
      2.2.1. Tính sim (d, c_i), i=1,..., k
      2.2.2. $S_t = S_t \cup \{d\}$ nếu sim $(d, c_t) = \min \{\text{sim}(d, c_i) | i=1, ..., k\}$
   2.3. $\forall i : c_i = \frac{1}{\|S_i\|} \sum_{d \in S_i} d$ (Tính lại trọng tâm các cụm sau thực hiện bước 2)
3. Nếu chưa gặp Điều kiện dừng thì quay lại bước 2, ngược lại Dừng

Ví dụ

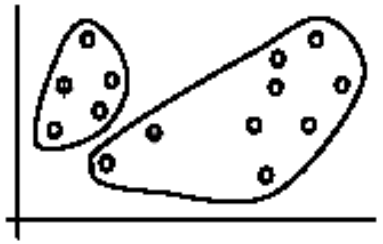
- Cho tập hợp điểm:
- X1={1,3}
- X2={1.5,3.2}
- X3={1.3,2.8}
- X4={3,1}

Gom thành 2 cụm, ban đầu cụm 1 gồm X1,X2, cụm 2 gồm X3,X4

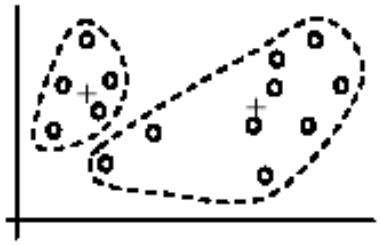
2. Thuật toán K-mean



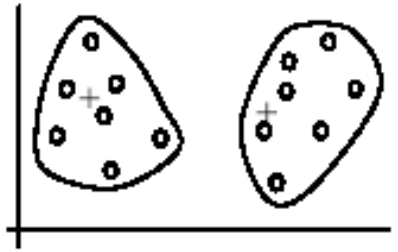
(A). Random selection of k centers



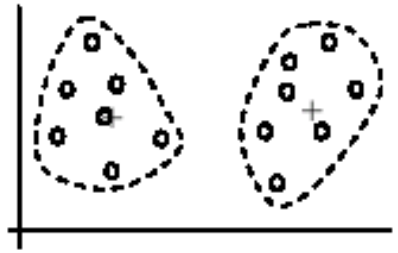
Iteration 1: (B). Cluster assignment



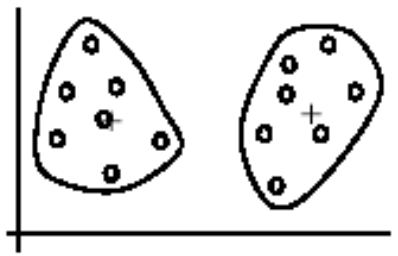
(C). Re-compute centroids



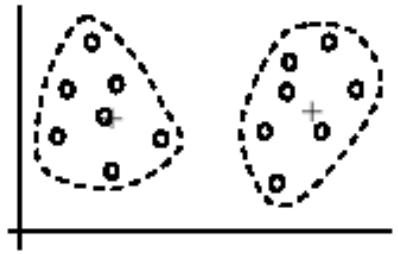
Iteration 2: (D). Cluster assignment



(E). Re-compute centroids



Iteration 3: (F). Cluster assignment



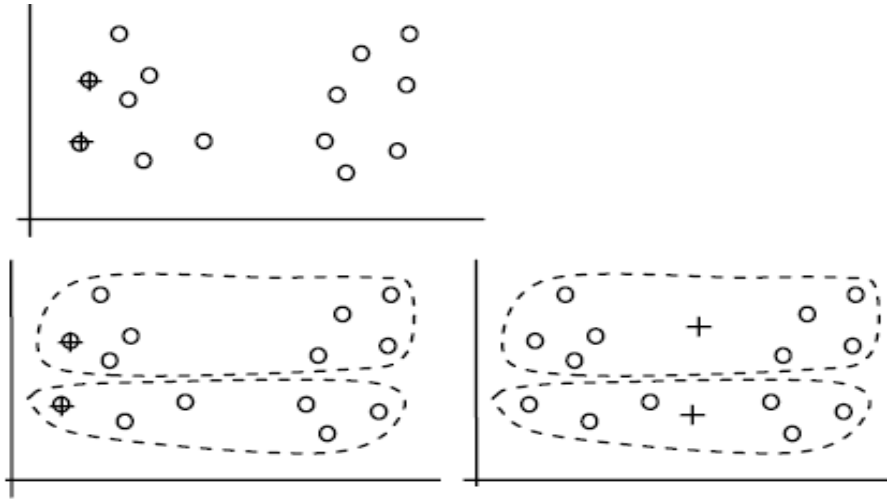
(G). Re-compute centroids

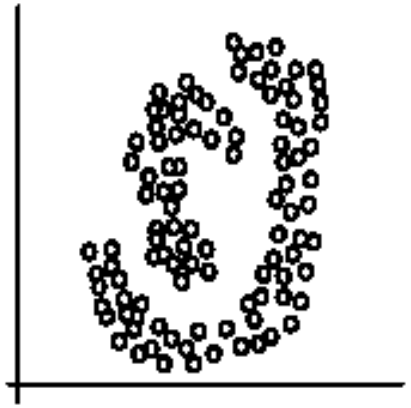
Trực quan hoạt động của thuật toán K-mean:
https://www.naftaliharris.com/blog/visualizing-k-means-clustering/
https://code-specialist.com/k-means-algorithm

2. Thuật toán K-mean

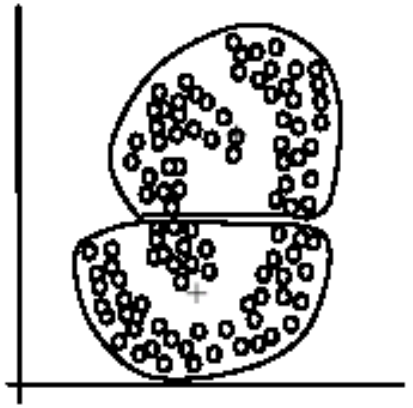
- Ưu điểm
  - Đơn giản, dễ sử dụng
  - Hiệu quả về thời gian: tuyến tính O(tkn), t số lần lặp, k số cụm, n là số phần tử
  - Một thuật toán phân cụm phổ biến nhất
  - Thường cho tối ưu cục bộ. Tối ưu toàn cục rất khó tìm
- Nhược điểm
  - Phải "tính trung bình được": dữ liệu phân lớp thì dựa theo tần số
  - Cần cho trước k : số cụm
  - Nhạy cảm với ngoại lệ (cách xa so với đại đa số dữ liệu còn lại): ngoại lệ thực tế, ngoại lệ do quan sát sai (làm sạch dữ liệu).
  - Nhạy cảm với mẫu ban đầu: cần phương pháp chọn mẫu thô tốt
  - Không thích hợp với các tập dữ liệu không siêu-ellip hoặc siêu cầu (các thành phần con không ellip/cầu hóa)

2. Thuật toán K-mean

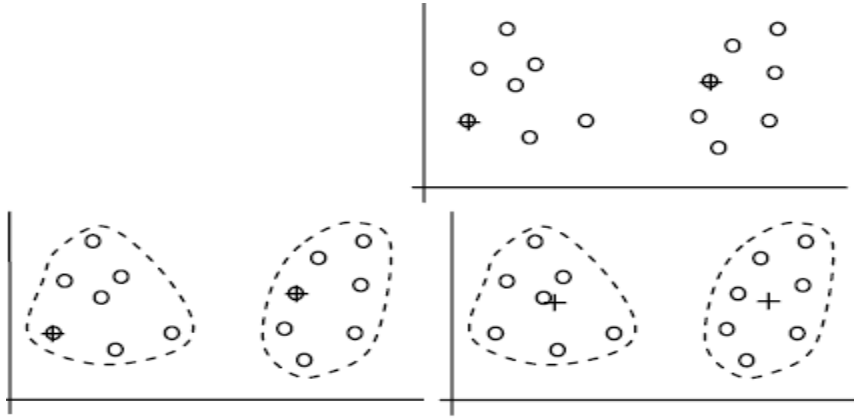




(A): Two natural clusters



(B): *k*-means clusters



2. Thuật toán K-mean

- Ưu điểm
  - Đơn giản, dễ sử dụng
  - Hiệu quả về thời gian: tuyến tính O(tkn), t số lần lặp, k số cụm, n là số phần tử
  - Một thuật toán phân cụm phổ biến nhất
  - Thường cho tối ưu cục bộ. Tối ưu toàn cục rất khó tìm
- Nhược điểm
  - Phải "tính trung bình được": dữ liệu phân lớp thì dựa theo tần số
  - Cần cho trước k : số cụm
  - Nhạy cảm với ngoại lệ (cách xa so với đại đa số dữ liệu còn lại): ngoại lệ thực tế, ngoại lệ do quan sát sai (làm sạch dữ liệu)
  - Nhạy cảm với mẫu ban đầu: cần phương pháp chọn mẫu thô tốt
  - Không thích hợp với các tập dữ liệu không siêu-ellip hoặc siêu cầu (các thành phần con không ellip/cầu hóa)

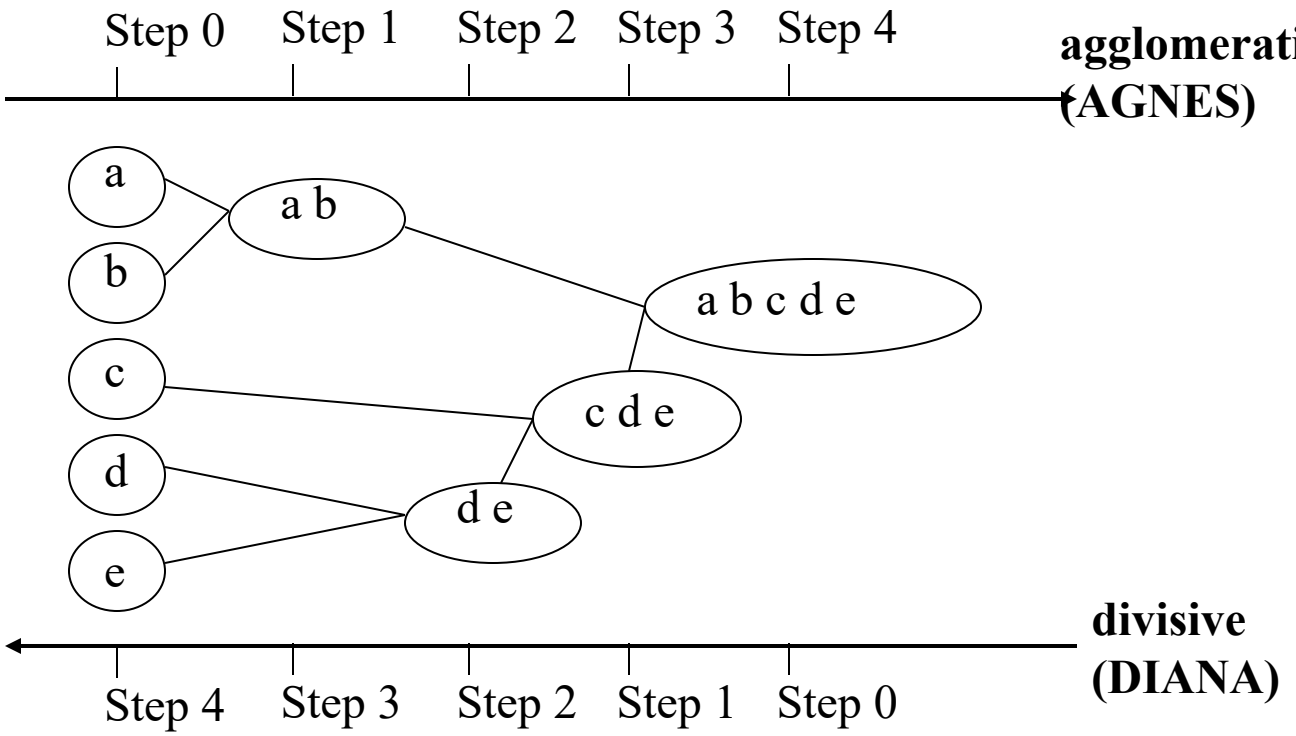
2. Minh họa bằng Python

3. Phân cụm phân cấp

- HAC: Hierarchical agglomerative clustering
- Một số độ đo phân biệt cụm
  - Độ tương tự hai dữ liệu
  - Độ tương tư giữa hai cụm
    - Độ tương tự giữa hai đại diện
    - Độ tương tự cực đại giữa hai dữ liệu thuộc hai cụm: single-link
    - Độ tương tự cực tiểu giữa hai dữ liệu thuộc hai cum: complete-link
    - Độ tương tự trung bình giữa hai dữ liệu thuộc hai cum
- Sơ bộ về thuật toán
  - Đặc điểm: Không cho trước số lượng cụm k, cho phép đưa ra các phương án phân cụm theo các giá trị k khác nhau
  - Lưu ý: k là một tham số ⇨ "tìm k tốt nhất"
  - Tinh chỉnh: Từ cụ thể tới khái quát

3. Gom cụm dữ liệu bằng phân cấp

- Use distance matrix as clustering criteria. This method does not require the number of clusters k as an input, but needs a termination condition



3. Minh họa bằng Python

4. Một số giải thuật gom cụm khác

- Affinity Propagation
- Mean Shift
- Spectral clustering
- DBSCAN
- OPTICS
- BIRCH

5. Các phương pháp đánh giá việc phân cụm dữ liệu

- Đánh giá ngoại (*external validation*)
  - Đánh giá kết quả gom cụm dựa vào cấu trúc được chỉ định trước cho tập dữ liệu
  - Độ đo: Rand statistic, Jaccard coefficient, Folkes and Mallows index, …
- Đánh giá nội (*internal validation*)
  - Đánh giá kết quả gom cụm theo số lượng các vector của chính tập dữ liệu (ma trận gần – *proximity matrix*)
  - Độ đo: Hubert's Γ statistic, Silhouette index, Dunn's index, …

5. Các phương pháp đánh giá việc phân cụm dữ liệu (tt)

- Đánh giá tương đối (*relative validation*)
  - Đánh giá kết quả gom cụm bằng việc so sánh các kết quả gom cụm khác ứng với các bộ trị thông số khác nhau

→ Tiêu chí cho việc đánh giá và chọn kết quả gom cụm tối ưu

- Độ nén (*compactness*): các đối tượng trong cụm nên gần nhau.
- Độ phân tách (*separation*): các cụm nên xa nhau.

5. Đánh giá kết quả gom cụm: Đánh giá ngoài

- Giả sử G1 , G2 , … , Gn là tập các cụm được gom cụm bằng một quá trình học có giám sát. A1 , A2 , … , An là tập các cụm được gom cụm bằng giải thuật đề nghị.
- Cho D là tập dữ liệu chứa các chuỗi dữ liệu hoặc là các đặc trưng, với mọi cặp (Di , Dj) ta đếm các số liệu sau:
- a là số cặp thuộc về một cụm trong G và được gom cụm tương ứng trong A.
- b là số cặp thuộc về một cụm trong G nhưng không được gom cụm tương ứng trong A.
- c là số cặp thuộc về một cụm trong A nhưng không được gom cụm tương ứng trong G.
- d là số cặp không thuộc về một cụm trong A và cũng không được gom cụm tương ứng trong G.

5. Đánh giá kết quả gom cụm: Đánh giá ngoài

Sử dụng các phép đo như sau:

- Hệ số tương đồng (%) của Jaccard (1901):
  - $Jaccard = \frac{a}{a+b+c}$
- Hệ số Rand:
  - $Rand = \frac{a+d}{a+b+c+d}$
- Hệ số Folkes và Mallow (FM):
  - $FM = \sqrt{\frac{a}{a+b} \times \frac{a}{a+c}}$

5. Đánh giá kết quả gom cụm

$$d(\boldsymbol{x}, \boldsymbol{y})^2 = \sum_{j=1}^{m} (x_j - y_j)^2 = \|\boldsymbol{x} - \boldsymbol{y}\|_2^2$$

Bình phương khoảng cách **Euclidean**

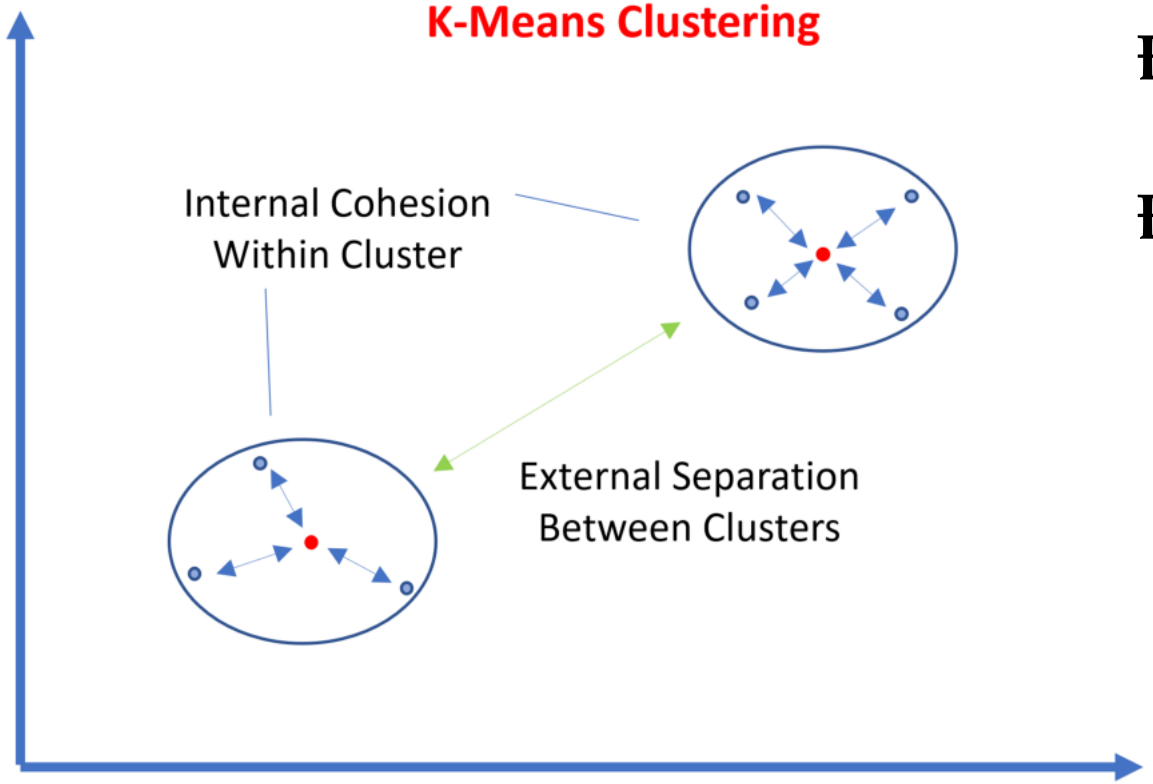
$$SSE = \sum_{i=1}^{n} \sum_{j=1}^{k} w^{(i,j)} \left\| \boldsymbol{x}^{(i)} - \boldsymbol{\mu}^{(j)} \right\|_2^2$$

sum of squared errors (SSE)
Hay cluster inertia

$\boldsymbol{\mu}^{(j)}$ Trọng tâm của cụm thứ j

$$w^{(i,j)} = \begin{cases} 1, & \text{if } \boldsymbol{x}^{(i)} \in j \\ 0, & \text{otherwise} \end{cases}$$

5. Đánh giá kết quả gom cụm : Chỉ số hình bóng (Silhouette Score)



Độ kết dính (cluster cohesion): $a^{(i)}$

Độ tách biệt (cluster separation): $b^{(i)}$

$$s^{(i)} = \frac{b^{(i)} - a^{(i)}}{max\{b^{(i)}, a^{(i)}\}}$$



THANK YOU FOR WATCHING!