ĐỀ THI MẪU CUỐI KỲ – MÔN: KHAI PHÁ DỮ LIỆU (ITS324)

Thời gian làm bài: 60 phút | Tổng số câu: 40 | Không sử dụng tài liệu

Câu 1. Khai phá dữ liệu (Data Mining) trong bối cảnh doanh nghiệp chủ yếu phục vụ mục đích nào?

A. Sao lưu và phục hồi dữ liệu khi hệ thống gặp sự cố

B. Phát hiện mẫu, xu hướng và tri thức ẩn để hỗ trợ ra quyết định kinh doanh

C. Tăng tốc độ truy vấn cơ sở dữ liệu quan hệ

D. Thiết kế và tối ưu hóa schema cơ sở dữ liệu

Câu 2. Trong quy trình KDD (Knowledge Discovery in Databases), giai đoạn nào thường chiếm nhiều thời gian và công sức nhất trong thực tế?

A. Xây dựng mô hình khai phá dữ liệu

B. Đánh giá và diễn giải kết quả

C. Tiền xử lý và chuẩn bị dữ liệu

D. Chọn lựa thuật toán khai phá phù hợp

Câu 3. Khai phá dữ liệu mô tả (Descriptive Mining) và khai phá dữ liệu dự đoán (Predictive Mining) khác nhau cơ bản ở điểm nào?

A. Mô tả xử lý dữ liệu số; Dự đoán xử lý dữ liệu phân loại

B. Mô tả tóm lược đặc trưng dữ liệu hiện tại; Dự đoán xây dựng mô hình để suy luận kết quả tương lai

C. Mô tả chỉ dùng trong thống kê học; Dự đoán dùng trong machine learning

D. Hai loại không có sự khác biệt về mục tiêu

Câu 4. Ngân hàng muốn phân tích hàng triệu giao dịch để phát hiện hành vi bất thường có khả năng gian lận trong thời gian thực. Kỹ thuật khai phá dữ liệu nào phù hợp nhất?

A. Luật kết hợp (Association Rules) để tìm sản phẩm tài chính hay xuất hiện cùng nhau

B. Phân cụm (Clustering) để nhóm khách hàng có hành vi tương đồng

C. Phát hiện ngoại lai (Outlier Detection) kết hợp Phân lớp (Classification) từ dữ liệu lịch sử có nhãn

D. Hồi quy (Regression) để dự đoán số dư tài khoản

Câu 5. Phương pháp nào sau đây được dùng để chuyển đổi biến phân loại (categorical) thành dạng vector nhị phân (0/1) để đưa vào các thuật toán học máy?

A. Min-Max Normalization

B. Z-score Standardization

C. One-Hot Encoding

D. Log Transformation

Câu 6. Khi dữ liệu thuộc tính "thu nhập" có phân phối lệch phải (right-skewed) với một số giá trị cực lớn, phương pháp điền giá trị thiếu nào phù hợp nhất?

A. Mean Imputation vì phản ánh giá trị trung bình toàn tập

B. Median Imputation vì ít bị ảnh hưởng bởi ngoại lai, phản ánh trung tâm phân phối tốt hơn

C. Mode Imputation vì giá trị xuất hiện nhiều nhất là đại diện tốt nhất

D. Điền giá trị 0 để không ảnh hưởng đến tính toán

Câu 7. "Curse of Dimensionality" (Lời nguyền chiều) trong khai phá dữ liệu mô tả hiện tượng nào?

A. Khi số chiều tăng, dữ liệu trở nên thưa thớt và khoảng cách giữa các điểm mất dần ý nghĩa phân biệt

B. Khi giảm số chiều, mô hình mất hoàn toàn độ chính xác

C. Khi có quá nhiều dữ liệu, thuật toán không thể hội tụ

D. Khi dữ liệu có quá nhiều giá trị thiếu ở nhiều chiều

Câu 8. Phân phối điểm thi của sinh viên: Q1 = 60, Q3 = 78. Áp dụng phương pháp IQR (hệ số 1.5), điểm nào sau đây là ngoại lai (outlier)? [IQR = Q3 − Q1 ; Ngưỡng dưới = Q1 − 1.5×IQR ; Ngưỡng trên = Q3 + 1.5×IQR]

A. Điểm 35 — dưới ngưỡng dưới (33)

B. Điểm 50 — trong phạm vi bình thường

C. Điểm 95 — trong phạm vi bình thường

D. Điểm 68 — nằm gần tứ phân vị

Câu 9. Trong phân tích luật kết hợp, "Độ hỗ trợ" (Support) của tập mục {X, Y} được định nghĩa là gì?

A. Số lần {X,Y} xuất hiện tuyệt đối trong cơ sở dữ liệu

B. Tỷ lệ phần trăm giao dịch chứa đồng thời cả X và Y trên tổng số giao dịch

C. Xác suất mua Y khi đã biết mua X

D. Mức độ tương quan thống kê giữa X và Y

Câu 10. Tính chất "Anti-monotone" của thuật toán Apriori giúp tỉa không gian tìm kiếm như thế nào?

A. Nếu tập mục phổ biến thì mọi tập cha (superset) của nó cũng phổ biến

B. Nếu một tập mục không phổ biến thì mọi tập mở rộng (superset) cũng không phổ biến → có thể bỏ qua toàn bộ

C. Độ hỗ trợ tăng dần theo kích thước tập mục

D. Tất cả tập mục con (subset) có cùng Support với tập cha

Câu 11. Trong luật kết hợp, tại sao Lift (Độ nâng) thường được xem là chỉ số đánh giá quan trọng hơn Confidence?

A. Lift tính toán đơn giản hơn Confidence

B. Lift cho biết mối quan hệ có ý nghĩa thực sự hay chỉ do tần suất cao tự nhiên của từng mục riêng lẻ

C. Confidence luôn bằng Lift trong mọi trường hợp

D. Lift không phụ thuộc vào ngưỡng min_support

Câu 12. Confidence của luật A→B đạt 88%, mặt hàng B có tần suất mua tự nhiên là 92%. Lift của luật này gần bằng bao nhiêu và ý nghĩa là gì? [Lift = Confidence(A→B) / Support(B)]

A. Lift ≈ 1.05 > 1: mối quan hệ tích cực

B. Lift ≈ 0.96 < 1: mua A thực sự làm giảm nhẹ khả năng mua B

C. Lift = 1.0: hai mặt hàng hoàn toàn độc lập

D. Không tính được Lift từ các thông số đã cho

Câu 13. Cơ sở dữ liệu 600 giao dịch: {Máy tính} xuất hiện 180 lần, {Phần mềm} xuất hiện 240 lần, {Máy tính, Phần mềm} cùng xuất hiện 120 lần. Tính Confidence("Máy tính → Phần mềm") và Lift? [Confidence = Sup(X,Y)/Sup(X) ; Lift = Confidence/Sup(Y)]

A. Confidence = 66.7%, Lift = 1.67

B. Confidence = 50%, Lift = 1.25

C. Confidence = 66.7%, Lift = 1.0

D. Confidence = 40%, Lift = 0.8

Câu 14. 6 giao dịch: T1:{A,B,C}, T2:{A,B,D}, T3:{A,C,D}, T4:{B,C,D}, T5:{A,B,C}, T6:{A,B,D}. Với min_support = 50%, tập mục 2 phần tử nào KHÔNG phổ biến?

A. {A,B} (4/6 = 67%)

B. {B,C} (3/6 = 50%)

C. {C,D} (2/6 = 33%)

D. {A,D} (3/6 = 50%)

Câu 15. Siêu thị tìm được luật "Tã lót → Bia" với Support = 3%, Confidence = 72%, Lift = 4. Diễn giải ý nghĩa thực tiễn của luật này?

A. Chỉ 3% khách mua tã lót nên luật không đáng tin cậy

B. 72% khách mua tã lót cũng mua bia; Lift=4 cho thấy khả năng mua bia tăng gấp 4 lần so với mức trung bình

C. Cần tăng Confidence lên 90% trước khi áp dụng luật

D. Lift=4 nghĩa là 4 trong 10 khách hàng mua cả tã lót và bia

Câu 16. Trong đánh giá mô hình phân lớp, "Ma trận nhầm lẫn" (Confusion Matrix) cung cấp thông tin gì?

A. Thể hiện cấu trúc cây quyết định đã xây dựng

B. Phân tích chi tiết các loại dự đoán đúng/sai (TP, TN, FP, FN) theo từng lớp

C. So sánh tốc độ xử lý của các mô hình khác nhau

D. Mô tả phân phối dữ liệu trong tập huấn luyện

Câu 17. Phân lớp Naive Bayes được gọi là "Naive" (Ngây thơ) vì lý do nào?

A. Thuật toán đơn giản và không cần huấn luyện

B. Giả định các thuộc tính đầu vào hoàn toàn độc lập có điều kiện, dù thực tế thường không đúng

C. Chỉ áp dụng được khi dữ liệu có phân phối chuẩn
D. Kết quả phân lớp không chính xác trong mọi trường hợp

Câu 18. Khi nào nên ưu tiên dùng F1-Score thay vì Accuracy để đánh giá mô hình phân lớp?

A. Khi tập dữ liệu cân bằng giữa các lớp
B. Khi dữ liệu mất cân bằng (imbalanced) và chi phí FP/FN không đồng đều
C. Khi chỉ cần đánh giá nhanh mà không cần chi tiết
D. Khi mô hình là hồi quy tuyến tính

Câu 19. Kỹ thuật "Pruning" (Cắt tỉa) trong cây quyết định có mục đích chính là gì?

A. Tăng độ sâu cây để học được nhiều quy tắc hơn
B. Giảm overfitting bằng cách loại bỏ các nhánh không cải thiện đáng kể độ chính xác trên tập kiểm tra
C. Tăng tốc độ xây dựng cây trong giai đoạn huấn luyện
D. Chuyển đổi cây sang dạng luật IF-THEN

Câu 20. Confusion Matrix: TP=42, TN=98, FP=18, FN=42. Tính Accuracy, Precision và Recall? [Accuracy=(TP+TN)/Total ; Precision=TP/(TP+FP) ; Recall=TP/(TP+FN)]

A. Accuracy=70%, Precision=70%, Recall=50%
B. Accuracy=80%, Precision=70%, Recall=60%
C. Accuracy=70%, Precision=60%, Recall=50%
D. Accuracy=75%, Precision=65%, Recall=55%

Câu 21. Trong thuật toán K-means, WCSS (Within-Cluster Sum of Squares) hay Inertia được dùng để làm gì?

A. Xác định số cụm K tối ưu thông qua Elbow Method bằng cách quan sát điểm gãy của đồ thị WCSS
B. Tính khoảng cách giữa các centroid của các cụm khác nhau
C. Đánh giá chất lượng phân cụm dựa trên nhãn thực của dữ liệu
D. Khởi tạo ngẫu nhiên các centroid ban đầu

Câu 22. So với K-means, Hierarchical Clustering có ưu điểm nào nổi bật?

A. Nhanh hơn đáng kể với dữ liệu lớn
B. Không cần xác định số cụm K trước; dendrogram cho phép quan sát cấu trúc phân cụm ở nhiều mức
C. Ít nhạy cảm hơn với ngoại lai trong dữ liệu
D. Luôn tìm ra phân cụm tối ưu toàn cục

Câu 23. K-means với K=2: Centroid C1=(3,5), C2=(8,2). Điểm dữ liệu P=(6,4) sẽ được gán vào cụm nào? [Khoảng cách Euclidean: $d = \sqrt{((x_2-x_1)^2 + (y_2-y_1)^2)}$]

A. Cụm 1 ($d(P,C1) \approx 3.16 < d(P,C2) \approx 2.83$)
B. Cụm 2 ($d(P,C2) \approx 2.83 < d(P,C1) \approx 3.16$)

C. Cả hai cụm vì khoảng cách bằng nhau

D. Không thể xác định với thông tin đã cho

Câu 24. Hierarchical Clustering (Single Linkage) với 4 điểm trên trục số: W(0), X(2), Y(8), Z(11). Thứ tự các cặp được gộp là gì? [Single Linkage: khoảng cách 2 cụm = khoảng cách nhỏ nhất giữa 2 điểm bất kỳ]

A. {W,X} → {Y,Z} → {W,X,Y,Z}

B. {X,Y} → {W,Z} → {W,X,Y,Z}

C. {W,X,Y} → {Z} → toàn bộ

D. {Y,Z} → {W,X} → {W,X,Z} → toàn bộ

Câu 25. DBSCAN với eps=2, MinPts=3. Điểm X có 7 điểm lân cận trong bán kính eps. Điểm Y có 2 điểm lân cận trong eps nhưng nằm trong vùng lân cận của X. Phân loại X và Y là gì?

A. X là Core Point, Y là Border Point

B. X là Border Point, Y là Core Point

C. Cả X và Y đều là Core Point

D. X là Core Point, Y là Noise Point

Câu 26. Trong khai phá dữ liệu luồng (Stream Mining), tại sao phải xử lý dữ liệu trong một lần duyệt duy nhất (one-pass)?

A. Do dữ liệu luồng luôn có cấu trúc đơn giản không cần nhiều lần duyệt

B. Dữ liệu luồng đến liên tục, không thể lưu trữ toàn bộ; cần xử lý tức thời với bộ nhớ hạn chế

C. One-pass cho độ chính xác cao hơn multi-pass

D. Dữ liệu luồng chỉ chứa dữ liệu số không cần nhiều phép tính

Câu 27. TF-IDF trong khai phá văn bản được dùng để làm gì?

A. Dịch văn bản từ ngôn ngữ này sang ngôn ngữ khác

B. Đo lường tầm quan trọng của từ: từ phổ biến toàn corpus giảm trọng số, từ đặc trưng riêng tài liệu tăng trọng số

C. Phân tích cảm xúc (sentiment) của văn bản

D. Tóm tắt tự động nội dung tài liệu dài

Câu 28. Hệ thống gợi ý (Recommender System) loại nào phù hợp khi muốn gợi ý cho người dùng mới chưa có lịch sử tương tác?

A. Collaborative Filtering vì dựa trên hành vi người dùng tương tự

B. Content-based Filtering vì chỉ cần đặc trưng của item, không cần lịch sử tương tác

C. Matrix Factorization vì tốt nhất với dữ liệu thưa

D. Hybrid Filtering nhưng cần ít nhất 10 đánh giá

Câu 29. Công ty logistics muốn theo dõi GPS của 10,000 xe tải theo thời gian thực để phát hiện tắc nghẽn và điều phối lộ trình. Kỹ thuật nào phù hợp nhất?

A. Batch Processing với Hadoop vì xử lý được khối lượng lớn

B. Stream Mining với Sliding Window để phân tích xu hướng vị trí liên tục trong thời gian thực

C. Offline Clustering K-means trên dữ liệu lịch sử

D. Association Rules để tìm tuyến đường thường đi cùng nhau

Câu 30. Hệ thống gợi ý phim mới ra mắt (cold start problem): bộ phim chưa có đánh giá từ người dùng. Chiến lược nào hiệu quả nhất?

A. Đợi thu thập đủ đánh giá rồi mới gợi ý

B. Dùng Content-based Filtering dựa trên metadata (thể loại, đạo diễn, diễn viên) kết hợp hồ sơ sở thích người dùng

C. Dùng Collaborative Filtering với giả định người dùng mới thích phim phổ biến

D. Gợi ý ngẫu nhiên để thu thập dữ liệu nhanh hơn

Câu 31. So với Apriori, thuật toán FP-Growth có ưu điểm gì trong khai phá tập phổ biến?

A. FP-Growth yêu cầu nhiều lần quét cơ sở dữ liệu để đảm bảo độ chính xác

B. FP-Growth chỉ quét CSDL 2 lần và nén dữ liệu vào FP-Tree, tránh sinh candidate itemset tốn kém

C. FP-Growth không cần ngưỡng min_support

D. FP-Growth chỉ hoạt động tốt khi dữ liệu đã được sắp xếp

Câu 32. Tập huấn luyện 12 mẫu: 8 mẫu thuộc lớp (+) và 4 mẫu thuộc lớp (−). Tính Entropy của tập S? [Entropy(S) = $-p_+ \log_2(p_+) - p_- \log_2(p_-)$]

A. 0.918 bits

B. 0.750 bits

C. 1.000 bits

D. 0.544 bits

Câu 33. Thuật toán k-NN với k=5 phân loại điểm mới P. 5 láng giềng gần nhất có nhãn: [B, A, A, B, A]. P được phân loại vào lớp nào?

A. Lớp A (3 phiếu vs 2 phiếu)

B. Lớp B (2 phiếu nhưng khoảng cách gần hơn)

C. Không xác định được vì cần k lẻ

D. Lớp A và B với xác suất bằng nhau

Câu 34. 5-fold Cross Validation cho kết quả: 75%, 80%, 80%, 85%, 80%. Tính Mean Accuracy và Standard Deviation? [Mean = $\Sigma x_i/n$; SD = $\sqrt{(\Sigma(x_i-\bar{x})^2/n)}$]

A. Mean = 80%, SD ≈ 3.16%

B. Mean = 80%, SD ≈ 2.00%

C. Mean = 82%, SD ≈ 3.16%

D. Mean = 80%, SD ≈ 5.00%

Câu 35. K-means: sau vòng lặp đầu tiên, Cụm 1 có 3 điểm: P1=(5,1), P2=(6,2), P3=(8,3). Tính centroid mới của Cụm 1? [Centroid = (mean_x, mean_y)]

A. (6.33, 2)
B. (6, 2)
C. (7, 3)
D. (6.5, 2)

Câu 36. Davies-Bouldin Index (DBI) đánh giá chất lượng phân cụm như thế nào?

A. DBI càng lớn thì phân cụm càng tốt vì các cụm tách biệt
B. DBI càng nhỏ thì phân cụm càng tốt (cụm nhỏ gọn, cách xa nhau)
C. DBI = 0 là giá trị lý tưởng trong mọi trường hợp
D. DBI chỉ áp dụng được cho K-means, không dùng cho Hierarchical

Câu 37. 300 giao dịch: A xuất hiện 150 lần, B xuất hiện 120 lần, A∩B xuất hiện 60 lần. Tính Support(A,B), Confidence(A→B) và Lift? [Sup=count/total ; Conf=Sup(A,B)/Sup(A) ; Lift=Conf/Sup(B)]

A. Sup=20%, Confidence=40%, Lift=1.0
B. Sup=20%, Confidence=50%, Lift=1.25
C. Sup=40%, Confidence=60%, Lift=1.5
D. Sup=20%, Confidence=40%, Lift=0.8

Câu 38. Trong SVM (Support Vector Machine), kỹ thuật "Kernel Trick" giải quyết vấn đề gì?

A. Tăng tốc quá trình huấn luyện bằng cách giảm số lượng support vector
B. Cho phép phân loại dữ liệu không tuyến tính bằng cách ánh xạ ngầm lên không gian đặc trưng chiều cao hơn
C. Giảm overfitting bằng cách thêm regularization vào hàm mục tiêu
D. Chọn tự động tham số C và gamma tối ưu

Câu 39. PCA cho 5 eigenvalues: 12, 4, 2, 1, 1 (tổng = 20). Cần bao nhiêu Principal Component để giữ lại ít nhất 80% phương sai? [% phương sai PC_i = $eigenvalue_i$ / tổng eigenvalues]

A. 1 PC (60%)
B. 2 PC (80%)
C. 3 PC (90%)
D. 4 PC (95%)

Câu 40. Bộ dữ liệu 20 bản ghi: 12 thuộc lớp "Mua" và 8 thuộc lớp "Không mua". Entropy của tập S là bao nhiêu? [Entropy(S) = $-\Sigma\ p_i \log_2(p_i)$]

A. 0.971 bits
B. 0.863 bits
C. 0.954 bits
D. 1.0 bits